

Departamento de Engenharia Informática

Play4Change: Aplicação de Aprendizagem Adaptativa para Educação Cívica

1 : Radesh Ilesh Gamanbhai Govind (A51620@alunos.isel.pt)

Relatório para a Unidade Curricular de Projeto e Seminário
da Licenciatura em Engenharia Informática e de Computadores

Professores : Nuno Datia Professor
António Serrador Professor
Michel Vorenhout Professor

Resumo

A U!REKA é uma aliança europeia de instituições de ensino superior cuja missão é formar os profissionais de amanhã e apoiar a transição das cidades para modelos mais sustentáveis. Como possível contributo a essa missão surge o Play4Change: uma proposta de plataforma de educação digital, informal e gamificada, para a educação cívica e para as competências que essa transição exige. A solução usa inteligência artificial para ajustar os conteúdos ao ritmo e às dificuldades de cada utilizador; o progresso é reconhecido em distintivos que assinalam cada nova competência adquirida; e mecanismos de envolvimento — como sequências diárias de utilização (streaks) — combatem o abandono comum nestas plataformas. Este relatório descreve o protótipo desenvolvido e a avaliação preliminar com utilizadores de diferentes idades e contextos, cujo feedback revelou forte receptividade ao papel da IA no esclarecimento de dúvidas e na personalização da aprendizagem.

Palavras-chave: aprendizagem adaptativa, educação cívica, gamificação, inteligência artificial, cidades sustentáveis

Abstract

U!REKA is a European alliance of higher-education institutions whose mission is to educate the professionals of tomorrow and support the transition of cities towards more sustainable models. As a possible contribution to that mission, Play4Change proposes an informal, gamified digital education platform aimed at civic education and at the competences this transition demands from citizens. The solution uses artificial intelligence to adjust content to each user's pace and learning difficulties; progress is recognised through badges that signal each newly acquired competence; and engagement mechanisms — such as daily-use streaks — address the high dropout rates typical of such platforms. This report describes the prototype developed and the preliminary evaluation carried out with users of different ages and backgrounds, whose feedback revealed strong receptiveness to the role of AI in clarifying doubts and personalising learning.

Keywords: adaptive learning, civic education, gamification, artificial intelligence, sustainable cities

Utilização de Inteligência Artificial

Ferramentas e modelos utilizados

Ferramenta	Modelo	Aplicação Técnica
Google Gemini	Pro	Ingestão de documentação técnica extensa e pesquisa de padrões arquiteturais emergentes.
Claude Code	Opus	Análise de dependências do repositório via CLI e estruturação de decisões de design.
Claude	Sonnet	Geração de scaffolding de código, resolução de erros de compilação em tempo real e incompatibilidade de dependências.

Tabela 1: Ferramentas de inteligência artificial utilizadas, modelos e respectivas aplicações técnicas.

Declaração de integridade acadêmica

A responsabilidade arquitetural, a qualidade do código submetido e as decisões de implementação descritas neste documento pertencem exclusivamente ao autor, tendo os modelos de linguagem sido utilizados estritamente como aceleradores de formatação e resolução de impasses técnicos.

Agradecimentos

A realização deste trabalho não teria sido possível sem o contributo, directo ou indirecto, de um conjunto de pessoas a quem devo reconhecimento genuíno.

Ao **Professor Nuno Datia** e ao **Professor Michel Vorenhout**, orientadores deste projecto, expresso a minha profunda gratidão pela disponibilidade, pelas observações e pela liberdade intelectual que me concederam para explorar caminhos pouco convencionais. A qualidade deste trabalho deve muito à exigência que colocaram e à confiança que depositaram. Ao **Instituto Superior de Engenharia de Lisboa** e ao **Instituto Politécnico de Lisboa**, pela formação académica e pelo enquadramento institucional que tornaram possível um projecto com esta dimensão e ambição.

Aos colegas com quem partilhei percurso ao longo destes anos, agradeço as conversas, os debates técnicos e a camaradagem que tornam o processo de aprender menos solitário e mais fértil. A disponibilidade para discutir ideias, questionar abordagens e partilhar dificuldades foi, muitas vezes, o que impediu que um obstáculo se tornasse um impasse.

Aos amigos de longa data, o reconhecimento pela paciência e pela presença constante. A um projecto desta natureza não se exige apenas competência técnica — exige-se também resistência, e essa constrói-se com o apoio de quem se mantém próximo independentemente das circunstâncias.

À minha família, o agradecimento mais profundo e mais difícil de circunscrever em palavras. A dedicação exigida por um trabalho desta envergadura impõe custos que recaem, inevitavelmente, sobre aqueles que estão mais próximos. A paciência, o suporte incondicional e a crença no valor daquilo que estava a ser construído foram indispensáveis.

A todos os que contribuíram para este percurso:

Ilesh Gamanbhai	Jignaben Mistry
Divyesh Govind	Professor Nuno Datia
Professor António Serrador	Professor Michel Vorenhout
Pedro Gomes	Guilherme Coutinho
Martim Monteiro	Alexandre Tavares
André Nunes	Francisco Tavares
Rodrigo Sampaio	Simão Afonso
Fábio Nibau	Maria Lopes
Júlia Santana	Vasco Garcia

Radesh Ilesh Gamanbhai Govind

Índice

Utilização de Inteligência Artificial	vii
Agradecimentos	ix
Lista de Figuras	xv
Lista de Tabelas	xvii
Lista de Listagens	xix
1 Introdução	1
1.1 A U!REKA e o desafio da transição para cidades sustentáveis	1
1.2 Da literacia digital à literacia cívica: o papel da inteligência artificial	1
1.3 Objetivos	3
1.4 O problema e a pergunta que orienta este trabalho	4
1.5 Como o Play4Change procura responder a este desafio	4
1.6 Organização do documento	5
2 Enquadramento e Estado da Arte	7
2.1 Conceitos fundamentais	7
2.2 Educação cívica e competências para a transição sustentável	9
2.3 Trabalho relacionado: o que já existe e o que se pode aprender com isso	10
2.4 Síntese e posicionamento do projeto	11
3 Design e Implementação do Sistema	13
3.1 Visão geral da arquitectura	13
3.2 Módulos e responsabilidades	14
3.2.1 Camada de apresentação	15
3.2.2 Rede de fronteira	15

3.2.3	Servidor de aplicação	15
3.2.4	Camada de persistência	16
3.2.5	Observabilidade externa	17
3.3	Fluxos de interacção	17
3.3.1	Autenticação	17
3.3.2	Criar tópico e gerar conteúdo	18
3.3.2.1	Ingestão de conteúdo: PDF e URL	19
3.3.3	Editar questão de um tópico	21
3.3.4	Inscrição num tópico	22
3.3.5	Abandono de tópico	23
3.3.6	Resposta correcta a um desafio	24
3.3.7	Resposta errada e activação do percurso adaptativo	25
3.3.8	Percurso de consolidação	26
3.3.9	Modo de explicação por IA	28
3.4	O motor de inteligência artificial	29
3.4.1	Geração de tarefas do percurso fixo	29
3.4.2	Geração adaptativa: ramos de consolidação	31
3.4.3	Geração da explicação holística	32
3.5	Reconhecimento: o sistema de dist intivos	33
3.6	Envolvimento: mecanismos de retenção	34
3.7	Interface de programação	34
3.8	Síntese do desenvolvimento	34
4	Ferramentas, Tecnologias e Metodologia	37
4.1	Arquitectura tecnológica	37
4.2	Pipeline de integração e entrega contínua	39
4.3	Metodologia de desenvolvimento	41
5	Avaliação e Resultados	43
5.1	Metodologia de avaliação	43
5.2	Dados comportamentais: a utilização real	43
5.3	Resultados do questionário	46
5.4	O ciclo adaptativo em ação: um exemplo real	47
5.5	Dois perfis de utilizador: uma descoberta central	48

<i>ÍNDICE</i>	xiii
5.6 Feedback qualitativo e sugestões de melhoria	49
5.7 Posicionamento face a abordagens alternativas no contexto U!REKA	49
5.8 Discussão dos resultados	50
6 Conclusão	53
6.1 Síntese do trabalho realizado	53
6.2 Limitações	54
6.3 Trabalho futuro	54
Referências	57

Lista de Figuras

1.1	Áreas e competências do quadro DigComp 2.2	2
1.2	Os três pilares do Play4Change	3
2.1	Plataformas analisadas posicionadas nos três eixos do Play4Change	12
3.1	Arquitectura lógica do sistema <u>Play4Change</u>	13
3.2	Sequência de autenticação por <u>magic link</u>	18
3.3	Pipeline de geração de conteúdo em quatro fases	19
3.4	Sequência de criação de tópico e geração de conteúdo	21
3.5	Sequência de edição de uma questão de tópico	22
3.6	Sequência de inscrição num tópico	23
3.7	Sequência de abandono de tópico	23
3.8	Sequência de resposta correcta a um desafio	25
3.9	Sequência: resposta errada e activação do percurso adaptativo	26
3.10	Sequência do percurso de consolidação	27
3.11	Máquina de estados do percurso adaptativo	28
3.12	Sequência do ciclo de explicação holística	29
3.13	Escada progressiva para o modo de explicação	33
4.1	Topologia de infraestrutura de produção do Play4Change	39
4.2	Pipeline CI/CD do Play4Change com os três workflows GitHub Actions	39
5.1	Inscrições e conclusões por tópico	44
5.2	Distribuição das sessões adaptativas por padrão de erro	45
5.3	Distribuição das pontuações SUS por participante	46

Lista de Tabelas

1	Ferramentas de IA utilizadas no desenvolvimento	vii
2.1	Comparação informal de plataformas de educação digital segundo os três pilares do Play4Change	11
3.1	Módulos do sistema e respectivas responsabilidades	14
3.2	Regras de classificação determinística de padrões de erro	26
3.3	Mapeamento de nível de audiência para descrição no prompt	30
3.4	Estratégias de reutilização na geração adaptativa	31
3.5	Mapeamento de padrões de erro para instruções pedagógicas no prompt	32
3.6	Principais <u>endpoints</u> REST do <u>Play4Change</u>	35
4.1	Tecnologias utilizadas no Play4Change por camada	38
4.2	Critérios de qualidade verificados na pipeline de CI	40
5.1	Indicadores globais de utilização extraídos da base de dados	44
5.2	Dados de utilização por participante (anonimizados)	45
5.3	Dimensões de envolvimento e adaptatividade avaliadas	47
5.4	Comparação dos dois grupos de utilizadores identificados	49

Lista de Listagens

3.1	System prompt da geração de tarefas	29
3.2	User prompt da geração de tarefas	30
3.3	System prompt da geração adaptativa	31
3.4	System prompt do modo de explicação	32
3.5	System prompt do diálogo de explicação	33

Capítulo 1

Introdução

1.1 A U!REKA e o desafio da transição para cidades sustentáveis

A U!REKA ([European University Alliance](#)) é uma aliança que reúne mais de trinta instituições de ensino superior e parceiros de toda a Europa, com a missão de educar os profissionais europeus de amanhã e de preparar estudantes, docentes e a comunidade em geral para liderar a transição para cidades neutras em carbono, sustentáveis e inteligentes [12]. Entre os seus centros de competência contam-se áreas como as “cidades resilientes e neutras em carbono” e a “governança inovadora e o envolvimento dos cidadãos” [11], o que reflete bem a forma como a aliança entende esta transição: não apenas como um problema de engenharia ou de planeamento urbano, mas também como um desafio de participação cívica.

É precisamente aí que reside a dificuldade central que este projeto procura ajudar a resolver. Tornar uma cidade mais sustentável não depende só de construir melhores infraestruturas ou de garantir financiamento — depende também de que os próprios cidadãos compreendam o que está em causa, saibam como agir e se sintam parte do processo. Sem essa apropriação por parte das pessoas, mesmo as melhores políticas correm o risco de ficar pelo caminho. O [Play4Change](#) nasce da vontade de dar um contributo concreto a este problema, propondo-se como uma possível solução — ainda numa fase de protótipo — a apresentar à própria U!REKA: uma forma de ajudar os cidadãos a desenvolver, de modo simples e acessível, as competências cívicas e digitais de que precisam para participar nesta mudança.

1.2 Da literacia digital à literacia cívica: o papel da inteligência artificial

Para fundamentar esta proposta, foi importante perceber primeiro o que se entende, hoje, por “estar preparado” para participar de forma ativa e informada no mundo digital. O relatório [DigComp 2.2 – The Digital Competence Framework for Citizens](#), publicado pelo Centro Comum de Investigação da Comissão Europeia, oferece precisamente esse retrato: organiza a competência digital em cinco grandes áreas — procurar e avaliar informação, comunicar e colaborar, criar conteúdos, manter-se em segurança e resolver problemas — e descreve-as através de exemplos concretos do que uma pessoa sabe, é capaz de fazer e valoriza em cada uma delas [14]. A Figura 1.1 ilustra esta organização e os subtemas que cada área abrange.




Figura 1.1: As cinco áreas de competência digital e respectivas competências, segundo o quadro DigComp 2.2. Fonte: adaptado de [14], com base em material disponibilizado sob licença Creative Commons Attribution 4.0 (CC BY 4.0).

Do ponto de vista do Play4Change, são principalmente as **áreas 1 e 2** do DigComp as que mais diretamente se traduzem em objetivos de aprendizagem da plataforma. A área 1 (literacia informacional e de dados) cobre competências como saber pesquisar e avaliar informação, compreender como os algoritmos moldam os resultados de pesquisa, e identificar desinformação — todas críticas para qualquer cidadão que tenta formar uma opinião informada sobre políticas de mobilidade urbana, eficiência energética ou qualidade do ar. A área 2 (comunicação e colaboração) cobre a capacidade de comunicar em meios digitais, participar em processos de tomada de decisão online e colaborar de forma construtiva — competências igualmente centrais para a participação cívica digital. O DigComp não é, em si, um programa de estudos: descreve o que se espera saber, não como se chega lá. O Play4Change ocupa esse espaço intermédio, propondo uma forma concreta — informal, adaptativa e gamificada — de ajudar os cidadãos a avançar neste mapa de competências ao seu próprio ritmo.

Duas ideias retiradas desse documento influenciaram diretamente a forma como o Play4Change foi pensado. A primeira é a constatação de que a competência digital e a competência cívica caminham lado a lado: saber procurar, avaliar e comunicar informação de forma crítica é também a base para participar na vida em sociedade — e é exatamente essa ponte entre “saber lidar com o digital” e “ser um cidadão ativo” que o projeto procura explorar. A segunda é o modo como o relatório descreve a presença cada vez maior da inteligência artificial no dia a dia das pessoas: motores de pesquisa que se adaptam a quem os usa, sistemas que ajudam a identificar do que cada um precisa, ferramentas que respondem a perguntas em linguagem natural. O Play4Change apropria-se desta mesma lógica, mas

vira-a a favor da aprendizagem: usa a inteligência artificial não para mostrar a alguém aquilo que já espera ver, mas para perceber onde tem mais dificuldade e ajustar o caminho de aprendizagem a essa pessoa em concreto [13].

1.3 Objetivos

Tendo este enquadramento como pano de fundo, o projeto Play4Change propõe-se conceber e desenvolver uma plataforma de educação digital, informal e gamificada, que ajude os cidadãos a adquirir, de forma natural e continuada, competências relevantes para a transição para cidades sustentáveis — com particular destaque para a dimensão da educação cívica.

Para que esta proposta não ficasse apenas como uma boa ideia solta, todo o trabalho foi organizado à volta de três pilares que se reforçam mutuamente — **reconhecimento**, **envolvimento** e **personalização** — e que são apresentados em detalhe na Secção 1.5. A Figura 1.2 resume esta estrutura: os três pilares funcionam como bases que sustentam o Play4Change e, em conjunto, é que tornam possível responder ao desafio de capacitar os cidadãos sem os perder pelo caminho.




Figura 1.2: Os três pilares — reconhecimento, envolvimento e personalização — que sustentam a proposta do Play4Change e orientam os objetivos deste trabalho.

De forma mais concreta, e organizando-os já à luz destes três pilares, este trabalho procura:

- **Reconhecimento** Dar a cada utilizador um sinal claro e tangível do seu progresso, através de um sistema de distintivos que assinala a aquisição de novas competências [9];
- **Envolvimento** Pensar em mecanismos que tornem a aplicação suficientemente apelativa para que as pessoas queiram voltar — respondendo a um dos maiores problemas da educação digital, que é o abandono ao fim de pouco tempo;
- **Personalização** Conceber uma forma de aprendizagem adaptativa, em que a inteligência artificial ajusta os conteúdos ao que cada pessoa já sabe, ao seu ritmo e às dificuldades que vai sentindo [6, 13];
- Construir e testar um protótipo funcional que materialize, de forma integrada, estes três pilares;
- Recolher, junto de pessoas de diferentes idades, contextos e níveis de educação, uma primeira perceção sobre o que funciona bem, o que pode ser melhorado e o que mais valorizam nesta forma de aprender.

1.4 O problema e a pergunta que orienta este trabalho

A transição para cidades mais sustentáveis enfrenta desafios de infraestrutura, de financiamento e de coordenação entre diferentes entidades — mas enfrenta também, e talvez sobretudo, o desafio de preparar as pessoas para essa mudança. É sobre esta última dimensão que este projeto se debruça.

O problema tem pelo menos três camadas que se reforçam mutuamente. A primeira é o **déficit de competências digitais e cívicas**: uma parte significativa da população europeia não dispõe das competências digitais básicas definidas pelo quadro DigComp [14], o que limita a sua capacidade de participar em processos de decisão que decorrem, crescentemente, em plataformas digitais — desde consultas públicas municipais a plataformas de participação cidadã. A segunda camada é a da **desinformação e da desconfiança**: num ambiente marcado por uma abundância de informação e por dificuldades crescentes de verificação, a capacidade de avaliar criticamente o que se lê é simultaneamente mais necessária e mais difícil de desenvolver sem prática estruturada e continuada. A terceira camada, talvez a mais diretamente prática, é o **problema do abandono nas plataformas de aprendizagem digital**: mesmo quando as pessoas começam a usar ferramentas de educação online, a taxa de abandono é muito elevada — plataformas de e-learning registam frequentemente taxas de conclusão de cursos abaixo dos 10% [6], o que levanta a questão de saber se o problema não está tanto na disponibilidade de conteúdos como na forma como estes são apresentados e na motivação que conseguem (ou não) gerar.

É sobre este último ponto que os mecanismos de envolvimento e personalização do Play4Change procuram atuar diretamente. A hipótese que orienta este trabalho é que a combinação de conteúdos curtos e contextualizados (relevantes para o dia a dia), de reconhecimento visível do progresso e de personalização adaptativa pode melhorar significativamente a retenção e o envolvimento a longo prazo — criando as condições para que a aprendizagem de competências cívicas e digitais deixe de ser uma tarefa pontual e passe a ser um hábito. Desta hipótese nasce a pergunta que orienta o projeto: de que forma pode uma plataforma de educação digital, informal e gamificada, apoiada por inteligência artificial, ajudar os cidadãos a desenvolver as competências de que precisam para participar na transição para cidades sustentáveis — e, ao mesmo tempo, conseguir que continuem a usá-la ao longo do tempo?

1.5 Como o Play4Change procura responder a este desafio

Para responder a esta pergunta, a proposta do Play4Change organiza-se à volta de três ideias que se complementam e reforçam mutuamente:

- **Reconhecer o que a pessoa já é capaz de fazer** — sempre que alguém conclui um tópico ou domina uma nova competência, a aplicação assinala isso de forma visível, através de um distintivo. É uma forma simples de dizer “conseguiste”, que dá à pessoa uma noção concreta da evolução do seu próprio percurso;
- **Manter a pessoa interessada em continuar** — um dos maiores obstáculos das plataformas de aprendizagem digital é que as pessoas começam com entusiasmo e, passado pouco tempo, deixam de as usar. O Play4Change procura contrariar essa tendência através de mecanismos que tornam o regresso à aplicação algo natural e motivador, e não mais uma tarefa;

- **Adaptar-se a quem está do outro lado** — nem todas as pessoas aprendem da mesma forma, no mesmo ritmo, ou partem do mesmo ponto. Por isso, a aplicação recorre à inteligência artificial para perceber as dificuldades de cada utilizador e ajustar-se a elas, tornando a experiência mais próxima e mais útil para cada pessoa em particular.

Do ponto de vista técnico, estes três pilares traduzem-se em componentes específicos da plataforma. O **reconhecimento** concretiza-se num motor de distintivos que avalia o desempenho do utilizador e desbloqueia emblemas quando determinados limiares de domínio são atingidos, seguindo a lógica de aprendizagem por mestria [1]. O **envolvimento** materializa-se em mecanismos como as sequências de dias consecutivos de utilização (*streaks*), notificações de lembrança e a lógica de desbloqueio diário de conteúdos que torna o regresso à aplicação algo esperado e natural. A **personalização** é suportada por um sistema de inteligência artificial que classifica os erros do utilizador em padrões reconhecíveis [13], gera percursos de reforço adaptados ao seu perfil de dificuldade recorrendo a um modelo de linguagem de grande dimensão [6], e mantém sessões de explicação interativa em que o utilizador pode esclarecer as suas dúvidas por conversação. O Capítulo 3 detalha como cada um destes componentes foi concebido e implementado.

Importa deixar claro que aquilo que se apresenta neste relatório é um protótipo funcional — um primeiro passo que demonstra que a ideia é viável, mas que deixa também muito espaço para crescer em cada uma destas três frentes, como se discute mais adiante no Capítulo 6.

1.6 Organização do documento

O presente relatório está organizado da seguinte forma. O Capítulo 2 aprofunda o enquadramento e o estado da arte, situando o Play4Change no contexto da educação digital, da aprendizagem adaptativa e dos quadros de referência europeus de competência digital e cívica que serviram de inspiração a este trabalho. O Capítulo 3 descreve o processo de desenvolvimento da solução — desde os requisitos até à arquitetura, à implementação e às opções de design da interface. O Capítulo 4 apresenta as ferramentas, tecnologias e metodologias utilizadas ao longo do projeto, dando particular atenção ao papel que a inteligência artificial desempenhou não só na aplicação, mas também no próprio processo de a desenvolver. O Capítulo 5 apresenta e discute os resultados da avaliação preliminar feita junto de utilizadores reais. Por fim, o Capítulo 6 reúne as principais conclusões deste trabalho, assume com transparência as suas limitações, e aponta caminhos para o que pode vir a seguir.

Capítulo 2

Enquadramento e Estado da Arte

2.1 Conceitos fundamentais

Antes de se analisar o panorama de soluções existentes, é importante clarificar três conceitos que estruturam toda a proposta do Play4Change: a gamificação, a aprendizagem adaptativa e o papel da inteligência artificial na personalização da aprendizagem. Estes três conceitos não são independentes — pelo contrário, é precisamente da sua articulação que nasce a lógica dos três pilares (reconhecimento, envolvimento e personalização) já apresentados na Secção 1.5.

Gamificação

A gamificação consiste na aplicação de elementos e mecânicas tipicamente associados a jogos — como pontos, níveis, distintivos, tabelas de classificação ou sequências de progresso — a contextos que não são, em si, jogos, com o objetivo de aumentar a motivação e o envolvimento dos utilizadores [9]. No domínio da educação digital, a gamificação é frequentemente usada precisamente para responder ao problema do abandono: ao tornar o processo de aprendizagem mais apelativo e ao reconhecer visivelmente o progresso da pessoa, procura-se que esta sinta vontade de continuar. É desta lógica que nascem, em larga medida, dois dos três pilares do Play4Change: o **reconhecimento** — a visibilidade tangível do progresso através de distintivos que assinalam competências adquiridas — e o **envolvimento** — os mecanismos que tornam o regresso à aplicação algo natural e motivador, e não mais uma tarefa.

A literatura sobre gamificação em contextos educativos revela resultados promissores, mas também aponta limites importantes. O estudo de revisão sistemática de Toda et al. [9], que analisou mais de uma década de investigação, conclui que os elementos da chamada tríade PBL (Points, Badges, Leaderboards) têm impacto positivo no envolvimento e na persistência a curto prazo, mas que o seu efeito sustentado depende criticamente do modo como são integrados no contexto pedagógico. Em particular, os autores alertam para um risco que o design de qualquer plataforma gamificada deve considerar: o da motivação extrínseca — aprender para ganhar pontos ou subir numa tabela — substituir gradualmente a motivação intrínseca, sobretudo em utilizadores que, à partida, já estariam motivados a aprender.

Esta tensão entre motivação extrínseca e intrínseca é central na Teoria da Autodeterminação

(Self-Determination Theory) [5], que identifica três necessidades psicológicas básicas cujo suporte favorece a motivação duradoura: a **autonomia** (sentir que as próprias escolhas fazem sentido), a **competência** (sentir-se capaz e em crescimento) e a **relação** (sentir-se ligado aos outros). Uma plataforma que se limita a acumular pontos satisfaz potencialmente apenas a competência, e de forma superficial; o Play4Change procura alargar este espectro: as sequências de dias consecutivos (*streaks*) apelam à autonomia ao tornar o regresso uma decisão da própria pessoa, os distintivos reconhecem competência genuína (só são atribuídos quando se domina um tópico a um nível mínimo), e a estrutura de tópicos relacionados com a vida cívica real procura tornar a aprendizagem significativa para além do jogo em si.

Aprendizagem adaptativa

A aprendizagem adaptativa designa abordagens em que o percurso, o ritmo ou o nível de dificuldade dos conteúdos se ajustam ao desempenho e às necessidades de cada pessoa, em vez de seguirem um percurso único e igual para todos [13]. Em vez de um modelo “tamanho único”, a ideia é que cada pessoa avance ao seu próprio ritmo, recebendo mais apoio onde sente mais dificuldade e podendo avançar mais depressa onde já domina a matéria. Este conceito está diretamente na base do pilar da **personalização**.

O ponto de partida histórico para compreender a importância da adaptação no ensino é o chamado problema das 2 sigma, identificado por Bloom em 1984 [2]: num estudo controlado, os alunos que receberam tutoria individual regular apresentaram desempenhos 2 desvios padrão acima dos alunos em regime de ensino convencional em grupo — um resultado notável, que Bloom apelidou de “o maior problema da pedagogia”, dada a impossibilidade prática de escalar a tutoria individual. A questão que se seguiu — e que tem orientado décadas de investigação em tecnologia educacional — foi: como escalar os benefícios da tutoria individual a custo acessível?

Os Sistemas de Tutoria Inteligente (*Intelligent Tutoring Systems*, ITS) emergiram precisamente como resposta a esta questão. VanLehn [13], numa revisão abrangente de 2011, mostra que os ITS com retro-alimentação ao nível do passo (*step-level feedback*) — ou seja, sistemas que reagem imediatamente a cada interação do utilizador, e não apenas à resposta final — conseguem ganhos de 0,4 a 1,0 desvio padrão em relação ao ensino convencional. Embora aquém dos 2 sigma da tutoria humana, este resultado valida a abordagem adaptativa como alternativa viável e escalável, especialmente quando combinada com a disponibilidade permanente que o software pode oferecer.

A aprendizagem por mestria (*mastery learning*) [1] é outro conceito central: o utilizador não avança para um tópico novo antes de demonstrar que domina o anterior, o que força uma progressão sólida em vez de uma superficial. No Play4Change, esta lógica aplica-se tanto à progressão entre tópicos (só se acede ao tópico *B* depois de dominar o tópico *A*, verificado através de um grafo de pré-requisitos) como à geração de percursos de reforço quando um erro recorrente é detetado. A adaptação dá-se, portanto, a dois níveis: na estrutura do percurso a longo prazo e na geração de conteúdo de apoio em resposta a dificuldades concretas em tempo real.

Inteligência artificial na personalização da aprendizagem

A inteligência artificial tem vindo a tornar a aprendizagem adaptativa cada vez mais viável e acessível, ao permitir analisar o desempenho de cada utilizador e gerar ou ajustar conteúdos de forma praticamente individual — algo que seria muito difícil de fazer manualmente, à escala de milhares de utilizadores [6]. É também esta capacidade que torna possível um dos objetivos centrais do Play4Change: que cada pessoa sinta que a aplicação “percebe” onde tem mais dificuldade e a ajuda a esclarecer essas dúvidas, em vez de a confrontar com um conjunto fixo e genérico de exercícios.

Os Modelos de Linguagem de Grande Dimensão (Large Language Models, LLM) tornaram concreta uma possibilidade que antes era apenas teórica: gerar conteúdos pedagógicos personalizados a pedido, em linguagem natural, de forma economicamente acessível e à escala. Kasneci et al. [6] identificam, numa análise abrangente das oportunidades e desafios dos LLM na educação, que entre as potencialidades mais relevantes estão precisamente a geração de exercícios adaptados ao nível do aprendente, a explicação de conceitos de formas diferentes consoante o perfil da pessoa, e o feedback imediato e personalizado. Os mesmos autores sublinham, porém, que a utilização acrítica destes modelos levanta desafios sérios: a possibilidade de gerar conteúdos incorretos ou imprecisos (hallucinations), a necessidade de supervisão editorial, e o risco de substituição do pensamento crítico do aprendente por uma dependência excessiva nas respostas da máquina.

Para mitigar o risco de qualidade, o Play4Change adopta uma abordagem de geração ancorada em contexto, inspirada no padrão Retrieval-Augmented Generation (RAG) [8]: em vez de pedir ao modelo que gere conteúdo livremente a partir de um pedido vago, o sistema constrói um prompt estruturado que inclui o perfil de dificuldade do utilizador, o tópico pedagógico em causa, exemplos de exercícios anteriores considerados bem-sucedidos e um esquema JSON que o modelo deve respeitar na resposta. Adicionalmente, a resposta do modelo é validada contra esse esquema e, em caso de falha de formato, o pedido é reenviado com uma indicação explícita dos erros encontrados. Esta combinação de contexto estruturado, exemplos de referência e validação pós-geração procura tornar a saída do LLM suficientemente fiável para ser apresentada ao utilizador sem revisão humana prévia — reconhecendo, ao mesmo tempo, que esta garantia é parcial e que a supervisão editorial dos conteúdos gerados continua a ser um passo importante para uma versão madura da plataforma.

2.2 Educação cívica e competências para a transição sustentável

A educação cívica — entendida como o processo pelo qual os cidadãos desenvolvem o conhecimento, as competências e a disposição para participar ativamente na vida pública e nas decisões coletivas — é reconhecida como um dos pilares das democracias participativas. No contexto específico da transição para cidades mais sustentáveis, esta dimensão adquire particular relevância: as políticas urbanas têm maior probabilidade de produzir resultados quando os cidadãos compreendem o que está em causa, sentem que têm um papel a desempenhar e são efetivamente envolvidos nos processos de decisão [11].

O quadro de referência DigComp 2.2 [14] fornece uma estrutura útil para operacionalizar estas competências no mundo digital. Das cinco áreas que o quadro organiza — literacia informacional, comunicação e colaboração, criação de conteúdos digitais, segurança e resolução de problemas —, as duas primeiras têm uma ligação direta à cidadania ativa: saber avaliar criticamente a informação que se encontra online, distinguir fontes fiáveis de desinformação, e saber comunicar e colaborar de forma construtiva

em meios digitais são, simultaneamente, competências digitais e competências cívicas. Não existe, portanto, uma separação clara entre “literacia digital” e “literacia cívica” — a segunda pressupõe, em boa medida, a primeira.

O desafio central que o Play4Change enfrenta é o da **acessibilidade da aprendizagem informal**: como chegar a cidadãos que não estão em contextos de aprendizagem formal — que não são estudantes, que não frequentam formações profissionais — e que talvez nunca tenham formulado o desejo explícito de “melhorar as suas competências cívicas digitais”? A resposta que este projeto propõe assenta em três princípios. Primeiro, a **informalidade**: o formato de jogo, com sessões curtas e sem pressão avaliativa, baixa a barreira de entrada. Segundo, a **acessibilidade imediata**: uma aplicação móvel que não requer inscrição em instituições, sem custos de acesso, disponível em qualquer hora e lugar. Terceiro, a **relevância percebida**: os conteúdos são enquadrados em situações concretas da vida nas cidades — temas que a pessoa reconhece como pertinentes ao seu quotidiano, e não como matéria académica abstrata. É esta combinação que distingue a proposta do Play4Change de abordagens de educação cívica mais tradicionais.

2.3 Trabalho relacionado: o que já existe e o que se pode aprender com isso

Antes de desenhar a solução, foi feita uma análise informal de um conjunto de plataformas de educação digital amplamente conhecidas e utilizadas — Kahoot!, Duolingo, Coursera, Khan Academy e edX. O objetivo desta análise não foi produzir um estudo comparativo exaustivo, mas sim perceber, de forma prática, em que é que cada uma destas plataformas se destaca — e, em particular, o que cada uma faz bem em relação aos três pilares definidos para o Play4Change: reconhecimento, envolvimento e personalização. A análise é qualitativa e baseia-se na experiência direta de utilização das plataformas e na documentação pública disponível. A partir daqui, procurou-se “herdar” as ideias mais relevantes de cada uma e adaptá-las, ainda que de forma parcial — lembrando sempre que o Play4Change, nesta fase, é apenas um protótipo funcional e não uma plataforma completa.

A Tabela 2.1 resume esta análise, posicionando cada plataforma relativamente aos três pilares.

Antes de analisar os resultados, merecem nota dois aspetos transversais. O primeiro é a **dimensão temática**: todas as plataformas analisadas são agnósticas quanto ao tema — o Duolingo ensina línguas, o Kahoot! pode ser usado para qualquer quiz, e o Coursera e o edX cobrem toda a espécie de cursos académicos. Nenhuma delas foi concebida especificamente para a educação cívica relacionada com a sustentabilidade urbana, o que significa que mesmo as melhores práticas identificadas neste levantamento teriam de ser recontextualizadas. O segundo aspeto é a **origem da experiência**: a maioria destas plataformas foi concebida para contextos web, com aplicações móveis como extensão. O Play4Change foi desenhado desde o início como uma aplicação móvel nativa — partindo do princípio de que o telemóvel é o ponto de acesso privilegiado da maioria dos cidadãos à internet, em particular nos grupos etários e socioeconómicos que importa não excluir.

Desta análise resultou uma perceção relativamente clara: nenhuma destas plataformas é simultaneamente forte nos três pilares. O Duolingo destaca-se no envolvimento e no reconhecimento, mas o seu modelo de personalização é relativamente simples; a Khan Academy é uma referência em personalização através da aprendizagem por mestria, mas o seu reconhecimento e envolvimento são mais discretos;

Plataforma	Reconhecimento	Envolvimento	Personalização
Kahoot!	Pontuações e pódios em tempo real que celebram o desempenho individual e do grupo	Formato de jogo/quiz competitivo, muito eficaz a tornar o momento de avaliação divertido	Pouco adaptativo: os mesmos quizzes são apresentados a todos os participantes
Duolingo	Sistema de níveis, ligas e distintivos que assinalam claramente cada progresso	Sequências diárias (<i>streaks</i>), lembretes e notificações que incentivam o regresso todos os dias	Ajusta a dificuldade dos exercícios de acordo com os erros e acertos do utilizador
Coursera	Certificados formais e emblemas associados à conclusão de cursos e módulos	Estrutura por prazos e módulos que organiza o estudo, mas com pouca componente lúdica	Percursos de aprendizagem recomendados com base nos interesses e no histórico do utilizador
Khan Academy	Pontos de energia, distintivos e mapas de progresso que tornam visível o que já foi dominado	Painel de progresso e missões que ajudam o utilizador a saber sempre “o que vem a seguir”	Aprendizagem por mestria (<i>mastery learning</i>) [1]: só se avança quando se domina o tema anterior
edX	Certificados verificados e indicadores de conclusão por módulo	Fóruns de discussão e prazos que criam uma sensação de comunidade e de ritmo	Conteúdos relativamente uniformes, com pouca adaptação automática ao desempenho individual

Tabela 2.1: Comparação informal de cinco plataformas de educação digital amplamente conhecidas, segundo os três pilares definidos para o Play4Change: reconhecimento, envolvimento e personalização.

o Kahoot! é extremamente envolvente no momento da utilização, mas pouco adaptado a cada pessoa; e o Coursera e o edX valorizam sobretudo o reconhecimento formal (certificados), com menos ênfase no envolvimento contínuo do dia a dia. A Figura 2.1 traduz esta perceção num gráfico de três eixos — um para cada pilar (reconhecimento, envolvimento e personalização) — em que o “volume” ocupado por cada plataforma mostra, de forma imediata, em quantos e em quais pilares ela é forte; a área tracejada representa a meta a que o Play4Change aspira: ser razoavelmente forte nos três ao mesmo tempo, e não apenas num deles.

2.4 Síntese e posicionamento do projeto

A análise apresentada permite tirar uma conclusão simples, mas importante para todo o desenho do Play4Change: cada uma das plataformas estudadas resolve bem uma parte do problema — seja tornar o momento de aprendizagem divertido, seja reconhecer o progresso de forma visível, seja adaptar os conteúdos a quem aprende — mas raramente as três coisas ao mesmo tempo, e raramente com um foco em temas de cidadania e sustentabilidade.

Esta síntese informou diretamente as decisões de design do Play4Change. Do conjunto de plataformas analisadas, **adotaram-se**: as sequências diárias (*streaks*) e os distintivos de progresso do Duolingo; a progressão por mestria da Khan Academy [1]; e o formato de quiz interativo e imediato do Kahoot!. **Não se adotaram**, pelo menos nesta fase, os certificados formais do Coursera e do edX — que implicariam um nível de acreditação externo fora do âmbito de um protótipo — nem as tabelas de classificação altamente competitivas que algumas destas plataformas utilizam, por se entender que podem ter efeitos desmotivadores em utilizadores menos experientes, contrariando os princípios da Teoria da Autodeterminação [5].




Figura 2.1: Cada plataforma representada num gráfico de três eixos — reconhecimento, envolvimento e personalização — de acordo com o nível (baixo, médio ou alto) atribuído na Tabela 2.1. A área a tracejado assinala a meta do Play4Change: alcançar um nível elevado nos três pilares em simultâneo, em vez de se destacar apenas num deles.

A diferença mais fundamental entre o Play4Change e todas as plataformas analisadas reside na combinação de **tema** (educação cívica para a transição sustentável) e de **personalização gerativa** (uso de um LLM para gerar conteúdos adaptativos em tempo real, com base no perfil de dificuldade de cada utilizador, e não apenas para selecionar conteúdos de um repositório fixo). Esta combinação, tanto quanto foi possível apurar neste levantamento, não está presente em nenhuma das plataformas existentes — o que justifica a proposta, mas também coloca desafios concretos: o custo da inferência de IA a escala, a garantia de qualidade dos conteúdos gerados e a necessidade de validação pedagógica são dimensões que este protótipo apenas começa a explorar, e que uma versão madura da plataforma terá necessariamente de endereçar com maior rigor.

É exatamente nesse espaço que o Play4Change se posiciona: não como um substituto de nenhuma das plataformas analisadas, mas como uma proposta que tenta reunir, num único produto aplicado à educação cívica, aquilo que cada uma faz de melhor — apoiando-se na inteligência artificial para que esta combinação se ajuste a cada pessoa em particular. O resultado, nesta fase, é um protótipo funcional: uma primeira demonstração de que a ideia é viável e tem valor, não ainda uma plataforma completa e madura.

Capítulo 3

Design e Implementação do Sistema

Este capítulo descreve como o Play4Change foi concebido e implementado. A ênfase recai sobre a **arquitetura lógica** do sistema — os seus módulos, as respectivas responsabilidades e os fluxos de interacção que os atravessam — e sobre o **motor de inteligência artificial** que sustenta a personalização adaptativa: como os prompts são construídos, como a resposta do modelo é processada e como o sistema lida com falhas.

3.1 Visão geral da arquitectura




Figura 3.1: Arquitectura lógica do Play4Change. As cinco zonas — Apresentação, Rede de Fronteira, Aplicação, Persistência e Observabilidade — interagem através de protocolos e contratos bem definidos. Os serviços externos (LLM e Email) são acedidos exclusivamente pelo servidor de aplicação, isolando os clientes de qualquer dependência directa.

O Play4Change organiza-se em cinco zonas lógicas claramente delimitadas (Figura 3.1): a camada de **apresentação**, que agrega os clientes que interagem com o sistema; a **rede de fronteira**, responsável pela terminação TLS e pelo encaminhamento de tráfego; o **servidor de aplicação**, onde reside toda a lógica de domínio; a camada de **persistência**, que garante o armazenamento durável dos dados; e a

zona de **observabilidade**, que recolhe e expõe métricas operacionais. Acresce ainda um conjunto de **serviços externos** que o servidor utiliza para capacidades que transcendem o seu perímetro: geração de linguagem natural e entrega de correio electrónico.

3.2 Módulos e responsabilidades

Esta secção descreve cada módulo pelo que é responsável por garantir, não pelas tecnologias que usa. A Tabela 3.1 fornece um resumo antes da descrição detalhada.

Módulo	Responsabilidades principais
Mobile Client	Renderizar a experiência de aprendizagem; submeter respostas; navegar nos percursos adaptativo e de explicação; apresentar distintivos e streak.
Web Client	Interface de administração; criar, editar e publicar tópicos; monitorizar progresso de utilizadores; configurar pré-requisitos e o grafo de aprendizagem.
Reverse Proxy	Terminar ligações TLS; encaminhar pedidos para o servidor de aplicação; servir a SPA do cliente web; proteger o servidor de exposição directa à internet.
Autenticação & Segurança	Emitir e validar magic links; emitir, renovar e revogar tokens de sessão; impor limites de frequência por IP; garantir que cada pedido autenticado tem o papel correcto.
Lógica de Domínio	Orquestrar todos os casos de uso: inscrição em tópicos, entrega e avaliação de tarefas, geração do percurso adaptativo, emissão de distintivos e gestão de preferências do utilizador.
Agendadores	Executar tarefas temporais sem intervenção humana: expirar inscrições inactivas, encerrar revisões por pares pendentes, e detectar gerações de IA presas (<u>watchdog</u>).
Agente de IA	Construir prompts contextualizados; invocar o fornecedor de LLM; validar e sanear a resposta; gerir a deduplicação vectorial; isolar o resto do sistema de qualquer dependência directa do modelo.
Base de Dados	Persistir o estado durável de todos os agregados de domínio; suportar pesquisa por similaridade vectorial para deduplicação de tarefas geradas.
Armazenamento de Objectos	Guardar ficheiros binários (PDFs, fotografias de submissões); disponibilizar URLs pré-assinados para acesso temporário.
Métricas DB	Receber e armazenar séries temporais de métricas operacionais recolhidas do servidor por scraping periódico.
Dashboard	Visualizar as métricas operacionais em painéis de tempo real para observabilidade e detecção de anomalias.
Fornecedor de LLM	Gerar texto determinado por prompt; devolver respostas estruturadas (JSON) ou em prosa; sem estado persistente sobre o sistema.
API de Email	Entregar transaccionalmente mensagens de correio electrónico (magic links de autenticação) com garantias de entrega e rastreio.

Tabela 3.1: Módulos do sistema Play4Change e respectivas responsabilidades. A descrição foca o o quê (contrato de responsabilidade), não o como (tecnologia de implementação).

3.2.1 Camada de apresentação

A camada de apresentação é o único ponto de contacto directo com o utilizador humano, composta por dois clientes independentes com finalidades distintas.

O **Mobile Client** é o canal primário de aprendizagem. A sua responsabilidade central é traduzir o modelo de domínio devolvido pela API REST numa experiência de utilização fluída: apresentar a tarefa diária, recolher a resposta, comunicar o resultado (correcto ou errado) e — quando despoletado pelo servidor — navegar automaticamente para o percurso adaptativo ou para o modo de explicação. O cliente não contém lógica de negócio: toda a avaliação de respostas, atribuição de pontos e classificação de erros ocorre exclusivamente no servidor.

O **Web Client** serve os administradores de conteúdo. As suas responsabilidades incluem criar tópicos a partir de documentos PDF ou URLs, monitorizar em tempo real o progresso de geração de tarefas via SSE, editar individualmente as questões geradas pela IA, configurar o grafo de pré-requisitos, e consultar relatórios de utilização.

3.2.2 Rede de fronteira

O **Reverse Proxy** interpõe-se entre a internet pública e o servidor de aplicação, cumprindo três responsabilidades distintas: terminação TLS (recebe ligações HTTPS e reencaminha internamente via HTTP); encaminhamento de tráfego (distingue pedidos de API de activos estáticos); e fronteira de segurança (o servidor nunca está exposto directamente à internet pública).

3.2.3 Servidor de aplicação

O servidor de aplicação é o núcleo do sistema, organizado internamente em cinco sub-módulos.

Autenticação e Segurança. Responsável por garantir que apenas utilizadores legítimos acedem ao sistema com o nível de privilégio correcto. Gere o ciclo de vida completo do magic link (emissão, hash, consumo atómico, expiração); emite e valida pares de tokens de acesso e renovação; impõe limites de frequência por endereço IP; e valida o papel (`ROLE_USER` ou `ROLE_ADMIN`) em cada pedido protegido. Não tem conhecimento de qualquer lógica de negócio.

Lógica de Domínio. Implementa todos os casos de uso e mantém os invariantes do domínio: avaliar respostas e calcular pontos com penalização temporal; classificar padrões de erro de forma determinística; orquestrar o ciclo de vida das inscrições; gerir o desbloqueio diário de tarefas por índice; detectar a necessidade de percurso adaptativo e despoletá-lo assincronamente; emitir dist intivos quando os critérios de mestria são atingidos; e verificar a integridade do grafo de pré-requisitos por pesquisa em largura.

Agendadores. Executa tarefas temporais em segundo plano sem intervenção humana, organizadas em três responsabilidades distintas.

A primeira é a **expiração de inscrições**: um job periódico percorre as inscrições `ACTIVE` cujo `dueDate` já foi ultrapassado e as transita para `EXPIRED`, impedindo que utilizadores inactivos continuem a ocupar vagas em tópicos com limite de inscritos.

A segunda é o **encerramento de revisões por pares**: quando o sistema suporta submissões abertas com revisão por outros utilizadores, um job independente detecta revisões cujo prazo de resposta expirou e fecha-as automaticamente com o estado `TIMED_OUT`, desbloqueando o progresso do autor.

A terceira e mais crítica é o **watchdog de geração de IA**: qualquer geração de conteúdo que permaneça no estado `GENERATING` por mais tempo do que o timeout configurado é considerada presa — tipicamente por falha do servidor durante a chamada assíncrona ao LLM. O watchdog detecta estes casos, transita o registo para `FAILED` e, consoante o tipo de geração, ou marca o tópico como `FAILED` (para conteúdo de percurso fixo) ou repõe a atribuição original em `PENDING` (para sessões de explicação), garantindo que nenhum utilizador fica bloqueado indefinidamente à espera de conteúdo que nunca vai chegar.

Agente de IA. É o único ponto de contacto com o fornecedor de LLM. A sua principal responsabilidade é **isolar** o resto do sistema de qualquer dependência do modelo: o servidor de aplicação nunca sabe que modelo está a ser usado, que API está a ser chamada, ou que formato de resposta é devolvido. O agente expõe uma interface com três operações: gerar tarefas de percurso fixo, gerar um ramo adaptativo para um padrão de erro, e gerar explicação em prosa. Internamente, constrói prompts contextualizados, valida o JSON produzido (com retenção automática), saneia o texto gerado, calcula embeddings para deduplicação vectorial e reporta métricas de latência e taxa de falha.

Observabilidade (interna ao servidor). Instrumenta o servidor com contadores e temporizadores que cobrem os eventos de negócio mais relevantes: submissões correctas e incorrectas, sessões adaptativas criadas e resolvidas, gerações de IA com sucesso e falha, inscrições concluídas, distintivos emitidos. Os dados são expostos num endpoint de scraping sem impacto na performance dos pedidos.

3.2.4 Camada de persistência

A camada de persistência divide-se em dois componentes com responsabilidades completamente distintas.

Base de Dados. Armazena todo o estado durável do domínio: utilizadores, inscrições, atribuições, sessões adaptativas, sessões de explicação, templates de tarefas, distintivos e o grafo de pré-requisitos. O modelo relacional garante a consistência transaccional dos invariantes críticos — nomeadamente a natureza atómica do consumo de tokens de autenticação e da transição de estado das inscrições.

Para além da persistência relacional clássica, a base de dados suporta **pesquisa por similaridade vectorial**: cada template de tarefa gerado pelo LLM é associado a um embedding de 1024 dimensões que representa semanticamente o seu conteúdo. Na geração de ramos adaptativos, o sistema calcula o embedding do contexto de dificuldade actual e executa uma pesquisa de vizinhos mais próximos por similaridade cosseno, recuperando ramos previamente gerados que sejam semanticamente equivalentes. Este mecanismo, descrito em detalhe na Secção 3.4.2, elimina gerações redundantes e reduz tanto a latência como o custo de chamadas ao LLM.

Armazenamento de Objectos. Responsável por guardar ficheiros binários que não têm lugar num modelo relacional: os PDFs que os administradores carregam para criar tópicos, e eventuais ficheiros de submissão dos utilizadores. O acesso aos ficheiros nunca é feito directamente pelo cliente — o servidor gera URLs pré-assinados com tempo de vida limitado que permitem ao cliente descarregar ou visualizar o ficheiro directamente a partir do armazenamento, sem que o conteúdo binário transite pelo servidor de aplicação. Isto elimina um gargalo de banda e garante que os ficheiros nunca são expostos sem autorização implícita do servidor.

3.2.5 Observabilidade externa

A observabilidade do sistema é composta por dois componentes que operam fora do servidor de aplicação, garantindo que a monitorização não interfere com a execução da lógica de negócio.

Métricas DB. Recebe e armazena séries temporais de métricas operacionais recolhidas do servidor por scraping periódico ao endpoint de observabilidade interna. A arquitectura de pull — em que a base de métricas vai buscar os dados ao servidor em vez de o servidor os enviar — garante que uma eventual indisponibilidade da base de métricas não afecta o desempenho nem a disponibilidade do servidor. As métricas cobertas incluem: latência de pedidos por rota, taxa de erro HTTP, contadores de eventos de negócio (inscrições, submissões, dist intivos), e métricas de desempenho da JVM (memória, GC, threads).

Dashboard. Visualiza as métricas armazenadas na base de métricas em painéis de tempo real, acessíveis à equipa de operações. Os painéis estão organizados em dois níveis: um nível operacional, que exhibe a saúde imediata do sistema (taxa de erro, latência p95, utilização de recursos); e um nível de produto, que exhibe métricas de envolvimento dos utilizadores (inscrições activas, taxa de conclusão de tópicos, sessões adaptativas criadas por dia, dist intivos emitidos). A separação entre os dois níveis permite que tanto engenheiros como gestores de produto extraiam valor da mesma infra-estrutura de observabilidade sem navegar por painéis irrelevantes para os seus objectivos.

3.3 Fluxos de interacção

Esta secção apresenta os diagramas de sequência dos principais fluxos do sistema. Cada diagrama descreve a interacção entre actores (cliente, servidor, componentes internos, serviços externos) para um caso de uso concreto.

3.3.1 Autenticação

O Play4Change usa autenticação sem palavra-passe (passwordless) baseada em magic links. O fluxo divide-se em duas fases: pedido do link e verificação do token.

Na fase de pedido (passos 1–4 da Figura 3.2), o utilizador fornece apenas o endereço de email. O servidor gera um token opaco criptograficamente seguro, armazena **apenas o seu hash SHA-256** na base de dados (o token em claro nunca é persistido), e envia o link por email. Esta separação garante que mesmo um acesso não autorizado à base de dados não compromete os tokens activos.

Na fase de verificação (passos 5–8), o servidor calcula o hash do token recebido e executa uma actualização atómica:

```
UPDATE SET used=true WHERE token=$hash AND used=false AND expires_at>NOW()
```

Esta operação atómica elimina a janela de Time-of-Check/Time-of-Use (TOCTOU) que existiria com um `SELECT` seguido de `UPDATE` separados.




Figura 3.2: Autenticação passwordless. O token opaco em claro nunca é persistido — apenas o seu hash SHA-256 é armazenado (passo 2). A verificação usa uma actualização atómica (passo 6) que elimina a janela TOCTOU. Se o token for inválido, usado ou expirado, o servidor rejeita sem informação adicional.

3.3.2 Criar tópico e gerar conteúdo

A criação de um tópico desencadeia um **pipeline de geração em quatro fases** (Figura 3.4). O pedido HTTP do administrador retorna imediatamente com o identificador do tópico (passo 3); toda a geração ocorre em background de forma assíncrona, com notificação em tempo real ao cliente via SSE.

As quatro fases são: **INGESTION** (extração do texto do PDF ou URL); **ANALYSIS** (limpeza e estruturação do módulo de aprendizagem); **GENERATION** (chamada ao LLM com o texto extraído como contexto); e **INDEXING** (persistência dos templates de tarefas com embeddings e criação da microcompetência associada ao tópico). Após a transição para **ACTIVE**, o tópico fica disponível para inscrições. A Figura 3.3 ilustra o fluxo completo, incluindo os caminhos de falha em cada fase.




Figura 3.3: Pipeline de geração de conteúdo assíncrona. O caminho feliz (setas sólidas) transita o tópico de **PENDING** para **ACTIVE** em quatro fases; o administrador é notificado em tempo real via SSE (setas pontilhadas roxas) após cada fase. Qualquer falha (setas a vermelho) transita directamente para **FAILED** sem degradar silenciosamente a qualidade do conteúdo.

3.3.2.1 Ingestão de conteúdo: PDF e URL

A fase de **INGESTION** é a primeira do pipeline e determina a qualidade de todo o conteúdo que o LLM vai gerar. O administrador fornece o conteúdo numa de duas formas: um ficheiro PDF carregado directamente, ou um URL público a partir do qual o sistema descarrega o conteúdo. Em ambos os casos, o objectivo é o mesmo: obter texto simples e limpo que possa ser injectado no contexto do LLM.

Ingestão de PDF. O ficheiro é recebido pelo servidor, persistido no armazenamento de objectos e depois processado por extracção de texto. O processador percorre o PDF página a página, extrai o conteúdo textual de cada uma e concatena-o preservando a ordem original do documento. O texto resultante é normalizado: espaços múltiplos e quebras de linha excessivas são colapsadas para reduzir ruído sem perder estrutura semântica.

Esta abordagem funciona bem para PDFs **nativamente digitais** — documentos criados por processadores de texto ou exportados de apresentações — porque o texto está codificado de forma programaticamente acessível. No entanto, enfrenta uma limitação fundamental com **PDFs digitalizados** (imagens de páginas físicas): nestes casos, o extractor não encontra texto e devolve uma *string* vazia ou quase vazia. Sem texto, o LLM recebe um contexto inadequado e as tarefas geradas serão genéricas e desligadas do conteúdo real do documento. O sistema detecta esta situação quando o texto extraído é inferior a um

limiar mínimo de caracteres e transita o tópico para `FAILED` com uma mensagem de erro explícita, em vez de gerar conteúdo de baixa qualidade silenciosamente.

Ingestão de URL. Quando o administrador fornece um URL, o servidor efectua um pedido HTTP GET ao destino e extrai o conteúdo textual da página. O HTML recebido é processado para remover markup, scripts, estilos e elementos de navegação, retendo apenas o texto principal da página.

Esta abordagem tem três limitações importantes. A primeira é a dependência de **renderização no servidor**: páginas que carregam o seu conteúdo dinamicamente via JavaScript (aplicações single-page) devolvem apenas o esqueleto HTML inicial sem conteúdo real, uma vez que o sistema não executa um motor de renderização completo. A segunda é o **acesso restrito**: URLs que exigem autenticação, que estão por trás de paywalls, ou que bloqueiam pedidos de servidores automatizados resultam num erro de acesso que falha a ingestão. A terceira é a **instabilidade do conteúdo**: ao contrário de um PDF, uma página web pode ser alterada pelo seu proprietário após a criação do tópico, tornando o conteúdo gerado desactualizado sem qualquer notificação ao sistema.

Limite de contexto e truncagem. Independentemente da fonte, o texto extraído é truncado a **50.000 caracteres** antes de ser injectado no prompt do LLM (campo `subjectDomain`). Este limite existe porque os modelos de linguagem têm uma janela de contexto finita e porque textos excessivamente longos diluem a atenção do modelo, reduzindo a coerência e a especificidade das tarefas geradas.

A truncagem tem uma implicação directa: para documentos longos — manuais técnicos, dissertações, relatórios extensos — apenas os primeiros 50.000 caracteres são usados como contexto. Se o conteúdo mais relevante estiver distribuído ao longo de todo o documento, as tarefas geradas podem reflectir apenas a primeira porção. Esta é uma **limitação conhecida do protótipo**: uma versão de produção beneficiaria de uma estratégia de chunking inteligente que seleccionasse os excertos mais relevantes para o objectivo do módulo em vez de truncar linearmente.




Figura 3.4: Criação de tópico e pipeline de geração assíncrona em quatro fases. O pedido HTTP retorna imediatamente (passo 3). A geração executa numa coroutine independente, notificando o cliente via SSE (passos 9 e 11). Em caso de falha em qualquer fase, o tópico transita para **FAILED**.

3.3.3 Editar questão de um tópico

Após a geração inicial, o administrador pode corrigir ou melhorar individualmente qualquer questão gerada pela IA (Figura 3.5). O mecanismo usa versionamento imutável: a versão anterior nunca é

apagada, apenas marcada como *superseded*. Isto preserva a integridade referencial de todas as atribuições já feitas com a versão anterior.




Figura 3.5: Edição de uma questão. O versionamento imutável garante que atribuições já feitas permanecem íntegras: a versão anterior é marcada como *superseded* (passo 2) e uma nova versão com *isCurrent=true* é inserida (passo 3). Novos utilizadores receberão automaticamente a versão actualizada.

3.3.4 Inscrição num tópico

A inscrição é o ponto de entrada de cada percurso de aprendizagem (Figura 3.6). Antes de criar a inscrição, o servidor verifica três condições: o tópico deve estar activo, não expirado, e os seus pré-requisitos devem estar concluídos. A verificação de pré-requisitos consulta o conjunto de tópicos já concluídos pelo utilizador; caso existam em falta, o pedido é rejeitado com indicação precisa dos identificadores em falta.

Em caso de sucesso, é criada uma *Enrollment* e é atribuída imediatamente a primeira tarefa (índice 0), com as opções baralhadas de forma determinística usando uma semente derivada do identificador do utilizador, do template e da inscrição.




Figura 3.6: Inscrição num tópico. O servidor executa três guardas (estado, expiração, pré-requisitos) antes de criar a inscrição (passo 3) e atribuir a primeira tarefa com opções baralhadas deterministicamente (passo 4).

3.3.5 Abandono de tópico

O utilizador pode abandonar uma inscrição activa em qualquer momento (Figura 3.7). A inscrição transita para o estado `PAUSED` em vez de ser apagada: a data de pausa é registada para permitir ajustar o `enrolledAt` numa eventual reinscrição, compensando o período de inactividade no cálculo do índice diário.




Figura 3.7: Abandono de tópico. A inscrição transita para `PAUSED` com registo de data (passo 3). Numa eventual reinscrição, o servidor calcula os dias de pausa e ajusta o `enrolledAt` para que o índice de dias não salte abruptamente.

3.3.6 Resposta correcta a um desafio

Quando o utilizador responde correctamente (Figura 3.8), o servidor executa em sequência: validação da propriedade da atribuição; mapeamento da opção seleccionada pelo índice de exibição para o índice original (invertendo o baralhar); comparação com a resposta canónica; cálculo de pontos com penalização temporal; actualização do streak; e verificação da condição de conclusão do tópico.

A penalização temporal aplica-se quando a resposta é submetida após o prazo, de acordo com a equação:

$$P = \begin{cases} P_{\max} & \text{se } \Delta t \leq 0 \text{ (dentro do prazo)} \\ 0.75 \cdot P_{\max} & \text{se } 0 < \Delta t \leq 24\text{h} \\ 0.50 \cdot P_{\max} & \text{se } 24\text{h} < \Delta t \leq 72\text{h} \\ 0.25 \cdot P_{\max} & \text{se } \Delta t > 72\text{h} \end{cases} \quad (3.1)$$

onde $\Delta t = t_{\text{submissão}} - t_{\text{prazo}}$ e $P_{\max}$ é o valor máximo de pontos definido no template da tarefa.




Figura 3.8: Submissão correcta. A opção seleccionada é mapeada para o índice original invertendo o baralhar (passo 2). Os pontos são calculados com penalização temporal (Equação 3.1). O streak é incrementado, a conclusão do tópico é verificada (passo 6) e o dist intivo é emitido de forma idempotente se os critérios forem cumpridos (passo 5).

3.3.7 Resposta errada e activação do percurso adaptativo

Uma resposta errada desencadeia a geração assíncrona de um percurso adaptativo (Figura 3.9). O servidor classifica imediata e deterministicamente o padrão de erro usando três regras em cascata, conforme a Tabela 3.2.

Padrão classificado	Condição de detecção (por ordem de prioridade)
TIME_PRESSURE	$t_{\text{submissão}} > t_{\text{prazo}}$ — submetido após o prazo de 24 horas.
READING_ERROR	A opção seleccionada é adjacente (± 1) à opção correcta na ordem de exibição actual (após baralhar).
WRONG_CONCEPT	Default — nenhuma das condições anteriores se verificou.

Tabela 3.2: Regras de classificação determinística de padrões de erro, aplicadas em cascata. A classificação é síncrona, local e não envolve IA.




Figura 3.9: Resposta errada. O padrão de erro é classificado síncronamente e de forma determinística (passo 1, cfr. Tabela 3.2). A sessão adaptativa é criada antes do retorno HTTP (passo 2); a geração das subtarefas pelo LLM decorre assincronamente (passos 4–6). O cliente recebe imediatamente o resultado com `struggleTriggered:true`.

3.3.8 Percurso de consolidação

O percurso de consolidação é constituído por três subtarefas adaptativas geradas pelo LLM especificamente para o padrão de erro detectado (Figura 3.10). Se o utilizador completar todas com sucesso, a sessão transita para `RESOLVED` e a tarefa original é reposta em estado `PENDING` para uma nova tentativa autónoma. Se falhar em pelo menos uma subtarefa e a profundidade máxima ainda não tiver sido atingida, um novo ramo adaptativo é gerado com os ramos já vistos excluídos (evitando repetição). Se a profundidade máxima (`MAX_STRUGGLE_DEPTH = 1`) for atingida, o sistema escala para o modo de explicação.

A Figura 3.11 apresenta a máquina de estados completa deste percurso.




Figura 3.10: Percurso de consolidação. O fluxo diverge em três desfechos: (a) todas correctas → sessão resolvida e tarefa original reposta; (b) alguma errada e profundidade não atingida → novo ramo excluindo ramos já vistos; (c) profundidade máxima atingida → escala para sessão de explicação.




Figura 3.11: Máquina de estados completa do percurso adaptativo: uma resposta errada desencadeia a geração de subtarefas; se o utilizador voltar a falhar e atingir a profundidade máxima ($\text{MAX_STRUGGLE_DEPTH} = 1$), o sistema escala para uma sessão de explicação e diálogo com o LLM.

3.3.9 Modo de explicação por IA

Quando o utilizador esgota a profundidade máxima adaptativa, o sistema escala para o modo de explicação holística (Figura 3.12). A criação da `ExplanationSession` é síncrona: o servidor persiste o registo com estado `GENERATING` e devolve imediatamente o identificador ao cliente (passo 2), que navega para o ecrã de explicação sem esperar pelo LLM. Se a geração falhar, um mecanismo de *fallback* automático repõe a atribuição original em `PENDING`, garantindo que o utilizador nunca fica bloqueado. Uma vez no estado `ACTIVE`, o utilizador pode iniciar N rondas de diálogo antes de encerrar a sessão.




Figura 3.12: Modo de explicação holística. A criação da sessão é síncrona (passo 2); a geração do texto é assíncrona (passos 3–6) com fallback automático em caso de falha. Após transição para ACTIVE, N rondas de diálogo com o LLM são possíveis (passo 8); a resolução (passo 9) repõe a tarefa em PENDING.

3.4 O motor de inteligência artificial

O agente de IA é a componente mais complexa do sistema. Esta secção descreve em detalhe como cada operação de geração funciona: a construção dos prompts, o processamento da resposta, a deduplicação vectorial e o tratamento de falhas.

3.4.1 Geração de tarefas do percurso fixo

O prompt é composto por dois componentes: um system prompt que estabelece o perfil do modelo e as regras invariantes de formato, e um user prompt que fornece o contexto específico do tópico.

O system prompt (Listagem 3.1) impõe três restrições fundamentais: o idioma (obrigatório em toda a resposta), o formato de saída (JSON array apenas, sem texto adicional), e a posição da resposta correcta (sempre no índice 0 do array de opções — o sistema baralha antes de enviar ao utilizador).

```

1 You are an expert educational content designer specialising in
2 gamified learning experiences. You create engaging daily
3 multiple-choice tasks that teach real skills through practice,
4 not memorisation.
5
6 LANGUAGE: You MUST generate ALL text content in {language}.
7 Do not mix languages.
8
9 RULES:
10 - Each task completable in 5-15 minutes
11 - Practical and actionable, not theoretical
12 - Difficulty must match audience level exactly
13 - Hints must guide without giving away the answer
  
```

```

14 - Always generate exactly 4 options per task
15 - Correct answer always at index 0 (system shuffles before display)
16 - Wrong options must be plausible
17
18 OUTPUT FORMAT: Valid JSON array only. No preamble.
19 [{
20   "title": "string (max 60 chars)",
21   "description": "string (max 300 chars)",
22   "hint": "string (max 150 chars)",
23   "pointsReward": number (10-100),
24   "options": ["correct", "wrong1", "wrong2", "wrong3"],
25   "correctAnswerIndex": 0
26 }]

```

Listagem 3.1: System prompt para geração de tarefas do percurso fixo (fonte: TaskGenerationPrompt.kt). As regras do formato JSON são explícitas para minimizar falhas de esquema.

O user prompt (Listagem 3.2) injeta o contexto específico do tópico, incluindo o texto extraído (até 50.000 caracteres), o objectivo do módulo, o nível de audiência e o idioma. A instrução de progressão lógica das tarefas reflecte o princípio do scaffolding cognitivo: tarefas mais cedo constroem fundamentos, tarefas mais tarde aplicam conceitos em cenários mais complexos.

```

1 Generate {taskCount} multiple-choice learning tasks for:
2
3 Subject Domain: {subjectDomain} [max 50 000 chars]
4 Module Objective: {moduleObjective} [max 2 000 chars]
5 Audience Level: {audienceLevel}
6 Language: {language}
7
8 Tasks must progress logically -- earlier tasks build foundations,
9 later tasks apply concepts in more complex scenarios.
10
11 Remember: correct answer at index 0.
12 Generate the JSON array now:

```

Listagem 3.2: User prompt para geração de tarefas (fonte: TaskGenerationPrompt.kt).

O nível de audiência é traduzido para linguagem natural conforme a Tabela 3.3.

Nível	Descrição injectada no prompt
BEGINNER	Beginner — assumes no prior knowledge, uses simple language, concrete examples
INTERMEDIATE	Intermediate — assumes basic familiarity, introduces complexity, some abstraction
ADVANCED	Advanced — assumes solid foundation, focuses on nuance, edge cases, and depth

Tabela 3.3: Tradução do nível de audiência para descrição em linguagem natural incluída no prompt. A granularidade semântica afecta directamente a dificuldade e o vocabulário das tarefas geradas.

Validação e retenção automática. Após receber a resposta do LLM, o agente valida o JSON produzido. Se o número de tarefas com esquema válido for inferior ao solicitado, o agente executa automaticamente uma segunda invocação com um schema reminder adicional. Se a segunda tentativa também falhar, a geração é reportada como falhada e o tópico transita para `FAILED`.

Deduplicação vectorial. Cada tarefa gerada com sucesso é vectorizada (embedding de 1024 dimensões) e comparada por similaridade cosseno com os embeddings das tarefas já existentes no módulo. Se a distância cosseno exceder o limiar de duplicação, a tarefa é marcada como `DUPLICATE` e descartada, evitando que regenerações produzam questões semanticamente redundantes.

3.4.2 Geração adaptativa: ramos de consolidação

A geração de um ramo adaptativo inclui um mecanismo de reutilização baseado em similaridade que evita chamar o LLM quando já existe conteúdo equivalente. O processo começa por calcular um embedding do contexto de dificuldade e procura na base de dados vectorial um ramo similar previamente gerado, excluindo os ramos que o utilizador já viu para esta atribuição.

O resultado determina a estratégia de reutilização conforme a Tabela 3.4.

Estratégia	Limiar	Comportamento
<code>FULL_REUSE</code>	$\cos \geq 0.90$	Reutiliza integralmente o ramo existente; sem chamada ao LLM.
<code>PARTIAL_REUSE</code>	$0.65 \leq \cos < 0.90$	Reutiliza parte das subtarefas proporcionalmente à similaridade; gera as restantes com o LLM.
<code>FRESH_GENERATION</code>	$\cos < 0.65$	Gera todas as subtarefas de raiz.

Tabela 3.4: Estratégias de reutilização de ramos adaptativos em função da similaridade cosseno. A reutilização total ou parcial reduz a latência e o custo de chamadas ao LLM.

A proporção de subtarefas reutilizadas na estratégia `PARTIAL_REUSE` é calculada por interpolação linear:

$$n_{\text{reutilizadas}} = \left\lceil N \cdot \frac{\cos \theta - \theta_{\text{partial}}}{\theta_{\text{full}} - \theta_{\text{partial}}} \right\rceil, \quad N = 3, \quad \theta_{\text{partial}} = 0.65, \quad \theta_{\text{full}} = 0.90 \quad (3.2)$$

O resultado é restringido ao intervalo $[1, N]$ para garantir que pelo menos uma subtarefa é sempre reutilizada no modo parcial.

O system prompt adaptativo (Listagem 3.3) distingue-se do prompt de percurso fixo por focar a scaffolding remediativa: o modelo é instruído a começar pelo conceito mais simples possível e a reencadrar a dificuldade como uma oportunidade.

```

1 You are an expert adaptive learning coach. A student is struggling
2 with a specific task. Your job is to create a short sequence of
3 simpler subtasks that scaffold the student back to success.
4
5 PRINCIPLES:
6 - Diagnose the root cause from the error pattern
7 - Start with the simplest possible related concept

```

```

8 - Each subtask builds on the previous one
9 - Final subtask brings student back to original task level
10 - Be encouraging -- frame as achievable steps, not remediation
11 - Each subtask completable in 3-10 minutes

```

Listagem 3.3: System prompt para geração de ramos adaptativos de consolidação (fonte: `StruggleAnalysisPrompt.kt`).

O user prompt injeta o padrão de erro com a sua tradução pedagógica (Tabela 3.5), permitindo ao LLM gerar subtarefas especificamente adaptadas ao tipo de dificuldade detectada.

Padrão de erro	Instrução pedagógica no prompt
WRONG_CONCEPT	The student misunderstands the core concept. Start by re-explaining it differently.
PARTIAL_UNDERSTANDING	The student understands the concept but applies the wrong steps. Focus on procedure.
READING_ERROR	The task instructions were unclear. Provide clearer, more explicit guidance.
TIME_PRESSURE	The student rushed under time pressure. Use paced, step-by-step practice tasks.

Tabela 3.5: Tradução dos padrões de erro para instruções pedagógicas específicas incluídas no prompt adaptativo. A especificidade da instrução é o principal factor de qualidade das subtarefas geradas.

3.4.3 Geração da explicação holística

O modo de explicação é activado quando o utilizador esgota o percurso adaptativo. O sistema dispõe nesse ponto de informação rica sobre o histórico de dificuldades, compilada num contexto de explicação que inclui: a descrição da tarefa original e o objectivo do módulo; o histórico completo das sessões adaptativas (padrão de erro, títulos das subtarefas tentadas); o nível de audiência; e a língua do utilizador.

O system prompt de explicação (Listagem 3.4) especifica explicitamente o formato de saída como prosa corrida (sem JSON, sem listas, sem cabeçalhos), com 3 a 5 parágrafos. Esta restrição é intencional: o utilizador que chegou a este ponto já viu estrutura suficiente de múltipla escolha; o que precisa é de uma explicação natural, empática e fluída.

```

1 You are a patient and empathetic learning coach helping a student
2 who has struggled repeatedly with the same concept.
3
4 YOUR GOAL:
5 - Synthesise what went wrong across all their attempts
6 - Explain the underlying concept clearly and simply
7 - Use concrete examples relevant to the subject domain
8 - Be encouraging -- frame struggles as a normal part of learning
9 - Keep the explanation concise: 3-5 paragraphs maximum
10 - Write in plain prose -- no JSON, no bullet lists, no headers
11 - Match the learner's language exactly

```

Listagem 3.4: System prompt para geração da explicação holística (fonte: `ExplanationPrompt.kt`).

Para o diálogo subsequente, o system prompt de resposta (Listagem 3.5) instrui o modelo a agir como coach conversacional focado, com respostas de 2 a 4 frases. Cada mensagem é enviada ao modelo

juntamente com o histórico completo da conversa, construído dinamicamente como texto simples com prefixos de papel (Coach: / Student:).

```

1 You are a patient learning coach in an ongoing conversation
2 with a confused student who already received an initial explanation.
3
4 PRINCIPLES:
5 - Address their exact question directly
6 - Use simple language and concrete examples
7 - Keep replies focused: 2-4 sentences
8 - Be warm and encouraging
9 - Write in the same language as the student
10 - Plain prose only

```

Listagem 3.5: System prompt para as rondas de diálogo após a explicação holística (fonte: ExplanationPrompt.kt).

A Figura 3.13 sintetiza a escada progressiva do modo de IA desde a geração de tarefas adaptativas até ao diálogo livre.




Figura 3.13: Escada do percurso adaptativo para o modo de explicação. Com `MAX_STRUGGLE_DEPTH = 1`, após uma única falha no percurso adaptativo, o sistema escala directamente para a sessão de explicação holística e o diálogo com o LLM.

3.5 Reconhecimento: o sistema de dist intivos

O pilar do **reconhecimento** implementa-se através de dist intivos (*badges*) associados a microcompetências. Cada tópico tem exactamente uma microcompetência correspondente, criada durante a fase INDEXING do pipeline. A emissão do dist intivo é idempotente: o serviço `BadgeIssuanceService` verifica se o utilizador cumpre os critérios após cada submissão correcta, mas nunca emite o mesmo dist intivo duas vezes.

A condição de emissão é formal: sendo n o número total de tarefas do tópico, s o número de tarefas submetidas e c o número de respostas correctas, um dist intivo é emitido se e só se:

$$s \geq n \quad \text{e} \quad \frac{c}{n} \geq \alpha, \quad \text{com } \alpha = 0.60 \quad (3.3)$$

O limiar $\alpha = 0.60$ foi calibrado para ser exigente o suficiente para conferir significado ao dist intivo, mas permissivo o suficiente para não frustrar utilizadores que fizeram a maior parte do percurso correctamente, aproximando-se da lógica de mastery learning [1], em que a progressão exige domínio comprovado mas não perfeição absoluta. A literatura sobre gamificação em educação sugere que os dist intivos têm maior impacto motivacional quando assinalam competências genuínas e reconhecíveis [9].

3.6 Envolvimento: mecanismos de retenção

O terceiro pilar — o **envolvimento** — é sustentado por três mecanismos complementares.

O primeiro é o streak: um contador de dias consecutivos de actividade incrementado a cada resposta correcta ou percurso adaptativo resolvido. Não é penalizado por uma resposta errada, apenas pelo abandono total num dia, incentivando a tentativa mesmo sem certeza. Actua como commitment device: ao tornar o histórico de actividade algo que o utilizador não quer interromper, cria uma pressão positiva ao regresso diário [9].

O segundo é a **progressão por pré-requisitos**: os tópicos podem ser organizados num grafo dirigido acíclico (DAG), em que um tópico só fica desbloqueado depois de o utilizador concluir as suas dependências. A detecção de ciclos usa pesquisa em largura (BFS) na camada de serviço, garantindo que o administrador não pode criar dependências circulares inadvertidamente. Para o utilizador, o grafo completo é visível no `endpoint /enrollments/{id}/roadmap`, servindo simultaneamente como motivação (progress visibility) e orientação (next step clarity).

O terceiro é o **desbloqueio diário por índice**: as tarefas são atribuídas uma por dia, com desbloqueio à meia-noite no fuso horário do utilizador. Este ritmo cadenciado reduz a sobrecarga cognitiva e cria uma razão concreta para voltar todos os dias, mantendo o hábito fácil de iniciar e manter.

3.7 Interface de programação

A Tabela 3.6 sintetiza os principais endpoints REST que expõem as funcionalidades descritas neste capítulo.

3.8 Síntese do desenvolvimento

O desenvolvimento do Play4Change produziu um protótipo funcional com três camadas bem definidas — servidor, cliente multiplataforma e painel de administração — articuladas por uma API REST segundo os princípios da arquitectura hexagonal [4]. A separação entre o contrato de porta (`TaskGenerationPort`) e a sua implementação (`LangChain4jTaskGenerationAdapter`) garante que o fornecedor de LLM pode ser substituído sem alterações no servidor de aplicação.

Método	Caminho	Auth	Responsabilidade
POST	/auth/magic-link	—	Solicitar magic link
GET	/auth/verify?token={t}	—	Verificar token e emitir sessão
POST	/enrollments	USER	Inscrever utilizador num tópico
DELETE	/enrollments/{topicId}	USER	Abandonar inscrição
GET	/topics/{id}/task	USER	Obter tarefa do dia
POST	/assignments/{id}/submit	USER	Submeter resposta
GET	/enrollments/{id}/roadmap	USER	Obter mapa visual do percurso
GET	/struggle/{enrollmentId}	USER	Obter sessão adaptativa activa
POST	/struggle/{sId}/tasks/{tId}/submit	USER	Submeter subtarefa adaptativa
GET	/explanations/{sessionId}	USER	Obter sessão de explicação
POST	/explanations/{sId}/messages	USER	Enviar mensagem ao LLM
POST	/explanations/{sId}/resolve	USER	Encerrar sessão de explicação
GET	/badges	USER	Listar dist intivos conquistados
POST	/admin/topics	ADMIN	Criar tópico (URL ou PDF)
PATCH	/admin/tasks/{taskId}	ADMIN	Editar questão (versionamento)
POST	/admin/topics/{id}/prerequisites	ADMIN	Definir pré-requisitos
GET	/admin/learning-graph	ADMIN	Obter DAG completo de tópicos

Tabela 3.6: Principais endpoints REST do Play4Change. Os endpoints sem autenticação são públicos; USER requer token de acesso válido; ADMIN requer adicionalmente o papel de administrador.

O mecanismo mais complexo e distintivo é o percurso adaptativo: a combinação de classificação determinística de erros (§3.3.7), geração assíncrona com deduplicação vectorial por similaridade cosseno (§3.4.2), e escala para explicação em prosa com diálogo livre (§3.3.9) representa a contribuição mais original deste protótipo relativamente às plataformas existentes.

Importa delimitar com clareza o que este protótipo é e o que não é. O fluxo completo — criação de tópico, geração de conteúdo, percurso adaptativo, emissão de dist intivo — está implementado e testado de ponta a ponta. No entanto, uma versão de produção exigiria: a calibração fina dos limiares de deduplicação e de profundidade adaptativa com dados reais; cobertura de testes de integração e de carga; e, sobretudo, validação pedagógica do conteúdo gerado pelo LLM por especialistas em educação. Estes aspectos são discutidos nas limitações do Capítulo 6.

Capítulo 4

Ferramentas, Tecnologias e Metodologia

Este capítulo descreve o conjunto de tecnologias que constituem o ecossistema técnico do Play4Change, a pipeline de integração e entrega contínua que garante a qualidade do código em cada alteração, e a forma como a inteligência artificial foi utilizada ao longo do próprio processo de desenvolvimento — não apenas como funcionalidade da plataforma, mas como ferramenta de trabalho.

4.1 Arquitectura tecnológica

O Play4Change é composto por quatro camadas tecnológicas distintas: o servidor de aplicação, a aplicação móvel, o painel de administração web e a infraestrutura de suporte. A Tabela 4.1 resume as tecnologias principais em cada camada.

Servidor

O servidor foi implementado em **Kotlin** com o framework **Spring Boot 3.2**, seguindo uma arquitectura hexagonal (Ports & Adapters) [4] que separa a lógica de negócio das suas dependências externas. A escolha do Kotlin em vez do Java tradicional permitiu aproveitar a expressividade da linguagem — em particular as coroutines para operações assíncronas, os tipos não-anuláveis para redução de erros de null pointer, e o estilo funcional para as transformações de dados. O Spring Boot forneceu a base REST, a gestão de transações e o suporte à autenticação com JWT [10].

A base de dados **PostgreSQL 16** foi estendida com a extensão **pgvector**, que adiciona suporte a vectores de embeddings directamente no mesmo motor relacional. Esta co-localização elimina a necessidade de um sistema vectorial separado e mantém todas as garantias ACID para a camada de personalização. O **Redis** é utilizado para a cache de resultados de consultas frequentes e para controlo de ritmo das chamadas à API de IA. A integração com o modelo de linguagem **Mistral 7B** é feita através do **LangChain4j 0.36.2** [7], implementando o padrão RAG [8] descrito no Capítulo 2.

Camada	Tecnologia	Papel
Servidor	Spring Boot 3.2 (Kotlin)	API REST, lógica de negócio, orquestração de IA
	PostgreSQL 16 + pgvector	Base de dados relacional e vectorial
	Redis 7	Cache de sessões e controlo de ritmo (<u>rate limiting</u>)
	MinIO	Armazenamento de objectos (imagens, assets)
	Mistral 7B / LangChain4j	Geração de conteúdo adaptativo e explicações
Móvel	Resend	Envio transaccional de correio electrónico
	Kotlin Multiplatform 2.3	Base de código partilhada Android/iOS
	Compose Multiplatform 1.10	Interface declarativa nativa
	Decompose 3.3	Navegação e gestão de estado
Web (admin)	Koin	Injecção de dependências
	React 18 + TypeScript	Painel de administração de conteúdos
	Vite + Tailwind CSS	<u>Bundler</u> e design system utilitário
Infraestrutura	TanStack Query	Gestão de estado remoto e cache HTTP
	Docker + Docker Compose	Orquestração local e de produção
	nginx 1.27	<u>Reverse proxy</u> e servidor do cliente estático
	Prometheus + Grafana	Observabilidade, métricas e alertas

Tabela 4.1: Tecnologias principais do Play4Change, organizadas por camada funcional.

Aplicação móvel

A aplicação móvel foi desenvolvida com **Kotlin Multiplatform (KMP) 2.3** e **Compose Multiplatform 1.10**, o que permite partilhar a maior parte da lógica de negócio e da interface entre Android e iOS a partir de um único código-base. A navegação e a gestão de estado são tratadas pelo **Decompose 3.3**, que oferece uma abstracção de stack de componentes compatível com ambas as plataformas e com testes unitários.

Painel de administração

O painel web de administração é uma aplicação **React 18** em **TypeScript**, construída com **Vite** e **Tailwind CSS**. Permite criar e gerir tópicos, tarefas e conteúdos, monitorizar inscrições e visualizar dados de utilização. O **TanStack Query** é utilizado para a gestão de estado remoto, garantindo cache automática, revalidação e tratamento consistente de estados de carregamento e erro.

Infraestrutura de produção

Todo o ambiente de produção é definido num único ficheiro `docker-compose.yml` com sete serviços: servidor Spring Boot, PostgreSQL, Redis, MinIO, nginx, Prometheus e Grafana. O **nginx** actua como reverse proxy — recebe os pedidos externos na porta 80, encaminha as chamadas à API (prefixadas em `/play4change-server/`) para o servidor na porta 8080, e serve o cliente React como conteúdo estático. O **Prometheus** recolhe métricas expostas pelo actuador Spring Boot a cada 15 segundos e o **Grafana** apresenta-as em três dashboards pré-configurados: um dashboard geral, um centrado na

latência da IA e um que mostra o fluxo do aprendente em tempo real. A Figura 4.1 ilustra a topologia de produção.




Figura 4.1: Topologia de infraestrutura de produção: o nginx recebe todo o tráfego externo e distribui-o; o servidor Spring Boot comunica com as quatro dependências de dados e com a API de IA; o Prometheus recolhe métricas do servidor e o Grafana apresenta-as em dashboards.

4.2 Pipeline de integração e entrega contínua

O Play4Change adota uma pipeline de Continuous Integration / Continuous Delivery (CI/CD) implementada em GitHub Actions, composta por três workflows distintos com responsabilidades bem delimitadas. A Figura 4.2 ilustra como os três workflows se articulam com os eventos do repositório.




Figura 4.2: Os três workflows da pipeline CI/CD do Play4Change: o primeiro corre em cada commit ou pull request; o segundo é desencadeado por uma tag semântica e produz o APK assinado; o terceiro corre semanalmente e verifica vulnerabilidades CVE nas dependências.

Workflow 1 — Integração Contínua

O workflow de CI é desencadeado em todos os commits para a branch `main` e em todos os pull requests que a ela se destinam. Corre num agente macOS (exigência do toolchain Android) e executa quatro passos em sequência:

1. **Gitleaks** — varredura de segredos no histórico completo do repositório (`fetch-depth: 0`). Se forem detectadas credenciais, chaves de API ou outros segredos comprometidos no código, o workflow falha imediatamente antes de qualquer compilação.
2. **JDK 21 (Eclipse Temurin)** — configuração do ambiente Java com cache automática das dependências Gradle entre execuções, reduzindo o tempo de compilação em execuções subsequentes.
3. **Gradle build + testes** — compila todos os módulos (servidor, móvel, common) e executa os testes unitários e de integração com JUnit 5, MockK e SpringMockK. O passo exclui explicitamente o packaging de release para reduzir o tempo de execução em CI.
4. **Detekt** — análise estática do código Kotlin do servidor, verificando aderência às regras definidas em `detekt.yml`: complexidade ciclomática, tamanho de funções, dependências em concretos em vez de interfaces, e estilo de código.

Apenas se todos os passos passarem é que um pull request pode ser integrado na branch principal. A Tabela 4.2 resume os critérios de qualidade verificados em cada passo.

Ferramenta	O que verifica	Critério de falha
Gitleaks	Segredos no histórico git	Qualquer correspondência com os detectores predefinidos
JUnit 5 + MockK	Testes unitários e de integração	Qualquer teste falhado
Detekt	Qualidade e estilo do código Kotlin	Violações acima do limiar configurado

Tabela 4.2: Ferramentas e critérios de qualidade verificados em cada execução da pipeline de integração contínua.

Workflow 2 — Release do APK Android

O workflow de release é desencadeado exclusivamente por tags com prefixo `v` (por exemplo, `v1.2.3`). Este mecanismo garante que os binários de produção são sempre rastreáveis a uma versão explícita. O workflow: restaura os ficheiros sensíveis (keystore e `google-services.json`) a partir de segredos encriptados do repositório, nunca armazenados em texto simples; calcula automaticamente o `versionCode` Android a partir da tag semântica, segundo a fórmula $\text{MAJOR} \times 10000 + \text{MINOR} \times 100 + \text{PATCH}$; compila e assina o APK de release com a keystore de produção; e cria automaticamente uma GitHub Release com o `play4change.apk` anexado, tornando-o imediatamente disponível para distribuição sem qualquer passo manual.

Workflow 3 — Verificação semanal de dependências (OWASP)

O terceiro workflow corre automaticamente todas as segundas-feiras às 06:00 UTC. Utiliza a ferramenta **OWASP Dependency Check** para analisar todos os JARs do servidor e dos módulos móveis em busca de vulnerabilidades conhecidas registadas na base de dados CVE (Common Vulnerabilities and Exposures). O workflow falha se forem encontradas vulnerabilidades com score CVSS igual ou superior a 7 (“High” ou “Critical”), forçando uma resposta atempada. Os relatórios HTML gerados ficam disponíveis como artefactos no GitHub durante 30 dias. Esta verificação periódica é particularmente relevante para uma plataforma que usa um LLM externo e que processa dados de utilizadores

— onde uma dependência comprometida poderia ter impacto directo na privacidade dos dados ou na integridade dos conteúdos gerados.

4.3 Metodologia de desenvolvimento

O desenvolvimento do Play4Change seguiu um processo iterativo e incremental, próximo de uma metodologia ágil informal adequada a uma equipa de dimensão reduzida. O controlo de versões foi feito com **Git** e o repositório alojado no **GitHub**, com uma estratégia de feature branches: cada nova funcionalidade ou correcção é desenvolvida numa branch dedicada (por exemplo, `feature/jwt-auth` ou `bugfix/daily-reminders`), submetida como pull request e sujeita a revisão de código antes de ser integrada na branch `main`. Toda a integração é protegida pela pipeline de CI descrita na secção anterior.

A gestão de dependências é centralizada no ficheiro `gradle/libs.versions.toml`, o que garante consistência entre todos os módulos do projecto e facilita actualizações coordenadas. O **Flyway** é utilizado para a gestão de migrações da base de dados: cada alteração ao esquema SQL é registada como um ficheiro de migração versionado, aplicado de forma automática e ordenada aquando do arranque do servidor, garantindo que o estado da base de dados é sempre rastreável e reproduzível em qualquer ambiente.

Capítulo 5

Avaliação e Resultados

Este capítulo apresenta os resultados de uma avaliação preliminar do protótipo Play4Change. A avaliação combina duas fontes de dados complementares: um **questionário estruturado pós-utilização** com 12 participantes, que fornece dados subjectivos sobre usabilidade e envolvimento percebidos, e os **dados comportamentais registados na base de dados** do protótipo durante o período de testes, que fornecem evidência objectiva da utilização real — inscrições, percursos concluídos, padrões de erro, sessões adaptativas e distintivos emitidos. A triangulação destas duas fontes permite uma leitura mais completa do que qualquer uma delas isolada conseguiria.

5.1 Metodologia de avaliação

O questionário foi administrado de forma remota através de um formulário online, após os participantes terem explorado livremente o protótipo. Estava organizado em quatro secções: perfil do respondente; usabilidade e envolvimento em escala de Likert de 1 a 5; os dez itens da System Usability Scale (SUS) [3]; e questões abertas sobre pontos fortes e áreas de melhoria. A SUS foi seleccionada pela sua brevidade e pela existência de uma escala interpretativa estabelecida — pontuações acima de 68 consideram-se acima da média, acima de 80,3 “excelentes” [3].

Os dados comportamentais foram extraídos diretamente da base de dados PostgreSQL do protótipo em produção, cobrindo o período completo de utilização desde o arranque até à data de avaliação. Incluem registos de inscrições, submissões de tarefas, sessões adaptativas (struggle) e sessões de explicação por IA.

5.2 Dados comportamentais: a utilização real

Visão geral agregada

A Tabela 5.1 apresenta os indicadores globais extraídos da base de dados no final do período de avaliação.

Estes números contrariaram uma afirmação que seria prematura — a de que nenhum utilizador concluiu um percurso completo durante os testes. Os dados mostram o oposto: **16 inscrições foram concluídas**

Indicador	Valor
Utilizadores registados	15
Utilizadores com pelo menos uma inscrição	14
Inscrições em tópicos (total)	27
Inscrições concluídas	16 (59%)
Distintivos emitidos	16
Utilizadores com pelo menos um distintivo	9 (60%)
Tarefas submetidas	105
Acerto final nas tarefas	104/105 (99%)
Sessões adaptativas (<i>struggle</i>) geradas	55
Sessões adaptativas resolvidas	54 (98%)
Sessões de explicação por IA	39
Sequência (<i>streak</i>) máxima registada	13 dias

Tabela 5.1: Indicadores globais de utilização do protótipo Play4Change extraídos da base de dados no final do período de avaliação.

por 9 utilizadores distintos, com 100% das conclusões a resultar na emissão de um distintivo, o que indica que o limiar de mestria $\alpha = 0.60$ foi atingido em todos os casos.

Taxas de conclusão por tópico

A Figura 5.1 compara, para cada tópico disponível, o número de inscrições e o número de conclusões. Os três tópicos com utilizadores activos registam taxas de conclusão entre 50% e 67%, o que é notavelmente positivo para um protótipo com utilizadores sem qualquer incentivo externo obrigatório.




Figura 5.1: Número de inscrições e conclusões por tópico durante o período de avaliação. A percentagem indica a taxa de conclusão. O tópico “Capstone” pressupõe a conclusão dos anteriores, sendo esperada uma taxa menor nesta fase.

Percurso por utilizador

A Tabela 5.2 apresenta os dados de utilização por participante (emails anonimizados), ordenados por número de tópicos concluídos. O perfil dos utilizadores mais activos é revelador: os dois com mais inscrições concluídas (P1 e P2) apresentam streaks de 13 e 9 dias, respectivamente, e percorreram cada um 11 a 12 sessões adaptativas, sugerindo um envolvimento genuíno e sustentado com a plataforma.

P	Ins.	Conc.	Streak	Pts	Bad.	Luta	Expl.
P1	3	3	13	442 800	3	11	6
P2	3	3	9	749 520	3	12	11
P3	3	2	6	15 400	2	4	3
P4	2	2	5	4 000	2	2	2
P5	4	2	10	80 940	2	8	2
P6	2	1	5	7 400	1	3	3
P7	1	1	5	500	1	1	1
P8	1	1	5	700	1	2	1
P9	1	1	5	500	1	1	1
P10	2	0	1	400	0	3	3
P11	1	0	2	75	0	1	0
P12	1	0	3	180	0	1	1
P13	1	0	1	180	0	3	3
P14	2	0	1	0	0	3	2
P15	0	–	–	–	0	0	0

Tabela 5.2: Dados comportamentais por utilizador. Ins.=inscrições; Conc.=concluídas; Streak=dias consecutivos máximos; Pts=pontos totais acumulados; Bad.=distintivos; Luta=sessões adaptativas; Expl.=sessões de explicação. Linha de separação distingue utilizadores com conclusões dos sem conclusões.

Acerto nas tarefas e o papel do ciclo adaptativo

Das 105 tarefas submetidas, **104 obtiveram a resposta correta como submissão final (99%)**. Este número não deve ser lido como indicador de facilidade excessiva; deve ser lido como indicador da eficácia do ciclo adaptativo. Os dados mostram que foram geradas 55 sessões de percurso adaptativo durante o mesmo período, o que implica que uma proporção significativa de tarefas envolveu pelo menos uma resposta errada inicial, seguida de um percurso de reforço que culminou na resposta correta. **54 das 55 sessões adaptativas foram resolvidas (98,2%)** e nenhuma foi abandonada — o utilizador trabalhou sempre até ao final do percurso.

Padrões de erro e tempo de resolução

A Figura 5.2 ilustra a distribuição das sessões adaptativas pelos dois padrões de erro detetados pelo classificador.




Figura 5.2: Distribuição das 55 sessões adaptativas pelos dois padrões de erro identificados pelo ErrorPatternClassifier. O READING_ERROR indica que o utilizador respondeu sem ler o enunciado com atenção; o WRONG_CONCEPT indica uma lacuna conceptual genuína. Os tempos médios de resolução foram calculados entre detected_at e resolved_at.

A predominância de READING_ERROR (56%) é pedagogicamente informativa: mais de metade dos erros resultaram não de lacunas conceptuais, mas de leituras apressadas do enunciado — um comportamento

típico em formatos de quiz rápido [13], e que o percurso adaptativo conseguiu endereçar com sucesso em média em apenas 3 minutos. Os erros de `WRONG_CONCEPT` demoram ligeiramente menos a resolver (2 minutos), possivelmente porque são mais diretamente endereçáveis com uma explicação conceptual focada.

5.3 Resultados do questionário

Usabilidade geral e pontuação SUS

Os 12 participantes do questionário atribuíram à usabilidade geral e navegação uma pontuação média de **4,17 em 5** ($\sigma = 1,19$). A pontuação SUS calculada segundo o método de Brooke [3] foi de **76,0/100**, acima da média histórica de 68. Importa, contudo, sublinhar que a dimensão da amostra ($n = 12$) não permite qualquer extrapolação estatística: a pontuação deve ser lida como um indicador inicial positivo, mas estatisticamente irrelevante dada a dimensão da amostra, e não como uma validação conclusiva da usabilidade da plataforma. A Figura 5.3 representa as pontuações individuais ordenadas de forma crescente e revela uma distribuição bimodal que é analisada na Secção 5.5.




Figura 5.3: Pontuações SUS individuais dos 12 participantes do questionário, ordenadas de forma crescente. A linha a tracejado assinala o limiar histórico de 68 pontos.

Envolvimento e relevância percebida

A Tabela 5.3 resume as quatro dimensões de envolvimento avaliadas. O apelo visual destacou-se com a pontuação mais elevada (4,33/5), seguido da relevância percebida dos conteúdos para situações reais (4,00/5) — um resultado alinhado com o objetivo de situar as perguntas em contextos cívicos do dia a dia.

A percepção da adaptatividade da IA (4,08/5) é, neste contexto, um dado qualitativo digno de nota: nenhum dos 12 participantes discordou da afirmação de que os percursos de aprendizagem se adaptaram eficazmente ao seu desempenho. Ainda que a dimensão da amostra ($n = 12$) impeça qualquer

Dimensão	Média	Distribuição
Motivação para aprender sobre educação cívica / cidades sustentáveis	3,83	1×SA, 8×A, 3×N
Relevância dos desafios para situações reais	4,00	4×SA, 5×A, 2×N, 1×D
Apelo visual e estética	4,33	6×SA, 4×A, 2×N
Encorajamento ao regresso diário	3,92	2×SA, 7×A, 3×N
Adaptatividade da IA ao desempenho e interesses	4,08	4×SA, 5×A, 3×N

Tabela 5.3: Médias e distribuições de resposta para as dimensões de envolvimento e adaptatividade percebida (SA=Concordo totalmente, A=Concordo, N=Neutro, D=Discordo). $n = 12$.

generalização estatística, este resultado é coerente com a taxa de resolução de 98% observada nos dados comportamentais e constitui uma hipótese de investigação a aprofundar em estudos futuros com amostras de maior dimensão.

5.4 O ciclo adaptativo em ação: um exemplo real

Para ilustrar concretamente como o ciclo erro → percurso adaptativo → explicação por IA funciona na prática, apresenta-se a seguir o registo completo de uma sessão de explicação extraída da base de dados. O utilizador estava a realizar o tópico Sustainable Cities & Civic Engagement e tinha cometido um `READING_ERROR` na tarefa principal. Após concluir o percurso adaptativo sem sucesso, foi aberta uma sessão de explicação por diálogo livre com a IA. A sessão ficou registada como `RESOLVED` e durou aproximadamente 3 minutos.

O excerto abaixo transcreve as oito mensagens trocadas (papel USER e papel AI), preservando o texto original em inglês conforme armazenado na base de dados:

A tarefa original:

“A digital device is a tool that uses electronic signals to process, store, or send information. Examples include phones, computers, and tablets. — Which of the following is NOT a digital device? A) A calculator that adds numbers. B) A microwave that shows time. C) A toaster that pops up bread. D) A smartphone that plays music.”

Diálogo de explicação:

USER “Why is my answer wrong?”

AI “Could you share the exact sentence or paragraph you wrote? That way I can see exactly where the misunderstanding is and help fix it.”

USER “A smartphone that plays music is a digital device”

AI “Ah, I see the confusion! A smartphone playing music is indeed a digital device, but the question is about digital public services [...]. Think of it this way: your smartphone is just the tool — digital public services are the services that run on those tools to make cities greener. Does that help clarify the difference?”

USER [partilha o enunciado completo da pergunta e a indicação de que C é a resposta correta]

AI “Ah, now I see the mix-up! The clue is in the definition: a digital device has to process, store, or send information. A toaster just heats bread — it doesn’t do any of those things, so it’s not digital. But a smartphone plays music by processing data, so it is digital. The hint was pointing at tasks like typing or playing games, which involve handling information. Does that make sense now?”

USER “Yes, then why is C right and not D?”

AI “A toaster pops up bread because a timer inside it has counted down; that timer is a tiny computer storing and counting ‘ticks,’ so it does process and store information. A smartphone playing music is also digital, but the question lets only one answer be chosen, and the hint wants the simplest device that still fits the definition.”

Esta sequência ilustra vários aspectos importantes do ciclo. Em primeiro lugar, a IA não deu a resposta de imediato — solicitou que o utilizador explicitasse a sua dúvida, forçando-o a articular o raciocínio (pergunta socrática). Em segundo lugar, quando o utilizador continuou sem perceber, a IA escalou a explicação para um nível de maior detalhe técnico, sem perder a acessibilidade da linguagem. Em terceiro lugar, a última troca — “Yes, then why is C right and not D?” — mostra que o utilizador chegou a um nível de compreensão suficiente para formular a dúvida correta: já não estava perdido, estava a refinar. Toda a sessão decorreu em **menos de 3 minutos**.

Este exemplo ilustra o princípio de step-level feedback que VanLehn [13] identificou como o elemento diferenciador dos sistemas de tutoria inteligente mais eficazes: não é a quantidade de informação fornecida, mas a sua adequação ao momento exato da dificuldade do aprendente.

5.5 Dois perfis de utilizador: uma descoberta central

Tanto os dados do questionário como os dados comportamentais apontam para a mesma clivagem: a amostra divide-se em dois grupos com experiências marcadamente distintas.

O **Grupo A** — oito participantes no questionário com SUS entre 75 e 98 (média ≈ 90), correspondendo na base de dados a utilizadores como P1 e P2 (3 tópicos concluídos, streaks de 9 a 13 dias, 11 a 12 sessões adaptativas resolvidas) — representa utilizadores com maturidade digital que adoptaram a plataforma de forma entusiasta. Os seus comentários descrevem-na como “intuitiva”, “fácil de entender” e “uma ideia muito bem concebida com tudo o que precisa para evoluir”. Crucialmente, estes utilizadores **não fugiram das dificuldades**: os 12 percursos adaptativos de P2 mostram que o utilizador errou com frequência, mas continuou sempre e resolveu tudo. O ciclo de erro é sentido, para este grupo, não como frustração mas como oportunidade de aprendizagem — exatamente o que o design procurava.

O **Grupo B** — quatro participantes no questionário com SUS entre 35 e 60 (média ≈ 47), correspondendo a utilizadores como P10 e P14 (0 tópicos concluídos, streak de 1 dia, 3 sessões adaptativas sem resolução) — representa utilizadores para quem a plataforma digital constitui, em si mesma, uma barreira: “Because it’s so confusing, it ends up not being so helpful, what would make people lose interest in this app and also patience”. Para este grupo, o problema não é o conteúdo — é o meio. A aprendizagem autónoma por aplicação móvel pressupõe um grau mínimo de familiaridade digital que este grupo ainda não tem, e que é precisamente o que o Play4Change procura ajudar a desenvolver.

Os dados do Grupo B demonstram uma falha crítica no desenho da experiência de utilização (UX). Ao exigir literacia digital prévia para operar uma plataforma desenhada para ensinar literacia cívica e digital, o protótipo falhou o seu público-alvo primário. Este não é um “paradoxo de acessibilidade”

inevitável das plataformas de educação digital — é uma falha de requisitos que deve ser reconhecida e corrigida. No seu estado atual, a plataforma Play4Change é viável apenas para utilizadores com o perfil do Grupo A. Iterar para o Grupo B exigiria uma reformulação profunda do processo de integração (onboarding), eventualmente com apoio presencial, e possivelmente uma interface alternativa simplificada — trabalho futuro discutido no Capítulo 6.

A Tabela 5.4 sintetiza as diferenças entre os dois grupos.

Dimensão	Grupo A (n≈8–9)	Grupo B (n≈4–6)
SUS médio	≈90 (Excelente)	≈47 (Mau)
Tópicos concluídos	1–3 por utilizador	0
Streak máx.	5–13 dias	1–3 dias
Sessões adaptativas	Numerosas, todas resolvidas	Poucas ou sem resolução
Reação ao ciclo IA	“Fascinante e útil”	Fluxo não percebido
Envolvimento real	Alto e sustentado	Abandonado cedo
Perfil presumível	Confortável com tecnologia	Pouca familiaridade digital

Tabela 5.4: Síntese dos dois grupos de utilizadores identificados, combinando dados do questionário e dados comportamentais da base de dados.

5.6 Feedback qualitativo e sugestões de melhoria

As respostas abertas do questionário revelaram três temas recorrentes de melhoria que merecem registo. O primeiro, referido por três participantes independentes, é a introdução de **funcionalidades sociais e comunitárias** — a possibilidade de comparar progressos com amigos, criar uma “rivalidade positiva” ou partilhar conhecimento. Este tema está diretamente alinhado com a dimensão de relação da Teoria da Autodeterminação [5] e com a investigação sobre gamificação que identifica a componente social como um dos motores de retenção mais eficazes [9]. O segundo tema foi a **consistência e qualidade da interface**, com sugestões específicas de hierarquia visual mais clara e respostas da IA mais concisas num ecrã de telemóvel. O terceiro tema, particularmente interessante, foi a sugestão de **personalização geográfica**: que a IA adaptasse as perguntas à cidade ou região onde o utilizador se encontra, usando dados públicos disponíveis para tornar os conteúdos hiper-locais. Esta ideia é conceptualmente consistente com os centros de competência da U!REKA [11] e poderá orientar uma iteração futura da plataforma.

5.7 Posicionamento face a abordagens alternativas no contexto U!REKA

O programa U!REKA proporcionou uma circunstância pouco comum em projetos académicos: a possibilidade de observar, em simultâneo, propostas de outros grupos que partiram do mesmo desafio — promover a literacia cívica e digital dos cidadãos no contexto da transição para cidades sustentáveis [11] — mas chegaram a arquiteturas de solução marcadamente distintas. Esta observação direta permite um posicionamento mais preciso do Play4Change do que o que a literatura isolada proporcionaria.

Duas linhas de abordagem alternativa foram identificadas neste contexto.

A **primeira** centra-se no envolvimento como alavanca principal, materializando-se numa aplicação **móvel nativa** com mecânicas de jogo mais imersivas: ciclos de recompensa imediata, competição em tempo

real e interfaces projetadas para maximizar o tempo de sessão. Esta abordagem alinha-se com os resultados de Toda et al. [9], que mostram que os elementos da tríade Points, Badges, Leaderboards têm impacto positivo no envolvimento e na persistência a curto prazo, e com a reconhecida eficácia do formato de jogo a baixar a barreira de entrada. O risco, identificado pelos próprios autores, é o da motivação extrínseca substituir gradualmente a motivação intrínseca [5]: o utilizador pode continuar a jogar sem que daí resulte aprendizagem estruturada. Mais concretamente, os dados do Grupo B (Secção 5.5) sugerem que, para utilizadores com menor familiaridade digital, uma interface mais rica em estímulos pode ampliar, e não atenuar, a desorientação — o paradoxo de acessibilidade agrava-se em vez de se resolver.

A **segunda** abordagem é formalmente mais próxima do Play4Change — uma **aplicação web** com conteúdos cívicos estruturados, percursos temáticos e mecanismos de reconhecimento — mas sem componente adaptativa de inteligência artificial. A acessibilidade é semelhante: qualquer browser, sem instalação, sem custo. O que não está presente é a resposta ao momento de falha: quando o utilizador erra, não existe um mecanismo que detete o padrão do erro, gere um percurso de reforço calibrado à natureza específica da dificuldade, e conduza o utilizador até à compreensão genuína. É precisamente este elemento que VanLehn [13] identifica como o diferenciador central entre os sistemas de tutoria inteligente mais eficazes e os demais: não é a quantidade de conteúdo disponível, mas o step-level feedback — a resposta adaptada ao momento exato da dificuldade de cada aprendente, e não apenas ao resultado final.

O diferencial do Play4Change não está no formato de jogo nem na acessibilidade da aplicação web. Está no que acontece depois do erro. A inteligência artificial é utilizada não para gerar conteúdo genérico à partida, mas para detetar o padrão da falha (`READING_ERROR` ou `WRONG_CONCEPT`), construir um percurso de reforço calibrado a essa dificuldade específica e, se necessário, conduzir o utilizador por um diálogo socrático até que a confusão se resolva — como documentado na sessão transcrita na Secção 5.4. Os 54 percursos adaptativos resolvidos em 55 gerados (98%) são a expressão empírica desta escolha de design. É neste sentido que o Play4Change procura aproximar-se do que Bloom designou como o problema das 2 sigma [2]: tornar escalável, a custo acessível, o benefício que a tutoria humana individualizada oferece — benefício que os Modelos de Linguagem de Grande Dimensão tornaram, pela primeira vez, concretamente viável à escala de milhares de utilizadores [6].

A questão que as três abordagens deixam em aberto é, em última análise, a mesma: como chegar ao Grupo B sem perder o Grupo A? Nem o jogo mais imersivo nem a aplicação web mais limpa resolvem integralmente o paradoxo de acessibilidade identificado na Secção 5.5. O Play4Change, com a sua aposta na personalização adaptativa, responde melhor ao perfil do Grupo A; a solução para o Grupo B exige provavelmente uma intervenção de onboarding presencial ou guiada que nenhuma das três abordagens, isolada, consegue substituir.

5.8 Discussão dos resultados

Os dados combinados permitem fazer uma leitura estruturada de cada um dos três pilares.

O pilar da **personalização** obteve os resultados mais sólidos: 99% de acerto final nas tarefas, 98% de resolução das sessões adaptativas, 4,08/5 na percepção de adaptatividade, e referências espontâneas múltiplas ao ciclo de explicação como a melhor funcionalidade. O exemplo de sessão apresentado na Secção 5.4 mostra como a IA consegue, em 3 minutos, conduzir um utilizador de uma confusão conceptual real a uma compreensão genuína — o tipo de step-level feedback que VanLehn [13] identifica como

central na eficácia dos sistemas de tutoria inteligente.

O pilar do **reconhecimento** obteve também um resultado muito concreto: 16 distintivos emitidos a 9 utilizadores, com uma taxa de aprovação de 100% nos tópicos concluídos (o limiar $\alpha = 0.60$ foi atingido por todos os que completaram). Este limiar foi **definido de forma heurística**, sem validação empírica prévia da sua adequação pedagógica; faltam testes longitudinais que permitam determinar se esta métrica tem, de facto, qualquer impacto real na retenção dos utilizadores a médio e longo prazo. Porém, os participantes sugeriram que os distintivos atuais teriam maior poder motivacional se ancorados a valor no mundo real (descontos, bilhetes para eventos, reconhecimento em plataformas externas) — uma evolução que está fora do âmbito deste protótipo mas que justificaria investigação em iterações futuras.

O pilar do **envolvimento** apresenta o quadro mais nuançado. Para o Grupo A, os mecanismos de streak e desbloqueio diário funcionaram bem: streaks de 9 a 13 dias em utilizadores que completaram múltiplos tópicos são um sinal de hábito criado. Para o Grupo B, os mesmos mecanismos não foram suficientes para criar tração. A sugestão mais recorrente — funcionalidades sociais — aponta para a dimensão que o protótipo não cobre: a comunidade.

Limitações da avaliação

Esta avaliação tem limitações que devem ser explicitamente reconhecidas. A **dimensão da amostra** do questionário ($n = 12$) é insuficiente para extrair conclusões estatisticamente robustas; os resultados devem ser entendidos como indicadores e hipóteses a testar em estudos mais alargados. A **amostragem por conveniência** pode sobre-representar utilizadores com familiaridade digital, enviesando positivamente os resultados do Grupo A. Os **dados comportamentais**, embora objetivos, cobrem um período de utilização relativamente curto e sem protocolo de tarefa estruturado — o que significa que alguns utilizadores podem ter explorado apenas partes da plataforma. Por fim, **nenhum tópico de conteúdo foi validado por especialistas em educação cívica**, o que é uma limitação importante para uma versão madura da plataforma e está discutido no Capítulo 6.

Apesar destas limitações, a triangulação entre questionário e dados comportamentais permitiu uma leitura mais completa do que qualquer uma das fontes isolada: os dados de utilização confirmaram hipóteses levantadas pelo questionário (a personalização funciona, o streak cria hábito no Grupo A) e as respostas qualitativas explicaram padrões visíveis nos dados (o abandono do Grupo B reflete-se nos streaks de 1 dia).

Capítulo 6

Conclusão

6.1 Síntese do trabalho realizado

Este trabalho partiu de uma questão simples mas exigente: como pode uma plataforma de educação digital, informal e gamificada, apoiada por inteligência artificial, ajudar os cidadãos a desenvolver as competências de que precisam para participar na transição para cidades sustentáveis — e, ao mesmo tempo, conseguir que continuem a usá-la ao longo do tempo? Para responder a esta questão, foi concebido e implementado o Play4Change: um protótipo funcional organizado à volta de três pilares complementares — reconhecimento, envolvimento e personalização.

Olhando para os objectivos definidos na Secção 1.3, o balanço é positivo. O **sistema de distintivos** foi implementado e validado: 16 distintivos foram emitidos a 9 utilizadores em condições reais de utilização, com 100% das conclusões de tópicos a resultar na emissão do respectivo emblema, o que confirma que o limiar de mestria $\alpha = 0.60$ funcionou como portão de qualidade efectivo. Os **mecanismos de envolvimento** foram implementados e geraram evidências de hábito real no Grupo A: sequências de até 13 dias consecutivos de utilização em utilizadores que completaram múltiplos tópicos são um resultado que nenhum incentivo externo obrigatório pode explicar. A **personalização adaptativa** foi o pilar com resultados mais consistentes: 99% de acerto final nas tarefas e 98% de resolução das sessões adaptativas demonstram que o ciclo detecção–remediação–resolução funciona eficazmente, e o exemplo de sessão apresentado no Capítulo 5 ilustra concretamente como a IA consegue conduzir um utilizador de uma confusão conceptual genuína a uma compreensão clara em menos de 3 minutos.

Do ponto de vista técnico, o protótipo representa uma proposta arquitectural coerente e funcional: um servidor em Kotlin com Spring Boot 3 e arquitectura hexagonal, uma aplicação móvel em Kotlin Multiplatform com Compose, um painel de administração React, infraestrutura observável com Prometheus e Grafana, e uma pipeline CI/CD com três workflows GitHub Actions que garantem qualidade, rastreabilidade e distribuição automatizada. A plataforma chegou ao estado de produção com utilizadores reais, dados comportamentais registados e uma avaliação junto de 12 participantes — o que, para um protótipo desenvolvido no âmbito de um projecto académico, representa um nível de maturidade acima do esperado numa primeira iteração.

A contribuição mais original deste trabalho é a combinação, num único produto, de **tema** (educação cívica para a transição sustentável) e de **personalização gerativa** (uso de um LLM para gerar percursos adaptativos em tempo real, com base no perfil de dificuldade de cada utilizador). Tanto quanto

foi possível apurar na análise do estado da arte, esta combinação não está presente em nenhuma das plataformas existentes analisadas.

6.2 Limitações

A honestidade sobre as limitações é parte integrante de qualquer trabalho de investigação e desenvolvimento. As limitações do Play4Change organizam-se em três níveis.

Limitações da avaliação. A amostra do questionário ($n = 12$, amostragem por conveniência) é insuficiente para conclusões estatisticamente robustas. Os resultados devem ser lidos como hipóteses e indicadores, não como evidências definitivas. O período de utilização coberto pelos dados comportamentais é relativamente curto e sem protocolo de tarefa estruturado, o que significa que alguns utilizadores podem ter explorado apenas partes da plataforma. Não há grupo de controlo, pelo que não é possível atribuir causalmente os resultados à plataforma em vez de a outros factores.

Limitações do protótipo. Nenhum tópico de conteúdo foi validado por especialistas em educação cívica ou em sustentabilidade urbana. A qualidade pedagógica dos conteúdos gerados pelo LLM depende da qualidade dos prompts e do modelo — e embora a validação de esquema JSON e a abordagem RAG [8] reduzam o risco de conteúdos malformados, não eliminam o risco de imprecisões factuais (hallucinations). A cobertura de testes de integração e o tratamento de erros de rede na aplicação móvel ficaram abaixo do que seria desejável numa versão de produção madura. A plataforma não foi submetida a auditoria de segurança independente.

Limitações de alcance. O **paradoxo de acessibilidade** identificado na Secção 5.5 é talvez a limitação mais estrutural: a plataforma é mais eficaz para quem já tem literacia digital de base, mas pode afastar precisamente quem mais beneficiaria de a desenvolver. Este paradoxo não é específico do Play4Change — afecta a maioria das plataformas de educação digital [6] — mas é especialmente problemático num contexto de educação cívica onde o objectivo explícito é reduzir desigualdades de participação. Resolver este paradoxo exigirá abordagens complementares que estão fora do âmbito do presente protótipo.

6.3 Trabalho futuro

As limitações identificadas apontam directamente para os caminhos mais prioritários de evolução. Há cinco direcções que merecem destaque. As duas primeiras — integração social e onboarding adaptado — respondem directamente ao paradoxo de acessibilidade identificado na avaliação e são as que mais alargam a base de utilizadores da plataforma. A terceira — validação pedagógica dos conteúdos — é o pré-requisito mais crítico para qualquer escalonamento real: sem ela, a plataforma não pode ser disponibilizada a públicos mais alargados com garantias de qualidade. As duas últimas são evoluções desejáveis mas de impacto mais incremental.

Integração social e comunitária. A sugestão mais recorrente na avaliação qualitativa foi a introdução de funcionalidades sociais: comparação de progresso entre amigos, desafios colectivos e partilha de conquistas. Este vector está directamente alinhado com a dimensão de relação da Teoria da Autodeterminação [5] e com a evidência na literatura de que a componente social é um dos motores de retenção mais eficazes em contextos de gamificação [9]. Uma versão futura do Play4Change que incorpore esta

dimensão poderia transformar o que é hoje uma experiência individual numa experiência de aprendizagem colectiva e contextualizada na comunidade local.

Onboarding adaptado ao Grupo B. O paradoxo de acessibilidade identificado na avaliação sugere que os utilizadores com menor literacia digital precisam de uma experiência de entrada diferente: tutoriais guiados interactivos, sessões de apoio inicial presencial integradas na distribuição, ou uma versão simplificada da interface com menos opções e navegação mais linear. Investigar que intervenções de onboarding reduzem efectivamente a barreira para este grupo — sem infantilizar a experiência para o Grupo A — é um problema de investigação com impacto directo na missão do projecto.

Validação pedagógica dos conteúdos. Uma versão madura da plataforma precisaria de um processo de revisão dos conteúdos gerados pela IA por especialistas em educação cívica e em sustentabilidade urbana. Este processo poderia ser estruturado de várias formas: revisão editorial periódica por amostragem, feedback dos utilizadores sobre a qualidade das explicações, ou um mecanismo de marcação de conteúdos suspeitos. A ausência deste componente é a limitação de qualidade mais importante a resolver antes de qualquer escalonamento da plataforma.

Personalização geográfica. Vários participantes sugeriram que a plataforma deveria adaptar as perguntas à cidade ou região onde o utilizador se encontra, usando dados públicos disponíveis para tornar os conteúdos hiper-locais. Esta ideia — questionar um utilizador em Lisboa sobre a qualidade do ar no Parque das Nações, ou um utilizador no Porto sobre a ciclovía da Avenida dos Aliados — está conceptualmente alinhada com os centros de competência da U!REKA [11] e poderia aumentar significativamente a relevância percebida dos conteúdos.

Distintivos com valor no mundo real. A avaliação revelou que os utilizadores percebem os distintivos como um reconhecimento simbólico interessante, mas com valor limitado fora da aplicação. Uma direcção possível são os Open Badges — um padrão aberto (IMS Global) para emissão de credenciais digitais verificáveis que podem ser partilhadas em perfis profissionais e reconhecidas por empregadores ou instituições. Integrar este padrão numa versão futura do Play4Change ligaria o reconhecimento dentro da plataforma a valor tangível fora dela, potencialmente aumentando a motivação dos utilizadores mais orientados para resultados concretos.

Em síntese, o Play4Change é um primeiro passo viável e com valor demonstrado. Os dados de utilização e a avaliação com utilizadores reais confirmam que a proposta tem fundamento — há utilizadores que a adoptam com entusiasmo genuíno, completam percursos, resolvem dificuldades com a ajuda da IA e regressam dias seguidos. O caminho até uma plataforma madura, acessível a todos os perfis de cidadão e com conteúdos validados é longo, mas este protótipo fornece uma base técnica, pedagógica e conceptual sólida sobre a qual construí-lo.

Referências

- [1] Benjamin S. Bloom, “Learning for Mastery”, *Evaluation Comment*, vol. 1, n.º 2, páginas 1–12, 1968.
- [2] Benjamin S. Bloom, “The 2 Sigma Problem: The Search for Methods of Group Instruction as Effective as One-to-One Tutoring”, *Educational Researcher*, vol. 13, n.º 6, páginas 4–16, 1984. DOI: [10.3102/0013189X013006004](https://doi.org/10.3102/0013189X013006004)
- [3] John Brooke, “SUS: A ‘quick and dirty’ usability scale”, em *Usability Evaluation in Industry*, P.W. Jordan, B. Thomas, B.A. Weerdmeester & I.L. McClelland, eds., London: Taylor & Francis, 1996, páginas 189–194.
- [4] Alistair Cockburn, *Hexagonal Architecture*, <https://alistair.cockburn.us/hexagonal-architecture/>, Acedido em 10 de junho de 2026, 2005.
- [5] Edward L. Deci & Richard M. Ryan, *Intrinsic Motivation and Self-Determination in Human Behavior*. New York: Plenum Press, 1985. DOI: [10.1007/978-1-4899-2271-7](https://doi.org/10.1007/978-1-4899-2271-7)
- [6] Enkelejda Kasneci, Kathrin Sessler, Stefan Küchemann, Maria Bannert, Daryna Dementieva, Frank Fischer, Urs Gasser, Georg Groh, Stephan Günemann, Eyke Hüllermeier et al., “ChatGPT for Good? On Opportunities and Challenges of Large Language Models for Education”, *Learning and Individual Differences*, vol. 103, pág. 102 274, 2023. DOI: [10.1016/j.lindif.2023.102274](https://doi.org/10.1016/j.lindif.2023.102274)
- [7] LangChain4j Contributors, *LangChain4j: LangChain for Java*, <https://github.com/langchain4j/langchain4j>, Acedido em 10 de junho de 2026, 2023.
- [8] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel & Douwe Kiela, “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”, em *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, 2020, páginas 9459–9474.
- [9] Armando M. Toda, Wilk T. Ota, Caio Mozo, Pedro H. D. Valle, Jacques D. Brancher & Seiji Isotani, “Gamification in education: a systematic mapping over ten years”, em *Brazilian Symposium on Computers in Education (SBIE)*, 2019, páginas 1–10. DOI: [10.5753/cbie.sbie.2019.1403](https://doi.org/10.5753/cbie.sbie.2019.1403)
- [10] Michael B. Jones, John Bradley & Nat Sakimura, “JSON Web Token (JWT)”, Internet Engineering Task Force, RFC 7519, mai. de 2015. DOI: [10.17487/RFC7519](https://doi.org/10.17487/RFC7519)
- [11] U!REKA, *Our alliance – Mission, vision and strategy*, <https://ureka.eu/alliance/>, Acedido em 8 de junho de 2026, 2026.
- [12] U!REKA, *U!REKA – European University Alliance*, <https://ureka.eu/>, Acedido em 8 de junho de 2026, 2026.
- [13] Kurt VanLehn, “The Relative Effectiveness of Human Tutoring, Intelligent Tutoring Systems, and Other Tutoring Systems”, *Educational Psychologist*, vol. 46, n.º 4, páginas 197–221, 2011. DOI: [10.1080/00461520.2011.611369](https://doi.org/10.1080/00461520.2011.611369)

- [14] Riina Vuorikari, Stefano Kluzer & Yves Punie, “DigComp 2.2: The Digital Competence Framework for Citizens – With new examples of knowledge, skills and attitudes”, Publications Office of the European Union, Luxembourg, rel. téc. EUR 31006 EN, 2022, JRC128415. DOI: [10.2760/115376](https://doi.org/10.2760/115376)