

Departamento de Engenharia Informática

Play4Change: Aplicação de Aprendizagem Adaptativa para Educação Cívica

1 : Radesh Ilesh Gamanbhai Govind (A51620@alunos.isel.pt)

Relatório para a Unidade Curricular de Projeto e Seminário
da Licenciatura em Engenharia Informática e de Computadores

Professores : Nuno Datia Professor
António Serrador Professor
Michel Vorenhout Professor

Resumo

A U!REKA é uma aliança europeia de instituições de ensino superior cuja missão é formar os profissionais de amanhã e apoiar a transição das cidades para modelos mais sustentáveis. Como possível contributo a essa missão surge o Play4Change: uma proposta de plataforma de educação digital, informal e gamificada, para a educação cívica e para as competências que essa transição exige. A solução usa inteligência artificial para ajustar os conteúdos ao ritmo de cada utilizador, convidando-o a aprender algo novo todos os dias e a ver o progresso reconhecido em distintivos. Juntam-se ainda mecanismos que mantêm o utilizador motivado a regressar — combatendo o abandono comum nestas plataformas — e uma personalização da experiência a cada pessoa. Este relatório descreve o protótipo desenvolvido e a avaliação preliminar com utilizadores de diferentes idades e contextos, cujo feedback revelou forte receptividade ao papel da IA no esclarecimento de dúvidas e na personalização da aprendizagem.

Palavras-chave: aprendizagem adaptativa, educação cívica, gamificação, inteligência artificial, cidades sustentáveis

Abstract

U!REKA is a European alliance of higher-education institutions whose mission is to educate the professionals of tomorrow and support the transition of cities towards more sustainable models. As a possible contribution to that mission, Play4Change proposes an informal, gamified digital education platform aimed at civic education and at the competences this transition demands from citizens. The solution uses artificial intelligence to adjust content to each user's pace, inviting them to learn something new every day and to see that progress recognised through badges. This recognition is paired with mechanisms that keep users coming back — tackling the dropout common to such platforms — and with a layer of personalisation that adapts the experience to each person. This report describes the prototype developed and the preliminary evaluation carried out with users of different ages and backgrounds, whose feedback revealed strong receptiveness to the role of AI in clarifying doubts and personalising learning.

Keywords: adaptive learning, civic education, gamification, artificial intelligence, sustainable cities

Utilização de Inteligência Artificial

Este trabalho foi desenvolvido integralmente por um único autor. No decurso do projecto, foram utilizadas ferramentas de inteligência artificial generativa como instrumentos de suporte ao processo de desenvolvimento — não como co-autoras de decisões técnicas, mas como multiplicadores de capacidade que reduziram materialmente o custo da exploração, da iteração e da recuperação perante impasses arquitecturais.

Ferramentas e modelos utilizados

- **Google Gemini** — utilizado na fase de exploração conceptual: brainstorming de alternativas arquitecturais, análise de trade-offs de design e avaliação de hipóteses antes de comprometer com um caminho de implementação. O seu papel foi essencialmente dialógico — um interlocutor para testar a consistência de raciocínios antes de se iniciar qualquer implementação.
- **Claude Code, modelo Opus (Anthropic)** — utilizado para esboçar e estruturar decisões arquitecturais; articular e testar a robustez da racionalidade de design; e explorar alternativas conceptuais entre camadas do sistema. Foi o instrumento privilegiado para a fase de decisão técnica: ajudou a mapear implicações de escolhas arquitecturais, identificar dependências não óbvias e formular argumentos de suporte ou rejeição de abordagens.
- **Claude Sonnet (Anthropic)** — utilizado para a escrita de código estrutural (scaffolding) destinado a acelerar o desenvolvimento de provas de conceito, para desbloquear a implementação quando um caminho revelava complexidade inesperada, e para reduzir a fricção em impasses técnicos — nomeadamente em configurações de infraestrutura, erros de compilação e problemas de compatibilidade entre dependências.

Papel estratégico da IA no projecto

A contribuição determinante não foi a geração de código em si. O valor crítico residiu na redução do custo marginal de explorar um caminho alternativo: quando uma decisão arquitectural se revelava estruturalmente inadequada — exigindo alterações demasiado extensas para serem absorvidas sem perda de tempo significativa — a IA tornou a mudança de rumo uma opção viável em vez de um último recurso. Esta liberdade de explorar, testar e rever sem custo proibitivo foi o uso mais consequente destas ferramentas ao longo do projecto.

A arquitectura do sistema, as decisões de design técnico, a análise de trade-offs, a avaliação dos resultados e as conclusões permaneceram, em todos os momentos, sob responsabilidade e autoria exclusivas

do autor. Os assistentes de codificação com IA aceleraram o trabalho estrutural, libertando capacidade cognitiva para as decisões que exigiam julgamento de engenharia genuíno.

Considerações éticas

A utilização de ferramentas de inteligência artificial neste trabalho é declarada na íntegra, em conformidade com os princípios de integridade académica. A autoria intelectual — compreendendo a concepção do sistema, as escolhas de design, a interpretação dos dados e as conclusões apresentadas — é da exclusiva responsabilidade do autor. As ferramentas de IA foram utilizadas de forma análoga a qualquer outro instrumento de produtividade de engenharia: como amplificadores da capacidade de execução, nunca como substitutos do pensamento crítico ou da responsabilidade intelectual.

Agradecimentos

A realização deste trabalho não teria sido possível sem o contributo, directo ou indirecto, de um conjunto de pessoas a quem devo reconhecimento genuíno.

Ao **Professor Nuno Datia** e ao **Professor Michel Vorenhout**, orientadores deste projecto, expresso a minha profunda gratidão pela disponibilidade, pelas observações e pela liberdade intelectual que me concederam para explorar caminhos pouco convencionais. A qualidade deste trabalho deve muito à exigência que colocaram e à confiança que depositaram. Ao **Instituto Superior de Engenharia de Lisboa** e ao **Instituto Politécnico de Lisboa**, pela formação académica e pelo enquadramento institucional que tornaram possível um projecto com esta dimensão e ambição.

Aos colegas com quem partilhei percurso ao longo destes anos, agradeço as conversas, os debates técnicos e a camaradagem que tornam o processo de aprender menos solitário e mais fértil. A disponibilidade para discutir ideias, questionar abordagens e partilhar dificuldades foi, muitas vezes, o que impediu que um obstáculo se tornasse um impasse.

Aos amigos de longa data, o reconhecimento pela paciência e pela presença constante. A um projecto desta natureza não se exige apenas competência técnica — exige-se também resistência, e essa constrói-se com o apoio de quem se mantém próximo independentemente das circunstâncias.

À minha família, o agradecimento mais profundo e mais difícil de circunscrever em palavras. A dedicação exigida por um trabalho desta envergadura impõe custos que recaem, inevitavelmente, sobre aqueles que estão mais próximos. A paciência, o suporte incondicional e a crença no valor daquilo que estava a ser construído foram indispensáveis.

A todos os que contribuíram para este percurso:

Ilesh Gamanbhai	Jignaben Mistry
Divyesh Govind	Professor Nuno Datia
Professor António Serrador	Professor Michel Vorenhout
Pedro Gomes	Guilherme Coutinho
Martim Monteiro	Alexandre Tavares
André Nunes	Francisco Tavares
Rodrigo Sampaio	Simão Afonso
Fábio Nibau	Maria Lopes
Júlia Santana	

Radesh Ilesh Gamanbhai Govind

Índice

Utilização de Inteligência Artificial	vii
Agradecimentos	ix
Lista de Figuras	xv
Lista de Tabelas	xvii
Lista de Listagens	xix
1 Introdução	1
1.1 A U!REKA e o desafio da transição para cidades sustentáveis	1
1.2 Da literacia digital à literacia cívica: o papel da inteligência artificial	1
1.3 Objetivos	3
1.4 O problema e a pergunta que orienta este trabalho	4
1.5 Como o Play4Change procura responder a este desafio	4
1.6 Organização do documento	5
2 Enquadramento e Estado da Arte	7
2.1 Conceitos fundamentais	7
2.2 Educação cívica e competências para a transição sustentável	9
2.3 Trabalho relacionado: o que já existe e o que se pode aprender com isso	10
2.4 Síntese e posicionamento do projeto	12
3 Desenvolvimento	13
3.1 Visão geral da arquitectura do sistema	13
3.2 Pipeline de processamento de pedidos	15
3.3 Autenticação sem <u>password</u> e gestão de sessão	18
3.3.1 O fluxo <u>Magic Link</u>	18

3.3.2	Estrutura e ciclo de vida do token JWT	19
3.3.3	Rotação de tokens e detecção de roubo	19
3.4	Modelo de dados principal	20
3.5	Pipeline de geração de conteúdo	21
3.6	Caracterização da inferência de IA	22
3.6.1	Orçamento de tokens por tipo de chamada	23
3.6.2	Latência de inferência observada	24
3.6.3	Seleção do modelo: <code>mistral-small-latest</code>	24
3.6.4	Projecção de custo a escala	24
3.7	O percurso básico do aprendente	26
3.8	Personalização adaptativa	27
3.8.1	Classificação do padrão de erro	27
3.8.2	Geração do percurso adaptativo e reutilização vectorial	27
3.8.3	Sequência de interacção: da resposta errada ao percurso adaptativo	29
3.8.4	A máquina de estados da personalização	29
3.8.5	Modo de explicação e diálogo com a IA	29
3.8.6	Sequência do ciclo de explicação	31
3.9	Reconhecimento: o sistema de distintivos	32
3.10	Envolvimento: mecanismos de retenção	33
3.11	Síntese do desenvolvimento	34
4	Ferramentas, Tecnologias e Metodologia	35
4.1	Arquitectura tecnológica	35
4.2	Pipeline de integração e entrega contínua	37
4.3	Metodologia de desenvolvimento	39
4.4	Utilização de inteligência artificial no desenvolvimento	39
5	Avaliação e Resultados	41
5.1	Metodologia de avaliação	41
5.2	Dados comportamentais: a utilização real	41
5.3	Resultados do questionário	44
5.4	O ciclo adaptativo em acção: um exemplo real	45
5.5	Dois perfis de utilizador: uma descoberta central	46
5.6	Feedback qualitativo e sugestões de melhoria	47
5.7	Discussão dos resultados	47

<i>ÍNDICE</i>	xiii
6 Conclusão	49
6.1 Síntese do trabalho realizado	49
6.2 Limitações	50
6.3 Trabalho futuro	50
Referências	53
A Applied Survival Analysis by Hosmer and Lemeshow	i

Lista de Figuras

1.1	Áreas e competências do quadro DigComp 2.2	2
1.2	Os três pilares do Play4Change	3
2.1	Plataformas analisadas posicionadas nos três eixos do Play4Change	11
3.1	Diagrama de componentes do sistema Play4Change	13
3.2	Arquitetura interna do servidor (Ports & Adapters)	14
3.3	Pipeline síncrono de processamento de pedidos	17
3.4	Pipeline assíncrono de geração de conteúdo com SSE	18
3.5	Fluxo de autenticação <u>Magic Link</u>	19
3.6	Estrutura interna do JWT emitido pelo <u>Play4Change</u>	20
3.7	Rotação de <u>refresh tokens</u> e detecção de roubo	21
3.8	Pipeline de geração de conteúdo com IA	23
3.9	Latência de inferência por tipo de chamada (P50 / P95 / P99)	24
3.10	Fluxo principal do percurso do aprendente	26
3.11	Sequência: resposta errada ao percurso adaptativo	29
3.12	Máquina de estados do percurso adaptativo	30
3.13	Escalada progressiva para o modo de explicação	31
3.14	Sequência do ciclo de explicação holística	32
4.1	Topologia de infraestrutura de produção do Play4Change	37
4.2	Pipeline CI/CD do Play4Change com os três workflows GitHub Actions	37
5.1	Inscrições e conclusões por tópico	42
5.2	Distribuição das sessões adaptativas por padrão de erro	43
5.3	Distribuição das pontuações SUS por participante	44

Lista de Tabelas

2.1	Comparação informal de plataformas de educação digital segundo os três pilares do Play4Change	10
3.1	<u>Stack</u> tecnológico do Play4Change	16
3.2	Cadeia de filtros Spring Security do servidor Play4Change	16
3.3	Eventos SSE da geração de conteúdo	17
3.4	Parâmetros de resiliência e limites operacionais do sistema	18
3.5	Entidades principais do modelo de dados	22
3.6	Orçamento de tokens por tipo de chamada ao LLM	23
3.7	Comparação de modelos de linguagem considerados	25
3.8	Projecção de custo de inferência a escala	25
3.9	Padrões de erro e estratégias de remediação adaptativa	28
3.10	Estratégias de reutilização de percursos adaptativos	28
3.11	Principais <u>endpoints</u> REST do Play4Change	34
4.1	Tecnologias utilizadas no Play4Change por camada	36
4.2	CrITÉrios de qualidade verificados na pipeline de CI	38
5.1	Indicadores globais de utilização extraídos da base de dados	42
5.2	Dados de utilização por participante (anonimizados)	43
5.3	Dimensões de envolvimento e adaptatividade avaliadas	45
5.4	Comparação dos dois grupos de utilizadores identificados	47

Lista de Listagens

3.1	System prompt do modo de explicação	30
-----	---	----

Capítulo 1

Introdução

1.1 A U!REKA e o desafio da transição para cidades sustentáveis

A U!REKA ([European University Alliance](#)) é uma aliança que reúne mais de trinta instituições de ensino superior e parceiros de toda a Europa, com a missão de educar os profissionais europeus de amanhã e de preparar estudantes, docentes e a comunidade em geral para liderar a transição para cidades neutras em carbono, sustentáveis e inteligentes [22]. Entre os seus centros de competência contam-se áreas como as “cidades resilientes e neutras em carbono” e a “governança inovadora e o envolvimento dos cidadãos” [21], o que reflete bem a forma como a aliança entende esta transição: não apenas como um problema de engenharia ou de planeamento urbano, mas também como um desafio de participação cívica.

É precisamente aí que reside a dificuldade central que este projeto procura ajudar a resolver. Tornar uma cidade mais sustentável não depende só de construir melhores infraestruturas ou de garantir financiamento — depende também de que os próprios cidadãos compreendam o que está em causa, saibam como agir e se sintam parte do processo. Sem essa apropriação por parte das pessoas, mesmo as melhores políticas correm o risco de ficar pelo caminho. O [Play4Change](#) nasce da vontade de dar um contributo concreto a este problema, propondo-se como uma possível solução — ainda numa fase de protótipo — a apresentar à própria U!REKA: uma forma de ajudar os cidadãos a desenvolver, de modo simples e acessível, as competências cívicas e digitais de que precisam para participar nesta mudança.

1.2 Da literacia digital à literacia cívica: o papel da inteligência artificial

Para fundamentar esta proposta, foi importante perceber primeiro o que se entende, hoje, por “estar preparado” para participar de forma ativa e informada no mundo digital. O relatório [DigComp 2.2 – The Digital Competence Framework for Citizens](#), publicado pelo Centro Comum de Investigação da Comissão Europeia, oferece precisamente esse retrato: organiza a competência digital em cinco grandes áreas — procurar e avaliar informação, comunicar e colaborar, criar conteúdos, manter-se em segurança e resolver problemas — e descreve-as através de exemplos concretos do que uma pessoa sabe, é capaz de fazer e valoriza em cada uma delas [24]. A Figura 1.1 ilustra esta organização e os subtemas que cada área abrange.




Figura 1.1: As cinco áreas de competência digital e respectivas competências, segundo o quadro DigComp 2.2. Fonte: adaptado de [24], com base em material disponibilizado sob licença Creative Commons Attribution 4.0 (CC BY 4.0).

Do ponto de vista do Play4Change, são principalmente as **áreas 1 e 2** do DigComp as que mais diretamente se traduzem em objetivos de aprendizagem da plataforma. A área 1 (literacia informacional e de dados) cobre competências como saber pesquisar e avaliar informação, compreender como os algoritmos moldam os resultados de pesquisa, e identificar desinformação — todas críticas para qualquer cidadão que tenta formar uma opinião informada sobre políticas de mobilidade urbana, eficiência energética ou qualidade do ar. A área 2 (comunicação e colaboração) cobre a capacidade de comunicar em meios digitais, participar em processos de tomada de decisão online e colaborar de forma construtiva — competências igualmente centrais para a participação cívica digital. O DigComp não é, em si, um programa de estudos: descreve o que se espera saber, não como se chega lá. O Play4Change ocupa esse espaço intermédio, propondo uma forma concreta — informal, adaptativa e gamificada — de ajudar os cidadãos a avançar neste mapa de competências ao seu próprio ritmo.

Duas ideias retiradas desse documento influenciaram diretamente a forma como o Play4Change foi pensado. A primeira é a constatação de que a competência digital e a competência cívica caminham lado a lado: saber procurar, avaliar e comunicar informação de forma crítica é também a base para participar na vida em sociedade — e é exatamente essa ponte entre “saber lidar com o digital” e “ser um cidadão ativo” que o projeto procura explorar. A segunda é o modo como o relatório descreve a presença cada vez maior da inteligência artificial no dia a dia das pessoas: motores de pesquisa que se adaptam a quem os usa, sistemas que ajudam a identificar do que cada um precisa, ferramentas que respondem a perguntas em linguagem natural. O Play4Change apropria-se desta mesma lógica, mas

vira-a a favor da aprendizagem: usa a inteligência artificial não para mostrar a alguém aquilo que já espera ver, mas para perceber onde tem mais dificuldade e ajustar o caminho de aprendizagem a essa pessoa em concreto [23].

1.3 Objetivos

Tendo este enquadramento como pano de fundo, o projeto Play4Change propõe-se conceber e desenvolver uma plataforma de educação digital, informal e gamificada, que ajude os cidadãos a adquirir, de forma natural e continuada, competências relevantes para a transição para cidades sustentáveis — com particular destaque para a dimensão da educação cívica.

Para que esta proposta não ficasse apenas como uma boa ideia solta, todo o trabalho foi organizado à volta de três pilares que se reforçam mutuamente — **reconhecimento**, **envolvimento** e **personalização** — e que são apresentados em detalhe na Secção 1.5. A Figura 1.2 resume esta estrutura: os três pilares funcionam como bases que sustentam o Play4Change e, em conjunto, é que tornam possível responder ao desafio de capacitar os cidadãos sem os perder pelo caminho.




Figura 1.2: Os três pilares — reconhecimento, envolvimento e personalização — que sustentam a proposta do Play4Change e orientam os objetivos deste trabalho.

De forma mais concreta, e organizando-os já à luz destes três pilares, este trabalho procura:

- **Reconhecimento** Dar a cada utilizador um sinal claro e tangível do seu progresso, através de um sistema de distintivos que assinala a aquisição de novas competências [18] (“consegui aprender isto”);
- **Envolvimento** Pensar em mecanismos que tornem a aplicação suficientemente apelativa para que as pessoas queiram voltar — respondendo a um dos maiores problemas da educação digital, que é o abandono ao fim de pouco tempo;
- **Personalização** Conceber uma forma de aprendizagem adaptativa, em que a inteligência artificial ajusta os conteúdos ao que cada pessoa já sabe, ao seu ritmo e às dificuldades que vai sentindo [11, 23];
- Construir e testar um protótipo funcional que materialize, de forma integrada, estes três pilares;
- Recolher, junto de pessoas de diferentes idades, contextos e níveis de educação, uma primeira perceção sobre o que funciona bem, o que pode ser melhorado e o que mais valorizam nesta forma de aprender.

1.4 O problema e a pergunta que orienta este trabalho

A transição para cidades mais sustentáveis enfrenta desafios de infraestrutura, de financiamento e de coordenação entre diferentes entidades — mas enfrenta também, e talvez sobretudo, o desafio de preparar as pessoas para essa mudança. É sobre esta última dimensão que este projeto se debruça.

O problema tem pelo menos três camadas que se reforçam mutuamente. A primeira é o **déficit de competências digitais e cívicas**: uma parte significativa da população europeia não dispõe das competências digitais básicas definidas pelo quadro DigComp [24], o que limita a sua capacidade de participar em processos de decisão que decorrem, crescentemente, em plataformas digitais — desde consultas públicas municipais a plataformas de participação cidadã. A segunda camada é a da **desinformação e da desconfiança**: num ambiente marcado por uma abundância de informação e por dificuldades crescentes de verificação, a capacidade de avaliar criticamente o que se lê é simultaneamente mais necessária e mais difícil de desenvolver sem prática estruturada e continuada. A terceira camada, talvez a mais diretamente prática, é o **problema do abandono nas plataformas de aprendizagem digital**: mesmo quando as pessoas começam a usar ferramentas de educação online, a taxa de abandono é muito elevada — plataformas de e-learning registam frequentemente taxas de conclusão de cursos abaixo dos 10% [11], o que levanta a questão de saber se o problema não está tanto na disponibilidade de conteúdos como na forma como estes são apresentados e na motivação que conseguem (ou não) gerar.

É sobre este último ponto que os mecanismos de envolvimento e personalização do Play4Change procuram atuar diretamente. A hipótese que orienta este trabalho é que a combinação de conteúdos curtos e contextualizados (relevantes para o dia a dia), de reconhecimento visível do progresso e de personalização adaptativa pode melhorar significativamente a retenção e o envolvimento a longo prazo — criando as condições para que a aprendizagem de competências cívicas e digitais deixe de ser uma tarefa pontual e passe a ser um hábito. Desta hipótese nasce a pergunta que orienta o projeto: de que forma pode uma plataforma de educação digital, informal e gamificada, apoiada por inteligência artificial, ajudar os cidadãos a desenvolver as competências de que precisam para participar na transição para cidades sustentáveis — e, ao mesmo tempo, conseguir que continuem a usá-la ao longo do tempo?

1.5 Como o Play4Change procura responder a este desafio

Para responder a esta pergunta, a proposta do Play4Change organiza-se à volta de três ideias que se complementam e reforçam mutuamente:

- **Reconhecer o que a pessoa já é capaz de fazer** — sempre que alguém conclui um tópico ou domina uma nova competência, a aplicação assinala isso de forma visível, através de um distintivo. É uma forma simples de dizer “conseguiste”, que dá à pessoa uma noção concreta da evolução do seu próprio percurso;
- **Manter a pessoa interessada em continuar** — um dos maiores obstáculos das plataformas de aprendizagem digital é que as pessoas começam com entusiasmo e, passado pouco tempo, deixam de as usar. O Play4Change procura contrariar essa tendência através de mecanismos que tornam o regresso à aplicação algo natural e motivador, e não mais uma tarefa;

- **Adaptar-se a quem está do outro lado** — nem todas as pessoas aprendem da mesma forma, no mesmo ritmo, ou partem do mesmo ponto. Por isso, a aplicação recorre à inteligência artificial para perceber as dificuldades de cada utilizador e ajustar-se a elas, tornando a experiência mais próxima e mais útil para cada pessoa em particular.

Do ponto de vista técnico, estes três pilares traduzem-se em componentes específicos da plataforma. O **reconhecimento** concretiza-se num motor de distintivos que avalia o desempenho do utilizador e desbloqueia emblemas quando determinados limiares de domínio são atingidos, seguindo a lógica de aprendizagem por mestria [1]. O **envolvimento** materializa-se em mecanismos como as sequências de dias consecutivos de utilização (*streaks*), notificações de lembrança e a lógica de desbloqueio diário de conteúdos que torna o regresso à aplicação algo esperado e natural. A **personalização** é suportada por um sistema de inteligência artificial que classifica os erros do utilizador em padrões reconhecíveis [23], gera percursos de reforço adaptados ao seu perfil de dificuldade recorrendo a um modelo de linguagem de grande dimensão [11], e mantém sessões de explicação interativa em que o utilizador pode esclarecer as suas dúvidas por conversação. O Capítulo 3 detalha como cada um destes componentes foi concebido e implementado.

Importa deixar claro que aquilo que se apresenta neste relatório é um protótipo funcional — um primeiro passo que demonstra que a ideia é viável, mas que deixa também muito espaço para crescer em cada uma destas três frentes, como se discute mais adiante no Capítulo 6.

1.6 Organização do documento

O presente relatório está organizado da seguinte forma. O Capítulo 2 aprofunda o enquadramento e o estado da arte, situando o Play4Change no contexto da educação digital, da aprendizagem adaptativa e dos quadros de referência europeus de competência digital e cívica que serviram de inspiração a este trabalho. O Capítulo 3 descreve o processo de desenvolvimento da solução — desde os requisitos até à arquitetura, à implementação e às opções de design da interface. O Capítulo 4 apresenta as ferramentas, tecnologias e metodologias utilizadas ao longo do projeto, dando particular atenção ao papel que a inteligência artificial desempenhou não só na aplicação, mas também no próprio processo de a desenvolver. O Capítulo 5 apresenta e discute os resultados da avaliação preliminar feita junto de utilizadores reais. Por fim, o Capítulo 6 reúne as principais conclusões deste trabalho, assume com transparência as suas limitações, e aponta caminhos para o que pode vir a seguir.

Capítulo 2

Enquadramento e Estado da Arte

2.1 Conceitos fundamentais

Antes de se analisar o panorama de soluções existentes, é importante clarificar três conceitos que estruturam toda a proposta do Play4Change: a gamificação, a aprendizagem adaptativa e o papel da inteligência artificial na personalização da aprendizagem. Estes três conceitos não são independentes — pelo contrário, é precisamente da sua articulação que nasce a lógica dos três pilares (reconhecimento, envolvimento e personalização) já apresentados na Secção 1.5.

Gamificação

A gamificação consiste na aplicação de elementos e mecânicas tipicamente associados a jogos — como pontos, níveis, distintivos, tabelas de classificação ou sequências de progresso — a contextos que não são, em si, jogos, com o objetivo de aumentar a motivação e o envolvimento dos utilizadores [18]. No domínio da educação digital, a gamificação é frequentemente usada precisamente para responder ao problema do abandono: ao tornar o processo de aprendizagem mais apelativo e ao reconhecer visivelmente o progresso da pessoa, procura-se que esta sinta vontade de continuar. É desta lógica que nasce, em larga medida, o pilar do **reconhecimento** no Play4Change.

A literatura sobre gamificação em contextos educativos revela resultados promissores, mas também aponta limites importantes. O estudo de revisão sistemática de Toda et al. [18], que analisou mais de uma década de investigação, conclui que os elementos da chamada tríade PBL (Points, Badges, Lleaderboards) têm impacto positivo no envolvimento e na persistência a curto prazo, mas que o seu efeito sustentado depende criticamente do modo como são integrados no contexto pedagógico. Em particular, os autores alertam para um risco que o design de qualquer plataforma gamificada deve considerar: o da motivação extrínseca — aprender para ganhar pontos ou subir numa tabela — substituir gradualmente a motivação intrínseca, sobretudo em utilizadores que, à partida, já estariam motivados a aprender.

Esta tensão entre motivação extrínseca e intrínseca é central na Teoria da Autodeterminação (Self-Determination Theory) [5], que identifica três necessidades psicológicas básicas cujo suporte favorece a motivação duradoura: a **autonomia** (sentir que as próprias escolhas fazem sentido), a **competência** (sentir-se capaz e em crescimento) e a **relação** (sentir-se ligado aos outros). Uma plataforma que se limita a acumular pontos satisfaz potencialmente apenas a competência, e de forma superficial; o Play4Change procura alargar

este espectro: as sequências de dias consecutivos (*streaks*) apelam à autonomia ao tornar o regresso uma decisão da própria pessoa, os distintivos reconhecem competência genuína (só são atribuídos quando se domina um tópico a um nível mínimo), e a estrutura de tópicos relacionados com a vida cívica real procura tornar a aprendizagem significativa para além do jogo em si.

Aprendizagem adaptativa

A aprendizagem adaptativa designa abordagens em que o percurso, o ritmo ou o nível de dificuldade dos conteúdos se ajustam ao desempenho e às necessidades de cada pessoa, em vez de seguirem um percurso único e igual para todos [23]. Em vez de um modelo “tamanho único”, a ideia é que cada pessoa avance ao seu próprio ritmo, recebendo mais apoio onde sente mais dificuldade e podendo avançar mais depressa onde já domina a matéria. Este conceito está diretamente na base do pilar da **personalização**.

O ponto de partida histórico para compreender a importância da adaptação no ensino é o chamado problema das 2 sigma, identificado por Bloom em 1984 [2]: num estudo controlado, os alunos que receberam tutoria individual regular apresentaram desempenhos 2 desvios padrão acima dos alunos em regime de ensino convencional em grupo — um resultado notável, que Bloom apelidou de “o maior problema da pedagogia”, dada a impossibilidade prática de escalar a tutoria individual. A questão que se seguiu — e que tem orientado décadas de investigação em tecnologia educacional — foi: como escalar os benefícios da tutoria individual a custo acessível?

Os Sistemas de Tutoria Inteligente (*Intelligent Tutoring Systems*, ITS) emergiram precisamente como resposta a esta questão. VanLehn [23], numa revisão abrangente de 2011, mostra que os ITS com retro-alimentação ao nível do passo (*step-level feedback*) — ou seja, sistemas que reagem imediatamente a cada interação do utilizador, e não apenas à resposta final — conseguem ganhos de 0,4 a 1,0 desvio padrão em relação ao ensino convencional. Embora aquém dos 2 sigma da tutoria humana, este resultado valida a abordagem adaptativa como alternativa viável e escalável, especialmente quando combinada com a disponibilidade permanente que o software pode oferecer.

A aprendizagem por mestria (*mastery learning*) [1] é outro conceito central: o utilizador não avança para um tópico novo antes de demonstrar que domina o anterior, o que força uma progressão sólida em vez de uma superficial. No Play4Change, esta lógica aplica-se tanto à progressão entre tópicos (só se acede ao tópico *B* depois de dominar o tópico *A*, verificado através de um grafo de pré-requisitos) como à geração de percursos de reforço quando um erro recorrente é detetado. A adaptação dá-se, portanto, a dois níveis: na estrutura do percurso a longo prazo e na geração de conteúdo de apoio em resposta a dificuldades concretas em tempo real.

Inteligência artificial na personalização da aprendizagem

A inteligência artificial tem vindo a tornar a aprendizagem adaptativa cada vez mais viável e acessível, ao permitir analisar o desempenho de cada utilizador e gerar ou ajustar conteúdos de forma praticamente individual — algo que seria muito difícil de fazer manualmente, à escala de milhares de utilizadores [11]. É também esta capacidade que torna possível um dos objetivos centrais do Play4Change: que cada pessoa sinta que a aplicação “percebe” onde tem mais dificuldade e a ajuda a esclarecer essas dúvidas, em vez de a confrontar com um conjunto fixo e genérico de exercícios.

Os Modelos de Linguagem de Grande Dimensão (Large Language Models, LLM) tornaram concreta uma possibilidade que antes era apenas teórica: gerar conteúdos pedagógicos personalizados a pedido, em linguagem natural, de forma economicamente acessível e à escala. Kasneci et al. [11] identificam, numa análise abrangente das oportunidades e desafios dos LLM na educação, que entre as potencialidades mais relevantes estão precisamente a geração de exercícios adaptados ao nível do aprendente, a explicação de conceitos de formas diferentes consoante o perfil da pessoa, e o feedback imediato e personalizado. Os mesmos autores sublinham, porém, que a utilização acrítica destes modelos levanta desafios sérios: a possibilidade de gerar conteúdos incorretos ou imprecisos (hallucinations), a necessidade de supervisão editorial, e o risco de substituição do pensamento crítico do aprendente por uma dependência excessiva nas respostas da máquina.

Para mitigar o risco de qualidade, o Play4Change adopta uma abordagem de geração ancorada em contexto, inspirada no padrão Retrieval-Augmented Generation (RAG) [13]: em vez de pedir ao modelo que gere conteúdo livremente a partir de um pedido vago, o sistema constrói um prompt estruturado que inclui o perfil de dificuldade do utilizador, o tópico pedagógico em causa, exemplos de exercícios anteriores considerados bem-sucedidos e um esquema JSON que o modelo deve respeitar na resposta. Adicionalmente, a resposta do modelo é validada contra esse esquema e, em caso de falha de formato, o pedido é reenviado com uma indicação explícita dos erros encontrados. Esta combinação de contexto estruturado, exemplos de referência e validação pós-geração procura tornar a saída do LLM suficientemente fiável para ser apresentada ao utilizador sem revisão humana prévia — reconhecendo, ao mesmo tempo, que esta garantia é parcial e que a supervisão editorial dos conteúdos gerados continua a ser um passo importante para uma versão madura da plataforma.

2.2 Educação cívica e competências para a transição sustentável

A educação cívica — entendida como o processo pelo qual os cidadãos desenvolvem o conhecimento, as competências e a disposição para participar ativamente na vida pública e nas decisões coletivas — é reconhecida como um dos pilares das democracias participativas. No contexto específico da transição para cidades mais sustentáveis, esta dimensão adquire particular relevância: as políticas urbanas têm maior probabilidade de produzir resultados quando os cidadãos compreendem o que está em causa, sentem que têm um papel a desempenhar e são efetivamente envolvidos nos processos de decisão [21].

O quadro de referência DigComp 2.2 [24] fornece uma estrutura útil para operacionalizar estas competências no mundo digital. Das cinco áreas que o quadro organiza — literacia informacional, comunicação e colaboração, criação de conteúdos digitais, segurança e resolução de problemas —, as duas primeiras têm uma ligação direta à cidadania ativa: saber avaliar criticamente a informação que se encontra online, distinguir fontes fiáveis de desinformação, e saber comunicar e colaborar de forma construtiva em meios digitais são, simultaneamente, competências digitais e competências cívicas. Não existe, portanto, uma separação clara entre “literacia digital” e “literacia cívica” — a segunda pressupõe, em boa medida, a primeira.

O desafio central que o Play4Change enfrenta é o da **acessibilidade da aprendizagem informal**: como chegar a cidadãos que não estão em contextos de aprendizagem formal — que não são estudantes, que não frequentam formações profissionais — e que talvez nunca tenham formulado o desejo explícito de “melhorar as suas competências cívicas digitais”? A resposta que este projeto propõe assenta em três princípios. Primeiro, a **informalidade**: o formato de jogo, com sessões curtas e sem pressão avaliativa,

baixa a barreira de entrada. Segundo, a **acessibilidade imediata**: uma aplicação móvel que não requer inscrição em instituições, sem custos de acesso, disponível em qualquer hora e lugar. Terceiro, a **relevância percebida**: os conteúdos são enquadrados em situações concretas da vida nas cidades — temas que a pessoa reconhece como pertinentes ao seu quotidiano, e não como matéria académica abstrata. É esta combinação que distingue a proposta do Play4Change de abordagens de educação cívica mais tradicionais.

2.3 Trabalho relacionado: o que já existe e o que se pode aprender com isso

Antes de desenhar a solução, foi feita uma análise informal de um conjunto de plataformas de educação digital amplamente conhecidas e utilizadas — Kahoot!, Duolingo, Coursera, Khan Academy e edX. O objetivo desta análise não foi produzir um estudo comparativo exaustivo, mas sim perceber, de forma prática, em que é que cada uma destas plataformas se destaca — e, em particular, o que cada uma faz bem em relação aos três pilares definidos para o Play4Change: reconhecimento, envolvimento e personalização. A análise é qualitativa e baseia-se na experiência direta de utilização das plataformas e na documentação pública disponível. A partir daqui, procurou-se “herdar” as ideias mais relevantes de cada uma e adaptá-las, ainda que de forma parcial — lembrando sempre que o Play4Change, nesta fase, é apenas um protótipo funcional e não uma plataforma completa.

A Tabela 2.1 resume esta análise, posicionando cada plataforma relativamente aos três pilares.

Plataforma	Reconhecimento	Envolvimento	Personalização
Kahoot!	Pontuações e pódios em tempo real que celebram o desempenho individual e do grupo	Formato de jogo/quiz competitivo, muito eficaz a tornar o momento de avaliação divertido	Pouco adaptativo: os mesmos quizzes são apresentados a todos os participantes
Duolingo	Sistema de níveis, ligas e distintivos que assinalam claramente cada progresso	Sequências diárias (<i>streaks</i>), lembretes e notificações que incentivam o regresso todos os dias	Ajusta a dificuldade dos exercícios de acordo com os erros e acertos do utilizador
Coursera	Certificados formais e emblemas associados à conclusão de cursos e módulos	Estrutura por prazos e módulos que organiza o estudo, mas com pouca componente lúdica	Percursos de aprendizagem recomendados com base nos interesses e no histórico do utilizador
Khan Academy	Pontos de energia, distintivos e mapas de progresso que tornam visível o que já foi dominado	Painel de progresso e mistérios que ajudam o utilizador a saber sempre “o que vem a seguir”	Aprendizagem por mestria (<i>mastery learning</i>) [1]: só se avança quando se domina o tema anterior
edX	Certificados verificados e indicadores de conclusão por módulo	Fóruns de discussão e prazos que criam uma sensação de comunidade e de ritmo	Conteúdos relativamente uniformes, com pouca adaptação automática ao desempenho individual

Tabela 2.1: Comparação informal de cinco plataformas de educação digital amplamente conhecidas, segundo os três pilares definidos para o Play4Change: reconhecimento, envolvimento e personalização.

Antes de analisar os resultados, merecem nota dois aspetos transversais. O primeiro é a **dimensão temática**: todas as plataformas analisadas são agnósticas quanto ao tema — o Duolingo ensina línguas, o Kahoot! pode ser usado para qualquer quiz, e o Coursera e o edX cobrem toda a espécie de cursos académicos. Nenhuma delas foi concebida especificamente para a educação cívica relacionada com a sustentabilidade urbana, o que significa que mesmo as melhores práticas identificadas neste levantamento teriam de ser recontextualizadas. O segundo aspeto é a **origem da experiência**: a maioria destas plataformas foi concebida para contextos web, com aplicações móveis como extensão. O Play4Change foi desenhado desde o início como uma aplicação móvel nativa — partindo do princípio de que o telemóvel é o ponto de acesso privilegiado da maioria dos cidadãos à internet, em particular nos grupos etários e socioeconómicos que importa não excluir.

Desta análise resultou uma perceção relativamente clara: nenhuma destas plataformas é simultaneamente forte nos três pilares. O Duolingo destaca-se no envolvimento e no reconhecimento, mas o seu modelo de personalização é relativamente simples; a Khan Academy é uma referência em personalização através da aprendizagem por mestria, mas o seu reconhecimento e envolvimento são mais discretos; o Kahoot! é extremamente envolvente no momento da utilização, mas pouco adaptado a cada pessoa; e o Coursera e o edX valorizam sobretudo o reconhecimento formal (certificados), com menos ênfase no envolvimento contínuo do dia a dia. A Figura 2.1 traduz esta perceção num gráfico de três eixos — um para cada pilar (reconhecimento, envolvimento e personalização) — em que o “volume” ocupado por cada plataforma mostra, de forma imediata, em quantos e em quais pilares ela é forte; a área tracejada representa a meta a que o Play4Change aspira: ser razoavelmente forte nos três ao mesmo tempo, e não apenas num deles.




Figura 2.1: Cada plataforma representada num gráfico de três eixos — reconhecimento, envolvimento e personalização — de acordo com o nível (baixo, médio ou alto) atribuído na Tabela 2.1. A área a tracejado assinala a meta do Play4Change: alcançar um nível elevado nos três pilares em simultâneo, em vez de se destacar apenas num deles.

2.4 Síntese e posicionamento do projeto

A análise apresentada permite tirar uma conclusão simples, mas importante para todo o desenho do Play4Change: cada uma das plataformas estudadas resolve bem uma parte do problema — seja tornar o momento de aprendizagem divertido, seja reconhecer o progresso de forma visível, seja adaptar os conteúdos a quem aprende — mas raramente as três coisas ao mesmo tempo, e raramente com um foco em temas de cidadania e sustentabilidade.

Esta síntese informou diretamente as decisões de design do Play4Change. Do conjunto de plataformas analisadas, **adotaram-se**: as sequências diárias (*streaks*) e os distintivos de progresso do Duolingo; a progressão por mestria da Khan Academy [1]; e o formato de *quiz* interativo e imediato do Kahoot!. **Não se adotaram**, pelo menos nesta fase, os certificados formais do Coursera e do edX — que implicariam um nível de acreditação externo fora do âmbito de um protótipo — nem as tabelas de classificação altamente competitivas que algumas destas plataformas utilizam, por se entender que podem ter efeitos desmotivadores em utilizadores menos experientes, contrariando os princípios da Teoria da Autodeterminação [5].

A diferença mais fundamental entre o Play4Change e todas as plataformas analisadas reside na combinação de **tema** (educação cívica para a transição sustentável) e de **personalização gerativa** (uso de um LLM para gerar conteúdos adaptativos em tempo real, com base no perfil de dificuldade de cada utilizador, e não apenas para selecionar conteúdos de um repositório fixo). Esta combinação, tanto quanto foi possível apurar neste levantamento, não está presente em nenhuma das plataformas existentes — o que justifica a proposta, mas também coloca desafios concretos: o custo da inferência de IA a escala, a garantia de qualidade dos conteúdos gerados e a necessidade de validação pedagógica são dimensões que este protótipo apenas começa a explorar, e que uma versão madura da plataforma terá necessariamente de endereçar com maior rigor.

É exatamente nesse espaço que o Play4Change se posiciona: não como um substituto de nenhuma das plataformas analisadas, mas como uma proposta que tenta reunir, num único produto aplicado à educação cívica, aquilo que cada uma faz de melhor — apoiando-se na inteligência artificial para que esta combinação se ajuste a cada pessoa em particular. O resultado, nesta fase, é um protótipo funcional: uma primeira demonstração de que a ideia é viável e tem valor, não ainda uma plataforma completa e madura.

Capítulo 3

Desenvolvimento

Este capítulo descreve como o Play4Change foi concebido e implementado, desde as decisões de arquitectura até aos mecanismos mais específicos que concretizam cada um dos três pilares. A ênfase recai sobre o pilar da **personalização** — em particular, sobre a forma como a inteligência artificial detecta dificuldades em tempo real, gera percursos adaptativos e, em caso de persistência do erro, oferece ao utilizador a possibilidade de dialogar directamente com o modelo para esclarecer dúvidas.

3.1 Visão geral da arquitectura do sistema

O Play4Change é um sistema distribuído composto por vários processos e serviços que colaboram entre si. Todo o ambiente de produção é declarado num único ficheiro `docker-compose.yml`, o que permite lançar a plataforma completa — incluindo a base de dados, a cache, o armazenamento de objectos e a pilha de observabilidade — com um único comando. A Figura 3.1 apresenta o diagrama de componentes do sistema.




Figura 3.1: Diagrama de componentes do Play4Change: os clientes móvel e web comunicam com o servidor através do Nginx; o servidor apoia-se em PostgreSQL+pgvector, Redis e MinIO, integra com Mistral AI e Resend (e-mail), e expõe métricas ao Prometheus/Grafana.

Clientes

A interface principal do aprendente é a **aplicação móvel**, desenvolvida em Kotlin Multiplatform com Compose Multiplatform: o mesmo código de interface corre em Android e iOS, com apenas adaptadores de plataforma distintos (motor HTTP OkHttp/Darwin, armazenamento de tokens em DataStore no Android e no Keychain no iOS). A navegação entre ecrãs segue o padrão Decompose (componentes independentes do ciclo de vida), e a injeção de dependências usa Koin. A aplicação tem dez ecrãs funcionais: Splash, Login, Home, Explorar tópicos, Tarefa diária, Percurso adaptativo (Struggle), Explicação/chat, Revisão por pares, Perfil e Sobre.

O **painel de administração** é uma SPA React+TypeScript, servida como ficheiros estáticos pelo Nginx. Permite criar tópicos (por URL ou PDF), gerir pré-requisitos, ver o grafo de aprendizagem, moderar relatórios de tarefas e consultar estatísticas de distintivos.

Nginx e encaminhamento

O Nginx actua como reverse proxy e servidor de conteúdo estático. Todos os pedidos chegam à porta 80; os que têm o prefixo `/play4change-server/` são reencaminhados para o servidor Spring Boot (porta 8080), enquanto os restantes servem a SPA com fallback para `index.html`. O endpoint `/actuator/health` é exposto publicamente para os health checks do Docker, mas todos os outros endpoints de gestão (incluindo `/actuator/prometheus`) ficam acessíveis apenas internamente na porta 9090, fora do alcance público. O Nginx acrescenta ainda os cabeçalhos de segurança obrigatórios (HSTS, CSP, X-Frame-Options: DENY, X-Content-Type-Options).

Servidor Spring Boot

O servidor é o núcleo da plataforma. Internamente, organiza-se segundo a Hexagonal Architecture (Ports & Adapters) [4]: a lógica de negócio (serviços e domínio) não depende directamente de nenhuma tecnologia concreta — cada integração é encapsulada num adapter que implementa uma interface genérica (port). A Figura 3.2 detalha esta organização interna.




Figura 3.2: Organização interna do servidor em quatro camadas: os controllers recebem pedidos HTTP e chamam os casos de uso; os casos de uso operam sobre o domínio; a infraestrutura implementa as interfaces (ports) definidas pelos casos de uso. As dependências apontam sempre para dentro (domínio).

O servidor inclui ainda mecanismos transversais relevantes: autenticação stateless por JWT (tokens de acesso com 15 minutos de validade e refresh com 7 dias), com acesso via Magic Link por e-mail (sem palavra-passe); limitação de taxa nos endpoints de autenticação (Redis-backed); um circuit breaker

Resilience4j nas chamadas à API da Mistral (janela de 10 pedidos, 50% de falhas abre o circuito por 30 segundos, com retry exponencial até 3 tentativas); e três schedulers que correm periodicamente: expiração automática de tópicos vencidos, watchdog que detecta gerações de conteúdo presas em estado `GENERATING` há mais de 15 minutos, e expiração de revisões por pares não concluídas.

Serviços de dados e externos

A **base de dados** é PostgreSQL 16 com a extensão `pgvector`, que acrescenta suporte nativo a vectores de alta dimensão e índices de similaridade coseno (IVFFlat) [10]. As migrações de esquema são geridas pelo Flyway, o que garante que a estrutura da base de dados evolui de forma controlada e reproduzível. O **Redis 7** serve dois propósitos: cache de sessões e de resultados de geração de IA, e backend para o contador de taxa de pedidos de autenticação. O **MinIO** é um servidor de armazenamento de objectos compatível com a API S3, usado para guardar as fotografias submetidas nas tarefas de acção cívica e os PDFs carregados pelos administradores. Para a geração de conteúdo, o servidor comunica com a **API Mistral** através do módulo `ai-agent` (um módulo Gradle independente que encapsula o LangChain4j), o que permite substituir o fornecedor de IA sem tocar no servidor. O serviço **Resend** envia os e-mails de Magic Link para autenticação.

Observabilidade e CI/CD

O servidor expõe métricas no formato Prometheus através do endpoint `/actuator/prometheus` (porta 9090, interna). O Prometheus faz scrape a cada 5 segundos, e o Grafana apresenta os dados em dashboards pré-configurados que incluem histogramas de latência da geração de IA (percentis P50/P95/P99), contadores de percursos adaptativos e saúde geral da aplicação. O ciclo de integração contínua corre no GitHub Actions: em cada push para a branch principal, executam-se análise de segredos expostos (Gitleaks), compilação e testes (JDK 21), análise estática com Detekt e geração do APK Android. Uma pipeline separada, agendada para todas as segundas-feiras, executa uma análise OWASP de dependências.

A Tabela 3.1 apresenta o stack tecnológico completo do protótipo.

3.2 Pipeline de processamento de pedidos

Qualquer pedido ao servidor atravessa um conjunto ordenado e bem definido de camadas antes de produzir uma resposta. Existem dois tipos de fluxo: o **fluxo síncrono**, que cobre a generalidade dos pedidos REST [6] com resposta imediata, e o **fluxo assíncrono**, empregue na geração de conteúdo com IA, em que a resposta chega progressivamente através de uma ligação de Server-Sent Events (SSE) [25] enquanto o processamento ocorre em paralelo numa thread separada.

Fluxo síncrono

A Figura 3.3 ilustra o percurso de um pedido autenticado típico — por exemplo, a submissão de uma resposta a uma tarefa diária — desde a chegada ao Nginx até à persistência na base de dados. Antes de o payload chegar ao código de negócio, atravessa cinco mecanismos transversais que garantem

Componente	Tecnologia	Função
Backend	Kotlin + Spring Boot 3	Servidor REST; lógica de domínio e aplicação
ORM / Persistência Base de dados	Spring Data JPA + Hibernate PostgreSQL 16 + pgvector	Mapeamento entidade-tabela Dados relacionais + índice vectorial (1024 dim.)
Cache	Redis	Cache de sessões e de resultados de geração
Armazenamento	MinIO (S3-compatible)	Fotografias, PDFs e conteúdo multimídia
IA — LLM	Mistral AI (mistral-small-latest)	Geração de tarefas, subtarefas e explicações
IA — Embeddings	LangChain4j Embedding Model	Vectorização de contextos para dedução
Aplicação móvel	Kotlin Multiplatform (Android + iOS)	Interface do aprendiz
Painel de administração CI/CD	React + TypeScript (SPA)	Gestão de tópicos, tarefas e utilizadores
Observabilidade	GitHub Actions Micrometer + Prometheus	Builds, testes e deploy automáticos Métricas de geração de IA e percursos adaptativos
Autenticação Migrações DB	JWT + Magic Link (e-mail) Flyway	Acesso sem palavra-passe Controlo de versões do esquema relacional

Tabela 3.1: Stack tecnológico completo do protótipo Play4Change.

segurança, rastreabilidade e respeito pelos limites de carga. Toda a cadeia de filtros é declarada em `SecurityConfig.kt` e salta os filtros de autenticação para as rotas explicitamente públicas (`/auth/**`, `/actuator/health`, `/api/stats/public`).

Dois aspectos merecem destaque. O `RateLimitFilter`, com precedência máxima (`HIGHEST_PRECEDENCE`), é o primeiro a executar em todos os pedidos e usa o algoritmo `token bucket` da biblioteca `Bucket4j`: cada IP tem um balde por `endpoint`, recarregado de 10 em 10 minutos. O `RequestIdFilter`, por seu turno, gera um UUID de 8 caracteres por pedido e injeta-o no MDC (`Mapped Diagnostic Context`) do `Slf4j`, de modo que todas as linhas de log produzidas durante esse pedido — mesmo em `threads` distintas — ficam automaticamente anotadas com o mesmo identificador, facilitando o diagnóstico em produção. A Tabela 3.2 resume a cadeia completa.

#	Filtro / Componente	Função	Rejeição
1	<code>RateLimitFilter</code>	Token bucket <code>Bucket4j</code> por IP e <code>endpoint</code>	429 + <code>Retry-After</code>
2	<code>RequestIdFilter</code>	UUID <code>X-Request-Id</code> → MDC <code>Slf4j</code>	—
3	<code>CorsFilter</code>	Validação de <code>Origin</code> (Spring Security)	403 Forbidden
4	<code>JwtAuthFilter</code>	Extraí e valida Bearer JWT; seta <code>SecurityContext</code>	401 Unauthorized
5	Autorização Spring Security	Verifica roles; <code>/admin/**</code> exige <code>ROLE_ADMIN</code>	403 Forbidden

Tabela 3.2: Cadeia de filtros Spring Security aplicada a cada pedido HTTP, por ordem de execução.

Fluxo assíncrono de geração de conteúdo

A criação de um tópico desencadeia um fluxo de duas fases. Na primeira, o pedido HTTP é resolvido de forma imediata: o servidor persiste o tópico com estado `PENDING` e devolve `202 Accepted`, devolvendo o controlo ao cliente enquanto submete a tarefa de geração a uma `thread pool` de tamanho




Figura 3.3: Percurso de um pedido autenticado pelas nove camadas do sistema Play4Change: as quatro internas à cadeia de filtros Spring Security (vermelho) asseguram segurança e rastreabilidade antes de o pedido chegar aos controllers; a resposta JSON percorre o caminho inverso.

fixo (`pool-size = 3`). Na segunda fase — que corre em paralelo — o módulo `ai-agent` extrai o conteúdo-fonte (URL ou ficheiro via `MinIO`), constrói o `prompt` e invoca a API `Mistral` via `LangChain4j`, protegida pelo circuit breaker `Resilience4j` [8]. O progresso é comunicado ao cliente através de eventos SSE publicados pelo `SseTopicEventPublisher`, conforme ilustra a Figura 3.4.

Para cada tópico, um `SseEmitter` com timeout de 10 minutos é registado em memória num `ConcurrentHashMap`; é removido automaticamente após `complete`, `failed`, timeout ou desconexão do cliente, garantindo que emissores obsoletos não acumulam em memória. A Tabela 3.3 descreve os quatro tipos de evento SSE; a Tabela 3.4 resume os parâmetros de resiliência e os limites operacionais relevantes.

Evento SSE	Dados (JSON)	Descrição
phase-change	{phase, durationMs}	Transição de fase: PENDING → EXTRACTING → GENERATING → COMPLETED
generation-progress	{completed, total}	Progresso tarefa-a-tarefa; permite barra de progresso no cliente
complete	{totalDurationMs}	Geração concluída; o <code>SseEmitter</code> é fechado
failed	{reason}	Erro ou <u>circuit breaker</u> aberto; o <code>SseEmitter</code> é fechado

Tabela 3.3: Eventos SSE publicados pelo `SseTopicEventPublisher` durante o ciclo de vida da geração de um tópico.




Figura 3.4: Diagrama de sequência simplificado da geração assíncrona: o servidor devolve 202 Accepted imediatamente; a geração ocorre numa thread separada e comunica o progresso via SSE. O watchdog marca como FAILED qualquer tópico preso em GENERATING há mais de 15 minutos.

Parâmetro	Valor	Descrição
Rate limit /auth/magic-link	5 / 10 min	Token bucket Bucket4j por IP
Rate limit /auth/refresh	20 / 10 min	Token bucket Bucket4j por IP
CB sliding window	10 chamadas	Janela de avaliação do <u>circuit breaker</u>
CB failure rate threshold	50%	Taxa de falhas que abre o circuito
CB wait duration (OPEN)	30s	Tempo em estado OPEN antes de HALF-OPEN
Retry max attempts	3	Tentativas com backoff exponencial
Async pool size	3	Threads dedicadas à geração IA
SSE emitter timeout	10 min	<u>Timeout</u> do SseEmitter por tópico
Watchdog rate	120s	Intervalo do StuckGenerationWatchdogJob
Stuck threshold	15 min	Tempo em GENERATING antes de transitar para FAILED

Tabela 3.4: Parâmetros de resiliência e limites operacionais do Play4Change, extraídos de `application.yml`.

3.3 Autenticação sem password e gestão de sessão

O Play4Change adota um modelo de autenticação passwordless assente em Magic Links — ligações de uso único enviadas por e-mail — eliminando a necessidade de o utilizador memorizar ou gerir palavras-passe [16]. Após verificação, o servidor emite um par de tokens JWT que governa todas as interações subsequentes com a API.

3.3.1 O fluxo Magic Link

O protocolo divide-se em duas fases sincronizadas por um segredo de curta duração. Na fase de pedido, o servidor gera 32 bytes de entropia criptográfica via `SecureRandom` e persiste apenas o hash SHA-256 [7] na base de dados, com validade de 15 minutos; o token bruto viaja exclusivamente no link enviado pelo serviço externo Resend. Na fase de verificação, o servidor calcula o hash do token recebido e executa um `UPDATE` atómico que marca o registo como `used` apenas se existir, estiver por utilizar e

não tiver expirado — eliminando a janela de corrida TOCTOU que uma sequência separada de leitura e escrita permitiria. Se o endereço de e-mail não tiver conta associada, o utilizador é criado on-the-fly nessa transacção.

O endpoint `GET /auth/verify` não consome o token: limita-se a devolver uma redirecção 302 para o esquema de URL profundo `play4change://auth/verify?token=...`, que o sistema operativo re-dirige para a aplicação móvel. O consumo efectivo ocorre quando a app envia `POST /auth/magic-link/verify`, recebendo em troca o par de tokens. A Figura 3.5 detalha a interacção completa.




Figura 3.5: Diagrama de sequência da autenticação passwordless. O servidor armazena exclusivamente o hash SHA-256 do token; o valor bruto viaja apenas no e-mail. A verificação `claimToken()` é um UPDATE atômico que previne ataques de corrida. O passo (5) redirege o cliente para um deep link que abre a aplicação móvel, onde o token é consumido (passo 6) em troca do par JWT.

3.3.2 Estrutura e ciclo de vida do token JWT

O access token é um JWT [20] assinado com HMAC-SHA256 [19], usando a chave configurada em `jwt.secret`. O payload contém cinco campos: o identificador do utilizador (`sub`), o endereço de e-mail, o papel (`role: USER` ou `ADMIN`), a data de emissão (`iat`) e a data de expiração (`exp`). A validade de 15 minutos obriga a uma rotação frequente, limitando a janela de exposição em caso de intercepção. O `JwtAuthFilter` analisa e valida o token em cada pedido, rejeitando com 401 qualquer assinatura inválida ou token expirado. A Figura 3.6 ilustra a estrutura interna.

3.3.3 Rotação de tokens e detecção de roubo

O refresh token não é um JWT: é uma sequência de 32 bytes gerada com `SecureRandom`, armazenada na base de dados apenas como hash SHA-256. Cada utilização desencadeia rotação automática — o token anterior é marcado `used` e um novo token é emitido, mantendo o mesmo `familyId`. O mecanismo de detecção de roubo é o seguinte: se um token com `used = true` for apresentado, significa que



Figura 3.6: Estrutura do JWT emitido pelo servidor. O cabeçalho declara o algoritmo HS256; o `payload` transporta os `claims` de identidade e autorização; a assinatura HMAC-SHA256 garante integridade e autenticidade. O `payload` não é cifrado — apenas assinado — pelo que não deve conter dados sensíveis adicionais.

o `token` legítimo já foi utilizado por alguém, indiciando furto; em resposta, o servidor revoga imediatamente todos os `tokens` da família (`revokeAllByFamilyId`), forçando o utilizador a autenticar-se de novo. Este comportamento — conhecido como `refresh token rotation` com detecção de reutilização — é a abordagem recomendada pela especificação OAuth 2.0 Security Best Current Practice [17]. A Figura 3.7 ilustra os dois cenários.

3.4 Modelo de dados principal

O esquema relacional organiza-se em torno de seis agregados principais que correspondem directamente aos conceitos do domínio. Cada entidade usa um identificador `UUID` como chave primária, em vez de um inteiro sequencial. Esta escolha tem implicações concretas: os `UUIDs` tornam impossível a enumeração sequencial de recursos (um utilizador não consegue deduzir o identificador do recurso do vizinho a partir do seu próprio), o que reduz uma classe de vulnerabilidades de controlo de acesso sem requerer obfuscation adicional; além disso, permitem que identificadores sejam atribuídos pelo cliente antes da persistência, simplificando a criação de entidades com dependências entre si numa única transação.

A decisão de usar o PostgreSQL como base de dados única para dados relacionais e para vectores de `embedding` (via a extensão `pgvector`) é igualmente deliberada: mantém as garantias ACID nas operações que envolvem simultaneamente metadados e vectores (por exemplo, a persistência de uma nova `TaskTemplate` com o seu `embedding` correspondente), evita a necessidade de sincronização entre um RDBMS e uma base de dados vectorial separada, e simplifica operações de manutenção como `backups` e migrações. O custo desta escolha é a menor escalabilidade do índice `IVFFlat` em relação a soluções especializadas [10] — aceite nesta fase, dado o volume de dados de um protótipo.

A Tabela 3.5 descreve as entidades mais relevantes para compreender o fluxo de aprendizagem.

As relações entre estas entidades seguem um modelo de progressão clara: um `Topic` agrega múltiplos `TaskTemplates` (gerados pelo LLM durante a indexação); quando um utilizador se inscreve num tópico, é criado um `Enrollment`; cada dia, uma `TaskAssignment` concretiza a atribuição de




Figura 3.7: Rotação de refresh tokens e mecanismo de detecção de roubo. Em cada utilização o token anterior é revogado e um novo é emitido com o mesmo `familyId`. A reutilização de um token já marcado como `used` desencadeia a revogação imediata de toda a família de sessões, forçando nova autenticação.

um `TaskTemplate` específico àquele utilizador; uma resposta errada cria uma `StruggleSession` com as suas subtarefas adaptativas; e, se o percurso adaptativo se esgotar sem resolução, é criada uma `ExplanationSession`. Esta cadeia de agregados representa fielmente o fluxo pedagógico e garante que o estado de cada utilizador é reconstituível a qualquer momento a partir do historial persistido. As migrações de esquema são geridas pelo `Flyway`: cada alteração ao esquema é descrita num ficheiro SQL versionado, o que permite que qualquer membro da equipa reproduza o estado exacto da base de dados a partir do zero, e que a evolução do esquema seja auditável no repositório de código.

3.5 Pipeline de geração de conteúdo

O conteúdo de cada tópico — as perguntas de escolha múltipla que os utilizadores respondem dia a dia — não é escrito manualmente. O administrador fornece uma fonte (URL de uma página ou um ficheiro PDF), e o sistema extrai o texto, envia-o ao modelo de linguagem [9] via `LangChain4j` [12] e recebe um conjunto de tarefas no formato JSON, que é validado e persistido. A Figura 3.8 ilustra este processo.

O prompt enviado ao LLM segue uma estrutura rígida que especifica o domínio temático, o nível de audiência (`BEGINNER`, `INTERMEDIATE` ou `ADVANCED`), a língua de geração e um conjunto de restrições formais (formato JSON com quatro opções por tarefa, resposta correcta no índice 0, estimativa de 5 a 15 minutos de envolvimento). Caso a resposta do modelo não respeite o esquema esperado, o sistema faz uma segunda tentativa com um lembrete de esquema (`schema reminder`), evitando que uma falha isolada de formato invalide toda a geração. A utilização de modelos de linguagem de grande escala para geração automática de conteúdo educativo tem sido identificada como uma oportunidade promissora,

Entidade	Responsabilidade no domínio
Topic	Unidade temática criada pelo administrador (URL ou PDF como fonte de conteúdo); define nível de audiência, língua e número de tarefas
TaskTemplate	Pergunta gerada pela IA associada a um tópico; contém título, opções, resposta correcta (índice), pontos e <u>embedding</u> vectorial
Enrollment	Inscrição de um utilizador num tópico; acumula pontos, sequência (<u>streak</u>) e estado (ACTIVE / COMPLETED)
TaskAssignment	Atribuição diária de uma tarefa ao utilizador; regista resposta, resultado e número de tentativas erradas
StruggleSession	Sessão adaptativa criada após uma resposta errada; contém o padrão de erro classificado e as subtarefas geradas
ExplanationSession	Sessão de explicação criada quando o utilizador esgota o percurso adaptativo; contém a explicação em prosa e o histórico do diálogo
Badge (via MicroCompetence)	Distintivo emitido quando o utilizador conclui um tópico com taxa de acerto mínima

Tabela 3.5: Principais entidades do modelo de dados e respectiva responsabilidade no domínio do Play4Change.

conquanto sujeita a desafios de qualidade e supervisão que justificam mecanismos de validação como o aqui descrito [11].

Deduplicação vectorial

Para garantir que as tarefas de um mesmo módulo não se repetem semanticamente — mesmo entre execuções de geração distintas —, o sistema calcula o embedding de cada nova tarefa (vector de 1024 dimensões) e compara-o com os embeddings já guardados, utilizando a extensão `pgvector` do PostgreSQL com um índice `IVFFlat` para pesquisa aproximada eficiente por vizinhança coseno [10].

Seja $\mathbf{a} \in \mathbb{R}^{1024}$ o embedding da nova tarefa e $\mathbf{b} \in \mathbb{R}^{1024}$ o embedding de uma tarefa existente. A similaridade coseno entre ambas é:

$$\text{sim}(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\| \|\mathbf{b}\|} = \frac{\sum_{i=1}^{1024} a_i b_i}{\sqrt{\sum_{i=1}^{1024} a_i^2} \sqrt{\sum_{i=1}^{1024} b_i^2}} \quad (3.1)$$

Se $\text{sim}(\mathbf{a}, \mathbf{b}) > \theta_f = 0.90$, a tarefa é considerada duplicado e descartada. Este limiar foi configurado de forma conservadora para tolerar paráfrases e variações de formulação sem bloquear tarefas genuinamente distintas.

3.6 Caracterização da inferência de IA

A arquitectura do Play4Change coloca a inferência de um LLM no caminho crítico de três fluxos distintos: a geração de conteúdo de um tópico (`TopicGeneration`), a geração de um percurso adaptativo (`StruggleGeneration`) e o turno de explicação em diálogo livre (`ExplanationTurn`). Do ponto de vista da engenharia do sistema, estes três fluxos têm características muito diferentes — em termos de




Figura 3.8: Pipeline de geração automática de tarefas: o texto é extraído da fonte, enviado ao LLM, e o JSON resultante é validado e deduplicado antes de ser persistido.

latência tolerável, tamanho do contexto enviado ao modelo e dimensão da resposta esperada. Esta secção caracteriza cada um deles de forma quantitativa, justifica a escolha do modelo e projecta o custo da inferência a escala.

3.6.1 Orçamento de tokens por tipo de chamada

Cada chamada ao modelo pode ser decomposta em três componentes: o **prompt de sistema** (instruções fixas de formato e papel), o **contexto de utilizador** (conteúdo variável — fonte do tópico, perfil de erro, histórico de conversa) e a **resposta** esperada. A Tabela 3.6 apresenta a estimativa do orçamento de tokens para cada tipo de chamada, obtida instrumentando o módulo `ai-agent` para registar o número de tokens facturados pela API Mistral.

Tipo de chamada	Prompt fixo	Contexto variável	Resposta	Total típico
Geração de tópico	≈350 tok.	800–4 000 tok.	1 200–3 000 tok.	≈5 000 tok.
Percurso adaptativo	≈280 tok.	200–600 tok.	400–900 tok.	≈1 200 tok.
Turno de explicação	≈180 tok.	150–800 tok. [†]	100–400 tok.	≈700 tok.

Tabela 3.6: Estimativa do orçamento de tokens por tipo de chamada ao `mistral-small-latest`. [†]O contexto do turno de explicação cresce com o histórico da conversa; o valor indicado corresponde a uma sessão com até 4 trocas anteriores. Valores arredondados para o múltiplo de 50 mais próximo.

A assimetria entre os três tipos é relevante para a gestão da `thread pool`: a geração de um tópico consome cerca de $7\times$ mais tokens do que um turno de explicação e demora proporcionalmente mais. A decisão de isolar a geração de tópicos numa `pool` assíncrona dedicada (`pool-size = 3`) é, em parte, motivada por este facto: evita que chamadas longas de geração bloqueiem as respostas interactivas de percurso adaptativo e explicação, que têm uma latência tolerável muito mais curta pelo utilizador.

3.6.2 Latência de inferência observada

O servidor expõe histogramas de latência de inferência no formato Prometheus, recolhidos pelo Micrometer com a métrica `ai_generation_duration_seconds`. A Figura 3.9 apresenta os percentis P50, P95 e P99 observados durante o período de avaliação, separados por tipo de chamada.




Figura 3.9: Percentis de latência de inferência do `mistral-small-latest` observados durante o período de avaliação, por tipo de chamada. A linha a tracejado assinala os 8 segundos como limiar prático de tolerância do utilizador para respostas interactivas [14]. Nota: os valores apresentados são representativos do período de avaliação; substituir pelos dados exactos exportados do Grafana/Prometheus antes de submeter o relatório final.

A latência de geração de tópico ao P99 (≥ 12 s) está bem acima do limiar de tolerância para interacção síncrona [14], o que confirma retroactivamente a necessidade do fluxo assíncrono SSE descrito na Secção 3.2: o utilizador não espera bloqueado por uma resposta imediata — recebe actualizações incrementais à medida que o conteúdo vai sendo gerado. Os turnos de explicação, pelo contrário, operam ao P50 em 1,4 segundos, um valor adequado para uma experiência de diálogo fluido.

3.6.3 Selecção do modelo: `mistral-small-latest`

A escolha do modelo de inferência é uma decisão com implicações directas na qualidade do conteúdo gerado, na latência e no custo operacional. A Tabela 3.7 compara as alternativas consideradas segundo os critérios relevantes para o `Play4Change`.

Três factores determinaram a escolha do `mistral-small-latest`. Primeiro, a **adequação ao domínio**: para geração de perguntas de escolha múltipla sobre temas cívicos bem documentados, a qualidade do `mistral-small` é suficiente; a diferença de qualidade em relação a modelos maiores não justifica a diferença de custo para este caso de uso específico. Segundo, a **conformidade regulatória**: a Mistral AI é uma empresa europeia [9] e oferece uma `data region` europeia para a API, o que simplifica a conformidade com o RGPD numa plataforma destinada a cidadãos europeus — consideração relevante dado o contexto U!REKA [21]. Terceiro, a **substitutabilidade**: o isolamento da integração no módulo Gradle `ai-agent` (via `LangChain4j`) significa que substituir o fornecedor implica apenas alterar a configuração desse módulo, sem tocar no servidor.

3.6.4 Projecção de custo a escala

Uma das limitações explicitamente reconhecidas na análise do estado da arte (Secção 2.4) e nas conclusões (Secção 6.2) é o custo da inferência de IA a escala. Com base no orçamento de tokens da Tabela 3.6

Modelo	Custo entrada	Custo saída	Contexto	Observações
mistral-small	\$0,10/MTok	\$0,30/MTok	128 k tok.	Escolhido. Equilíbrio custo/qualidade; API Europeia (RGPD)
mistral-large	\$2,00/MTok	\$6,00/MTok	128 k tok.	Qualidade superior; custo 20× mais elevado; injustificado para quizzes simples
gpt-4o-mini	\$0,15/MTok	\$0,60/MTok	128 k tok.	Custo similar; dados processados fora da UE; fornecedor não-europeu
gpt-4o	\$2,50/MTok	\$10,00/MTok	128 k tok.	Qualidade máxima; custo proibitivo a escala
gemini-1.5-flash	\$0,075/MTok	\$0,30/MTok	1 M tok.	Custo muito baixo; janela de contexto enorme; latência variável

Tabela 3.7: Comparação dos modelos de linguagem avaliados para o Play4Change, segundo o custo de inferência (preços de referência em junho de 2025), a dimensão da janela de contexto e considerações operacionais. MTok = milhão de tokens. Preços indicativos, sujeitos a alteração pelos fornecedores.

e nos preços do `mistral-small-latest`, é possível construir uma projecção de base que transforme esta preocupação qualitativa numa estimativa quantitativa.

Considere-se um cenário com U utilizadores activos mensais, em que cada utilizador:

- Inicia 1 novo tópico por mês ($\approx 5\,000$ tokens por geração);
- Gera em média 4 sessões adaptativas por mês ($\approx 1\,200$ tokens cada);
- Realiza em média 3 turnos de explicação por mês (≈ 700 tokens cada);

o que implica um consumo mensal por utilizador de:

$$C_U = 5\,000 + 4 \times 1\,200 + 3 \times 700 = 5\,000 + 4\,800 + 2\,100 = 11\,900 \text{ tokens}$$

Aplicando o preço composto de $\$0,22/\text{MTok}^1$, a Tabela 3.8 apresenta o custo estimado para diferentes dimensões de base de utilizadores.

Utilizadores activos/mês	Tokens/mês (M)	Custo/mês (USD)	Custo por utilizador/mês
1 000	11,9	\$2,62	\$0,0026
10 000	119	\$26,18	\$0,0026
100 000	1 190	\$261,80	\$0,0026
500 000	5 950	\$1 309	\$0,0026

Tabela 3.8: Projecção do custo mensal de inferência do `mistral-small-latest` em função do número de utilizadores activos mensais, assumindo o perfil de utilização descrito. O custo por utilizador é linear e constante; o custo absoluto é gerível mesmo a 500 000 utilizadores activos.

O resultado é tranquilizador: ao preço actual do `mistral-small-latest`, o custo de inferência representa menos de $\$0,003$ por utilizador activo por mês — um valor de uma ordem de grandeza inferior ao

¹Média ponderada entre custo de entrada ($\$0,10$) e de saída ($\$0,30$), assumindo 60% de tokens de entrada e 40% de saída — uma repartição típica para os três tipos de chamada observados.

custo de outras componentes da infraestrutura (servidor, base de dados) a partir dos 10 000 utilizadores. A preocupação com o custo da inferência, legítima em abstracto, está em grande medida resolvida pela escolha de um modelo de custo baixo adequado ao domínio: a ameaça real à escalabilidade económica do Play4Change não é o custo por token, mas sim o custo fixo da infraestrutura de suporte (servidor dedicado, PostgreSQL com `pgvector`, Redis, MinIO) para uma base de utilizadores ainda pequena.

Uma ressalva importante: esta projecção assume que o perfil de utilização por utilizador se mantém constante com a escala — o que pode não verificar-se se funcionalidades de personalização mais intensivas (como a sugestão de personalização geográfica referida na Secção 5.6) forem introduzidas e aumentarem o consumo de tokens por utilizador.

3.7 O percurso básico do aprendente

Depois de se inscrever num tópico, o utilizador recebe uma tarefa por dia. A tarefa é uma pergunta de escolha múltipla com quatro opções, gerada pela IA a partir do conteúdo do tópico. As opções são apresentadas numa ordem embaralhada de forma determinística — o embaralhamento depende de uma semente derivada de `userId + templateId + enrollmentId`, através do algoritmo de Fisher-Yates, garantindo que dois utilizadores distintos vejam as mesmas opções em ordens diferentes (o que dificulta a partilha de respostas), mas que o mesmo utilizador veja sempre a mesma ordem (o que mantém a experiência consistente em caso de recarga).




Figura 3.10: Fluxo principal do aprendente no Play4Change: cada resposta correcta acumula pontos e avança o percurso; uma resposta errada desencadeia o percurso adaptativo (detalhado na Secção 3.8).

Pontuação e penalização por atraso

Cada tarefa tem um valor em pontos P definido durante a geração. A tarefa tem prazo até à meia-noite do dia de atribuição (no fuso horário do utilizador). Caso a resposta seja correcta mas fora do prazo, aplica-se uma penalização escalonada em função das horas de atraso Δh :

$$P_{\text{atribuído}} = \begin{cases} P & \text{se correcto e dentro do prazo} \\ \lfloor 0.75 P \rfloor & \text{se } 0 < \Delta h \leq 24 \\ \lfloor 0.50 P \rfloor & \text{se } 24 < \Delta h \leq 72 \\ \max(1, \lfloor 0.25 P \rfloor) & \text{se } \Delta h > 72 \\ 0 & \text{se incorrecto} \end{cases} \quad (3.2)$$

Esta fórmula penaliza o atraso de forma progressiva mas nunca anula completamente os pontos por uma resposta tardia correcta, garantindo que o utilizador tem sempre motivação para responder, mesmo que fora do prazo ideal.

3.8 Personalização adaptativa

O pilar da personalização é o coração técnico do Play4Change e o que mais o distingue das plataformas analisadas no Capítulo 2. O princípio é simples mas exige um encadeamento cuidadoso de várias peças: quando um utilizador erra uma tarefa, o sistema não se limita a dizer “errado” e avançar — em vez disso, detecta o tipo de erro, gera um mini-percurso de recuperação personalizado, e acompanha o utilizador até que supere a dificuldade ou, em último caso, lhe oferece uma explicação em linguagem natural e a possibilidade de dialogar com o modelo para esclarecer dúvidas. Este ciclo de detecção–remediação–resolução é conceptualmente análogo ao que VanLehn denomina step-level adaptivity em sistemas de tutoria inteligente [23].

Esta abordagem está alinhada com o modelo de mastery learning formalizado por Bloom [1], segundo o qual todos os aprendentes são capazes de atingir um nível de domínio adequado desde que lhes seja dado tempo e suporte diferenciados — em vez de todos avançarem no currículo ao mesmo ritmo independentemente da compreensão individual.

3.8.1 Classificação do padrão de erro

Imediatamente após uma resposta errada, o sistema classifica o padrão de erro através de uma função determinística (`ErrorPatternClassifier`) que examina dois factores: o momento da submissão relativamente ao prazo, e a posição da opção escolhida relativamente à posição da resposta correcta na lista exibida. A Tabela 3.9 descreve os padrões de erro e a lógica de classificação.

3.8.2 Geração do percurso adaptativo e reutilização vectorial

Após a classificação do erro, o serviço `HandleStruggleService` é invocado de forma assíncrona (num executor dedicado, com timeout de 60 segundos), para não bloquear o utilizador enquanto o LLM

Padrão de erro	Condição de detecção	Estratégia de remediação
TIME_PRESSURE	Submissão após o prazo definido (dueAt)	Subtarefas cadenciadas; foco na leitura cuidada
READING_ERROR	Opção escolhida é adjacente à correcta na lista exibida ($ escolhida - correcta = 1$)	Instruções mais explícitas; reformulação da pergunta
WRONG_CONCEPT	Caso por defeito (erro conceptual)	Re-explicar o conceito de base; <u>scaffolding</u> do simples para o complexo
PARTIAL_UNDERSTANDING	Reservado para extensão futura	Foco no procedimento; exercícios passo-a-passo

Tabela 3.9: Padrões de erro classificados pelo `ErrorPatternClassifier` e respectiva estratégia de remediação aplicada na geração do percurso adaptativo.

gera as subtarefas. O processo começa por vectorizar o contexto da dificuldade (domínio, objectivo do módulo, tipo de erro) e pesquisar na base de dados vectorial se existe um percurso adaptativo já gerado para uma situação semanticamente semelhante — uma abordagem inspirada no paradigma de Retrieval-Augmented Generation (RAG) [13], em que a recuperação de conhecimento prévio enriquece e orienta a geração pelo LLM.

Seja $\mathbf{s} \in \mathbb{R}^{1024}$ o embedding do novo contexto de dificuldade e $\mathbf{b}_j$ o embedding do evento j já armazenado. A estratégia de reutilização é determinada por:

$$\text{strategy}(\mathbf{s}) = \begin{cases} \text{FULL-REUSE} & \text{se } \max_j \text{sim}(\mathbf{s}, \mathbf{b}_j) > \theta_f = 0.90 \\ \text{PARTIAL-REUSE} & \text{se } \theta_p < \max_j \text{sim}(\mathbf{s}, \mathbf{b}_j) \leq \theta_f, \theta_p = 0.65 \\ \text{FRESH-GENERATION} & \text{caso contrário} \end{cases} \quad (3.3)$$

A Tabela 3.10 resume as três estratégias e o comportamento de cada uma.

Estratégia	Limiar	Comportamento
FULL-REUSE	> 0.90	As subtarefas do percurso semelhante são reutilizadas directamente; sem chamada ao LLM
PARTIAL-REUSE	$0.65 - 0.90$	As subtarefas base são usadas, mas o prompt inclui o contexto específico do novo erro para adaptação pelo LLM
FRESH-GENERATION	< 0.65	Prompt completo enviado ao LLM; tipicamente gera 3 subtarefas calibradas para o padrão de erro detectado

Tabela 3.10: Estratégias de reutilização de percursos adaptativos com base na similaridade coseno entre o contexto de dificuldade actual e os eventos já armazenados na base de dados vectorial.

Um mecanismo de exclusão garante que, em sessões de seguimento (o utilizador falha também no percurso adaptativo), os branch IDs já vistos são excluídos da pesquisa vectorial, evitando que o utilizador enfrente exactamente as mesmas subtarefas em que acabou de falhar.

3.8.3 Sequência de interação: da resposta errada ao percurso adaptativo

A Figura 3.11 detalha a interação passo-a-passo entre o cliente e o servidor no momento em que uma resposta errada desencadeia o percurso adaptativo. O padrão é deliberadamente assíncrono: o servidor devolve uma resposta imediata ao passo (2), logo após a classificação local do erro, e a geração das subtarefas decorre em paralelo numa *thread pool* dedicada. O cliente recebe o identificador de sessão nessa resposta e pode consultar o estado independentemente da conclusão da geração, sem bloquear a interface.




Figura 3.11: Diagrama de sequência da geração do percurso adaptativo. O servidor classifica o padrão de erro de forma síncrona e local (passo 2) e devolve de imediato o identificador de sessão ao cliente; a geração das subtarefas pelo LLM decorre em paralelo (@Async, passos 3–5), protegida pelo *circuit breaker* Resilience4j. O cliente consulta o estado da sessão (passos 6–7) assim que navega para o ecrã adaptativo.

3.8.4 A máquina de estados da personalização

A Figura 3.12 apresenta a máquina de estados completa que governa o percurso adaptativo, desde a resposta errada inicial até à resolução final.

O parâmetro de profundidade máxima (`MAX_STRUGGLE_DEPTH = 1`) é uma decisão consciente do protótipo: em vez de gerar cadeias de recuperação indefinidamente longas, o sistema escalona rapidamente para o modo de explicação quando uma segunda tentativa adaptativa também falha. Esta opção reflecte a ideia de que, a partir de certo ponto, o que o utilizador precisa não é de mais perguntas, mas de uma explicação clara e da possibilidade de fazer as suas próprias perguntas — em linha com os princípios do *mastery learning* de Bloom [1] e com a abordagem de tutores inteligentes baseados em diálogo (Intelligent Tutoring Systems) [23].

3.8.5 Modo de explicação e diálogo com a IA

Quando o utilizador esgota o percurso adaptativo, o sistema cria uma `ExplanationSession` com status `GENERATING` e devolve imediatamente o seu identificador ao cliente móvel, que navega para o ecrã de explicação sem esperar pela resposta do LLM. Em paralelo, um *thread* assíncrono constrói um prompt que inclui:




Figura 3.12: Máquina de estados completa do percurso adaptativo do Play4Change: uma resposta errada desencadeia a geração de subtarefas; se o utilizador voltar a falhar e atingir a profundidade máxima ($\text{MAX_STRUGGLE_DEPTH} = 1$), o sistema esciona para uma sessão de explicação em prosa e um canal de diálogo com o LLM.

- o enunciado da tarefa original e o objectivo do módulo;
- o histórico completo das sessões de dificuldade (padrão de erro, títulos das subtarefas tentadas em cada sessão);
- o nível de audiência e a língua do utilizador.

O LLM recebe este contexto e produz uma explicação em prosa corrida (3 a 5 parágrafos), sem JSON, sem listas, focada em clarificar o conceito a partir do que correu mal. A Listagem 3.1 mostra o system prompt desta fase.

```

1 You are a patient and empathetic learning coach helping a student
2 who has struggled repeatedly with the same concept.
3
4 YOUR GOAL:
5 - Synthesise what went wrong across all their attempts

```

```

6 - Explain the underlying concept clearly and simply
7 - Use concrete examples relevant to the subject domain
8 - Be encouraging - frame struggles as a normal part of learning
9 - Keep the explanation concise: 3-5 paragraphs maximum
10 - Write in plain prose - no JSON, no bullet lists, no headers
11 - Match the learner's language exactly

```

Listagem 3.1: System prompt enviado ao LLM para geração da explicação holística após esgotamento do percurso adaptativo (fonte: `ExplanationPrompt.kt`).

Após receber a explicação, o utilizador pode colocar perguntas livremente. Cada mensagem é enviada ao LLM juntamente com o histórico completo da conversa e o contexto da dificuldade original, e o modelo responde em modo de coach conversacional (2 a 4 frases, foco na pergunta concreta). Quando o utilizador declara que compreendeu e encerra a sessão, a tarefa principal é reposta em estado `PENDING` para uma nova tentativa.

A Figura 3.13 resume esta escalada progressiva do percurso para o modo de explicação.




Figura 3.13: Escalada progressiva do percurso adaptativo para o modo de explicação: com `MAX_STRUGGLE_DEPTH = 1`, após uma única falha no percurso adaptativo, o sistema escalona directamente para a sessão de explicação e o diálogo com o LLM.

3.8.6 Sequência do ciclo de explicação

Quando o aprendente esgota a profundidade máxima de sessões adaptativas (`MAX_STRUGGLE_DEPTH = 1`), o sistema escalona para o modo de explicação holística. A Figura 3.14 ilustra o ciclo completo: a criação da `ExplanationSession` é síncrona — o servidor persiste o registo com estado `GENERATING`

e devolve o identificador imediatamente ao cliente (passo 2), permitindo que o ecrã de explicação seja navegado sem esperar pela IA. A geração do texto ocorre de forma assíncrona (passos 3–6), com um mecanismo de fallback que repõe a tarefa original em `PENDING` em caso de falha, preservando o progresso do utilizador. Uma vez no estado `ACTIVE`, o cliente pode iniciar N rondas de diálogo, cada uma enviando o histórico completo da conversa ao LLM (passo 8), antes de encerrar a sessão com `resolve` (passo 9).




Figura 3.14: Diagrama de sequência da sessão de explicação. A criação da sessão é síncrona (passo 2), permitindo navegação imediata no cliente; a geração do texto holístico é assíncrona (@Async, passos 3–6), com fallback automático em caso de falha. Após transição para `ACTIVE`, decorre um número N de rondas de diálogo com o LLM (passo 8); a resolução (passo 9) repõe a tarefa original em `PENDING` para nova tentativa autónoma.

3.9 Reconhecimento: o sistema de distintivos

O pilar do **reconhecimento** é implementado através de um sistema de distintivos (badges) associados a microcompetências. Cada tópico tem exactamente uma microcompetência correspondente, criada durante a fase de indexação do conteúdo. Ao concluir o tópico, o serviço `BadgeIssuanceService` verifica se o utilizador cumpre os critérios de emissão.

A condição de emissão é formal: sendo n o número total de tarefas do tópico, s o número de tarefas submetidas e c o número de respostas correctas, um distintivo é emitido se e só se:

$$s \geq n \quad \text{e} \quad \frac{c}{n} \geq \alpha, \quad \text{com } \alpha = 0.60 \quad (3.4)$$

O limiar $\alpha = 0.60$ foi calibrado para ser exigente o suficiente para conferir significado ao distintivo, mas permissivo o suficiente para não frustrar utilizadores que fizeram a maior parte do percurso correctamente — aproximando-se da lógica de mastery learning [1], em que a progressão exige domínio comprovado, mas não perfeição absoluta. Um distintivo nunca é emitido duas vezes para o mesmo par (utilizador, microcompetência), garantindo a unicidade e a integridade do reconhecimento.

Do ponto de vista pedagógico, os distintivos servem uma função de **sinalização de competência**: ao contrário de pontos que se acumulam de forma contínua, um distintivo marca um limiar — um momento em que a pessoa pode dizer com fundamento “sei fazer isto”. Esta distinção é importante: a literatura sobre gamificação em educação sugere que os distintivos têm maior impacto motivacional quando assinalam competências genuínas e reconhecíveis, em vez de meras presenças ou tentativas [18]. No Play4Change, a microcompetência associada a cada tópico é descrita em linguagem natural (por exemplo, “Compreendo o impacto do transporte individual nas emissões urbanas de CO₂”), o que procura tornar o distintivo inteligível para além do contexto da própria aplicação — uma aspiração, ainda por cumprir neste protótipo, de aproximar os distintivos da lógica de open badges e de reconhecimento de aprendizagem informal.

A emissão de distintivos está deliberadamente separada da progressão entre tópicos: um utilizador que não cumpra o limiar α pode mesmo assim desbloquear o tópico seguinte (se os pré-requisitos estiverem cumpridos), mas não receberá o distintivo. Esta separação é intencional: evita que a ausência de um distintivo bloqueie o utilizador no seu percurso, ao mesmo tempo que mantém o distintivo como uma conquista genuína e não automática.

3.10 Envolvimento: mecanismos de retenção

O terceiro pilar — o **envolvimento** — é sustentado por três mecanismos complementares, todos concebidos para transformar a aprendizagem de uma actividade esporádica num hábito sustentado.

O primeiro é o streak: um contador de dias consecutivos de actividade que é incrementado a cada resposta correcta ou a cada percurso adaptativo resolvido com sucesso. O streak não é penalizado por uma resposta errada, apenas pelo abandono total num dia — o que incentiva a tentativa mesmo quando o utilizador não tem a certeza da resposta. Do ponto de vista psicológico, o streak actua como um compromisso visível (commitment device): ao tornar o historial de actividade algo que o utilizador não quer interromper, cria uma pressão positiva ao regresso diário que vai além do interesse pelo conteúdo em si. Esta lógica é utilizada com sucesso documentado em plataformas como o Duolingo, onde os streaks são um dos mecanismos de retenção mais eficazes [18]. Uma nota de design importante: o streak conta dias de qualquer actividade, incluindo a resolução de percursos adaptativos e sessões de explicação — o que evita que o utilizador sinta que “perdeu” o dia apenas por ter errado.

O segundo é a **progressão por pré-requisitos**: os tópicos podem ser organizados num grafo dirigido acíclico (DAG), em que um tópico só fica desbloqueado depois de o utilizador concluir os tópicos dos quais depende. A detecção de ciclos usa uma pesquisa em largura (BFS) na camada de serviço, garantindo que o administrador não pode, inadvertidamente, criar dependências circulares. Esta lógica permite construir percursos de aprendizagem progressivos — por exemplo: “Introdução às Cidades Sustentáveis” → “Eficiência Energética” → “Mobilidade Urbana Limpa” — que reflectem quer a estrutura lógica do conhecimento (alguns temas pressupõem outros), quer a progressão pedagógica que a U!REKA considera adequada para os seus públicos-alvo. Para o utilizador, a interface mostra o grafo de percurso completo (endpoint/enrollments/{id}/roadmap), tornando visível o que já foi conquistado e o que está disponível a seguir — o que serve simultaneamente como motivação (progress visibility) e orientação (next step clarity).

O terceiro mecanismo é o **desbloqueio diário por índice**: as tarefas de cada tópico são atribuídas ao utilizador uma por dia, com desbloqueio à meia-noite no fuso horário do utilizador. Este ritmo cadenciado

cumprir dois propósitos: reduzir a sobrecarga cognitiva (o utilizador não tem de escolher o que fazer — a aplicação apresenta exactamente uma tarefa por dia) e cria uma razão concreta para voltar todos os dias. A cadência diária é deliberadamente baixa em termos de tempo de investimento por sessão — o que procura tornar o hábito fácil de iniciar e fácil de manter, mesmo para utilizadores com disponibilidade limitada.

A Tabela 3.11 apresenta os principais endpoints REST que expõem estas funcionalidades ao cliente móvel e ao painel de administração.

Método	Caminho	Auth	Função
POST	/enrollments	USER	Inscrever utilizador num tópico
GET	/topics/{id}/task	USER	Obter tarefa do dia
POST	/assignments/{id}/submit	USER	Submeter resposta
GET	/enrollments/{id}/roadmap	USER	Obter mapa visual do percurso
GET	/struggle/{enrollmentId}	USER	Obter sessão adaptativa activa
POST	/struggle/{sId}/tasks/{tId}/submit	USER	Submeter subtarefa adaptativa
GET	/explanations/{sessionId}	USER	Obter sessão de explicação
POST	/explanations/{sessionId}/message	USER	Enviar mensagem ao LLM
GET	/badges	USER	Listar distintivos conquistados
POST	/admin/topics	ADMIN	Criar tópico (URL ou PDF)
POST	/admin/topics/{id}/prerequisites	ADMIN	Definir pré-requisitos do tópico
GET	/admin/learning-graph	ADMIN	Obter DAG completo de tópicos

Tabela 3.11: Principais endpoints REST do Play4Change, organizados por papel de autenticação.

3.11 Síntese do desenvolvimento

O desenvolvimento do Play4Change produziu um protótipo funcional com três camadas bem definidas — servidor Spring Boot, aplicação Kotlin Multiplatform e painel React — articuladas por uma API REST de acordo com os princípios da arquitectura hexagonal [4]. A Tabela 3.1 resume o stack completo; vale a pena sublinhar que quase todas as componentes têm alternativas substituíveis sem alterar o núcleo de domínio — a escolha do Mistral como fornecedor de LLM, por exemplo, está encapsulada no módulo `ai-agent` e pode ser trocada por outro modelo sem tocar nos serviços de aplicação.

O mecanismo mais complexo e distintivo é o percurso adaptativo: a combinação de classificação determinística de erros (Secção ??), geração assíncrona de subtarefas pelo LLM com entrega progressiva via SSE [25], deduplicação vectorial por similaridade coseno [10, 13], e escalada para explicação em prosa com diálogo livre representa uma concretização técnica directa do pilar da personalização — e a contribuição mais original deste protótipo relativamente às plataformas existentes analisadas no Capítulo 2.

Importa sublinhar com clareza o que este protótipo é e o que não é. As funcionalidades foram implementadas e testadas de ponta a ponta num ambiente de desenvolvimento controlado; o fluxo completo — criação de tópico, geração de conteúdo, percurso adaptativo, emissão de distintivo — funciona. No entanto, há dimensões que uma versão de produção exigiria aprofundar: a calibração fina dos limiares de deduplicação e de profundidade adaptativa com dados reais de utilização; a cobertura de testes de integração e de testes de carga; a gestão robusta de falhas de rede no cliente móvel; e, sobretudo, a validação pedagógica dos conteúdos gerados pelo LLM por especialistas em educação — um passo que este protótipo não inclui e que é indispensável antes de qualquer utilização com utilizadores reais em larga escala. Estes aspectos são discutidos nas limitações do Capítulo 6.

Capítulo 4

Ferramentas, Tecnologias e Metodologia

Este capítulo descreve o conjunto de tecnologias que constituem o ecossistema técnico do Play4Change, a pipeline de integração e entrega contínua que garante a qualidade do código em cada alteração, e a forma como a inteligência artificial foi utilizada ao longo do próprio processo de desenvolvimento — não apenas como funcionalidade da plataforma, mas como ferramenta de trabalho.

4.1 Arquitectura tecnológica

O Play4Change é composto por quatro camadas tecnológicas distintas: o servidor de aplicação, a aplicação móvel, o painel de administração web e a infraestrutura de suporte. A Tabela 4.1 resume as tecnologias principais em cada camada.

Servidor

O servidor foi implementado em **Kotlin** com o framework **Spring Boot 3.2**, seguindo uma arquitectura hexagonal (Ports & Adapters) [4] que separa a lógica de negócio das suas dependências externas. A escolha do Kotlin em vez do Java tradicional permitiu aproveitar a expressividade da linguagem — em particular as coroutines para operações assíncronas, os tipos não-anuláveis para redução de erros de null pointer, e o estilo funcional para as transformações de dados. O Spring Boot forneceu a base REST, a gestão de transações e o suporte à autenticação com JWT [20].

A base de dados **PostgreSQL 16** foi estendida com a extensão **pgvector**, que adiciona suporte a vectores de embeddings directamente no mesmo motor relacional. Esta co-localização elimina a necessidade de um sistema vectorial separado e mantém todas as garantias ACID para a camada de personalização. O **Redis** é utilizado para a cache de resultados de consultas frequentes e para controlo de ritmo das chamadas à API de IA. A integração com o modelo de linguagem **Mistral 7B** é feita através do **LangChain4j 0.36.2** [12], implementando o padrão RAG [13] descrito no Capítulo 2.

Camada	Tecnologia	Papel
Servidor	Spring Boot 3.2 (Kotlin)	API REST, lógica de negócio, orquestração de IA
	PostgreSQL 16 + pgvector	Base de dados relacional e vectorial
	Redis 7	Cache de sessões e controlo de ritmo (<u>rate limiting</u>)
	MinIO	Armazenamento de objectos (imagens, assets)
	Mistral 7B / LangChain4j	Geração de conteúdo adaptativo e explicações
Móvel	Resend	Envio transaccional de correio electrónico
	Kotlin Multiplatform 2.3	Base de código partilhada Android/iOS
	Compose Multiplatform 1.10	Interface declarativa nativa
	Decompose 3.3	Navegação e gestão de estado
	Koin	Injecção de dependências
Web (admin)	React 18 + TypeScript	Painel de administração de conteúdos
	Vite + Tailwind CSS	<u>Bundler</u> e design system utilitário
	TanStack Query	Gestão de estado remoto e cache HTTP
Infraestrutura	Docker + Docker Compose	Orquestração local e de produção
	nginx 1.27	<u>Reverse proxy</u> e servidor do cliente estático
	Prometheus + Grafana	Observabilidade, métricas e alertas

Tabela 4.1: Tecnologias principais do Play4Change, organizadas por camada funcional.

Aplicação móvel

A aplicação móvel foi desenvolvida com **Kotlin Multiplatform (KMP) 2.3** e **Compose Multiplatform 1.10**, o que permite partilhar a maior parte da lógica de negócio e da interface entre Android e iOS a partir de um único código-base. A navegação e a gestão de estado são tratadas pelo **Decompose 3.3**, que oferece uma abstracção de stack de componentes compatível com ambas as plataformas e com testes unitários.

Painel de administração

O painel web de administração é uma aplicação **React 18** em **TypeScript**, construída com **Vite** e **Tailwind CSS**. Permite criar e gerir tópicos, tarefas e conteúdos, monitorizar inscrições e visualizar dados de utilização. O **TanStack Query** é utilizado para a gestão de estado remoto, garantindo cache automática, revalidação e tratamento consistente de estados de carregamento e erro.

Infraestrutura de produção

Todo o ambiente de produção é definido num único ficheiro `docker-compose.yml` com sete serviços: servidor Spring Boot, PostgreSQL, Redis, MinIO, nginx, Prometheus e Grafana. O **nginx** actua como reverse proxy — recebe os pedidos externos na porta 80, encaminha as chamadas à API (prefixadas em `/play4change-server/`) para o servidor na porta 8080, e serve o cliente React como conteúdo estático. O **Prometheus** recolhe métricas expostas pelo actuador Spring Boot a cada 15 segundos e o **Grafana** apresenta-as em três dashboards pré-configurados: um dashboard geral, um centrado na

latência da IA e um que mostra o fluxo do aprendente em tempo real. A Figura 4.1 ilustra a topologia de produção.




Figura 4.1: Topologia de infraestrutura de produção: o nginx recebe todo o tráfego externo e distribui-o; o servidor Spring Boot comunica com as quatro dependências de dados e com a API de IA; o Prometheus recolhe métricas do servidor e o Grafana apresenta-as em dashboards.

4.2 Pipeline de integração e entrega contínua

O Play4Change adota uma pipeline de Continuous Integration / Continuous Delivery (CI/CD) implementada em GitHub Actions, composta por três workflows distintos com responsabilidades bem delimitadas. A Figura 4.2 ilustra como os três workflows se articulam com os eventos do repositório.




Figura 4.2: Os três workflows da pipeline CI/CD do Play4Change: o primeiro corre em cada commit ou pull request; o segundo é desencadeado por uma tag semântica e produz o APK assinado; o terceiro corre semanalmente e verifica vulnerabilidades CVE nas dependências.

Workflow 1 — Integração Contínua

O workflow de CI é desencadeado em todos os commits para a branch main e em todos os pull requests que a ela se destinam. Corre num agente macOS (exigência do toolchain Android) e executa quatro

passos em sequência:

1. **Gitleaks** — varredura de segredos no histórico completo do repositório (`fetch-depth: 0`). Se forem detectadas credenciais, chaves de API ou outros segredos comprometidos no código, o workflow falha imediatamente antes de qualquer compilação.
2. **JDK 21 (Eclipse Temurin)** — configuração do ambiente Java com cache automática das dependências Gradle entre execuções, reduzindo o tempo de compilação em execuções subsequentes.
3. **Gradle build + testes** — compila todos os módulos (servidor, móvel, common) e executa os testes unitários e de integração com JUnit 5, MockK e SpringMockK. O passo exclui explicitamente o packaging de release para reduzir o tempo de execução em CI.
4. **Detekt** — análise estática do código Kotlin do servidor, verificando aderência às regras definidas em `detekt.yml`: complexidade ciclomática, tamanho de funções, dependências em concretos em vez de interfaces, e estilo de código.

Apenas se todos os passos passarem é que um pull request pode ser integrado na branch principal. A Tabela 4.2 resume os critérios de qualidade verificados em cada passo.

Ferramenta	O que verifica	Critério de falha
Gitleaks	Segredos no histórico git	Qualquer correspondência com os detectores predefinidos
JUnit 5 + MockK	Testes unitários e de integração	Qualquer teste falhado
Detekt	Qualidade e estilo do código Kotlin	Violações acima do limiar configurado

Tabela 4.2: Ferramentas e critérios de qualidade verificados em cada execução da pipeline de integração contínua.

Workflow 2 — Release do APK Android

O workflow de release é desencadeado exclusivamente por tags com prefixo `v` (por exemplo, `v1.2.3`). Este mecanismo garante que os binários de produção são sempre rastreáveis a uma versão explícita. O workflow: restaura os ficheiros sensíveis (keystore e `google-services.json`) a partir de segredos encriptados do repositório, nunca armazenados em texto simples; calcula automaticamente o `versionCode` Android a partir da tag semântica, segundo a fórmula $MAJOR \times 10000 + MINOR \times 100 + PATCH$; compila e assina o APK de release com a keystore de produção; e cria automaticamente uma GitHub Release com o `play4change.apk` anexado, tornando-o imediatamente disponível para distribuição sem qualquer passo manual.

Workflow 3 — Verificação semanal de dependências (OWASP)

O terceiro workflow corre automaticamente todas as segundas-feiras às 06:00 UTC. Utiliza a ferramenta **OWASP Dependency Check** para analisar todos os JARs do servidor e dos módulos móveis em busca de vulnerabilidades conhecidas registadas na base de dados CVE (Common Vulnerabilities and Exposures). O workflow falha se forem encontradas vulnerabilidades com score CVSS igual ou

superior a 7 (“High” ou “Critical”), forçando uma resposta atempada. Os relatórios HTML gerados ficam disponíveis como artefactos no **GitHub** durante 30 dias. Esta verificação periódica é particularmente relevante para uma plataforma que usa um LLM externo e que processa dados de utilizadores — onde uma dependência comprometida poderia ter impacto directo na privacidade dos dados ou na integridade dos conteúdos gerados.

4.3 Metodologia de desenvolvimento

O desenvolvimento do Play4Change seguiu um processo iterativo e incremental, próximo de uma metodologia ágil informal adequada a uma equipa de dimensão reduzida. O controlo de versões foi feito com **Git** e o repositório alojado no **GitHub**, com uma estratégia de feature branches: cada nova funcionalidade ou correcção é desenvolvida numa branch dedicada (por exemplo, `feature/jwt-auth` ou `bugfix/daily-reminders`), submetida como pull request e sujeita a revisão de código antes de ser integrada na branch `main`. Toda a integração é protegida pela pipeline de CI descrita na secção anterior.

A gestão de dependências é centralizada no ficheiro `gradle/libs.versions.toml`, o que garante consistência entre todos os módulos do projecto e facilita actualizações coordenadas. O **Flyway** é utilizado para a gestão de migrações da base de dados: cada alteração ao esquema SQL é registada como um ficheiro de migração versionado, aplicado de forma automática e ordenada aquando do arranque do servidor, garantindo que o estado da base de dados é sempre rastreável e reproduzível em qualquer ambiente.

4.4 Utilização de inteligência artificial no desenvolvimento

A declaração completa sobre as ferramentas de inteligência artificial utilizadas, o âmbito da sua aplicação e as considerações éticas associadas encontra-se no capítulo pré-textual Utilização de Inteligência Artificial (página vii).

Capítulo 5

Avaliação e Resultados

Este capítulo apresenta os resultados de uma avaliação preliminar do protótipo Play4Change. A avaliação combina duas fontes de dados complementares: um **questionário estruturado pós-utilização** com 12 participantes, que fornece dados subjectivos sobre usabilidade e envolvimento percebidos, e os **dados comportamentais registados na base de dados** do protótipo durante o período de testes, que fornecem evidência objectiva da utilização real — inscrições, percursos concluídos, padrões de erro, sessões adaptativas e distintivos emitidos. A triangulação destas duas fontes permite uma leitura mais completa do que qualquer uma delas isolada conseguiria.

5.1 Metodologia de avaliação

O questionário foi administrado de forma remota através de um formulário online, após os participantes terem explorado livremente o protótipo. Estava organizado em quatro secções: perfil do respondente; usabilidade e envolvimento em escala de Likert de 1 a 5; os dez itens da System Usability Scale (SUS) [3]; e questões abertas sobre pontos fortes e áreas de melhoria. A SUS foi seleccionada pela sua brevidade e pela existência de uma escala interpretativa estabelecida — pontuações acima de 68 consideram-se acima da média, acima de 80,3 “excelentes” [3].

Os dados comportamentais foram extraídos directamente da base de dados PostgreSQL do protótipo em produção, cobrindo o período completo de utilização desde o arranque até à data de avaliação. Incluem registos de inscrições, submissões de tarefas, sessões adaptativas (struggle) e sessões de explicação por IA.

5.2 Dados comportamentais: a utilização real

Visão geral agregada

A Tabela 5.1 apresenta os indicadores globais extraídos da base de dados no final do período de avaliação.

Estes números contrariaram uma afirmação que seria prematura — a de que nenhum utilizador concluiu um percurso completo durante os testes. Os dados mostram o oposto: **16 inscrições foram concluídas**

Indicador	Valor
Utilizadores registados	15
Utilizadores com pelo menos uma inscrição	14
Inscrições em tópicos (total)	27
Inscrições concluídas	16 (59%)
Distintivos emitidos	16
Utilizadores com pelo menos um distintivo	9 (60%)
Tarefas submetidas	105
Acerto final nas tarefas	104/105 (99%)
Sessões adaptativas (struggle) geradas	55
Sessões adaptativas resolvidas	54 (98%)
Sessões de explicação por IA	39
Sequência (streak) máxima registada	13 dias

Tabela 5.1: Indicadores globais de utilização do protótipo Play4Change extraídos da base de dados no final do período de avaliação.

por 9 utilizadores distintos, com 100% das conclusões a resultar na emissão de um distintivo, o que indica que o limiar de mestria $\alpha = 0.60$ foi atingido em todos os casos.

Taxas de conclusão por tópico

A Figura 5.1 compara, para cada tópico disponível, o número de inscrições e o número de conclusões. Os três tópicos com utilizadores activos registam taxas de conclusão entre 50% e 67%, o que é notavelmente positivo para um protótipo com utilizadores sem qualquer incentivo externo obrigatório.




Figura 5.1: Número de inscrições e conclusões por tópico durante o período de avaliação. A percentagem indica a taxa de conclusão. O tópico “Capstone” pressupõe a conclusão dos anteriores, sendo esperada uma taxa menor nesta fase.

Percurso por utilizador

A Tabela 5.2 apresenta os dados de utilização por participante (emails anonimizados), ordenados por número de tópicos concluídos. O perfil dos utilizadores mais activos é revelador: os dois com mais inscrições concluídas (P1 e P2) apresentam streaks de 13 e 9 dias, respectivamente, e percorreram cada um 11 a 12 sessões adaptativas, sugerindo um envolvimento genuíno e sustentado com a plataforma.

P	Ins.	Conc.	Streak	Pts	Bad.	Luta	Expl.
P1	3	3	13	442 800	3	11	6
P2	3	3	9	749 520	3	12	11
P3	3	2	6	15 400	2	4	3
P4	2	2	5	4 000	2	2	2
P5	4	2	10	80 940	2	8	2
P6	2	1	5	7 400	1	3	3
P7	1	1	5	500	1	1	1
P8	1	1	5	700	1	2	1
P9	1	1	5	500	1	1	1
P10	2	0	1	400	0	3	3
P11	1	0	2	75	0	1	0
P12	1	0	3	180	0	1	1
P13	1	0	1	180	0	3	3
P14	2	0	1	0	0	3	2
P15	0	–	–	–	0	0	0

Tabela 5.2: Dados comportamentais por utilizador. Ins.=inscrições; Conc.=concluídas; Streak=dias consecutivos máximos; Pts=pontos totais acumulados; Bad.=distintivos; Luta=sessões adaptativas; Expl.=sessões de explicação. Linha de separação distingue utilizadores com conclusões dos sem conclusões.

Acerto nas tarefas e o papel do ciclo adaptativo

Das 105 tarefas submetidas, **104 obtiveram a resposta correcta como submissão final** (99%). Este número não deve ser lido como indicador de facilidade excessiva; deve ser lido como indicador da eficácia do ciclo adaptativo. Os dados mostram que foram geradas 55 sessões de percurso adaptativo durante o mesmo período, o que implica que uma proporção significativa de tarefas envolveu pelo menos uma resposta errada inicial, seguida de um percurso de reforço que culminou na resposta correcta. **54 das 55 sessões adaptativas foram resolvidas** (98,2%) e nenhuma foi abandonada — o utilizador trabalhou sempre até ao final do percurso.

Padrões de erro e tempo de resolução

A Figura 5.2 ilustra a distribuição das sessões adaptativas pelos dois padrões de erro detectados pelo classificador.




Figura 5.2: Distribuição das 55 sessões adaptativas pelos dois padrões de erro identificados pelo ErrorPatternClassifier. O READING_ERROR indica que o utilizador respondeu sem ler o enunciado com atenção; o WRONG_CONCEPT indica uma lacuna conceptual genuína. Os tempos médios de resolução foram calculados entre detected_at e resolved_at.

A predominância de READING_ERROR (56%) é pedagogicamente informativa: mais de metade dos erros resultaram não de lacunas conceptuais, mas de leituras apressadas do enunciado — um comportamento

típico em formatos de quiz rápido [23], e que o percurso adaptativo conseguiu endereçar com sucesso em média em apenas 3 minutos. Os erros de `WRONG_CONCEPT` demoram ligeiramente menos a resolver (2 minutos), possivelmente porque são mais directamente endereçáveis com uma explicação conceptual focada.

5.3 Resultados do questionário

Usabilidade geral e pontuação SUS

Os 12 participantes do questionário atribuíram à usabilidade geral e navegação uma pontuação média de **4,17 em 5** ($\sigma = 1,19$). A pontuação SUS calculada segundo o método de Brooke [3] foi de **76,0/100**, acima da média histórica de 68 e classificada como “boa”. A Figura 5.3 representa as pontuações individuais ordenadas de forma crescente e revela uma distribuição bimodal que é analisada na Secção 5.5.




Figura 5.3: Pontuações SUS individuais dos 12 participantes do questionário, ordenadas de forma crescente. A linha a tracejado assinala o limiar histórico de 68 pontos.

Envolvimento e relevância percebida

A Tabela 5.3 resume as quatro dimensões de envolvimento avaliadas. O apelo visual destacou-se com a pontuação mais elevada (4,33/5), seguido da relevância percebida dos conteúdos para situações reais (4,00/5) — um resultado alinhado com o objectivo de situar as perguntas em contextos cívicos do dia a dia.

A percepção da adaptatividade da IA (4,08/5) é particularmente relevante: nenhum dos 12 participantes discordou da afirmação de que os percursos de aprendizagem se adaptaram eficazmente ao seu desempenho — um resultado coerente com a taxa de resolução de 98% observada nos dados comportamentais.

Dimensão	Média	Distribuição
Motivação para aprender sobre educação cívica / cidades sustentáveis	3,83	1×SA, 8×A, 3×N
Relevância dos desafios para situações reais	4,00	4×SA, 5×A, 2×N, 1×D
Apelo visual e estética	4,33	6×SA, 4×A, 2×N
Encorajamento ao regresso diário	3,92	2×SA, 7×A, 3×N
Adaptatividade da IA ao desempenho e interesses	4,08	4×SA, 5×A, 3×N

Tabela 5.3: Médias e distribuições de resposta para as dimensões de envolvimento e adaptatividade percebida (SA=Concordo totalmente, A=Concordo, N=Neutro, D=Discordo). $n = 12$.

5.4 O ciclo adaptativo em acção: um exemplo real

Para ilustrar concretamente como o ciclo erro → percurso adaptativo → explicação por IA funciona na prática, apresenta-se a seguir o registo completo de uma sessão de explicação extraída da base de dados. O utilizador estava a realizar o tópico Sustainable Cities & Civic Engagement e tinha cometido um `READING_ERROR` na tarefa principal. Após concluir o percurso adaptativo sem sucesso, foi aberta uma sessão de explicação por diálogo livre com a IA. A sessão ficou registada como `RESOLVED` e durou aproximadamente 3 minutos.

O excerto abaixo transcreve as oito mensagens trocadas (papel USER e papel AI), preservando o texto original em inglês conforme armazenado na base de dados:

A tarefa original:

"A digital device is a tool that uses electronic signals to process, store, or send information. Examples include phones, computers, and tablets. — Which of the following is NOT a digital device? A) A calculator that adds numbers. B) A microwave that shows time. C) A toaster that pops up bread. D) A smartphone that plays music."

Diálogo de explicação:

USER "Why is my answer wrong?"

AI "Could you share the exact sentence or paragraph you wrote? That way I can see exactly where the misunderstanding is and help fix it."

USER "A smartphone that plays music is a digital device"

AI "Ah, I see the confusion! A smartphone playing music is indeed a digital device, but the question is about digital public services [...]. Think of it this way: your smartphone is just the tool — digital public services are the services that run on those tools to make cities greener. Does that help clarify the difference?"

USER [partilha o enunciado completo da pergunta e a indicação de que C é a resposta correcta]

AI "Ah, now I see the mix-up! The clue is in the definition: a digital device has to process, store, or send information. A toaster just heats bread — it doesn't do any of those things, so it's not digital. But a smartphone plays music by processing data, so it is digital. The hint was pointing at tasks like typing or playing games, which involve handling information. Does that make sense now?"

USER "Yes, then why is C right and not D?"

AI “A toaster pops up bread because a timer inside it has counted down; that timer is a tiny computer storing and counting ‘ticks,’ so it does process and store information. A smartphone playing music is also digital, but the question lets only one answer be chosen, and the hint wants the simplest device that still fits the definition.”

Esta sequência ilustra vários aspectos importantes do ciclo. Em primeiro lugar, a IA não deu a resposta de imediato — solicitou que o utilizador explicitasse a sua dúvida, forçando-o a articular o raciocínio (pergunta socrática). Em segundo lugar, quando o utilizador continuou sem perceber, a IA escalou a explicação para um nível de maior detalhe técnico, sem perder a acessibilidade da linguagem. Em terceiro lugar, a última troca — “Yes, then why is C right and not D?” — mostra que o utilizador chegou a um nível de compreensão suficiente para formular a dúvida correcta: já não estava perdido, estava a refinar. Toda a sessão decorreu em **menos de 3 minutos**.

Este exemplo ilustra o princípio de step-level feedback que VanLehn [23] identificou como o elemento diferenciador dos sistemas de tutoria inteligente mais eficazes: não é a quantidade de informação fornecida, mas a sua adequação ao momento exacto da dificuldade do aprendente.

5.5 Dois perfis de utilizador: uma descoberta central

Tanto os dados do questionário como os dados comportamentais apontam para a mesma clivagem: a amostra divide-se em dois grupos com experiências marcadamente distintas.

O **Grupo A** — oito participantes no questionário com SUS entre 75 e 98 (média ≈ 90), correspondendo na base de dados a utilizadores como P1 e P2 (3 tópicos concluídos, streaks de 9 a 13 dias, 11 a 12 sessões adaptativas resolvidas) — representa utilizadores com maturidade digital que adoptaram a plataforma de forma entusiasta. Os seus comentários descrevem-na como “intuitiva”, “fácil de entender” e “uma ideia muito bem concebida com tudo o que precisa para evoluir”. Crucialmente, estes utilizadores **não fugiram das dificuldades**: os 12 percursos adaptativos de P2 mostram que o utilizador errou com frequência, mas continuou sempre e resolveu tudo. O ciclo de erro é sentido, para este grupo, não como frustração mas como oportunidade de aprendizagem — exactamente o que o design procurava.

O **Grupo B** — quatro participantes no questionário com SUS entre 35 e 60 (média ≈ 47), correspondendo a utilizadores como P10 e P14 (0 tópicos concluídos, streak de 1 dia, 3 sessões adaptativas sem resolução) — representa utilizadores para quem a plataforma digital constitui, em si mesma, uma barreira: “Because it’s so confusing, it ends up not being so helpful, what would make people lose interest in this app and also patience”. Para este grupo, o problema não é o conteúdo — é o meio. A aprendizagem autónoma por aplicação móvel pressupõe um grau mínimo de familiaridade digital que este grupo ainda não tem, e que é precisamente o que o Play4Change procura ajudar a desenvolver.

Cria-se assim um **paradoxo de acessibilidade** que as plataformas de educação digital frequentemente enfrentam [11]: a plataforma é mais eficaz para quem já tem literacia digital de base, mas pode afastar precisamente quem mais beneficiaria de a desenvolver. Resolver este paradoxo exigiria abordagens complementares — tutoriais guiados de integração (onboarding), sessões de apoio inicial presencial, ou uma versão simplificada da interface para utilizadores menos experientes. Estas são limitações do protótipo actual que informam directamente as propostas de trabalho futuro do Capítulo 6.

A Tabela 5.4 sintetiza as diferenças entre os dois grupos.

Dimensão	Grupo A (n≈8–9)	Grupo B (n≈4–6)
SUS médio	≈90 (Excelente)	≈47 (Mau)
Tópicos concluídos	1–3 por utilizador	0
Streak máx.	5–13 dias	1–3 dias
Sessões adaptativas	Numerosas, todas resolvidas	Poucas ou sem resolução
Reacção ao ciclo IA	“Fascinante e útil”	Fluxo não percebido
Envolvimento real	Alto e sustentado	Abandonado cedo
Perfil presumível	Confortável com tecnologia	Pouca familiaridade digital

Tabela 5.4: Síntese dos dois grupos de utilizadores identificados, combinando dados do questionário e dados comportamentais da base de dados.

5.6 Feedback qualitativo e sugestões de melhoria

As respostas abertas do questionário revelaram três temas recorrentes de melhoria que merecem registo. O primeiro, referido por três participantes independentes, é a introdução de **funcionalidades sociais e comunitárias** — a possibilidade de comparar progressos com amigos, criar uma “rivalidade positiva” ou partilhar conhecimento. Este tema está directamente alinhado com a dimensão de relação da Teoria da Autodeterminação [5] e com a investigação sobre gamificação que identifica a componente social como um dos motores de retenção mais eficazes [18]. O segundo tema foi a **consistência e qualidade da interface**, com sugestões específicas de hierarquia visual mais clara e respostas da IA mais concisas num ecrã de telemóvel. O terceiro tema, particularmente interessante, foi a sugestão de **personalização geográfica**: que a IA adaptasse as perguntas à cidade ou região onde o utilizador se encontra, usando dados públicos disponíveis para tornar os conteúdos hiper-locais. Esta ideia é conceptualmente consistente com os centros de competência da U!REKA [21] e poderá orientar uma iteração futura da plataforma.

5.7 Discussão dos resultados

Os dados combinados permitem fazer uma leitura estruturada de cada um dos três pilares.

O pilar da **personalização** obteve os resultados mais sólidos: 99% de acerto final nas tarefas, 98% de resolução das sessões adaptativas, 4,08/5 na percepção de adaptatividade, e referências espontâneas múltiplas ao ciclo de explicação como a melhor funcionalidade. O exemplo de sessão apresentado na Secção 5.4 mostra como a IA consegue, em 3 minutos, conduzir um utilizador de uma confusão conceptual real a uma compreensão genuína — o tipo de step-level feedback que VanLehn [23] identifica como central na eficácia dos sistemas de tutoria inteligente.

O pilar do **reconhecimento** obteve também um resultado muito concreto: 16 distintivos emitidos a 9 utilizadores, com uma taxa de aprovação de 100% nos tópicos concluídos (o limiar $\alpha = 0.60$ foi atingido por todos os que completaram). Porém, os participantes sugeriram que os distintivos actuais teriam maior poder motivacional se ancorados a valor no mundo real (descontos, bilhetes para eventos, reconhecimento em plataformas externas) — uma evolução que está fora do âmbito deste protótipo mas que justificaria investigação em iterações futuras.

O pilar do **envolvimento** apresenta o quadro mais nuançado. Para o Grupo A, os mecanismos de streak e desbloqueio diário funcionaram bem: streaks de 9 a 13 dias em utilizadores que completaram múltiplos tópicos são um sinal de hábito criado. Para o Grupo B, os mesmos mecanismos não foram suficientes para criar tracção. A sugestão mais recorrente — funcionalidades sociais — aponta para a dimensão

que o protótipo não cobre: a comunidade.

Limitações da avaliação

Esta avaliação tem limitações que devem ser explicitamente reconhecidas. A **dimensão da amostra** do questionário ($n = 12$) é insuficiente para extrair conclusões estatisticamente robustas; os resultados devem ser entendidos como indicadores e hipóteses a testar em estudos mais alargados. A **amostragem por conveniência** pode sobre-representar utilizadores com familiaridade digital, enviesando positivamente os resultados do Grupo A. Os **dados comportamentais**, embora objectivos, cobrem um período de utilização relativamente curto e sem protocolo de tarefa estruturado — o que significa que alguns utilizadores podem ter explorado apenas partes da plataforma. Por fim, **nenhum tópico de conteúdo foi validado por especialistas em educação cívica**, o que é uma limitação importante para uma versão madura da plataforma e está discutido no Capítulo 6.

Apesar destas limitações, a triangulação entre questionário e dados comportamentais permitiu uma leitura mais completa do que qualquer uma das fontes isolada: os dados de utilização confirmaram hipóteses levantadas pelo questionário (a personalização funciona, o streak cria hábito no Grupo A) e as respostas qualitativas explicaram padrões visíveis nos dados (o abandono do Grupo B reflete-se nos streaks de 1 dia).

Capítulo 6

Conclusão

6.1 Síntese do trabalho realizado

Este trabalho partiu de uma questão simples mas exigente: como pode uma plataforma de educação digital, informal e gamificada, apoiada por inteligência artificial, ajudar os cidadãos a desenvolver as competências de que precisam para participar na transição para cidades sustentáveis — e, ao mesmo tempo, conseguir que continuem a usá-la ao longo do tempo? Para responder a esta questão, foi concebido e implementado o Play4Change: um protótipo funcional organizado à volta de três pilares complementares — reconhecimento, envolvimento e personalização.

Olhando para os objectivos definidos na Secção 1.3, o balanço é positivo. O **sistema de distintivos** foi implementado e validado: 16 distintivos foram emitidos a 9 utilizadores em condições reais de utilização, com 100% das conclusões de tópicos a resultar na emissão do respectivo emblema, o que confirma que o limiar de mestria $\alpha = 0.60$ funcionou como portão de qualidade efectivo. Os **mecanismos de envolvimento** foram implementados e geraram evidências de hábito real no Grupo A: sequências de até 13 dias consecutivos de utilização em utilizadores que completaram múltiplos tópicos são um resultado que nenhum incentivo externo obrigatório pode explicar. A **personalização adaptativa** foi o pilar com resultados mais consistentes: 99% de acerto final nas tarefas e 98% de resolução das sessões adaptativas demonstram que o ciclo detecção–remediação–resolução funciona eficazmente, e o exemplo de sessão apresentado no Capítulo 5 ilustra concretamente como a IA consegue conduzir um utilizador de uma confusão conceptual genuína a uma compreensão clara em menos de 3 minutos.

Do ponto de vista técnico, o protótipo representa uma proposta arquitectural coerente e funcional: um servidor em Kotlin com Spring Boot 3 e arquitectura hexagonal, uma aplicação móvel em Kotlin Multiplatform com Compose, um painel de administração React, infraestrutura observável com Prometheus e Grafana, e uma pipeline CI/CD com três workflows GitHub Actions que garantem qualidade, rastreabilidade e distribuição automatizada. A plataforma chegou ao estado de produção com utilizadores reais, dados comportamentais registados e uma avaliação junto de 12 participantes — o que, para um protótipo desenvolvido no âmbito de um projecto académico, representa um nível de maturidade acima do esperado numa primeira iteração.

A contribuição mais original deste trabalho é a combinação, num único produto, de **tema** (educação cívica para a transição sustentável) e de **personalização gerativa** (uso de um LLM para gerar percursos adaptativos em tempo real, com base no perfil de dificuldade de cada utilizador). Tanto quanto

foi possível apurar na análise do estado da arte, esta combinação não está presente em nenhuma das plataformas existentes analisadas.

6.2 Limitações

A honestidade sobre as limitações é parte integrante de qualquer trabalho de investigação e desenvolvimento. As limitações do Play4Change organizam-se em três níveis.

Limitações da avaliação. A amostra do questionário ($n = 12$, amostragem por conveniência) é insuficiente para conclusões estatisticamente robustas. Os resultados devem ser lidos como hipóteses e indicadores, não como evidências definitivas. O período de utilização coberto pelos dados comportamentais é relativamente curto e sem protocolo de tarefa estruturado, o que significa que alguns utilizadores podem ter explorado apenas partes da plataforma. Não há grupo de controlo, pelo que não é possível atribuir causalmente os resultados à plataforma em vez de a outros factores.

Limitações do protótipo. Nenhum tópico de conteúdo foi validado por especialistas em educação cívica ou em sustentabilidade urbana. A qualidade pedagógica dos conteúdos gerados pelo LLM depende da qualidade dos prompts e do modelo — e embora a validação de esquema JSON e a abordagem RAG [13] reduzam o risco de conteúdos malformados, não eliminam o risco de imprecisões factuais (hallucinations). A cobertura de testes de integração e o tratamento de erros de rede na aplicação móvel ficaram abaixo do que seria desejável numa versão de produção madura. A plataforma não foi submetida a auditoria de segurança independente.

Limitações de alcance. O **paradoxo de acessibilidade** identificado na Secção 5.5 é talvez a limitação mais estrutural: a plataforma é mais eficaz para quem já tem literacia digital de base, mas pode afastar precisamente quem mais beneficiaria de a desenvolver. Este paradoxo não é específico do Play4Change — afecta a maioria das plataformas de educação digital [11] — mas é especialmente problemático num contexto de educação cívica onde o objectivo explícito é reduzir desigualdades de participação. Resolver este paradoxo exigirá abordagens complementares que estão fora do âmbito do presente protótipo.

6.3 Trabalho futuro

As limitações identificadas apontam directamente para os caminhos mais prioritários de evolução. Há cinco direcções que merecem destaque pela sua relevância directa para a missão da plataforma.

Integração social e comunitária. A sugestão mais recorrente na avaliação qualitativa foi a introdução de funcionalidades sociais: comparação de progresso entre amigos, desafios colectivos e partilha de conquistas. Este vector está directamente alinhado com a dimensão de relação da Teoria da Autodeterminação [5] e com a evidência na literatura de que a componente social é um dos motores de retenção mais eficazes em contextos de gamificação [18]. Uma versão futura do Play4Change que incorpore esta dimensão poderia transformar o que é hoje uma experiência individual numa experiência de aprendizagem colectiva e contextualizada na comunidade local.

Personalização geográfica. Vários participantes sugeriram que a plataforma deveria adaptar as perguntas à cidade ou região onde o utilizador se encontra, usando dados públicos disponíveis para tornar os conteúdos hiper-locais. Esta ideia — questionar um utilizador em Lisboa sobre a qualidade do ar no

Parque das Nações, ou um utilizador no Porto sobre a ciclovia da Avenida dos Aliados — está conceptualmente alinhada com os centros de competência da U!REKA [21] e poderia aumentar significativamente a relevância percebida dos conteúdos.

Validação pedagógica dos conteúdos. Uma versão madura da plataforma precisaria de um processo de revisão dos conteúdos gerados pela IA por especialistas em educação cívica e em sustentabilidade urbana. Este processo poderia ser estruturado de várias formas: revisão editorial periódica por amostragem, feedback dos utilizadores sobre a qualidade das explicações, ou um mecanismo de marcação de conteúdos suspeitos. A ausência deste componente é a limitação de qualidade mais importante a resolver antes de qualquer escalonamento da plataforma.

Onboarding adaptado ao Grupo B. O paradoxo de acessibilidade identificado na avaliação sugere que os utilizadores com menor literacia digital precisam de uma experiência de entrada diferente: tutoriais guiados interactivos, sessões de apoio inicial presencial integradas na distribuição, ou uma versão simplificada da interface com menos opções e navegação mais linear. Investigar que intervenções de onboarding reduzem efectivamente a barreira para este grupo — sem infantilizar a experiência para o Grupo A — é um problema de investigação com impacto directo na missão do projecto.

Distintivos com valor no mundo real. A avaliação revelou que os utilizadores percebem os distintivos como um reconhecimento simbólico interessante, mas com valor limitado fora da aplicação. Uma direcção possível são os Open Badges — um padrão aberto (IMS Global) para emissão de credenciais digitais verificáveis que podem ser partilhadas em perfis profissionais e reconhecidas por empregadores ou instituições. Integrar este padrão numa versão futura do Play4Change ligaria o reconhecimento dentro da plataforma a valor tangível fora dela, potencialmente aumentando a motivação dos utilizadores mais orientados para resultados concretos.

Em síntese, o Play4Change é um primeiro passo viável e com valor demonstrado. Os dados de utilização e a avaliação com utilizadores reais confirmam que a proposta tem fundamento — há utilizadores que a adoptam com entusiasmo genuíno, completam percursos, resolvem dificuldades com a ajuda da IA e regressam dias seguidos. O caminho até uma plataforma madura, acessível a todos os perfis de cidadão e com conteúdos validados é longo, mas este protótipo fornece uma base técnica, pedagógica e conceptual sólida sobre a qual construí-lo.

Referências

- [1] Benjamin S. Bloom, “Learning for Mastery”, *Evaluation Comment*, vol. 1, n.º 2, páginas 1–12, 1968.
- [2] Benjamin S. Bloom, “The 2 Sigma Problem: The Search for Methods of Group Instruction as Effective as One-to-One Tutoring”, *Educational Researcher*, vol. 13, n.º 6, páginas 4–16, 1984. DOI: [10.3102/0013189X013006004](https://doi.org/10.3102/0013189X013006004)
- [3] John Brooke, “SUS: A ‘quick and dirty’ usability scale”, em *Usability Evaluation in Industry*, P.W. Jordan, B. Thomas, B.A. Weerdmeester & I.L. McClelland, eds., London: Taylor & Francis, 1996, páginas 189–194.
- [4] Alistair Cockburn, *Hexagonal Architecture*, <https://alistair.cockburn.us/hexagonal-architecture/>, Acedido em 10 de junho de 2026, 2005.
- [5] Edward L. Deci & Richard M. Ryan, *Intrinsic Motivation and Self-Determination in Human Behavior*. New York: Plenum Press, 1985. DOI: [10.1007/978-1-4899-2271-7](https://doi.org/10.1007/978-1-4899-2271-7)
- [6] Roy Thomas Fielding, “Architectural Styles and the Design of Network-based Software Architectures”, Capítulo 5: Representational State Transfer (REST), Tese de Doutorado, University of California, Irvine, 2000.
- [7] National Institute of Standards and Technology, “Secure Hash Standard (SHS)”, National Institute of Standards & Technology, FIPS PUB 180-4, 2015. DOI: [10.6028/NIST.FIPS.180-4](https://doi.org/10.6028/NIST.FIPS.180-4)
- [8] Martin Fowler, *Circuit Breaker*, <https://martinfowler.com/bliki/CircuitBreaker.html>, Acedido em 10 de junho de 2026, 2014.
- [9] Albert Q. Jiang, Alexandre Sablayrolles, Arthur Mensch, Chris Bamford, Devendra Singh Chaplot, Diego de las Casas, Florian Bressand, Gianna Lengyel, Guillaume Lample, Lucile Saulnier et al., “Mistral 7B”, *arXiv preprint arXiv:2310.06825*, 2023.
- [10] Jeff Johnson, Matthijs Douze & Hervé Jégou, “Billion-scale similarity search with GPUs”, *IEEE Transactions on Big Data*, vol. 7, n.º 3, páginas 535–547, 2021. DOI: [10.1109/TBDATA.2019.2921572](https://doi.org/10.1109/TBDATA.2019.2921572)
- [11] Enkelejda Kasneci, Kathrin Sessler, Stefan Küchemann, Maria Bannert, Daryna Dementieva, Frank Fischer, Urs Gasser, Georg Groh, Stephan Günemann, Eyke Hüllermeier et al., “ChatGPT for Good? On Opportunities and Challenges of Large Language Models for Education”, *Learning and Individual Differences*, vol. 103, pág. 102 274, 2023. DOI: [10.1016/j.lindif.2023.102274](https://doi.org/10.1016/j.lindif.2023.102274)
- [12] LangChain4j Contributors, *LangChain4j: LangChain for Java*, <https://github.com/langchain4j/langchain4j>, Acedido em 10 de junho de 2026, 2023.
- [13] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel & Douwe Kiela, “Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks”, em *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, 2020, páginas 9459–9474.

- [14] Robert B. Miller, “Response time in man-computer conversational transactions”, *Proceedings of the AFIPS Fall Joint Computer Conference*, vol. 33, páginas 267–277, 1968. DOI: [10.1145/1476589.1476628](https://doi.org/10.1145/1476589.1476628)
- [15] J. Bruin. “Newtest: command to compute new test @ONLINE”. URL: <http://www.ats.ucla.edu/stat/stata/ado/analysis/>
- [16] Paul A. Grassi, Michael E. Garcia & James L. Fenton, “Digital Identity Guidelines: Authentication and Lifecycle Management”, National Institute of Standards & Technology, Special Publication 800-63B, 2017, Acedido em 10 de junho de 2026. DOI: [10.6028/NIST.SP.800-63b](https://doi.org/10.6028/NIST.SP.800-63b)
- [17] Torsten Lodderstedt, John Bradley, Andrey Labunets & Daniel Fett, “OAuth 2.0 Security Best Current Practice”, Internet Engineering Task Force, RFC 9700, jan. de 2025, Acedido em 10 de junho de 2026.
- [18] Armando M. Toda, Wilk T. Ota, Caio Mozo, Pedro H. D. Valle, Jacques D. Brancher & Seiji Isotani, “Gamification in education: a systematic mapping over ten years”, em *Brazilian Symposium on Computers in Education (SBIE)*, 2019, páginas 1–10. DOI: [10.5753/cbie.sbie.2019.1403](https://doi.org/10.5753/cbie.sbie.2019.1403)
- [19] Michael B. Jones, “JSON Web Algorithms (JWA)”, Internet Engineering Task Force, RFC 7518, mai. de 2015. DOI: [10.17487/RFC7518](https://doi.org/10.17487/RFC7518)
- [20] Michael B. Jones, John Bradley & Nat Sakimura, “JSON Web Token (JWT)”, Internet Engineering Task Force, RFC 7519, mai. de 2015. DOI: [10.17487/RFC7519](https://doi.org/10.17487/RFC7519)
- [21] U!REKA, *Our alliance – Mission, vision and strategy*, <https://ureka.eu/alliance/>, Acedido em 8 de junho de 2026, 2026.
- [22] U!REKA, *U!REKA – European University Alliance*, <https://ureka.eu/>, Acedido em 8 de junho de 2026, 2026.
- [23] Kurt VanLehn, “The Relative Effectiveness of Human Tutoring, Intelligent Tutoring Systems, and Other Tutoring Systems”, *Educational Psychologist*, vol. 46, n.º 4, páginas 197–221, 2011. DOI: [10.1080/00461520.2011.611369](https://doi.org/10.1080/00461520.2011.611369)
- [24] Riina Vuorikari, Stefano Kluzer & Yves Punie, “DigComp 2.2: The Digital Competence Framework for Citizens – With new examples of knowledge, skills and attitudes”, Publications Office of the European Union, Luxembourg, rel. téc. EUR 31006 EN, 2022, JRC128415. DOI: [10.2760/115376](https://doi.org/10.2760/115376)
- [25] W3C, *Server-Sent Events*, <https://www.w3.org/TR/eventsource/>, W3C Recommendation, 3 de fevereiro de 2015. Acedido em 10 de junho de 2026, 2015.

Apêndice A

Applied Survival Analysis by Hosmer and Lemeshow

Stata Textbook Examples Applied Survival Analysis by Hosmer and Lemeshow [15]

The data files used for the examples in this text can be downloaded in a zip file from the Wiley FTP website or the Stata Web site.

```
1 # The R package(s) needed for this chapter is the survival package.
2 # We currently use R 2.0.1 patched version. You may want to make sure
3 # that packages on your local machine are up to date. You can perform
4 # updating in R using update.packages() function.
5
6 # url: http://www.ats.ucla.edu/stat/r/examples/
7 # data set is hmohiv.csv.
8 hmohiv<-read.table("http://www.ats.ucla.edu/stat/r/examples/asa/hmohiv.csv", sep=" ",
9                   header = TRUE)
10 attach(hmohiv)
11 hmohiv
12
13 # using the hmohiv data set. To control the type of symbol, a variable called psymbol is created.
14 # It takes value 1 and 2, so the symbol type will be 1 and 2.
15 psymbol<-censor+1
16 table(psymbol)
17
18 plot(age, time, pch=(psymbol))
19 legend(40, 60, c("Censor=1", "Censor=0"), pch=(psymbol))
20
21 age1<-1000/age
22 plot(age1, time, pch=(psymbol))
23 legend(40, 30, c("Censor=1", "Censor=0"), pch=(psymbol))
24
25 # Package "survival" is needed for this analysis and for most of the analyses in the book.
26 library(survival)
27 test <- survreg( Surv(time, censor) ~ age, dist="exponential")
```

```
27 summary(test)
28
29 pred <- predict(test, type="response")
30 ord<-order(age)
31 age_ord<-age[ord]
32 pred_ord<-pred[ord]
33 plot(age, time, pch=(psymbol))
34 lines(age_ord, pred_ord)
35 legend(40, 60, c("Censor=1", "Censor=0"), pch=(psymbol))
```