

Departamento de Engenharia Informática

Play4Change: Aplicação de Aprendizagem Adaptativa para Educação Cívica

51620 : Radesh Ilesh Gamanbhai Govind (A51620@alunos.isel.pt)

Relatório para a Unidade Curricular de Projeto e Seminário
da Licenciatura em Engenharia Informática e de Computadores

Professores : Nuno Datia Professor
António Serrador Professor
Michel Vorenhout Professor

Resumo

A U!REKA é uma aliança europeia de instituições de ensino superior cuja missão é preparar cidadãos para liderar a transição para cidades neutras em carbono e sustentáveis. Esta transição exige competências digitais e cívicas — definidas pelo quadro DigComp 2.2 — que a maioria das plataformas de aprendizagem digital não desenvolve com eficácia, em parte pela taxa de abandono que as caracteriza.

Para endereçar este problema, foi desenvolvido e avaliado o Play4Change: uma plataforma móvel gamificada assente em três pilares. O primeiro é um motor de geração de conteúdo pedagógico alimentado por um modelo de linguagem (Mistral AI), capaz de ingerir documentos e URLs e de ativar percursos adaptativos personalizados quando o utilizador erra. O segundo é um sistema de distintivos com limiar de mestria que assinala cada competência adquirida. O terceiro engloba mecanismos de retenção — sequências diárias de utilização (streaks) e um modo de explicação holística por IA — que combatem o abandono.

A avaliação preliminar com 12 utilizadores obteve uma pontuação SUS de 76/100 (banda “Bom”), uma taxa de conclusão de tópicos de 59% e uma resolução de 98,2% das sessões adaptativas. Os dados revelaram uma clivagem bimodal: utilizadores com elevada familiaridade digital (SUS médio 89,4) adoptaram a plataforma com entusiasmo, enquanto utilizadores menos familiarizados (SUS médio 47,5) abandonaram cedo — evidenciando que a barreira não é o conteúdo, mas o meio. O ciclo de feedback por IA foi espontaneamente identificado como a funcionalidade mais valorizada por 7 dos 11 respondentes.

Palavras-chave: aprendizagem adaptativa, educação cívica, gamificação, inteligência artificial, DigComp, cidades sustentáveis

Abstract

U!REKA is a European alliance of higher-education institutions whose mission is to educate the professionals of tomorrow and support the transition of cities towards more sustainable models. As a possible contribution to that mission, Play4Change proposes an informal, gamified digital education platform aimed at civic education and at the competences this transition demands from citizens. The solution uses artificial intelligence to adjust content to each user's pace and learning difficulties; progress is recognised through badges that signal each newly acquired competence; and engagement mechanisms — such as daily-use streaks — address the high dropout rates typical of such platforms. This report describes the prototype developed and the preliminary evaluation carried out with users of different ages and backgrounds, whose feedback revealed strong receptiveness to the role of AI in clarifying doubts and personalising learning.

Keywords: adaptive learning, civic education, gamification, artificial intelligence, sustainable cities

Utilização de Inteligência Artificial

Ferramentas e modelos utilizados

Ferramenta	Modelo	Aplicação Técnica
Google Gemini	Pro	Apoio à investigação preliminar de padrões.
Claude Code	Opus	Auxílio na organização de notas de design.
Claude	Sonnet	Geração de scaffolding de código e resolução de erros de compilação.

Tabela 1: Ferramentas de inteligência artificial utilizadas, modelos e respectivas aplicações técnicas.

Declaração de integridade académica

A responsabilidade arquitectural, a qualidade do código submetido e as decisões de implementação descritas neste documento pertencem exclusivamente ao autor, tendo os modelos de linguagem sido utilizados estritamente como aceleradores de formatação e resolução de impasses técnicos.

Todo o código gerado ou reestruturado com apoio de IA foi revisto manualmente pelo autor antes de integração, incluindo leitura linha a linha, execução dos testes automatizados existentes e, sempre que aplicável, verificação manual do comportamento em ambiente de desenvolvimento. As notas de design organizadas com apoio do Claude Code Opus foram igualmente revistas e validadas contra os requisitos e decisões arquitecturais do autor antes de serem incorporadas no relatório, de forma a garantir que nenhuma afirmação técnica ou de design resulta de uma sugestão da IA sem confirmação independente.

Agradecimentos

A realização deste trabalho não teria sido possível sem o contributo, directo ou indirecto, de um conjunto de pessoas a quem devo reconhecimento genuíno.

Ao **Professor Nuno Datia** e ao **Professor Michel Vorenhout**, orientadores deste projecto, expresso a minha gratidão pela disponibilidade, pelas observações e pela liberdade intelectual que me concederam para explorar caminhos pouco convencionais. A qualidade deste trabalho deve muito à exigência que colocaram e à confiança que depositaram. Ao **Instituto Superior de Engenharia de Lisboa** e ao **Instituto Politécnico de Lisboa**, pela formação académica e pelo enquadramento institucional que tornaram possível um projecto com esta dimensão e ambição.

Aos colegas com quem partilhei percurso ao longo destes anos, agradeço as conversas, os debates técnicos e a camaradagem que tornam o processo de aprender menos solitário e mais fértil. A disponibilidade para discutir ideias, questionar abordagens e partilhar dificuldades foi, muitas vezes, o que impediu que um obstáculo se tornasse um impasse.

Aos amigos de longa data, o reconhecimento pela paciência e pela presença constante. A um projecto desta natureza não se exige apenas competência técnica — exige-se também resistência, e essa constrói-se com o apoio de quem se mantém próximo independentemente das circunstâncias.

À minha família, o agradecimento mais profundo e mais difícil de circunscrever em palavras. A dedicação exigida por um trabalho desta envergadura impõe custos que recaem, inevitavelmente, sobre aqueles que estão mais próximos. A paciência, o suporte incondicional e a crença no valor daquilo que estava a ser construído foram indispensáveis.

A todos os que contribuíram para este percurso:

Família: Ilesh Gamanbhai, Jignaben Mistry, Divyesh Govind.

Orientação e corpo docente: Professor Nuno Datia, Professor António Serrador, Professor Michel Vorenhout.

Colegas e amigos: Pedro Gomes, Guilherme Coutinho, Martim Monteiro, Alexandre Tavares, André Nunes, Francisco Tavares, Rodrigo Sampaio, Simão Afonso, Fábio Nibau, Maria Lopes, Júlia Santana, Vasco Garcia.

Radesh Ilesh Gamanbhai Govind

Índice

Utilização de Inteligência Artificial	vii
Agradecimentos	ix
Lista de Figuras	xiv
Lista de Tabelas	xv
Lista de Listagens	xvi
1 Introdução	1
1.1 Contexto e o Problema	1
1.2 A Solução: <u>Play4Change</u>	2
1.3 Hipótese, Pilares e Objetivos	3
1.4 Organização do Documento	4
2 Enquadramento e Estado da Arte	5
2.1 Conceitos fundamentais	5
2.2 Educação cívica e competências para a transição sustentável	7
2.3 Trabalho relacionado	7
2.4 Síntese e posicionamento do projeto	8
3 Design e Implementação do Sistema	11
3.1 Visão geral da arquitetura	11
3.2 Módulos e responsabilidades	12
3.2.1 Camada de apresentação	12
3.2.2 Rede de fronteira	12
3.2.3 Servidor de aplicação	12
3.2.4 Camada de persistência	14

3.2.5	Observabilidade externa	15
3.3	Fluxos de interacção	15
3.3.1	Autenticação	15
3.3.2	Criar tópico e gerar conteúdo	17
3.3.2.1	Ingestão de conteúdo: PDF e URL	18
3.3.3	Editar questão de um tópico	20
3.3.4	Inscrição num tópico	21
3.3.5	Abandono de tópico	22
3.3.6	Resposta correta a um desafio	23
3.3.7	Resposta errada e ativação do percurso adaptativo	24
3.3.8	Percurso de consolidação	25
3.3.9	Modo de explicação por IA	28
3.4	O motor de inteligência artificial	29
3.4.1	Geração de tarefas do percurso fixo	29
3.4.2	Geração adaptativa: ramos de consolidação	30
3.4.3	Geração da explicação holística	31
3.5	Reconhecimento: o sistema de distintivos	32
3.6	Envolvimento: mecanismos de retenção	33
3.7	Interface de programação	33
3.8	Síntese do desenvolvimento	33
4	Ferramentas, Tecnologias e Metodologia	35
4.1	Arquitetura tecnológica	35
4.2	Pipeline de integração e entrega contínua	37
4.3	Metodologia de desenvolvimento	39
5	Avaliação e Resultados	41
5.1	Metodologia de avaliação	41
5.2	Integridade do sistema de geração	41
5.3	Comportamento dos utilizadores	42
5.3.1	Visão geral	42
5.3.2	Padrões de utilização por tópico	43
5.3.3	Padrões de erro e ciclo adaptativo	43
5.3.4	Usabilidade e perfis de utilizador	44
5.3.5	O ciclo adaptativo em ação: um exemplo real	46
5.3.6	Limitações	47

<i>ÍNDICE</i>	xiii
6 Conclusão	49
6.1 Síntese do trabalho realizado	49
6.2 Limitações	50
6.3 Trabalho futuro	50
A Prompts do Motor de Inteligência Artificial	i
A.1 Percurso fixo	i
A.2 Percurso adaptativo	ii
A.3 Modo de explicação	ii

Lista de Figuras

1.1	Áreas e competências do quadro DigComp 2.2	2
1.2	Os três pilares do Play4Change	3
2.1	Plataformas analisadas posicionadas nos três eixos do Play4Change	9
3.1	Arquitetura lógica do sistema <u>Play4Change</u>	11
3.2	Sequência de autenticação por <u>magic link</u>	17
3.3	Pipeline de geração de conteúdo em quatro fases	18
3.4	Sequência de criação de tópico e geração de conteúdo	20
3.5	Sequência de edição de uma questão de tópico	21
3.6	Sequência de inscrição num tópico	22
3.7	Sequência de abandono de tópico	22
3.8	Sequência de resposta correcta a um desafio	24
3.9	Sequência: resposta errada e activação do percurso adaptativo	25
3.10	Sequência do percurso de consolidação	27
3.11	Máquina de estados do percurso adaptativo	28
3.12	Sequência do ciclo de explicação holística	29
3.13	Escada progressiva para o modo de explicação	32
4.1	Topologia de infraestrutura de produção do Play4Change	37
4.2	Pipeline CI/CD do Play4Change com os três workflows GitHub Actions	38
5.1	Distribuição das pontuações SUS por participante (valores exatos do CSV)	45

Lista de Tabelas

1	Ferramentas de IA utilizadas no desenvolvimento	vii
1.1	Organização do relatório.	4
2.1	Análise comparativa de plataformas de educação digital segundo os três pilares do Play4Change	8
3.1	Módulos do sistema e respectivas responsabilidades	13
3.2	Regras de classificação determinística de padrões de erro	25
3.3	Mapeamento de nível de audiência para descrição no prompt	30
3.4	Estratégias de reutilização na geração adaptativa	30
3.5	Mapeamento de padrões de erro para instruções pedagógicas no prompt	31
3.6	Principais <u>endpoints</u> REST do <u>Play4Change</u>	34
4.1	Tecnologias utilizadas no Play4Change por camada	36
4.2	CrITÉRIOS de qualidade verificados na pipeline de CI	38
5.1	Tempos reais de transição do pipeline de geração (fonte: <code>topic_phase_log</code>)	42
5.2	Indicadores globais de utilização extraídos da base de dados em produção	43
5.3	Indicadores de utilização e densidade de sessões adaptativas por tópico	43
5.4	Distribuição dos padrões de erro e resultados do ciclo adaptativo	44
5.5	Médias por questão da SUS calculadas a partir dos dados brutos do CSV ($n = 12$)	45
5.6	Comparação dos dois grupos de utilizadores identificados	46
6.1	Prioridades de trabalho futuro, organizadas por pilar e evidência da avaliação.	50

Lista de Listagens

A.1	System prompt da geração de tarefas	i
A.2	User prompt da geração de tarefas	ii
A.3	System prompt da geração adaptativa	ii
A.4	System prompt do modo de explicação	ii
A.5	System prompt do diálogo de explicação	iii

Capítulo 1

Introdução

1.1 Contexto e o Problema

A U!REKA ([European University Alliance](#)) é uma aliança de mais de trinta instituições de ensino superior europeias com a missão de preparar estudantes, docentes e cidadãos para liderar a transição para cidades neutras em carbono, sustentáveis e inteligentes [[ureka2026website](#)]. Os seus centros de competência abrangem áreas como as “cidades resilientes e neutras em carbono” e a “governança inovadora e o envolvimento dos cidadãos” [[ureka2026alliance](#)] — um reconhecimento de que esta transição não é apenas um problema de engenharia ou de financiamento, mas também um problema de participação cívica. Tornar uma cidade mais sustentável exige que os cidadãos compreendam o que está em jogo, saibam como agir e se sintam parte do processo.

A questão que se coloca imediatamente é: o que significa, em termos concretos, “estar preparado” para essa participação? O relatório [DigComp 2.2 – The Digital Competence Framework for Citizens](#), publicado pelo Centro Comum de Investigação da Comissão Europeia, oferece esse referencial: organiza a competência digital em cinco grandes áreas — procurar e avaliar informação, comunicar e colaborar, criar conteúdos, manter-se em segurança e resolver problemas — e descreve-as através de exemplos concretos do que uma pessoa sabe, é capaz de fazer e valoriza em cada uma delas [[vuorikari2022digcomp](#)]. A Figura 1.1 ilustra esta estrutura.

Para o [Play4Change](#), as **áreas 1 e 2** são as mais diretamente relevantes: literacia informacional (saber pesquisar, avaliar e identificar desinformação) e comunicação e colaboração digitais (participar em processos de decisão [online](#) e colaborar de forma construtiva). São precisamente estas as competências que o défice atual mais penaliza — e que, sem prática estruturada, mais dificilmente se desenvolvem.

O problema tem três camadas que se reforçam mutuamente. A primeira é o **défice de competências digitais e cívicas**: em 2023, apenas 56% da população europeia entre os 16 e os 74 anos possuía pelo menos as competências digitais básicas definidas pelo quadro DigComp [[vuorikari2022digcomp](#), [eurostat2023digitalskills](#)] — ou seja, quase metade dos cidadãos europeus fica abaixo desse limiar, o que limita a sua capacidade de participar em processos de decisão que decorrem crescentemente em plataformas digitais — desde consultas públicas municipais a plataformas de participação cidadã. A segunda é a **desinformação e a desconfiança**: num ambiente marcado pela abundância de informação e pela dificuldade crescente de verificação, a capacidade de avaliação crítica é simultaneamente mais necessária e mais difícil de desenvolver sem prática continuada. A terceira, e a mais diretamente operacional, é o **abandono nas plataformas de aprendizagem digital**: mesmo quando as pessoas adotam




Figura 1.1: As cinco áreas de competência digital e respetivas competências, segundo o quadro DigComp 2.2. Fonte: adaptado de [vuorikari2022digcomp], com base em material disponibilizado sob licença Creative Commons Attribution 4.0 (CC BY 4.0).

ferramentas de educação online, a taxa de conclusão raramente ultrapassa os 10% [jordan2014mooc]. O problema não está na disponibilidade de conteúdos — está na incapacidade das plataformas existentes de motivar a continuidade.

É sobre este conjunto de falhas que o projeto se debruça: de que forma pode uma plataforma de educação digital, informal e gamificada, apoiada por inteligência artificial, ajudar os cidadãos a desenvolver as competências de que precisam para participar na transição para cidades sustentáveis — e, ao mesmo tempo, conseguir que continuem a usá-la ao longo do tempo?

1.2 A Solução: Play4Change

Em resposta à pergunta com que termina a secção anterior, o Play4Change é a resposta de engenharia proposta para este problema. Trata-se de uma plataforma de educação digital informal, gamificada e suportada por inteligência artificial, concebida para ajudar os cidadãos a adquirir, de forma natural e continuada, as competências cívicas e digitais de que precisam para participar na transição para cidades sustentáveis.

A proposta não é um curso estruturado nem uma plataforma de e-learning convencional. O Play4Change é pensado como uma experiência de aprendizagem quotidiana — breve, contextualizada e adaptativa —

que compete com o hábito de consumo de conteúdo digital passivo e o substitui por algo que exige e recompensa o pensamento crítico. A secção seguinte detalha a hipótese central que sustenta esta proposta e os três pilares técnicos em que se traduz.

1.3 Hipótese, Pilares e Objetivos

A hipótese central que orienta este trabalho é que a combinação de conteúdos curtos e contextualizados, reconhecimento visível do progresso e personalização adaptativa pode contribuir para melhorar a retenção e o envolvimento a longo prazo — transformando a aprendizagem de competências cívicas e digitais de uma tarefa pontual num hábito. Esta hipótese é avaliada de forma preliminar no Capítulo 5, com uma amostra reduzida de utilizadores, pelo que as conclusões aqui apresentadas têm valor indicativo e não definitivo. Esta hipótese traduz-se em três pilares técnicos que estruturam toda a arquitetura do Play4Change.




Figura 1.2: Os três pilares — reconhecimento, envolvimento e personalização — que sustentam a proposta do Play4Change e orientam os objetivos deste trabalho.

Reconhecimento. Sempre que um utilizador atinge um limiar de domínio num tópico, a plataforma assinala esse facto de forma explícita através de um distintivo. Este mecanismo, ancorado na lógica de aprendizagem por mestria [**bloom1968learning**], cumpre duas funções: dá ao utilizador uma noção concreta da sua progressão e fornece ao sistema um sinal de competência verificada.

Envolvimento. A taxa de abandono que caracteriza as plataformas de e-learning é uma falha de design motivacional, não de conteúdo. O Play4Change responde com mecanismos específicos: sequências de utilização consecutiva (streaks) e desbloqueio diário de conteúdos [**ott2019gamification**]. Estes mecanismos transformam o regresso à aplicação num comportamento esperado e recompensado, em vez de uma decisão a tomar de novo todos os dias.

Personalização. Não existe percurso de aprendizagem ótimo único. A plataforma usa inteligência artificial para classificar os erros do utilizador em padrões reconhecíveis, gerar percursos de reforço adaptados ao seu perfil de dificuldade recorrendo a um modelo de linguagem de grande dimensão [**kasneci2023chatgpt**], e manter sessões de explicação interativa em que o utilizador esclarece dúvidas por conversação. A IA não apresenta ao utilizador o que ele já espera ver — ajusta o caminho ao que ainda não domina.

De forma concreta, este trabalho propõe-se a cumprir dois tipos de objetivos: objetivos de design, diretamente ligados aos três pilares acima descritos, e objetivos de processo, relativos à construção e validação do protótipo.

Objetivos de design:

- **Reconhecimento** — construir um motor de distintivos que assinale a aquisição de competências de forma objetiva e verificável;
- **Envolvimento** — implementar mecanismos que reduzam o abandono e promovam a utilização continuada;
- **Personalização** — desenvolver um sistema de aprendizagem adaptativa suportado por IA que ajuste os conteúdos ao ritmo e às dificuldades de cada utilizador.

Objetivos de processo:

- **Construção** — construir e validar um protótipo funcional que integre os três pilares de forma coerente;
- **Avaliação** — recolher, junto de utilizadores de diferentes perfis, uma primeira avaliação do que funciona, do que pode melhorar e do que mais valorizam nesta forma de aprender.

O Capítulo 3 detalha como cada um destes componentes foi concebido e implementado. O presente relatório descreve um protótipo — um primeiro passo que demonstra viabilidade, mas que deixa espaço deliberado para crescer em cada uma destas três frentes, como se discute no Capítulo 6.

1.4 Organização do Documento

O presente relatório está organizado em seis capítulos, conforme descrito na Tabela 1.1.

Tabela 1.1: Organização do relatório.

Capítulo	Título	Conteúdo
1	Introdução	Contextualiza o problema, apresenta a solução e define os objetivos e pilares do <u>Play4Change</u> .
2	Enquadramento	Aprofunda o estado da arte no âmbito da educação digital, da aprendizagem adaptativa e dos quadros europeus de competência digital e cívica.
3	Design e Implementação do Sistema	Descreve o processo de construção da solução — requisitos, arquitetura, implementação e <u>design</u> da interface.
4	Ferramentas, Tecnologias e Metodologia	Apresenta as tecnologias e metodologias usadas, com destaque para o papel da inteligência artificial no produto e no processo de desenvolvimento.
5	Avaliação	Apresenta e discute os resultados da avaliação preliminar realizada junto de utilizadores reais.
6	Conclusão	Reúne as conclusões principais, assume as limitações do trabalho e aponta caminhos para trabalho futuro.

Capítulo 2

Enquadramento e Estado da Arte

2.1 Conceitos fundamentais

Três conceitos estruturam os pilares do Play4Change: gamificação, aprendizagem adaptativa e inteligência artificial. A sua articulação sustenta diretamente reconhecimento, envolvimento e personalização — os pilares definidos na Secção 1.3.

Gamificação

A gamificação aplica mecânicas de jogo — pontos, níveis, distintivos, streaks — a contextos não-lúdicos para aumentar motivação e persistência [ott2019gamification]. Fundamenta dois pilares: **reconhecimento** (distintivos que assinalam competências dominadas) e **envolvimento** (mecanismos de regresso natural à plataforma).

Os mecanismos de Points e Badges geram envolvimento a curto prazo, mas podem substituir motivação intrínseca por extrínseca [ott2019gamification]. A Teoria da Autodeterminação [deci1985intrinsic] identifica três necessidades psicológicas que sustentam motivação duradoura:

- **Autonomia:** os streaks reforçam um regresso voluntário — a decisão é sempre da pessoa.
- **Competência:** os distintivos são atribuídos apenas quando um tópico é efetivamente dominado, não por mera participação.
- **Relação:** os tópicos cívicos ancoram a aprendizagem em situações reais, tornando-a significativa para além do jogo.

Aprendizagem adaptativa

A aprendizagem adaptativa ajusta percurso, ritmo e dificuldade ao desempenho individual em vez de um currículo uniforme [vanlehn2011relative]. Sustenta o pilar da **personalização**.

Três resultados de investigação fundamentam esta abordagem:

- **Problema das 2 sigma** [bloom1984sigma]: tutoria individual supera o ensino convencional em 2 desvios padrão — um dos efeitos mais expressivos documentados em pedagogia.

- **Step-level feedback** [vanlehn2011relative]: ITS com retroalimentação por passo obtêm ganhos de 0,4 a 1,0 desvio padrão face ao ensino convencional — podendo constituir uma alternativa escalável à tutoria individual humana.
- **Aprendizagem por mestria** [bloom1968learning]: o utilizador não avança enquanto não dominar o tópico atual; no Play4Change, reforçada por um grafo de pré-requisitos e geração de percursos de remediação em tempo real.

IA na personalização

Os modelos de linguagem de grande escala (LLM) permitem gerar conteúdos pedagógicos personalizados a pedido, em linguagem natural e à escala [kasneci2023chatgpt]. O risco principal é a geração de conteúdo factualmente incorreto (hallucinations) — afirmações plausíveis mas sem suporte documental, particularmente graves num contexto de educação cívica.

RAG como condicionador da geração. O padrão Retrieval-Augmented Generation (RAG) [lewis2020rag] vai além da simples injeção de contexto no prompt. Na formulação original de Lewis et al., o modelo combina memória paramétrica (os pesos do LLM) com memória não-paramétrica (documentos recuperados em tempo real). O resultado é que a distribuição de probabilidade de geração fica condicionada pelos documentos recuperados: o conteúdo verificado fornecido no contexto reduz — sem eliminar — a probabilidade de o modelo gerar afirmações sem suporte documental [gao2023rag]. Note-se que o RAG não restringe literalmente o espaço latente do modelo (os seus pesos permanecem inalterados); o que muda é a distribuição condicional de geração para aquele prompt específico. No Play4Change, o prompt inclui o perfil de dificuldade do utilizador, o tópico pedagógico ativo e exemplos de exercícios validados — ancorando a geração em conteúdo previamente curado pela equipa pedagógica da U!REKA [ureka2026alliance].

Limites da janela de contexto e chunking. Os LLM têm janelas de contexto finitas, medidas em tokens. Documentos extensos não cabem integralmente num único prompt, tornando a segmentação (chunking) uma decisão de engenharia crítica. A estratégia mais simples divide o texto em blocos de tamanho fixo, mas pode cortar unidades semânticas a meio; a segmentação semântica preserva coerência, mas exige um pipeline de processamento mais complexo. Adicionalmente, Liu et al. [liu2023lost] demonstraram que, mesmo quando o contexto cabe na janela, o desempenho do modelo degrada quando a informação relevante se encontra no meio de um contexto longo — fenómeno designado lost in the middle. Estas limitações fundamentam uma decisão de implementação concreta no Play4Change: um limite máximo de 8000 caracteres no texto extraído para o prompt de geração, como compromisso entre completude do contexto e integridade da janela do modelo (detalhe no Capítulo 3).

Métricas de avaliação de sistemas RAG. As métricas clássicas de geração de linguagem natural (BLEU, ROUGE) são inadequadas para avaliar saídas de LLM em arquiteturas RAG, pois não medem fidelidade factual. O framework RAGAS [es2023ragas] propõe três métricas especializadas:

- **Faithfulness:** o grau em que a resposta gerada contém apenas afirmações suportadas pelo contexto recuperado — a principal barreira contra alucinações.

- **Answer Relevance:** o grau em que a resposta é pertinente relativamente à questão colocada, independentemente da fidelidade factual.
- **Context Precision:** a proporção do contexto recuperado que é de facto relevante para a geração — mede a qualidade do módulo de recuperação.

No protótipo atual, estas métricas não são computadas automaticamente. A garantia de integridade estrutural é assegurada por validação de esquema JSON após geração: caso a resposta não conforme com a estrutura esperada, o pedido é reenviado ao LLM com indicação explícita dos erros, sem revisão humana no caminho crítico. Esta abordagem garante integridade estrutural mas não substitui uma avaliação de fidelidade factual — uma limitação a endereçar em iterações futuras.

2.2 Educação cívica e competências para a transição sustentável

Literacia cívica e literacia digital são indissociáveis: o quadro DigComp 2.2 [vuorikari2022digcomp] formaliza as competências de avaliação crítica e de colaboração digital como condição da participação cívica informada em contextos de transição sustentável [ureka2026alliance]. Uma revisão sistemática da literatura sobre gamificação de processos de participação cívica (e-participation) conclui que mecânicas de jogo estão associadas a ganhos de envolvimento, motivação e aprendizagem cívica em contextos informais [hassan2020gameful], o que reforça — além do quê conta como competência (DigComp) — o porquê de uma abordagem gamificada e informal ser adequada para a desenvolver.

O Play4Change endereça a **aprendizagem informal** — cidadãos fora de contextos formais — através de três princípios:

- **Informalidade:** sessões curtas em formato de jogo, sem avaliação nem pressão institucional.
- **Acessibilidade imediata:** aplicação móvel sem registo obrigatório, sem custo, disponível em qualquer momento.
- **Relevância percebida:** conteúdos ancorados em situações reais da vida urbana, não em matéria académica abstrata.

2.3 Trabalho relacionado

A análise de plataformas de referência não se baseia em sobreposição temática — nenhuma das plataformas estudadas é uma ferramenta de educação cívica urbana — mas numa auditoria estrita de mecânicas de retenção, progressão e gamificação. O argumento de fundo é que os padrões arquiteturais de sucesso são transferíveis independentemente do domínio de conteúdo: o Play4Change extrai estas mecânicas para responder ao elevado défice de retenção e abandono que caracteriza a aprendizagem informal, aplicando-as de forma inovadora ao contexto da U!REKA [ureka2026alliance] e da sustentabilidade urbana. Cinco plataformas foram analisadas segundo os três pilares — reconhecimento, envolvimento e personalização — conforme sintetizado na Tabela 2.1.

A comparação é intencionalmente agnóstica quanto ao domínio de conteúdo. Duas distinções estruturais delimitam o âmbito da transferência:

Plataforma	Reconhecimento	Envolvimento	Personalização
Kahoot!	Pontuações e pódios em tempo real que celebram o desempenho individual e do grupo	Formato de jogo/quiz competitivo, muito eficaz a tornar o momento de avaliação divertido	Pouco adaptativo: os mesmos quizzes são apresentados a todos os participantes
Duolingo	Sistema de níveis, ligas e distintivos que assinalam claramente cada progresso	Sequências diárias (<u>streaks</u>), lembretes e notificações que incentivam o regresso todos os dias	Ajusta a dificuldade dos exercícios de acordo com os erros e acertos do utilizador
Coursera	Certificados formais e emblemas associados à conclusão de cursos e módulos	Estrutura por prazos e módulos que organiza o estudo, mas com pouca componente lúdica	Percursos de aprendizagem recomendados com base nos interesses e no histórico do utilizador
Khan Academy	Pontos de energia, distintivos e mapas de progresso que tornam visível o que já foi dominado	Painel de progresso e missões que ajudam o utilizador a saber sempre “o que vem a seguir”	Aprendizagem por mestria (<u>mastery learning</u>) [bloom1968learning]: só se avança quando se domina o tema anterior
edX	Certificados verificados e indicadores de conclusão por módulo	Fóruns de discussão e prazos que criam uma sensação de comunidade e de ritmo	Conteúdos relativamente uniformes, com pouca adaptação automática ao desempenho individual

Tabela 2.1: Benchmarking de produto de cinco plataformas de educação digital amplamente conhecidas, segundo os três pilares definidos para o Play4Change: reconhecimento, envolvimento e personalização.

- **Dimensão temática:** nenhuma das plataformas estudadas foi concebida para educação cívica urbana; são, porém, provas de conceito da eficácia das mecânicas de retenção que o Play4Change pretende incorporar. O que se importa não é o quê que ensinam, mas o como mantêm os utilizadores.
- **Ponto de acesso:** todas são primariamente web; o Play4Change é mobile-native — o canal privilegiado dos segmentos que mais importa incluir, e onde o défice de abandono é mais pronunciado.

A Figura 2.1 posiciona cada plataforma nos três eixos.

2.4 Síntese e posicionamento do projeto

Esta análise revelou um padrão consistente: cada plataforma excele numa dimensão — retenção diária via streaks, reconhecimento visível de progresso ou adaptação ao ritmo individual — mas nenhuma combina as três, nem as aplica à educação cívica. Esta conclusão orientou diretamente as decisões de design do Play4Change.

O critério de seleção foi estritamente comportamental: quais os padrões que comprovadamente reduzem o abandono e aumentam a persistência, independentemente do tema. Do conjunto de plataformas analisadas, **adotaram-se**: as sequências diárias (streaks) e os distintivos de progresso do Duolingo — mecânicas de retenção diária com eficácia amplamente documentada; a progressão por mestria da Khan Academy [**bloom1968learning**] — que impede o avanço enquanto o tópico atual não for dominado; e o formato de quiz interativo e imediato do Kahoot!. **Não se adotaram**, pelo menos nesta fase, os certificados formais do Coursera e do edX — que implicariam um nível de acreditação externo fora do




Figura 2.1: Cada plataforma representada num gráfico de três eixos — reconhecimento, envolvimento e personalização — de acordo com o nível (baixo, médio ou alto) atribuído na Tabela 2.1. Os três eixos são níveis ordinais independentes, não proporções de um total fixo: uma plataforma pode estar ao nível “alto” nos três simultaneamente. A área a tracejado — a única linha não sólida do gráfico — assinala a meta do Play4Change: alcançar um nível elevado nos três pilares em simultâneo, em vez de se destacar apenas num deles.

âmbito de um protótipo — nem as tabelas de classificação altamente competitivas, por potencialmente contrariarem os princípios da Teoria da Autodeterminação [deci1985intrinsic] em utilizadores menos experientes.

A diferença mais fundamental entre o Play4Change e todas as plataformas analisadas reside na combinação de **tema** (educação cívica para a transição sustentável) e de **personalização gerativa** (uso de um LLM para gerar conteúdos adaptativos em tempo real, com base no perfil de dificuldade de cada utilizador, e não apenas para selecionar conteúdos de um repositório fixo). Esta combinação, tanto quanto foi possível apurar neste levantamento, não está presente em nenhuma das plataformas existentes — o que justifica a proposta, mas também coloca desafios concretos: o custo da inferência de IA a escala, a garantia de qualidade dos conteúdos gerados e a necessidade de validação pedagógica são dimensões que este protótipo apenas começa a explorar, e que uma versão madura da plataforma terá necessariamente de endereçar com maior rigor. O resultado, nesta fase, é um protótipo funcional: prova de viabilidade da combinação, não ainda uma plataforma completa e madura.

Capítulo 3

Design e Implementação do Sistema

Este capítulo descreve como o Play4Change foi concebido e implementado. A ênfase recai sobre a **arquitetura lógica** do sistema — os seus módulos, as respetivas responsabilidades e os fluxos de interação que os atravessam — e sobre o **motor de inteligência artificial** que sustenta a personalização adaptativa: como os prompts são construídos, como a resposta do modelo é processada e como o sistema lida com falhas.

3.1 Visão geral da arquitetura




Figura 3.1: Arquitetura lógica do Play4Change. As cinco zonas — Apresentação, Rede de Fronteira, Aplicação, Persistência e Observabilidade — interagem através de protocolos e contratos bem definidos. Os serviços externos (LLM e Email) são acedidos exclusivamente pelo servidor de aplicação, isolando os clientes de qualquer dependência direta. Os rótulos do diagrama mantêm-se em inglês por refletirem diretamente a nomenclatura usada no código-fonte e na configuração de infraestrutura; U/D designa as operações de upload/download sobre o armazenamento de objetos, e R/W as operações de leitura/escrita sobre a base de dados relacional.

O Play4Change organiza-se em cinco zonas lógicas claramente delimitadas (Figura 3.1): a camada de **apresentação**, que agrega os clientes que interagem com o sistema; a **rede de fronteira**, responsável

pela terminação TLS e pelo encaminhamento de tráfego; o **servidor de aplicação**, onde reside toda a lógica de domínio; a camada de **persistência**, que garante o armazenamento durável dos dados; e a zona de **observabilidade**, que recolhe e expõe métricas operacionais. Acresce ainda um conjunto de **serviços externos** que o servidor utiliza para capacidades que transcendem o seu perímetro: geração de linguagem natural e entrega de correio eletrónico.

3.2 Módulos e responsabilidades

Esta secção descreve cada módulo pelo que é responsável por garantir, não pelas tecnologias que usa. A Tabela 3.1 fornece um resumo antes da descrição detalhada.

3.2.1 Camada de apresentação

A camada de apresentação é o único ponto de contacto direto com o utilizador humano, composta por dois clientes independentes com finalidades distintas.

O **Mobile Client** é o canal primário de aprendizagem. A sua responsabilidade central é traduzir o modelo de domínio devolvido pela API REST numa experiência de utilização fluída: apresentar a tarefa diária, recolher a resposta, comunicar o resultado (correto ou errado) e — quando despoletado pelo servidor — navegar automaticamente para o percurso adaptativo ou para o modo de explicação. O cliente não contém lógica de negócio: toda a avaliação de respostas, atribuição de pontos e classificação de erros ocorre exclusivamente no servidor.

O **Web Client** serve os administradores de conteúdo. As suas responsabilidades incluem criar tópicos a partir de documentos PDF ou URLs, monitorizar em tempo real o progresso de geração de tarefas via SSE, editar individualmente as questões geradas pela IA, configurar o grafo de pré-requisitos, e consultar relatórios de utilização.

3.2.2 Rede de fronteira

O **Reverse Proxy** interpõe-se entre a internet pública e o servidor de aplicação, cumprindo três responsabilidades distintas: terminação TLS (recebe ligações HTTPS e reencaminha internamente via HTTP); encaminhamento de tráfego (distingue pedidos de API de ativos estáticos); e fronteira de segurança (o servidor nunca está exposto diretamente à internet pública).

3.2.3 Servidor de aplicação

O servidor de aplicação é o núcleo do sistema, organizado internamente em cinco sub-módulos.

Autenticação e Segurança. Responsável por garantir que apenas utilizadores legítimos acedem ao sistema com o nível de privilégio correto. Gere o ciclo de vida completo do magic link (emissão, hash, consumo atómico, expiração); emite e valida pares de tokens de acesso e renovação; impõe limites de frequência por endereço IP; e valida o papel (`ROLE_USER` ou `ROLE_ADMIN`) em cada pedido protegido. Não tem conhecimento de qualquer lógica de negócio.

Módulo	Responsabilidades principais
Mobile Client	Renderizar a experiência de aprendizagem; submeter respostas; navegar nos percursos adaptativo e de explicação; apresentar distintivos e streak.
Web Client	Interface de administração; criar, editar e publicar tópicos; monitorizar progresso de utilizadores; configurar pré-requisitos e o grafo de aprendizagem.
Reverse Proxy	Terminar ligações TLS; encaminhar pedidos para o servidor de aplicação; servir a SPA do cliente web; proteger o servidor de exposição direta à internet.
Autenticação & Segurança	Emitir e validar magic links; emitir, renovar e revogar tokens de sessão; impor limites de frequência por IP; garantir que cada pedido autenticado tem o papel correto.
Lógica de Domínio	Orquestrar todos os casos de uso: inscrição em tópicos, entrega e avaliação de tarefas, geração do percurso adaptativo, emissão de distintivos e gestão de preferências do utilizador.
Agendadores	Executar tarefas temporais sem intervenção humana: expirar tópicos cujo período de inscrição terminou, e detectar gerações de IA presas (watchdog). A desativação de inscrições individuais e a revisão por pares são acionadas sincronamente pelos respetivos serviços, não por tarefas agendadas.
Agente de IA	Construir prompts contextualizados; invocar o fornecedor de LLM; validar e sanear a resposta; gerir a deduplicação vetorial; isolar o resto do sistema de qualquer dependência direta do modelo.
Base de Dados	Persistir o estado durável de todos os agregados de domínio; suportar pesquisa por similaridade vetorial para deduplicação de tarefas geradas.
Armazenamento de Objetos	Guardar ficheiros binários (PDFs, fotografias de submissões); disponibilizar URLs pré-assinados para acesso temporário.
Métricas DB	Receber e armazenar séries temporais de métricas operacionais recolhidas do servidor por scraping periódico.
Dashboard	Visualizar as métricas operacionais em painéis de tempo real para observabilidade e detecção de anomalias.
Fornecedor de LLM	Gerar texto determinado por prompt; devolver respostas estruturadas (JSON) ou em prosa; sem estado persistente sobre o sistema.
API de Email	Entregar transacionalmente mensagens de correio eletrónico (magic links de autenticação) com garantias de entrega e rastreio.

Tabela 3.1: Módulos do sistema Play4Change e respetivas responsabilidades. A descrição foca o o quê (contrato de responsabilidade), não o como (tecnologia de implementação).

Lógica de Domínio. Implementa todos os casos de uso e mantém os invariantes do domínio: avaliar respostas e calcular pontos com penalização temporal; classificar padrões de erro de forma determinística; orquestrar o ciclo de vida das inscrições; gerir o desbloqueio diário de tarefas por índice; detectar a necessidade de percurso adaptativo e despoletá-lo assincronamente; emitir distintivos quando os critérios de mestria são atingidos; e verificar a integridade do grafo de pré-requisitos por pesquisa em profundidade.

Agendadores. Executa tarefas temporais em segundo plano sem intervenção humana. O **watchdog de geração de IA**: qualquer geração de conteúdo que permaneça no estado `GENERATING` por mais tempo do que o timeout configurado é considerada presa — tipicamente por falha do servidor durante a chamada assíncrona ao LLM. O watchdog deteta estes casos, transita o registo para `FAILED` e, consoante o tipo de geração, ou marca o tópico como `FAILED` (para conteúdo de percurso fixo) ou repõe a atribuição original em `PENDING` (para sessões de explicação), garantindo que nenhum utilizador fica bloqueado indefinidamente à espera de conteúdo que nunca vai chegar. Um segundo agendador (`TopicExpirationJob`) expira tópicos cujo período de inscrição terminou; a desativação de inscrições individuais e a revisão por pares não são geridas por tarefas agendadas, mas acionadas sincronamente pelos serviços respetivos no momento em que ocorrem.

Agente de IA. É o único ponto de contacto com o fornecedor de LLM. A sua principal responsabilidade é **isolar** o resto do sistema de qualquer dependência do modelo: o servidor de aplicação nunca sabe que modelo está a ser usado, que API está a ser chamada, ou que formato de resposta é devolvido. O agente expõe uma interface com três operações: gerar tarefas de percurso fixo, gerar um ramo adaptativo para um padrão de erro, e gerar explicação em prosa. Internamente, constrói prompts contextualizados, valida o JSON produzido (com retenção automática), saneia o texto gerado, calcula embeddings para deduplicação vetorial e reporta métricas de latência e taxa de falha.

Observabilidade (interna ao servidor). Instrumenta o servidor com contadores e temporizadores que cobrem os eventos de negócio mais relevantes: submissões corretas e incorretas, sessões adaptativas criadas e resolvidas, gerações de IA com sucesso e falha, inscrições concluídas, distintivos emitidos. Os dados são expostos num endpoint de scraping sem impacto na performance dos pedidos.

3.2.4 Camada de persistência

A camada de persistência divide-se em dois componentes com responsabilidades completamente distintas.

Base de Dados. Armazena todo o estado durável do domínio: utilizadores, inscrições, atribuições, sessões adaptativas, sessões de explicação, templates de tarefas, distintivos e o grafo de pré-requisitos. O modelo relacional garante a consistência transacional dos invariantes críticos — nomeadamente a natureza atómica do consumo de tokens de autenticação e da transição de estado das inscrições.

Para além da persistência relacional clássica, a base de dados suporta **pesquisa por similaridade vetorial**: cada template de tarefa gerado pelo LLM é associado a um embedding de 1024 dimensões que

representa semanticamente o seu conteúdo. Na geração de ramos adaptativos, o sistema calcula o embedding do contexto de dificuldade atual e executa uma pesquisa de vizinhos mais próximos por similaridade cosseno, recuperando ramos previamente gerados que sejam semanticamente equivalentes. Este mecanismo, descrito em detalhe na Secção 3.4.2, elimina gerações redundantes e reduz tanto a latência como o custo de chamadas ao LLM.

Armazenamento de Objetos. Responsável por guardar ficheiros binários que não têm lugar num modelo relacional: os PDFs que os administradores carregam para criar tópicos, e eventuais ficheiros de submissão dos utilizadores. O acesso aos ficheiros nunca é feito diretamente pelo cliente — o servidor gera URLs pré-assinados com tempo de vida limitado que permitem ao cliente descarregar ou visualizar o ficheiro diretamente a partir do armazenamento, sem que o conteúdo binário transite pelo servidor de aplicação. Isto elimina um gargalo de banda e garante que os ficheiros nunca são expostos sem autorização implícita do servidor.

3.2.5 Observabilidade externa

A observabilidade do sistema é composta por dois componentes que operam fora do servidor de aplicação, garantindo que a monitorização não interfere com a execução da lógica de negócio.

Métricas DB. Recebe e armazena séries temporais de métricas operacionais recolhidas do servidor por scraping periódico ao endpoint de observabilidade interna. A arquitetura de pull — em que a base de métricas vai buscar os dados ao servidor em vez de o servidor os enviar — garante que uma eventual indisponibilidade da base de métricas não afecta o desempenho nem a disponibilidade do servidor. As métricas cobertas incluem: latência de pedidos por rota, taxa de erro HTTP, contadores de eventos de negócio (inscrições, submissões, distintivos), e métricas de desempenho da JVM (memória, GC, threads).

Dashboard. Visualiza as métricas armazenadas na base de métricas em painéis de tempo real, acessíveis à equipa de operações. Os painéis estão organizados em dois níveis: um nível operacional, que exhibe a saúde imediata do sistema (taxa de erro, latência p95, utilização de recursos); e um nível de produto, que exhibe métricas de envolvimento dos utilizadores (inscrições ativas, taxa de conclusão de tópicos, sessões adaptativas criadas por dia, distintivos emitidos). A separação entre os dois níveis permite que tanto engenheiros como gestores de produto extraiam valor da mesma infra-estrutura de observabilidade sem navegar por painéis irrelevantes para os seus objetivos.

3.3 Fluxos de interacção

Esta secção apresenta os diagramas de sequência dos principais fluxos do sistema. Cada diagrama descreve a interacção entre atores (cliente, servidor, componentes internos, serviços externos) para um caso de uso concreto.

3.3.1 Autenticação

O Play4Change usa autenticação sem palavra-passe (passwordless) baseada em magic links. O fluxo divide-se em duas fases: pedido do link e verificação do token.

Na fase de pedido (passos 1–4 da Figura 3.2), o utilizador fornece apenas o endereço de email. O servidor gera um token opaco criptograficamente seguro, armazena **apenas o seu hash SHA-256** na base de dados (o token em claro nunca é persistido), e envia o link por email. Esta separação garante que mesmo um acesso não autorizado à base de dados não compromete os tokens ativos. Ao contrário de uma password, o token é gerado aleatoriamente com entropia elevada e tem validade curta (15 minutos), pelo que não está sujeito a ataques de dicionário ou de tabelas pré-calculadas (rainbow tables); por essa razão, um salt — necessário para mitigar esses ataques em passwords de baixa entropia escolhidas por utilizadores — não é necessário aqui.

Na fase de verificação (passos 5–8), o servidor calcula o hash do token recebido e executa uma atualização atômica:

```
UPDATE SET used=true WHERE token=$hash AND used=false AND expires_at>NOW()
```

Esta operação atômica elimina a janela de Time-of-Check/Time-of-Use (TOCTOU) que existiria com um `SELECT` seguido de `UPDATE` separados.




Figura 3.2: Autenticação passwordless. O token opaco em claro nunca é persistido — apenas o seu hash SHA-256 é armazenado (passo 2). A verificação usa uma atualização atômica (passo 6) que elimina a janela TOCTOU. Se o token for inválido, usado ou expirado, o servidor rejeita sem informação adicional — uma decisão deliberada de segurança **anti-enumeração**: distinguir entre "token inválido", "já usado" e "expirado" na resposta daria a um atacante informação útil para inferir o estado de tokens que não lhe pertencem.

3.3.2 Criar tópico e gerar conteúdo

A criação de um tópico desencadeia um **pipeline de geração em quatro fases** (Figura 3.4). O pedido HTTP do administrador retorna imediatamente com o identificador do tópico (passo 3); toda a geração ocorre em background de forma assíncrona, com notificação em tempo real ao cliente via SSE.

As quatro fases são: **INGESTION** (extração do texto do PDF ou URL); **ANALYSIS** (limpeza e estruturação do módulo de aprendizagem); **GENERATION** (chamada ao LLM com o texto extraído como contexto); e **INDEXING** (persistência dos templates de tarefas com embeddings e criação da microcompetência associada ao tópico). Após a transição para *ACTIVE*, o tópico fica disponível para inscrições. A

Figura 3.3 ilustra o fluxo completo, incluindo os caminhos de falha em cada fase.




Figura 3.3: Pipeline de geração de conteúdo assíncrona. O caminho feliz (setas sólidas) transita o tópico de PENDING para ACTIVE em quatro fases; o administrador é notificado em tempo real via SSE (setas pontilhadas roxas) após cada fase. Qualquer falha (setas a vermelho) transita diretamente para FAILED sem degradar silenciosamente a qualidade do conteúdo.

3.3.2.1 Ingestão de conteúdo: PDF e URL

A fase de INGESTION é a primeira do pipeline e determina a qualidade de todo o conteúdo que o LLM vai gerar. O administrador fornece o conteúdo numa de duas formas: um ficheiro PDF carregado diretamente, ou um URL público a partir do qual o sistema descarrega o conteúdo. Em ambos os casos, o objetivo é o mesmo: obter texto simples e limpo que possa ser injetado no contexto do LLM.

Ingestão de PDF. O ficheiro é recebido pelo servidor, persistido no armazenamento de objetos e depois processado por extracção de texto. O processador percorre o PDF página a página, extrai o conteúdo textual de cada uma e concatena-o preservando a ordem original do documento. O texto resultante é normalizado: espaços múltiplos e quebras de linha excessivas são colapsadas para reduzir ruído sem perder estrutura semântica.

Esta abordagem funciona bem para PDFs **nativamente digitais** — documentos criados por processadores de texto ou exportados de apresentações — porque o texto está codificado de forma programaticamente acessível. No entanto, enfrenta uma limitação fundamental com **PDFs digitalizados** (imagens de páginas físicas): nestes casos, o extractor não encontra texto e devolve uma *string* vazia ou quase vazia. Sem texto, o LLM recebe um contexto inadequado e as tarefas geradas serão genéricas e desligadas do conteúdo real do documento. O sistema deteta esta situação quando o texto extraído é inferior a um limiar mínimo de caracteres e transita o tópico para FAILED com uma mensagem de erro explícita, em vez de gerar conteúdo de baixa qualidade silenciosamente.

Ingestão de URL. Quando o administrador fornece um URL, o servidor efetua um pedido HTTP GET ao destino e extrai o conteúdo textual da página. O HTML recebido é processado para remover markup,

scripts, estilos e elementos de navegação, retendo apenas o texto principal da página.

Esta abordagem tem três limitações importantes. A primeira é a dependência de **renderização no servidor**: páginas que carregam o seu conteúdo dinamicamente via JavaScript (aplicações single-page) devolvem apenas o esqueleto HTML inicial sem conteúdo real, uma vez que o sistema não executa um motor de renderização completo. A segunda é o **acesso restrito**: URLs que exigem autenticação, que estão por trás de paywalls, ou que bloqueiam pedidos de servidores automatizados resultam num erro de acesso que falha a ingestão. A terceira é a **instabilidade do conteúdo**: ao contrário de um PDF, uma página web pode ser alterada pelo seu proprietário após a criação do tópico, tornando o conteúdo gerado desatualizado sem qualquer notificação ao sistema.

Limite de contexto e truncagem. Independentemente da fonte, o texto extraído é truncado a **8 000 caracteres** antes de ser injetado no prompt do LLM, onde preenche o campo `subjectDomain` — o trecho de contexto temático que ancora a geração de tarefas ao conteúdo da fonte. Este limite existe porque os modelos de linguagem têm uma janela de contexto finita e porque textos excessivamente longos diluem a atenção do modelo, reduzindo a coerência e a especificidade das tarefas geradas.

A truncagem tem uma implicação direta: para documentos longos — manuais técnicos, dissertações, relatórios extensos — apenas os primeiros 8 000 caracteres são usados como contexto. Se o conteúdo mais relevante estiver distribuído ao longo de todo o documento, as tarefas geradas podem refletir apenas a primeira porção. Esta é uma **limitação conhecida do protótipo**: uma versão de produção beneficiaria de uma estratégia de chunking inteligente que selecionasse os excertos mais relevantes para o objetivo do módulo em vez de truncar linearmente.




Figura 3.4: Criação de tópico e pipeline de geração assíncrona em quatro fases. O pedido HTTP retorna imediatamente (passo 3). A geração executa numa coroutine independente, notificando o cliente via SSE (passos 9 e 11). Em caso de falha em qualquer fase, o tópico transita para `FAILED`.

3.3.3 Editar questão de um tópico

Após a geração inicial, o administrador pode corrigir ou melhorar individualmente qualquer questão gerada pela IA (Figura 3.5). Ao contrário da regeneração completa de um tópico — que usa versionamento imutável via `isCurrent/supersededBy` —, a edição individual de uma questão atualiza a

mesma linha da base de dados: o identificador (`id`) é preservado e apenas o campo `version` é incrementado, persistido através de um `UPDATE` (merge JPA), não de um `INSERT`. As instâncias da tarefa já geradas para essa template são apagadas e regeradas de imediato.

Esta escolha de implementação tem uma implicação prática que constitui uma **limitação conhecida do protótipo**: uma atribuição (`TaskAssignment`) ainda `PENDING` que referencia esta template passa a ver as opções e a resposta correta editadas no momento da submissão, em vez de continuar a referenciar a versão com que foi originalmente gerada. O mecanismo de versionamento imutável existe no modelo de domínio, mas serve apenas o caso de regeneração completa de um tópico, não a edição pontual de uma questão.




Figura 3.5: Edição de uma questão. A operação atualiza a mesma linha (`id` preservado, `version` incrementado — passo 2), não cria uma nova versão imutável. Atribuições `PENDING` que referenciem esta template passam a ver os campos editados no momento da submissão (passo 3).

3.3.4 Inscrição num tópico

A inscrição é o ponto de entrada de cada percurso de aprendizagem (Figura 3.6). Antes de criar a inscrição, o servidor verifica três condições: o tópico deve estar ativo, não expirado, e os seus pré-requisitos devem estar concluídos. A verificação de pré-requisitos consulta o conjunto de tópicos já concluídos pelo utilizador; caso existam em falta, o pedido é rejeitado com indicação precisa dos identificadores em falta.

Em caso de sucesso, é criada uma `Enrollment` e é atribuída imediatamente a primeira tarefa (índice 0), com as opções baralhadas de forma determinística usando uma semente derivada do identificador do utilizador, do template e da inscrição.




Figura 3.6: Inscrição num tópico. O servidor executa três guardas (estado, expiração, pré-requisitos) antes de criar a inscrição (passo 3) e atribuir a primeira tarefa com opções baralhadas deterministicamente (passo 4).

3.3.5 Abandono de tópico

O utilizador pode abandonar uma inscrição ativa em qualquer momento (Figura 3.7). A inscrição transita para o estado `PAUSED` em vez de ser apagada: a data de pausa é registada para permitir ajustar o `enrolledAt` numa eventual reinscrição, compensando o período de inatividade no cálculo do índice diário.




Figura 3.7: Abandono de tópico. A inscrição transita para `PAUSED` com registo de data (passo 3). Numa eventual reinscrição, o servidor calcula os dias de pausa e ajusta o `enrolledAt` para que o índice de dias não salte abruptamente.

3.3.6 Resposta correta a um desafio

Quando o utilizador responde correctamente (Figura 3.8), o servidor executa em sequência: validação da propriedade da atribuição; mapeamento da opção seleccionada pelo índice de exibição para o índice original (invertendo o baralhar); comparação com a resposta canónica; cálculo de pontos com penalização temporal; atualização do streak; e verificação da condição de conclusão do tópico.

A penalização temporal aplica-se quando a resposta é submetida após o prazo, de acordo com a equação:

$$P = \begin{cases} P_{\max} & \text{se } \Delta t \leq 0 \text{ (dentro do prazo)} \\ 0.75 \cdot P_{\max} & \text{se } 0 < \Delta t \leq 24\text{h} \\ 0.50 \cdot P_{\max} & \text{se } 24\text{h} < \Delta t \leq 72\text{h} \\ 0.25 \cdot P_{\max} & \text{se } \Delta t > 72\text{h} \end{cases} \quad (3.1)$$

onde $\Delta t = t_{\text{submissão}} - t_{\text{prazo}}$ e $P_{\max}$ é o valor máximo de pontos definido no template da tarefa.




Figura 3.8: Submissão correcta. A opção seleccionada é mapeada para o índice original invertendo o baralhar (passo 2). Os pontos são calculados com penalização temporal (Equação 3.1). O streak é incrementado, a conclusão do tópico é verificada (passo 6) e o distintivo é emitido de forma idempotente se os critérios forem cumpridos (passo 5).

3.3.7 Resposta errada e ativação do percurso adaptativo

Uma resposta errada desencadeia a geração assíncrona de um percurso adaptativo (Figura 3.9). O servidor classifica imediata e deterministicamente o padrão de erro usando três regras em cascata, conforme a Tabela 3.2; a resposta HTTP é devolvida de imediato, e só depois — já dentro do mesmo bloco assíncrono que invoca o LLM — é que a sessão de dificuldade (*StruggleSession*) é persistida na base de dados.

Padrão classificado	Condição de detecção (por ordem de prioridade)
TIME_PRESSURE	$t_{\text{submissão}} > t_{\text{prazo}}$ — submetido após o prazo de 24 horas.
READING_ERROR	A opção selecionada é adjacente (± 1) à opção correta na ordem de exibição atual (após baralhar).
WRONG_CONCEPT	Default — nenhuma das condições anteriores se verificou.

Tabela 3.2: Regras de classificação determinística de padrões de erro, aplicadas em cascata. A classificação é síncrona, local e não envolve IA.




Figura 3.9: Resposta errada. O padrão de erro é classificado sincronamente e de forma determinística (passo 1, cfr. Tabela 3.2); a resposta HTTP é devolvida de imediato (passo 2). Só depois, dentro do mesmo bloco assíncrono (`generationScope.launch`) que invoca o LLM, é que a sessão de dificuldade é persistida (passo 4) e as subtarefas são geradas ou reutilizadas (passos 5–7). O cliente só toma conhecimento da sessão ao consultar o endpoint de consolidação (passo 8).

3.3.8 Percurso de consolidação

O percurso de consolidação é constituído por três subtarefas adaptativas geradas pelo LLM especificamente para o padrão de erro detetado (Figura 3.10). Se o utilizador completar todas com sucesso, a sessão transita para `RESOLVED` e a tarefa original é reposta em estado `PENDING` para uma nova tentativa autónoma. Se falhar em pelo menos uma subtarefa e a profundidade máxima ainda não tiver sido atingida, um novo ramo adaptativo é gerado com os ramos já vistos excluídos (evitando repetição). Se a profundidade máxima (`MAX_STRUGGLE_DEPTH = 1`) for atingida, o sistema escala para o modo de

explicação.

A Figura 3.11 apresenta a máquina de estados completa deste percurso.




Figura 3.10: Percurso de consolidação. O fluxo diverge em três desfechos: (a) todas corretas → sessão resolvida e tarefa original reposta; (b) alguma errada e profundidade não atingida → novo ramo excluindo ramos já vistos; (c) profundidade máxima atingida → escala para sessão de explicação.




Figura 3.11: Máquina de estados completa do percurso adaptativo: uma resposta errada desencadeia a geração de subtarefas; se o utilizador voltar a falhar e atingir a profundidade máxima ($\text{MAX_STRUGGLE_DEPTH} = 1$), o sistema escala para uma sessão de explicação e diálogo com o LLM.

3.3.9 Modo de explicação por IA

Quando o utilizador esgota a profundidade máxima adaptativa, o sistema escala para o modo de explicação holística (Figura 3.12). A criação da `ExplanationSession` é síncrona: o servidor persiste o registo com estado `GENERATING` e devolve imediatamente o identificador ao cliente (passo 2), que navega para o ecrã de explicação sem esperar pelo LLM. Se a geração falhar, um mecanismo de `fallback` automático repõe a atribuição original em `PENDING`, garantindo que o utilizador nunca fica bloqueado. Uma vez no estado `ACTIVE`, o utilizador pode iniciar N rondas de diálogo antes de encerrar a sessão.




Figura 3.12: Modo de explicação holística. A criação da sessão é síncrona (passo 2); a geração do texto é assíncrona (passos 3–6) com fallback automático em caso de falha. Após transição para **ACTIVE**, N rondas de diálogo com o LLM são possíveis (passo 8); a resolução (passo 9) repõe a tarefa em **PENDING**.

3.4 O motor de inteligência artificial

O agente de IA é a componente mais complexa do sistema. Esta secção descreve em detalhe como cada operação de geração funciona: a construção dos prompts, o processamento da resposta, a deduplicação vetorial e o tratamento de falhas.

3.4.1 Geração de tarefas do percurso fixo

O prompt é composto por dois componentes: um system prompt que estabelece o perfil do modelo e as regras invariantes de formato, e um user prompt que fornece o contexto específico do tópico.

O system prompt (Listagem A.1) impõe três restrições fundamentais: o idioma (obrigatório em toda a resposta), o formato de saída (JSON array apenas, sem texto adicional), e a posição da resposta correta (sempre no índice 0 do array de opções — o sistema baralha antes de enviar ao utilizador).

O system prompt completo encontra-se na Listagem A.1 (Apêndice A).

O user prompt (Listagem A.2) injeta o contexto específico do tópico, incluindo o texto extraído (até 8 000 caracteres), o objetivo do módulo, o nível de audiência e o idioma. A instrução de progressão lógica das tarefas reflete o princípio do scaffolding cognitivo: tarefas mais cedo constroem fundamentos, tarefas mais tarde aplicam conceitos em cenários mais complexos.

O user prompt completo encontra-se na Listagem A.2 (Apêndice A).

O nível de audiência é traduzido para linguagem natural conforme a Tabela 3.3.

Nível	Descrição injetada no prompt
BEGINNER	Beginner — assumes no prior knowledge, uses simple language, concrete examples
INTERMEDIATE	Intermediate — assumes basic familiarity, introduces complexity, some abstraction
ADVANCED	Advanced — assumes solid foundation, focuses on nuance, edge cases, and depth

Tabela 3.3: Tradução do nível de audiência para descrição em linguagem natural incluída no prompt. A granularidade semântica afecta diretamente a dificuldade e o vocabulário das tarefas geradas.

Validação e retenção automática. Após receber a resposta do LLM, o agente valida o JSON produzido. Se o número de tarefas com esquema válido for inferior ao solicitado, o agente executa automaticamente uma segunda invocação com um schema reminder adicional. Se a segunda tentativa também falhar, a geração é reportada como falhada e o tópico transita para `FAILED`.

Deduplicação vetorial. Cada tarefa gerada com sucesso é vetorizada (embedding de 1024 dimensões) e comparada por similaridade cosseno com os embeddings das tarefas já existentes no módulo. Se a distância cosseno exceder o limiar de duplicação, a tarefa é marcada como `DUPLICATE` e descartada, evitando que regenerações produzam questões semanticamente redundantes.

3.4.2 Geração adaptativa: ramos de consolidação

A geração de um ramo adaptativo inclui um mecanismo de reutilização baseado em similaridade que evita chamar o LLM quando já existe conteúdo equivalente. O processo começa por calcular um embedding do contexto de dificuldade e procura na base de dados vetorial um ramo similar previamente gerado, excluindo os ramos que o utilizador já viu para esta atribuição.

O resultado determina a estratégia de reutilização conforme a Tabela 3.4.

Estratégia	Limiar	Comportamento
FULL_REUSE	$\cos > 0.90$	Reutiliza integralmente o ramo existente; sem chamada ao LLM.
PARTIAL_REUSE	$0.65 < \cos \leq 0.90$	Reutiliza parte das subtarefas proporcionalmente à similaridade; gera as restantes com o LLM.
FRESH_GENERATION	$\cos \leq 0.65$	Gera todas as subtarefas de raiz.

Tabela 3.4: Estratégias de reutilização de ramos adaptativos em função da similaridade cosseno. A reutilização total ou parcial reduz a latência e o custo de chamadas ao LLM.

A proporção de subtarefas reutilizadas na estratégia `PARTIAL_REUSE` é calculada por interpolação linear:

$$n_{\text{reutilizadas}} = \left\lceil N \cdot \frac{\cos \theta - \theta_{\text{partial}}}{\theta_{\text{full}} - \theta_{\text{partial}}} \right\rceil, \quad N = |\text{subtarefas válidas do ramo existente}|, \quad \theta_{\text{partial}} = 0.65, \quad \theta_{\text{full}} = 0.90 \quad (3.2)$$

Note-se que N não é uma constante fixa: corresponde ao número real de subtarefas válidas existentes no ramo encontrado (`existing.subtasks.size`), coincidindo com 3 apenas quando esse ramo tem exatamente três subtarefas válidas.

O resultado é restringido ao intervalo $[1, N]$ para garantir que pelo menos uma subtarefa é sempre reutilizada no modo parcial.

O system prompt adaptativo (Listagem A.3) distingue-se do prompt de percurso fixo por focar a scaffolding remediativa: o modelo é instruído a começar pelo conceito mais simples possível e a reencadram a dificuldade como uma oportunidade.

O system prompt completo encontra-se na Listagem A.3 (Apêndice A).

O user prompt injeta o padrão de erro com a sua tradução pedagógica (Tabela 3.5), permitindo ao LLM gerar subtarefas especificamente adaptadas ao tipo de dificuldade detetada.

Padrão de erro	Instrução pedagógica no prompt
WRONG_CONCEPT	The student misunderstands the core concept. Start by re-explaining it differently.
PARTIAL_UNDERSTANDING*	The student understands the concept but applies the wrong steps. Focus on procedure.
READING_ERROR	The task instructions were unclear. Provide clearer, more explicit guidance.
TIME_PRESSURE	The student rushed under time pressure. Use paced, step-by-step practice tasks.

Tabela 3.5: Tradução dos padrões de erro para instruções pedagógicas específicas incluídas no prompt adaptativo. A especificidade da instrução é o principal fator de qualidade das subtarefas geradas.

*PARTIAL_UNDERSTANDING está definido no modelo de domínio e mapeado na camada de serviço, mas não é emitido pelo classificador actual: requer uma máquina de estados de duas tentativas que não existe nesta versão do protótipo. O seu desenvolvimento está listado como trabalho futuro (§6.3).

3.4.3 Geração da explicação holística

O modo de explicação é ativado quando o utilizador esgota o percurso adaptativo. O sistema dispõe nesse ponto de informação rica sobre o histórico de dificuldades, compilada num contexto de explicação que inclui: a descrição da tarefa original e o objetivo do módulo; o histórico completo das sessões adaptativas (padrão de erro, títulos das subtarefas tentadas); o nível de audiência; e a língua do utilizador.

O system prompt de explicação (Listagem A.4) especifica explicitamente o formato de saída como prosa corrida (sem JSON, sem listas, sem cabeçalhos), com 3 a 5 parágrafos. Esta restrição é intencional: o utilizador que chegou a este ponto já viu estrutura suficiente de múltipla escolha; o que precisa é de uma explicação natural, empática e fluída.

O system prompt completo encontra-se na Listagem A.4 (Apêndice A).

Para o diálogo subsequente, o system prompt de resposta (Listagem A.5) instrui o modelo a agir como coach conversacional focado, com respostas de 2 a 4 frases. Cada mensagem é enviada ao modelo juntamente com o histórico completo da conversa, construído dinamicamente como texto simples com prefixos de papel (Coach: / Student:).

O system prompt completo encontra-se na Listagem A.5 (Apêndice A).

A Figura 3.13 sintetiza a escada progressiva do modo de IA desde a geração de tarefas adaptativas até ao diálogo livre.




Figura 3.13: Escada do percurso adaptativo para o modo de explicação. Com `MAX_STRUGGLE_DEPTH = 1`, após uma única falha no percurso adaptativo, o sistema escala diretamente para a sessão de explicação holística e o diálogo com o LLM.

3.5 Reconhecimento: o sistema de distintivos

O pilar do **reconhecimento** implementa-se através de distintivos (*badges*) associados a microcompetências. Cada tópico tem exatamente uma microcompetência correspondente, criada durante a fase INDEXING do pipeline. A emissão do distintivo é idempotente: o serviço `BadgeIssuanceService` verifica se o utilizador cumpre os critérios após cada submissão correta, mas nunca emite o mesmo distintivo duas vezes.

A condição de emissão é formal: sendo n o número total de tarefas do tópico, s o número de tarefas submetidas e c o número de respostas corretas, um distintivo é emitido se e só se:

$$s \geq n \quad \text{e} \quad c \geq \lfloor \alpha \cdot n \rfloor, \quad \text{com } \alpha = 0,60 \quad (3.3)$$

O número mínimo de respostas corretas é calculado por truncamento `((taskCount * 0.60).toInt())`, não por comparação exata da razão c/n com α ; na prática, isto torna o critério ligeiramente mais permissivo do que uma comparação exata para valores de n em que $\alpha \cdot n$ não é inteiro.

O limiar $\alpha = 0,60$ foi calibrado para ser exigente o suficiente para conferir significado ao distintivo, mas permissivo o suficiente para não frustrar utilizadores que fizeram a maior parte do percurso corretamente, aproximando-se da lógica de *mastery learning* [bloom1968learning], em que a progressão exige domínio comprovado mas não perfeição absoluta. A literatura sobre gamificação em educação sugere que os distintivos têm maior impacto motivacional quando assinalam competências genuínas e reconhecíveis [ott2019gamification].

3.6 Envolvimento: mecanismos de retenção

O terceiro pilar — o **envolvimento** — é sustentado por três mecanismos complementares.

O primeiro é o **streak**: um contador de dias consecutivos de atividade incrementado a cada resposta correta ou percurso adaptativo resolvido. Não é penalizado por uma resposta errada, apenas pelo abandono total num dia, incentivando a tentativa mesmo sem certeza. Atua como **commitment device**: ao tornar o histórico de atividade algo que o utilizador não quer interromper, cria uma pressão positiva ao regresso diário [ott2019gamification].

O segundo é a **progressão por pré-requisitos**: os tópicos podem ser organizados num grafo dirigido acíclico (DAG), em que um tópico só fica desbloqueado depois de o utilizador concluir as suas dependências. A detecção de ciclos usa pesquisa em profundidade (DFS) na camada de serviço, garantindo que o administrador não pode criar dependências circulares inadvertidamente. Para o utilizador, o grafo completo é visível no **endpoint** `/enrollments/{id}/roadmap`, servindo simultaneamente como motivação (**progress visibility**) e orientação (**next step clarity**).

O terceiro é o **desbloqueio diário por índice**: as tarefas são atribuídas uma por dia, com desbloqueio à meia-noite no fuso horário do utilizador. Este ritmo cadenciado reduz a sobrecarga cognitiva e cria uma razão concreta para voltar todos os dias, mantendo o hábito fácil de iniciar e manter.

3.7 Interface de programação

A Tabela 3.6 sintetiza os principais **endpoints** REST que expõem as funcionalidades descritas neste capítulo.

3.8 Síntese do desenvolvimento

O desenvolvimento do **Play4Change** produziu um protótipo funcional com três camadas bem definidas — servidor, cliente multiplatforma e painel de administração — articuladas por uma API REST segundo os princípios da arquitectura hexagonal [cockburn2005hexagonal]. A separação entre o contrato de porta (`TaskGenerationPort`) e a sua implementação (`LangChain4jTaskGenerationAdapter`) garante que o fornecedor de LLM pode ser substituído sem alterações no servidor de aplicação.

O mecanismo mais complexo e distintivo é o percurso adaptativo: a combinação de classificação determinística de erros (§3.3.7), geração assíncrona com deduplicação vectorial por similaridade cosseno (§3.4.2), e escala para explicação em prosa com diálogo livre (§3.3.9) representa a contribuição mais original deste protótipo relativamente às plataformas existentes.

Importa delimitar com clareza o que este protótipo é e o que não é. O fluxo completo — criação de tópico, geração de conteúdo, percurso adaptativo, emissão de distintivo — está implementado e testado de ponta a ponta. No entanto, uma versão de produção exigiria: a calibração fina dos limiares de deduplicação e de profundidade adaptativa com dados reais; cobertura de testes de integração e de carga; e, sobretudo, validação pedagógica do conteúdo gerado pelo LLM por especialistas em educação. Estes aspetos são discutidos nas limitações do Capítulo 6.

Método	Caminho	Auth	Responsabilidade
POST	/auth/magic-link	—	Solicitar magic link
GET	/auth/verify?token={t}	—	Verificar token e emitir sessão
POST	/enrollments	USER	Inscrever utilizador num tópico
DELETE	/enrollments/{topicId}	USER	Abandonar inscrição
GET	/topics/{id}/task	USER	Obter tarefa do dia
POST	/assignments/{id}/submit	USER	Submeter resposta
GET	/enrollments/{id}/roadmap	USER	Obter mapa visual do percurso
GET	/struggle/{enrollmentId}	USER	Obter sessão adaptativa ativa
POST	/struggle/{sId}/tasks/{tId}/submit	USER	Submeter subtarefa adaptativa
GET	/explanations/{sessionId}	USER	Obter sessão de explicação
POST	/explanations/{sId}/messages	USER	Enviar mensagem ao LLM
POST	/explanations/{sId}/resolve	USER	Encerrar sessão de explicação
GET	/badges	USER	Listar distintivos conquistados
POST	/admin/topics	ADMIN	Criar tópico (URL ou PDF)
PUT	/admin/tasks/{templateId}	ADMIN	Editar questão (atualização em linha)
POST	/admin/topics/{id}/prerequisites	ADMIN	Definir pré-requisitos
GET	/admin/learning-graph	ADMIN	Obter DAG completo de tópicos

Tabela 3.6: Principais endpoints REST do Play4Change. Os endpoints sem autenticação são públicos; USER requer token de acesso válido; ADMIN requer adicionalmente o papel de administrador.

Capítulo 4

Ferramentas, Tecnologias e Metodologia

Este capítulo descreve o conjunto de tecnologias que constituem o ecossistema técnico do Play4Change, a pipeline de integração e entrega contínua que garante a qualidade do código em cada alteração, e a forma como a inteligência artificial foi utilizada ao longo do próprio processo de desenvolvimento — não apenas como funcionalidade da plataforma, mas como ferramenta de trabalho.

4.1 Arquitetura tecnológica

O Play4Change é composto por quatro camadas tecnológicas distintas: o servidor de aplicação, a aplicação móvel, o painel de administração web e a infraestrutura de suporte. A Tabela 4.1 resume as tecnologias principais em cada camada.

Servidor

O servidor foi implementado em **Kotlin** com o framework **Spring Boot 3.2**, seguindo uma arquitetura hexagonal (Ports & Adapters) [[cockburn2005hexagonal](#)] que separa a lógica de negócio das suas dependências externas. A escolha do Kotlin em vez do Java tradicional permitiu aproveitar a expressividade da linguagem — em particular as coroutines para operações assíncronas, os tipos não-anuláveis para redução de erros de null pointer, e o estilo funcional para as transformações de dados. O Spring Boot forneceu a base REST, a gestão de transações e o suporte à autenticação com JWT [[rfc7519](#)].

A base de dados **PostgreSQL 16** foi estendida com a extensão **pgvector**, que adiciona suporte a vectores de embeddings directamente no mesmo motor relacional. Esta co-localização elimina a necessidade de um sistema vectorial separado e mantém todas as garantias ACID para a camada de personalização. O **Redis** é utilizado para a cache de resultados de consultas frequentes e para controlo de ritmo das chamadas à API de IA. A integração com o modelo de linguagem **mistral-small-latest** (API Mistral AI, acedida remotamente) é feita através do **LangChain4j 0.36.2** [[langchain4j](#)], implementando o padrão RAG [[lewis2020rag](#)] descrito no Capítulo 2. A escolha recaiu sobre a variante **small** da família Mistral por razões de custo e de latência: várias das funcionalidades que dependem do modelo — classificação de erros, geração de tarefas adaptativas — ocorrem no caminho síncrono ou semi-síncrono de pedidos

Camada	Tecnologia	Papel
Servidor	Spring Boot 3.2 (Kotlin)	API REST, lógica de negócio, orquestração de IA
	PostgreSQL 16 + pgvector	Base de dados relacional e vetorial
	Redis 7	Cache de sessões e controlo de ritmo (<u>rate limiting</u>)
	MinIO	Armazenamento de objetos (imagens, as-sets)
Móvel	mistral-small-latest /	Geração de conteúdo adaptativo e explica-ções (API Mistral AI)
	LangChain4j	Envio transacional de correio eletrónico
	Resend	
	Kotlin Multiplatform 2.3	Base de código partilhada Android/iOS
Web (admin)	Compose Multiplatform 1.10	Interface declarativa nativa
	Decompose 3.3.0-alpha01	Navegação e gestão de estado
	Koin	Injecção de dependências
	React 18 + TypeScript	Painel de administração de conteúdos
Infraestrutura	Vite + Tailwind CSS	<u>Bundler</u> e design system utilitário
	TanStack Query	Gestão de estado remoto e cache HTTP
	Docker + Docker Compose	Orquestração local e de produção
	nginx 1.27	<u>Reverse proxy</u> e servidor do cliente estático
	Prometheus + Grafana	Observabilidade, métricas e alertas

Tabela 4.1: Tecnologias principais do Play4Change, organizadas por camada funcional.

do utilizador, pelo que um modelo mais pequeno e mais rápido é preferível a um modelo de maior dimensão com tempos de resposta mais elevados. A integração através do LangChain4j, que abstrai o fornecedor concreto do modelo, mantém a possibilidade de substituir o modelo ou o fornecedor sem alterar a lógica de negócio.

Aplicação móvel

A aplicação móvel foi desenvolvida com **Kotlin Multiplatform (KMP) 2.3** e **Compose Multiplatform 1.10**, o que permite partilhar a maior parte da lógica de negócio e da interface entre Android e iOS a partir de um único código-base. A navegação e a gestão de estado são tratadas pelo **Decompose 3.3.0-alpha01**, que oferece uma abstracção de stack de componentes compatível com ambas as plataformas e com testes unitários. À data de desenvolvimento, era a solução mais madura disponível para navegação partilhada em KMP, ainda sem uma versão estável publicada; a dependência de uma biblioteca em fase alpha é assumida como um risco conhecido do protótipo, mitigado pela API da biblioteca estar isolada da restante lógica de negócio através da camada de apresentação.

Painel de administração

O painel web de administração é uma aplicação **React 18** em **TypeScript**, construída com **Vite** e **Tailwind CSS**. Permite criar e gerir tópicos, tarefas e conteúdos, monitorizar inscrições e visualizar dados de utilização. O **TanStack Query** é utilizado para a gestão de estado remoto, garantindo cache automática, revalidação e tratamento consistente de estados de carregamento e erro.

Infraestrutura de produção

Todo o ambiente de produção é definido num único ficheiro `docker-compose.yml` com sete serviços: servidor Spring Boot, PostgreSQL, Redis, MinIO, nginx, Prometheus e Grafana. O **nginx** actua como reverse proxy — recebe os pedidos externos na porta 80, encaminha as chamadas à API (prefixadas em `/play4change-server/`) para o servidor na porta 8080, e serve o cliente React como conteúdo estático. O **Prometheus** recolhe métricas expostas pelo actuador Spring Boot a cada 15 segundos e o **Grafana** apresenta-as em três dashboards pré-configurados: um dashboard geral, um centrado na latência da IA e um que mostra o fluxo do aprendente em tempo real. A Figura 4.1 ilustra a topologia de produção.




Figura 4.1: Topologia de infraestrutura de produção: o nginx recebe todo o tráfego externo e distribui-o; o servidor Spring Boot comunica com as quatro dependências de dados e com a API de IA; o Prometheus recolhe métricas do servidor e o Grafana apresenta-as em dashboards.

4.2 Pipeline de integração e entrega contínua

O Play4Change adopta uma pipeline de Continuous Integration / Continuous Delivery (CI/CD) implementada em **GitHub Actions**, composta por três workflows distintos com responsabilidades bem delimitadas. A Figura 4.2 ilustra como os três workflows se articulam com os eventos do repositório.

Workflow 1 — Integração Contínua

O workflow de CI é desencadeado em todos os commits para a branch `main` e em todos os pull requests que a ela se destinam. Corre num agente macOS — exigência do toolchain **iOS/Xcode**, e não do Android: como o módulo móvel é Kotlin Multiplatform e compila também para iOS, a compilação completa do projeto requer um agente com Xcode disponível, o que só os runners macOS da GitHub Actions oferecem — e executa quatro passos em sequência:

1. **Gitleaks** — varredura de segredos no histórico completo do repositório (`fetch-depth: 0`). Se forem detetadas credenciais, chaves de API ou outros segredos comprometidos no código, o workflow falha imediatamente antes de qualquer compilação.
2. **JDK 21 (Eclipse Temurin)** — configuração do ambiente Java com cache automática das dependências Gradle entre execuções, reduzindo o tempo de compilação em execuções subsequentes.




Figura 4.2: Os três workflows da pipeline CI/CD do Play4Change: o primeiro corre em cada `commit` ou `pull request`; o segundo é desencadeado por uma `tag` semântica e produz o APK assinado; o terceiro corre semanalmente e verifica vulnerabilidades CVE nas dependências.

- Gradle build + testes** — compila todos os módulos (`servidor`, `móvel`, `common`) e executa os testes unitários e de integração com JUnit 5, MockK e SpringMockK. O passo exclui explicitamente o `packaging` de `release` para reduzir o tempo de execução em CI.
- Detekt** — análise estática do código Kotlin do servidor, verificando aderência às regras definidas em `detekt.yml`: complexidade ciclomática, tamanho de funções, dependências em concretos em vez de interfaces, e estilo de código.

Apenas se todos os passos passarem é que um `pull request` pode ser integrado na `branch` principal. A Tabela 4.2 resume os critérios de qualidade verificados em cada passo.

Ferramenta	O que verifica	Critério de falha
Gitleaks	Segredos no histórico git	Qualquer correspondência com os detetores predefinidos
JUnit 5 + MockK Detekt	Testes unitários e de integração Qualidade e estilo do código Kotlin	Qualquer teste falhado Violações acima do limiar configurado

Tabela 4.2: Ferramentas e critérios de qualidade verificados em cada execução da pipeline de integração contínua.

Workflow 2 — Release do APK Android

O `workflow` de `release` é desencadeado exclusivamente por `tags` com prefixo `v` (por exemplo, `v1.2.3`). Este mecanismo garante que os binários de produção são sempre rastreáveis a uma versão explícita. O `workflow`: restaura os ficheiros sensíveis (`keystore` e `google-services.json`) a partir de segredos encriptados do repositório, nunca armazenados em texto simples; calcula automaticamente o `versionCode` Android a partir da `tag` semântica, segundo a fórmula $\text{MAJOR} \times 10000 + \text{MINOR} \times 100 + \text{PATCH}$; compila e assina o APK de `release` com a `keystore` de produção; e cria automaticamente uma `GitHub Release` com o `play4change.apk` anexado, tornando-o imediatamente disponível para distribuição sem qualquer passo manual.

Workflow 3 — Verificação semanal de dependências (OWASP)

O terceiro workflow corre automaticamente todas as segundas-feiras às 06:00 UTC. Utiliza a ferramenta **OWASP Dependency Check** para analisar todos os JARs do servidor e dos módulos móveis em busca de vulnerabilidades conhecidas registadas na base de dados CVE (Common Vulnerabilities and Exposures). O workflow falha se forem encontradas vulnerabilidades com score CVSS igual ou superior a 7 (“High” ou “Critical”), forçando uma resposta atempada. Os relatórios HTML gerados ficam disponíveis como artefatos no GitHub durante 30 dias. Esta verificação periódica é particularmente relevante para uma plataforma que usa um LLM externo e que processa dados de utilizadores — onde uma dependência comprometida poderia ter impacto direto na privacidade dos dados ou na integridade dos conteúdos gerados.

4.3 Metodologia de desenvolvimento

O desenvolvimento do Play4Change seguiu um processo iterativo e incremental, próximo de uma metodologia ágil informal adequada a um projeto de autoria individual. O controlo de versões foi feito com **Git** e o repositório alojado no **GitHub**, com uma estratégia de feature branches: cada nova funcionalidade ou correcção é desenvolvida numa branch dedicada (por exemplo, `feature/jwt-auth` ou `bugfix/daily-reminders`) e submetida como pull request antes de ser integrada na branch `main`. Tratando-se de um projeto de autor único, a revisão de código é uma autorrevisão — o próprio autor revê o diff completo da pull request antes de a integrar, em vez de uma revisão por terceiros — complementada pelos controlos automáticos e objetivos da pipeline de CI descrita na secção anterior (testes, análise estática e verificação de segredos), que atuam como um segundo filtro independente do julgamento do autor.

A gestão de dependências é centralizada no ficheiro `gradle/libs.versions.toml`, o que garante consistência entre todos os módulos do projeto e facilita atualizações coordenadas. O **Flyway** é utilizado para a gestão de migrações da base de dados: cada alteração ao esquema SQL é registada como um ficheiro de migração versionado, aplicado de forma automática e ordenada aquando do arranque do servidor, garantindo que o estado da base de dados é sempre rastreável e reproduzível em qualquer ambiente.

Capítulo 5

Avaliação e Resultados

Este capítulo reporta a avaliação preliminar do Play4Change sob dois ângulos: a integridade do sistema de geração de conteúdo (§5.2), com base nos registos da base de dados em produção e do Prometheus; e o comportamento dos utilizadores (§5.3), triangulando os dados comportamentais da BD com um questionário pós-utilização.

5.1 Metodologia de avaliação

O questionário ($n = 12$) foi administrado remotamente após exploração livre do protótipo. Organizava-se em quatro secções: perfil do respondente; usabilidade e envolvimento em escala de Likert; os dez itens da System Usability Scale (SUS) [brooke1996sus]; e questões abertas. Os itens foram cotados pelo método de Brooke [brooke1996sus], dando uma escala de 0 a 100; pontuações acima de 68 estão acima da média histórica e, segundo a escala de adjetivos de Bangor et al. [bangor2008empirical], pontuações acima de aproximadamente 71 são qualificadas como “boas” (good) e acima de 85 como “excelentes” (excellent).

Os dados comportamentais cobrem o último ciclo de testes contínuo após o derradeiro reset de desenvolvimento.¹ O rácio entre os 15 utilizadores registados na BD e os 12 questionários preenchidos explica-se por utilizadores do ciclo anterior que responderam ao formulário mas não voltaram a interagir com o protótipo após a reinicialização. Os doze respondentes (P01–P12) foram identificados no momento de resposta ao questionário, o que permitiu associar cada resposta ao respectivo utilizador na BD; é esta associação que sustenta o cruzamento entre pontuação SUS e dados comportamentais na Secção 5.3.4. Os três utilizadores registados na BD sem questionário associado não são incluídos nessa análise cruzada.

5.2 Integridade do sistema de geração

Os seis tópicos criados durante o período de avaliação transitaram todos para o estado `ACTIVE`, sem nenhum em `FAILED` — o que é consistente com o pipeline de quatro fases (`INGESTION`, `ANALYSIS`, `GENERATION`, `INDEXING`) ter operado dentro dos parâmetros de fiabilidade definidos, ainda que

¹A BD sofreu limpezas de estado intencionais durante o desenvolvimento (migrações Flyway V1–V28+). Os valores da Tabela 5.2 representam o snapshot do último ciclo, não o total histórico acumulado desde o início do projecto.

uma amostra de seis tópicos seja demasiado pequena para uma conclusão estatisticamente robusta sobre a taxa de falhas do pipeline. A Tabela 5.1 reporta os tempos de transição reais registados na tabela `topic_phase_log`.

Fase	Mín.	Máx.	Nota
INGESTION → ANALYSIS	13 ms	95 s	URL (instantâneo) vs PDF (extração)
ANALYSIS → GENERATION	10 ms	65 ms	Chamada LLM (<code>mistral-small-latest</code>)
GENERATION → INDEXING	6,3 s	11,3 s	
INDEXING → ACTIVE	54 s	121 s	<u>Embeddings</u> batch (58 templates)
Pipeline completo	≈1 min	≈4 min	6/6 tópicos ACTIVE; 0 FAILED

Tabela 5.1: Tempos de transição entre fases para os seis tópicos criados durante o período de avaliação, extraídos diretamente da tabela `topic_phase_log`. A variação na fase INGESTION reflete a diferença entre fontes URL e PDF.

A integridade das 58 task templates validadas é garantida por dois mecanismos: validação campo a campo do JSON produzido pelo LLM (com retenção automática via schema reminder em caso de falha) e um circuit breaker Resilience4j que interrompe o pipeline se a taxa de falhas ultrapassar 50% numa janela de 10 chamadas. Nenhum alerta Prometheus foi ativado durante o período de avaliação, o que é coerente com a ausência de relatos de erros de geração.

A latência de inferência medida pelo Prometheus manteve-se dentro do timeout de 60 s por chamada (P95 = 14,26 s para GENERATION; P95 = 4,04 s para ANALYSIS).

Os 33 ramos distintos servidos a 55 sessões mostram uma distribuição desigual: o ramo mais reutilizado serviu 22 das 55 sessões (40%), uma concentração que indica que a deduplicação vectorial (Secção 3) está a agrupar correctamente um padrão de erro particularmente comum num único ramo partilhado, em vez de gerar conteúdo redundante para cada ocorrência. Os restantes 32 ramos, cada um servindo entre 1 e poucas sessões, preservam diversidade para os padrões de erro menos frequentes.

5.3 Comportamento dos utilizadores

5.3.1 Visão geral

A Tabela 5.2 reporta os indicadores globais extraídos da BD. Os 104/105 acertos finais (99%) não indicam facilidade excessiva — indicam a eficácia do ciclo adaptativo: as 55 sessões geradas confirmam que uma parcela significativa de tarefas envolveu pelo menos uma resposta errada seguida de reforço. O número de sessões (55) excede o número de tarefas com pelo menos um erro inicial (25) porque uma única tarefa falhada pode originar mais do que uma sessão: se o utilizador falhar também as subtarefas de reforço, o sistema encadeia uma segunda sessão de struggle a partir da mesma tarefa original antes de, no limite de profundidade, escalar para uma sessão de explicação por IA — pelo que a contagem de sessões reflecte eventos de falha (incluindo reincidências), não tarefas distintas.

Quanto aos distintivos: a taxa de aprovação de 100% não constitui evidência independente da eficácia do limiar $\alpha = 0,60$, uma vez que, por construção, um distintivo só é persistido na base de dados depois de o critério de mestria já ter sido verificado como cumprido — não existe um caminho de código em

que a emissão de um distintivo falhe após a verificação. O valor de 100% é portanto estrutural, não uma medida de desempenho do sistema.

Indicador	Valor
Utilizadores registados	15
Utilizadores com pelo menos uma inscrição	14
Inscrições em tópicos (total)	27
Inscrições concluídas	16 (59%)
Distintivos emitidos	16 (a 9 utilizadores)
Tarefas submetidas	105
Acerto final nas tarefas	104/105 (99%)
Tarefas com pelo menos um erro inicial	25 (24%)
Sessões adaptativas (<i>struggle</i>) geradas	55
Sessões adaptativas resolvidas	54 (98,2%)
Sessões de explicação por IA	39 (100% resolvidas)
Tarefas adaptativas geradas (percurso consolidação)	172 em 33 ramos distintos
Sequência (<i>streak</i>) máxima registada	13 dias

Tabela 5.2: Indicadores globais de utilização do protótipo Play4Change extraídos da BD em produção no final do período de avaliação. Ver nota de rodapé da Secção 5.1 para o contexto dos resets de desenvolvimento.

5.3.2 Padrões de utilização por tópico

A Tabela 5.3 desagrega os indicadores por tópico. Os três tópicos com utilizadores activos registam taxas de conclusão entre 50% e 67%, positivas para um protótipo sem incentivo externo obrigatório. O dado mais informativo é a densidade de sessões adaptativas: Urban Indicators & Data Management gerou 23 sessões para apenas 4 inscrições (5,75 por inscrição), contra 0,75 de Sustainable Cities. Este gradiente reflecte a dificuldade intrínseca do conteúdo, não um efeito de volume.

Tópico	Inscritos	Concluídos	Taxa	Struggle sessions
Sustainable Cities & Civic Engagement	12	8	67%	9
Environmental Literacy	10	6	60%	19
Urban Indicators & Data Management	4	2	50%	23
Sustainability Specialist Capstone	1	0	0%	4

Tabela 5.3: Indicadores por tópico (apenas tópicos com inscrições). A coluna *Struggle sessions* normalizada pelas inscrições constitui um proxy da dificuldade percebida do conteúdo: Urban Indicators gerou 5,75 sessões por inscrição, contra 0,75 de Sustainable Cities. A linha Sustainability Specialist Capstone tem apenas 1 inscrito e é, por isso, anedótica — não comparável estatisticamente às restantes linhas. O tópico Energy Efficiency / Green Mobility não registou inscrições durante o período de avaliação.

5.3.3 Padrões de erro e ciclo adaptativo

O `ErrorPatternClassifier` classifica cada submissão errada em três padrões possíveis, aplicados em cascata: `TIME_PRESSURE` (prazo de submissão excedido), `READING_ERROR` (a opção escolhida era adjacente à correcta na ordem *shuffled* — leitura apressada do enunciado) e `WRONG_CONCEPT` (lacuna conceptual genuína, padrão por defeito). O padrão `TIME_PRESSURE` não foi observado durante a avaliação, uma vez que nenhuma submissão ultrapassou o prazo de 24 horas. A Tabela 5.4 sintetiza os resultados dos dois padrões observados.

Importa notar que a heurística do `READING_ERROR` é puramente posicional — compara apenas a posição da opção escolhida com a da opção correcta na lista shuffled, sem qualquer análise semântica do conteúdo das opções — e não foi validada contra um ground truth humano. Esta limitação é discutida na Secção 5.3.6 e ilustrada pelo próprio exemplo da Secção 5.3.5.

Padrão	Sessões	Resolvidas	Tarefas adapt.	Acerto nas adapt.
<code>READING_ERROR</code>	31 (56%)	30 (97%)	94	48/94 (51%)
<code>WRONG_CONCEPT</code>	24 (44%)	24 (100%)	72	47/72 (65%)
Total	55	54 (98,2%)	172 em 33 ramos	—

Tabela 5.4: Distribuição das 55 sessões adaptativas pelos dois padrões de erro observados (o terceiro padrão possível, `TIME_PRESSURE`, não foi ativado durante a avaliação) e resultados do percurso de consolidação. O acerto superior nas tarefas do `WRONG_CONCEPT` (65% vs 51%) sugere que este padrão responde melhor à remediação dirigida; o `READING_ERROR` resolve ao nível da sessão (97%) mas exige mais tentativas nas tarefas adaptativas.

A predominância de `READING_ERROR` (56%) é pedagogicamente informativa: mais de metade dos erros resultaram de leituras apressadas, não de lacunas conceptuais — comportamento típico em formatos de quiz rápido [[vanlehn2011relative](#)]. Três participantes independentes reportaram confusão quando “uma nova questão aparece subitamente” após um erro: o classificador actua correctamente, mas a sua acção permanece opaca para o utilizador (falha de comunicação UX, não do sistema).

Das 39 sessões de explicação por IA, todas ficaram no estado `RESOLVED` (100%). Este valor deve ser interpretado com cautela: o estado `RESOLVED` é atribuído tanto quando o utilizador termina a conversa explicitamente como quando a sessão é encerrada por um mecanismo de fallback em caso de falha ou timeout da geração — não existe, no código actual, um terceiro estado terminal que distinga uma compreensão efectivamente alcançada de um encerramento meramente técnico. O mesmo se aplica, de forma menos extrema, às 54/55 (98,2%) sessões adaptativas `RESOLVED`: este estado é atribuído quando todas as subtarefas de reforço foram respondidas, independentemente de o utilizador as ter respondido correctamente, pelo que a taxa de resolução mede a conclusão do percurso, não necessariamente a superação da dificuldade. A média de trocas foi de 0,72 por sessão — muitas sessões com 0 mensagens, porque o utilizador resolveu o percurso adaptativo sem recorrer ao diálogo; a sessão mais extensa teve 8 trocas.

5.3.4 Usabilidade e perfis de utilizador

Os 12 participantes atribuíram à usabilidade geral uma pontuação média de **4,17 em 5**. A pontuação SUS calculada a partir dos dados brutos do CSV foi de **76,0/100** — acima da média histórica de 68 e acima do limiar de aproximadamente 71 que qualifica uma pontuação como “boa” (good) na escala de adjetivos de Bangor et al. [[bangor2008empirical](#)], embora abaixo do limiar de 85 para “excelente”. A dimensão da amostra ($n = 12$) não permite extrapolação estatística; a pontuação deve ser lida como indicador inicial positivo.

A Figura 5.1 revela uma clivagem bimodal clara: quatro participantes ficam abaixo de 68 (Grupo B, SUS médio de 47,5) e oito ficam acima de 77,5 (Grupo A, SUS médio de 89,4).

A análise por questão SUS (Tabela 5.5) mostra que a plataforma é percebida como **fácil de usar** (Q3: 4,25) e **confiante de operar** (Q9: 4,25), com funções **bem integradas** (Q5: 4,00). Os itens mais




Figura 5.1: Pontuações SUS individuais dos 12 participantes, calculadas a partir das respostas brutas do CSV e ordenadas de forma crescente. Os valores são exatos (e.g., 77,5; 92,5; 97,5) sem arredondamento. A linha a tracejado assinala o limiar histórico de 68 pontos.

penalizadores são a **intenção de uso frequente** (Q1: 3,67) e a **velocidade de aprendizagem** (Q7: 3,67) — a barreira de entrada é baixa, mas o incentivo de regresso não é suficientemente robusto.

Q#	Formulação (resumida)	Pol.	Média
Q1	Usaria frequentemente	+	3,67
Q2	Desnecessariamente complexo	—	2,17
Q3	Fácil de usar	+	4,25
Q4	Precisaria de suporte técnico	—	1,75
Q5	Funções bem integradas	+	4,00
Q6	Demasiada inconsistência	—	1,67
Q7	A maioria aprenderia rapidamente	+	3,67
Q8	Pesado de usar	—	1,83
Q9	Confiante a usar	+	4,25
Q10	Precisou aprender muito antes	—	2,00

Tabela 5.5: Médias por questão da System Usability Scale calculadas a partir das respostas brutas do CSV. Pol. = polaridade da questão. Em negrito os itens mais salientes positiva e negativamente. $n = 12$.

A clivagem bimodal não corresponde à afiliação institucional: P05 (Alumni ISEL, SUS 35) e P09 (Estudante ISEL, SUS 60) ficaram no Grupo B, enquanto vários utilizadores externos obtiveram SUS acima de 90 (Grupo A). O agrupamento é comportamental:

- **Grupo A** ($n = 8$, SUS médio 89,4): adoptaram a plataforma com entusiasmo; completaram 1 a 3 tópicos; mantiveram streaks de 5 a 13 dias; sentiram o ciclo de erro como oportunidade de aprendizagem. Os 12 percursos adaptativos de P2 mostram que errar com frequência, mas persistir, é o perfil típico deste grupo.
- **Grupo B** ($n = 4$, SUS médio 47,5): a plataforma digital constitui, em si mesma, uma barreira — “Because it’s so confusing, it ends up not being so helpful, what would make people lose interest in this app and also patience” (P04). Não concluíram nenhum tópico; streaks de 1 a 3 dias. O problema não é o conteúdo, é o meio: a aprendizagem autónoma por aplicação web pressupõe um grau mínimo de familiaridade digital que este grupo ainda não possui.

Dimensão	Grupo A ($n = 8$)	Grupo B ($n = 4$)
SUS médio	89,4 (Bom/Excelente)	47,5 (Mau)
Amplitude SUS	77,5 – 97,5	35 – 60
Afiliação	Misto (Ext. + ISEL)	Misto (Ext. + ISEL)
Tópicos concluídos	1 – 3 por utilizador	0
Streak máx.	5 – 13 dias	1 – 3 dias
Reação ao ciclo IA	“Fascinante e útil”	Fluxo não percebido
Envolvimento real	Alto e sustentado	Abandonado cedo

Tabela 5.6: Síntese dos dois grupos de utilizadores, identificados pelo desempenho SUS e pelos dados comportamentais da BD. O agrupamento é comportamental, não por papel/afiliação.

O feedback qualitativo revelou três temas recorrentes: (1) **ciclo de feedback por IA** como melhor funcionalidade, mencionado espontaneamente por 7 dos 11 respondentes à questão aberta (“The fact that when we get an answer wrong, artificial intelligence tries to help us understand why we got it wrong” — P02; “AI adaptability to your answers” — P12); (2) **funcionalidades sociais e comunitárias** — comparação de progressos com amigos, “rivalidade positiva” (P01, P09, P11), directamente alinhado com a dimensão de relação da Teoria da Autodeterminação [deci1985intrinsic]; (3) **consistência da interface** — títulos mistos PT/EN, ausência de explicação quando a questão muda após um erro, e respostas da IA longas para ecrã de telemóvel.

5.3.5 O ciclo adaptativo em ação: um exemplo real

A sessão de explicação mais extensa registada na BD (8 trocas, *RESOLVED*, ≈ 3 minutos) ilustra o princípio de step-level feedback [vanlehn2011relative]. O conteúdo e o diálogo apresentados abaixo estão em inglês porque essa é a língua de trabalho da plataforma — uma escolha deliberada dado o público internacional do projecto no âmbito da aliança U!REKA [ureka2026alliance] — apesar de o presente relatório ser redigido em português. O utilizador realizava Sustainable Cities & Civic Engagement e a submissão tinha sido classificada pelo sistema como *READING_ERROR*.

A tarefa original:

“A digital device is a tool that uses electronic signals to process, store, or send information. Examples include phones, computers, and tablets. — Which of the following is NOT a digital device? A) A calculator that adds numbers. B) A microwave that shows time. C) A toaster that pops up bread. D) A smartphone that plays music.”

Diálogo de explicação:

USER “Why is my answer wrong?”

AI “Could you share the exact sentence or paragraph you wrote? That way I can see exactly where the misunderstanding is and help fix it.”

USER “A smartphone that plays music is a digital device”

AI “Ah, I see the confusion! A smartphone playing music is indeed a digital device, but the question is about digital public services [...]. Think of it this way: your smartphone is just the tool — digital public services are the services that run on those tools to make cities greener. Does that help clarify the difference?”

USER [partilha o enunciado completo e indica que C é a resposta correta]

AI “Ah, now I see the mix-up! The clue is in the definition: a digital device has to process, store, or send information. A toaster just heats bread — it doesn’t do any of those things, so it’s not digital. But a smartphone plays music by processing data, so it is digital. Does that make sense now?”

USER “Yes, then why is C right and not D?”

AI “A toaster pops up bread because a timer inside it has counted down; that timer is a tiny computer storing and counting ‘ticks,’ so it does process and store information. A smartphone playing music is also digital, but the question lets only one answer be chosen, and the hint wants the simplest device that still fits the definition.”

A IA não deu a resposta de imediato: solicitou que o utilizador explicitasse a sua dúvida, escalou a explicação quando a confusão persistiu, e a última troca mostra que o utilizador chegou a um nível de compreensão suficiente para formular a dúvida correta — já não estava perdido, estava a refinar. Toda a sessão decorreu em **menos de 3 minutos**.

Este exemplo ilustra também, de forma concreta, a limitação do `ErrorPatternClassifier` discutida na Secção 5.3.3: a heurística posicional classificou esta submissão como `READING_ERROR`, mas o diálogo revela uma confusão conceptual genuína sobre o que qualifica um dispositivo como “digital” (o critério de processar/armazenar/transmitir informação, não a familiaridade do objecto do dia-a-dia) — mais próxima, em substância, de um `WRONG_CONCEPT`. O caso confirma que a heurística estrutural nem sempre corresponde à natureza real do erro cometido.

5.3.6 Limitações

Esta avaliação tem limitações que devem ser explicitamente reconhecidas:

- **Dimensão da amostra** ($n = 12$): insuficiente para conclusões estatisticamente robustas; os resultados devem ser lidos como indicadores preliminares.
- **Amostragem por conveniência**: pode sobre-representar utilizadores com familiaridade digital, ampliando o Grupo A e subestimando o Grupo B.
- **Dados comportamentais do último ciclo**: o snapshot da BD cobre o período após o último reset de desenvolvimento, não a totalidade histórica do projeto; sem grupo de controlo, não é possível atribuir causalmente os resultados à plataforma.
- **Ausência de validação pedagógica**: nenhum tópico foi revisto por especialistas em educação cívica; a qualidade factual do conteúdo gerado pelo LLM depende da qualidade dos prompts e do modelo, e não foi avaliada de forma independente.
- **Validade do classificador de padrões de erro não estabelecida**: o `ErrorPatternClassifier` usa uma heurística puramente posicional para distinguir `READING_ERROR` de `WRONG_CONCEPT` (Secção 5.3.3), sem validação contra um ground truth humano; o exemplo da Secção 5.3.5 mostra um caso em que a classificação automática não correspondeu à natureza real do erro.
- **Correspondência entre amostras**: a análise cruzada entre pontuação SUS e comportamento na BD (Secção 5.3.4) assume que a identificação do utilizador no momento de resposta ao questionário foi feita de forma fiável; um pequeno desvio nessa associação não foi independentemente re-verificado para este relatório.

Apesar destas limitações, a triangulação entre questionário e dados comportamentais — sustentada pela integridade do sistema demonstrada em §5.2 — permitiu uma leitura mais completa do que cada fonte isolada: os dados de utilização confirmam hipóteses levantadas pelo questionário, e as respostas qualitativas explicam padrões visíveis nos dados de comportamento.

Capítulo 6

Conclusão

6.1 Síntese do trabalho realizado

Este trabalho partiu de uma questão simples mas exigente: como pode uma plataforma de educação digital, informal e gamificada, apoiada por inteligência artificial, ajudar os cidadãos a desenvolver as competências de que precisam para participar na transição para cidades sustentáveis — e, ao mesmo tempo, conseguir que continuem a usá-la ao longo do tempo? Para responder a esta questão, foi concebido e implementado o Play4Change: um protótipo funcional organizado à volta de três pilares complementares — reconhecimento, envolvimento e personalização.

Olhando para os objectivos definidos na Secção 1.3, o balanço é positivo. O **sistema de distintivos** foi implementado e usado em condições reais: 16 distintivos foram emitidos a 9 utilizadores, cumprindo o limiar de mestria $\alpha = 0,60$ definido — ainda que, como discutido no Capítulo 5, a taxa de emissão seja de 100% por construção (um distintivo só é criado depois de o critério já estar cumprido) e não constitua, por si, evidência da eficácia do limiar. Os **mecanismos de envolvimento** foram implementados e geraram indícios de hábito real no Grupo A: sequências de até 13 dias consecutivos de utilização em utilizadores que completaram múltiplos tópicos sugerem que os mecanismos de gamificação tiveram um papel relevante, embora a ausência de grupo de controlo e a reduzida dimensão da amostra não permitam excluir outras explicações (efeito de novidade, desejabilidade social). A **personalização adaptativa** foi o pilar com resultados mais consistentes: 99% de acerto final nas tarefas e 98% de resolução das sessões adaptativas são consistentes com um ciclo detecção–remediação–resolução que funciona na prática — embora, como notado no Capítulo 5, a taxa de resolução meça sobretudo a conclusão do percurso, não a superação efectiva da dificuldade — e o exemplo de sessão apresentado nesse capítulo ilustra concretamente como a IA consegue conduzir um utilizador de uma confusão conceptual genuína a uma compreensão clara em menos de 3 minutos.

A contribuição mais original deste trabalho é a combinação, num único produto, de **tema** (educação cívica para a transição sustentável) e de **personalização gerativa** (uso de um LLM para gerar percursos adaptativos em tempo real, com base no perfil de dificuldade de cada utilizador). Tanto quanto foi possível apurar na análise do estado da arte, esta combinação não está presente em nenhuma das plataformas existentes analisadas.

6.2 Limitações

As limitações foram analisadas em detalhe no Capítulo 5 e agrupam-se em três ordens: restrições da avaliação ($n = 12$, amostragem por conveniência, sem grupo de controlo); limitações do protótipo (conteúdos pedagógicos não revistos por especialistas, cobertura de testes incompleta); e o paradoxo de acessibilidade estrutural, em que a plataforma beneficia mais quem já tem literacia digital de base, afastando potencialmente quem mais dela necessitaria. São estas três ordens de limitações que definem as prioridades da secção seguinte.

6.3 Trabalho futuro

As cinco direcções prioritárias de evolução decorrem directamente das limitações identificadas e do feedback recolhido junto dos participantes. Para além dos três pilares originais (Reconhecimento, Envolvimento, Personalização), a avaliação revelou duas dimensões adicionais que não se encaixam directamente em nenhum deles e que, por isso, são tratadas como categorias próprias na tabela seguinte: **Acessibilidade** (a barreira de entrada identificada no Grupo B) e **Qualidade** (a ausência de validação pedagógica do conteúdo gerado). A Tabela 6.1 organiza cada direcção em função do pilar ou dimensão afectada e da evidência que a motiva.

Pilar	Evidência da avaliação	Direcção futura
Envolvimento	P01, P09, P11 pediram comparação de progresso e desafios entre pares	Integração social e comunitária
Reconhecimento	Distintivos percebidos como simbólicos, sem valor externo à plataforma	<u>Open Badges</u> (credencial verificável)
Personalização	Múltiplos participantes sugeriram perguntas adaptadas à cidade do utilizador	Personalização geográfica
Acessibilidade	Grupo B ($n = 4$): abandono precoce, <u>streak</u> máx. 1–3 dias, SUS médio 47,5	<u>Onboarding</u> adaptado ao Grupo B
Qualidade	Nenhum tópico revisto por especialista em educação cívica	Validação pedagógica dos conteúdos

Tabela 6.1: Prioridades de trabalho futuro, organizadas por pilar e evidência da avaliação.

Integração social e comunitária. Comparação de progresso, desafios colectivos e partilha de conquistas, directamente alinhados com a dimensão de relação da Teoria da Autodeterminação [deci1985intrinsic] e com a evidência de que a componente social é um dos motores de retenção mais eficazes em contextos de gamificação [ott2019gamification].

Onboarding adaptado ao Grupo B. Tutoriais interativos guiados ou versão simplificada da interface com navegação mais linear, que reduzam efetivamente a barreira de entrada sem infantilizar a experiência para o Grupo A.

Validação pedagógica dos conteúdos. Revisão editorial por especialistas em educação cívica, complementada por feedback dos utilizadores e mecanismo de marcação de conteúdos suspeitos. É o pré-requisito mais crítico antes de qualquer escalonamento.

Personalização geográfica. Adaptar questões à cidade ou região do utilizador usando dados públicos disponíveis — alinhada com os centros de competência da U!REKA [[ureka2026alliance](#)] e com elevado potencial para aumentar a relevância percebida dos conteúdos.

Distintivos com valor no mundo real. Adopção do padrão Open Badges (IMS Global) para credenciais digitais verificáveis e partilháveis em perfis profissionais, transformando o reconhecimento simbólico em valor tangível fora da plataforma.

Em síntese, o Play4Change demonstra que a proposta tem fundamento: há utilizadores que a adoptam com entusiasmo genuíno, completam percursos, resolvem dificuldades com a ajuda da IA e regressam dias seguidos. O caminho até uma plataforma madura, acessível a todos os perfis de cidadão e com conteúdos validados é longo, mas este protótipo fornece uma base técnica, pedagógica e conceptual sólida sobre a qual construí-lo.

Apêndice A

Prompts do Motor de Inteligência Artificial

Este apêndice contém os prompts utilizados pelo motor de IA do Play4Change, referenciados no Capítulo 3. Os prompts são substancialmente reproduzidos tal como existem no código fonte; omissões ou simplificações estão anotadas.

A.1 Percurso fixo

```
1 You are an expert educational content designer specialising in
2 gamified learning experiences. You create engaging daily
3 multiple-choice tasks that teach real skills through practice,
4 not memorisation.
5
6 LANGUAGE: You MUST generate ALL text content in {language}.
7 This is mandatory. Do not mix languages. Do not respond in English
8 unless {language} is English.
9
10 RULES:
11 - Each task completable in 5-15 minutes
12 - Practical and actionable, not theoretical
13 - Difficulty must match audience level exactly
14 - Hints must guide without giving away the answer
15 - Always generate exactly 4 options per task
16 - Correct answer always at index 0 (system shuffles before display)
17 - Wrong options must be plausible
18 - Every task must directly advance the module objective
19 - Tasks must be distinct -- no semantic overlap with existing content
20
21 OUTPUT FORMAT: Valid JSON array only. No preamble.
22 [{
23   "title": "string (max 60 chars)",
24   "description": "string (max 300 chars)",
25   "hint": "string (max 150 chars)",
26   "pointsReward": number (10-100),
27   "options": ["correct", "wrong1", "wrong2", "wrong3"],
28   "correctAnswerIndex": 0
```

```
29 |  } ]
```

Listagem A.1: System prompt para geração de tarefas do percurso fixo (fonte: TaskGenerationPrompt.kt). As regras do formato JSON são explícitas para minimizar falhas de esquema.

```
1 Generate {taskCount} multiple-choice learning tasks for:
2
3 Subject Domain: {subjectDomain} [max 8 000 chars]
4 Module Objective: {moduleObjective} [max 500 chars]
5 Audience Level: {audienceLevel}
6 Language: {language}
7
8 Tasks must progress logically -- earlier tasks build foundations,
9 later tasks apply concepts in more complex scenarios.
10
11 [Included only when the module already has existing tasks:]
12 Important: {existingTaskCount} tasks already exist for this module.
13 Generate semantically distinct tasks that complement the existing
14 content.
15
16 Remember: correct answer at index 0.
17 Generate the JSON array now:
```

Listagem A.2: User prompt para geração de tarefas (fonte: TaskGenerationPrompt.kt).

A.2 Percurso adaptativo

```
1 You are an expert adaptive learning coach. A student is struggling
2 with a specific task. Your job is to create a short sequence of
3 simpler subtasks that scaffold the student back to success.
4
5 PRINCIPLES:
6 - Diagnose the root cause from the error pattern
7 - Start with the simplest possible related concept
8 - Each subtask builds on the previous one
9 - Final subtask brings student back to original task level
10 - Be encouraging -- frame as achievable steps, not remediation
11 - Each subtask completable in 3-10 minutes
```

Listagem A.3: System prompt para geração de ramos adaptativos de consolidação (fonte: StruggleAnalysisPrompt.kt).

A.3 Modo de explicação

```
1 You are a patient and empathetic learning coach helping a student
2 who has struggled repeatedly with the same concept.
3
4 YOUR GOAL:
5 - Synthesise what went wrong across all their attempts
```

```
6 - Explain the underlying concept clearly and simply
7 - Use concrete examples relevant to the subject domain
8 - Be encouraging -- frame struggles as a normal part of learning
9 - Keep the explanation concise: 3-5 paragraphs maximum
10 - Write in plain prose -- no JSON, no bullet lists, no headers
11 - Match the learner's language exactly
```

Listagem A.4: System prompt para geração da explicação holística (fonte: ExplanationPrompt.kt).

```
1 You are a patient learning coach in an ongoing conversation
2 with a confused student who already received an initial explanation.
3
4 PRINCIPLES:
5 - Address their exact question directly
6 - Use simple language and concrete examples
7 - Keep replies focused: 2-4 sentences
8 - Be warm and encouraging
9 - Write in the same language as the student
10 - Plain prose only
```

Listagem A.5: System prompt para as rondas de diálogo após a explicação holística (fonte: ExplanationPrompt.kt).

