

# **Play4Change – Aplicação de Aprendizagem Adaptativa para Educação Cívica**

Radesh Ilesh Gamanbhai Govind

Orientadores: Nuno Datia  
Michel Vorenhout

Relatório do projeto realizado no âmbito de Projeto e Seminário  
Licenciatura em Engenharia Informática e de Computadores

11 de Junho de 2026



# INSTITUTO SUPERIOR DE ENGENHARIA DE LISBOA

## Play4Change – Aplicação de Aprendizagem Adaptativa para Educação Cívica

A51620 Radesh Ilesh Gamanbhai Govind

---

Orientadores: Nuno Datia

---

Michel Vorenhout

---

Relatório do projeto realizado no âmbito de Projeto e Seminário  
Licenciatura em Engenharia Informática e de Computadores

11 de Junho de 2026



# Resumo

O Play4Change é uma plataforma de aprendizagem adaptativa para o desenvolvimento de competências digitais segundo o referencial europeu DigComp 2.2, desenvolvida no âmbito do projeto U!REKA SHIFT em colaboração entre o ISEL e a Amsterdam University of Applied Sciences. O projeto responde à escassez de plataformas que integrem nativamente este referencial e que recorram à Inteligência Artificial para gerar e personalizar conteúdo pedagógico a partir de fontes documentais fornecidas por um formador, em vez de um catálogo estático pré-construído.

A plataforma é composta por um painel de administração web, uma aplicação móvel nativa para Android/iOS centrada num desafio diário, e um servidor Spring Boot que orquestra um *pipeline* assíncrono de ingestão de conteúdo (PDF ou URL), geração de tarefas por um modelo de linguagem (Mistral, via LangChain4j) e indexação vetorial em PostgreSQL/pgvector para deduplicação semântica e reutilização adaptativa de conteúdo. Quando um Learner erra um desafio, o sistema classifica o padrão do erro e gera um percurso de remediação adaptado, escalando para tutoria conversacional com IA caso a remediação não seja suficiente. A autenticação é *passwordless* por *magic link*, e a aplicação foi validada por uma análise de risco OWASP e uma suite de 49 ficheiros de teste automatizados.

A avaliação de usabilidade com doze utilizadores reais confirmou uma pontuação média de usabilidade (SUS) de 76,0, na categoria “Bom”, com a tutoria adaptativa por IA identificada como a funcionalidade mais valorizada. Os resultados confirmam a viabilidade técnica de uma plataforma que gera e adapta autonomamente o seu próprio conteúdo pedagógico, mantendo garantias de segurança e qualidade verificáveis.

**Palavras-chave:** Aprendizagem Adaptativa; Inteligência Artificial Generativa; *Retrieval-Augmented Generation*; Competências Digitais; DigComp 2.2.



# Abstract

Play4Change is an adaptive learning platform for developing digital competences under the European DigComp 2.2 framework, developed as part of the U!REKA SHIFT project in collaboration between ISEL and the Amsterdam University of Applied Sciences. The project addresses the scarcity of platforms that natively integrate this framework and use Artificial Intelligence to generate and personalise pedagogical content from documentary sources supplied by an instructor, rather than a static, pre-built catalogue.

The platform comprises a web administration panel, a native Android/iOS mobile application centred on a daily challenge, and a Spring Boot server that orchestrates an asynchronous content-ingestion pipeline (PDF or URL), task generation by a large language model (Mistral, via LangChain4j), and vector indexing in PostgreSQL/pgvector for semantic deduplication and adaptive content reuse. When a Learner answers a challenge incorrectly, the system classifies the error pattern and generates a tailored remediation path, escalating to conversational AI tutoring when remediation alone is insufficient. Authentication is passwordless via magic link, and the application was validated through an OWASP risk analysis and a suite of 49 automated test files.

A usability evaluation with twelve real users confirmed an average System Usability Scale (SUS) score of 76.0, in the “Good” category, with AI-driven adaptive tutoring identified as the most valued feature. The results confirm the technical feasibility of a platform that autonomously generates and adapts its own pedagogical content while maintaining verifiable security and quality guarantees.

**Keywords:** Adaptive Learning; Generative Artificial Intelligence; Retrieval-Augmented Generation; Digital Competences; DigComp 2.2.





# Utilização de Inteligência Artificial

No desenvolvimento deste projeto foram utilizadas as seguintes ferramentas de inteligência artificial generativa:

- **Google Gemini Flash e Gemini Pro** — utilizados principalmente na fase de investigação e enquadramento: pesquisa de conceitos, leitura e síntese de documentação técnica, e exploração de alternativas de design antes de tomar decisões de arquitetura. Foram também utilizados para *debater* e estudar tópicos novos — funcionando como interlocutor para clarificar dúvidas sobre padrões de domínio e comportamento de APIs externas.
- **Claude Sonnet (Claude Code e Claude Cowork)** — utilizados ao longo de todo o ciclo de desenvolvimento. O Claude Code (interface de linha de comandos) foi o principal auxiliar de programação: geração de esqueletos de código, sugestão e implementação de refactores, diagnóstico e correção de bugs, e escrita de testes unitários. O Claude Cowork (interface de desktop) foi utilizado na fase de redacção do relatório: análise de saídas do Claude Code, geração de figuras de diagramas de sequência com matplotlib.
- **Prova de conceitos (*proof of concepts*)** — em várias ocasiões, as ferramentas de IA foram utilizadas para construir protótipos mínimos que permitiram validar a viabilidade técnica de uma abordagem antes de a integrar no projeto principal.

Em todos os casos, o código e o texto gerados foram revistos, iterados, adaptados e validados pelo autor.



# Lista de Acrónimos e Siglas

| Sigla   | Significado                                             |
|---------|---------------------------------------------------------|
| API     | <i>Application Programming Interface</i>                |
| CORS    | <i>Cross-Origin Resource Sharing</i>                    |
| CSP     | <i>Content Security Policy</i>                          |
| DAG     | <i>Directed Acyclic Graph</i> (grafo acíclico dirigido) |
| DDD     | <i>Domain-Driven Design</i>                             |
| DigComp | <i>Digital Competence Framework for Citizens</i>        |
| DNS     | <i>Domain Name System</i>                               |
| ECTS    | <i>European Credit Transfer and Accumulation System</i> |
| HTTP(S) | <i>HyperText Transfer Protocol (Secure)</i>             |
| IA      | Inteligência Artificial                                 |
| ITS     | <i>Intelligent Tutoring System</i>                      |
| JPA     | <i>Jakarta Persistence API</i>                          |
| JSON    | <i>JavaScript Object Notation</i>                       |
| JVM     | <i>Java Virtual Machine</i>                             |
| JWT     | <i>JSON Web Token</i>                                   |
| LLM     | <i>Large Language Model</i>                             |
| MVI     | <i>Model-View-Intent</i>                                |
| OCR     | <i>Optical Character Recognition</i>                    |
| OWASP   | <i>Open Worldwide Application Security Project</i>      |
| RAG     | <i>Retrieval-Augmented Generation</i>                   |
| RBAC    | <i>Role-Based Access Control</i>                        |
| REST    | <i>Representational State Transfer</i>                  |
| SPA     | <i>Single Page Application</i>                          |
| SQL     | <i>Structured Query Language</i>                        |
| SSE     | <i>Server-Sent Events</i>                               |
| SSRF    | <i>Server-Side Request Forgery</i>                      |
| SUS     | <i>System Usability Scale</i>                           |
| TOCTOU  | <i>Time-Of-Check to Time-Of-Use</i>                     |
| TTL     | <i>Time To Live</i>                                     |
| URL     | <i>Uniform Resource Locator</i>                         |
| UUID    | <i>Universally Unique Identifier</i>                    |
| XSS     | <i>Cross-Site Scripting</i>                             |



# Índice

|          |                                                                     |           |
|----------|---------------------------------------------------------------------|-----------|
| <b>1</b> | <b>Introdução</b>                                                   | <b>1</b>  |
| 1.1      | Contextualização . . . . .                                          | 1         |
| 1.2      | Motivação . . . . .                                                 | 1         |
| 1.3      | Objetivos . . . . .                                                 | 2         |
| 1.4      | Âmbito, Limitações e Organização do Documento . . . . .             | 3         |
| <b>2</b> | <b>Estado da Arte</b>                                               | <b>5</b>  |
| 2.1      | Aprendizagem Adaptativa e Sistemas de Tutoria Inteligente . . . . . | 5         |
| 2.2      | Inteligência Artificial na Educação . . . . .                       | 6         |
| 2.2.1    | O Problema dos 2 Sigma e a Escalabilidade da Tutoria . . . . .      | 6         |
| 2.2.2    | Feedback Formativo e Aprendizagem Visível . . . . .                 | 6         |
| 2.2.3    | Teoria da Carga Cognitiva . . . . .                                 | 6         |
| 2.3      | Aprendizagem Formal, Informal e Móvel . . . . .                     | 7         |
| 2.4      | Retrieval-Augmented Generation . . . . .                            | 7         |
| 2.4.1    | Arquitetura RAG . . . . .                                           | 7         |
| 2.4.2    | RAG em Contextos Educativos . . . . .                               | 8         |
| 2.5      | Autenticação <i>Passwordless</i> . . . . .                          | 8         |
| 2.6      | Síntese Comparativa . . . . .                                       | 8         |
| <b>3</b> | <b>Análise e Requisitos</b>                                         | <b>11</b> |
| 3.1      | Identificação dos Utilizadores . . . . .                            | 11        |
| 3.1.1    | Administrador . . . . .                                             | 11        |
| 3.1.2    | Learner . . . . .                                                   | 11        |
| 3.2      | Requisitos Funcionais . . . . .                                     | 12        |
| 3.3      | Requisitos Não Funcionais . . . . .                                 | 13        |
| 3.4      | Casos de Uso Principais . . . . .                                   | 14        |
| 3.4.1    | CU01 — Submeter Conteúdo e Gerar Desafios . . . . .                 | 14        |
| 3.4.2    | CU02 — Responder ao Desafio Diário . . . . .                        | 15        |
| 3.4.3    | CU03 — Remediação Adaptativa (Struggle Path) . . . . .              | 15        |

|          |                                                                    |           |
|----------|--------------------------------------------------------------------|-----------|
| <b>4</b> | <b>Desenvolvimento</b>                                             | <b>17</b> |
| 4.1      | Arquitetura Geral do Sistema . . . . .                             | 17        |
| 4.1.1    | Visão Macro e Estilo Arquitetural . . . . .                        | 17        |
| 4.1.2    | Decomposição em Módulos . . . . .                                  | 18        |
| 4.1.3    | Camadas do Sistema . . . . .                                       | 18        |
| 4.1.4    | Domínio: Contextos Delimitados . . . . .                           | 19        |
| 4.1.5    | Fluxo Geral de Dados . . . . .                                     | 19        |
| 4.2      | Backend — Spring Server e Pipeline . . . . .                       | 20        |
| 4.2.1    | Organização do Projeto . . . . .                                   | 20        |
| 4.2.2    | Pipeline de Processamento de Pedidos . . . . .                     | 20        |
| 4.2.3    | Integração com os Restantes Componentes . . . . .                  | 21        |
| 4.3      | Autenticação Passwordless . . . . .                                | 22        |
| 4.3.1    | Modelo de Dados e Propriedades Criptográficas . . . . .            | 23        |
| 4.3.2    | Fluxo de Autenticação por Magic Link . . . . .                     | 23        |
| 4.3.3    | Ciclo de Vida dos Tokens JWT e Rotação de Refresh Tokens . . . . . | 24        |
| 4.3.4    | Autorização e Controlo de Acesso . . . . .                         | 24        |
| 4.4      | Ingestão e Extração de Conteúdo . . . . .                          | 25        |
| 4.4.1    | Extração de Texto: PDF e URL . . . . .                             | 25        |
| 4.4.2    | Limites e Validações . . . . .                                     | 27        |
| 4.5      | Modelo de IA e Estratégia de Prompting . . . . .                   | 28        |
| 4.5.1    | Modelo Escolhido e Justificação . . . . .                          | 28        |
| 4.5.2    | Estratégia de Prompting . . . . .                                  | 29        |
| 4.5.3    | Proteção e Limites da API de IA . . . . .                          | 30        |
| 4.6      | RAG — Retrieval-Augmented Generation . . . . .                     | 32        |
| 4.6.1    | Armazenamento de Conhecimento . . . . .                            | 32        |
| 4.6.2    | Recuperação e Reinjeção de Contexto . . . . .                      | 33        |
| 4.6.3    | Edição de Conteúdo e Invalidação . . . . .                         | 34        |
| 4.7      | Geração e Atribuição de Desafios . . . . .                         | 35        |
| 4.7.1    | Geração de Desafios . . . . .                                      | 35        |
| 4.7.2    | Atribuição aos Utilizadores . . . . .                              | 36        |
| 4.7.3    | Consolidation Path (Struggle Path) . . . . .                       | 37        |
| 4.7.4    | Tutoria com IA . . . . .                                           | 38        |
| 4.8      | Segurança da Aplicação . . . . .                                   | 38        |
| 4.8.1    | Proteção Contra XSS . . . . .                                      | 39        |
| 4.8.2    | Rate Limiting por IP . . . . .                                     | 40        |
| 4.8.3    | Validação e Sanitização de Inputs . . . . .                        | 40        |
| 4.8.4    | Outros Controlos de Segurança . . . . .                            | 41        |
| 4.8.5    | Análise de Riscos . . . . .                                        | 41        |

|          |                                                                                    |           |
|----------|------------------------------------------------------------------------------------|-----------|
| <b>5</b> | <b>Testes e Validação</b>                                                          | <b>43</b> |
| 5.1      | Estratégia de Testes . . . . .                                                     | 43        |
| 5.2      | Testes Unitários . . . . .                                                         | 44        |
| 5.2.1    | Objetos de Valor — <code>Name</code> . . . . .                                     | 44        |
| 5.2.2    | Autenticação — <code>TokenService</code> e <code>MagicLinkService</code> . . . . . | 44        |
| 5.2.3    | Baralhagem Anti-fraude e Cadência de Entrega . . . . .                             | 44        |
| 5.2.4    | Gestão de Tópicos e Detecção de Ciclos no DAG . . . . .                            | 45        |
| 5.2.5    | Detecção e Escalamento de Dificuldades . . . . .                                   | 45        |
| 5.3      | Testes de Integração . . . . .                                                     | 45        |
| 5.3.1    | Limitação de Taxa — <code>RateLimitTest</code> . . . . .                           | 45        |
| 5.3.2    | Controlo de Acesso ao Swagger . . . . .                                            | 46        |
| 5.3.3    | Controladores REST . . . . .                                                       | 46        |
| 5.3.4    | Frontend — Vitest + React Testing Library . . . . .                                | 46        |
| 5.4      | Testes de Segurança . . . . .                                                      | 47        |
| 5.4.1    | Prevenção de SSRF — <code>UrlSsrValidatorTest</code> . . . . .                     | 47        |
| 5.4.2    | Sanitização de Output IA — <code>AiOutputSanitiserTest</code> . . . . .            | 47        |
| 5.4.3    | Força Bruta e Magic Link . . . . .                                                 | 47        |
| 5.4.4    | Anti-fraude e Guarda de Arranque . . . . .                                         | 47        |
| 5.5      | Testes de Usabilidade . . . . .                                                    | 48        |
| 5.5.1    | Metodologia . . . . .                                                              | 48        |
| 5.5.2    | Análise SUS . . . . .                                                              | 48        |
| 5.5.3    | Análise Qualitativa . . . . .                                                      | 49        |
| <b>6</b> | <b>Resultados</b>                                                                  | <b>51</b> |
| 6.1      | Demonstração do Sistema . . . . .                                                  | 51        |
| 6.2      | Métricas de Desempenho . . . . .                                                   | 52        |
| 6.2.1    | Arquitetura de Observabilidade . . . . .                                           | 52        |
| 6.2.2    | Métricas Instrumentadas . . . . .                                                  | 53        |
| 6.2.3    | Limitação de Taxa por Caminho . . . . .                                            | 53        |
| 6.2.4    | Pool de Threads de Geração e Circuit Breaker . . . . .                             | 54        |
| 6.2.5    | Regras de Alerta Prometheus . . . . .                                              | 54        |
| 6.3      | Qualidade das Questões Geradas . . . . .                                           | 54        |
| 6.3.1    | Engenharia de Prompts e Reutilização Adaptativa . . . . .                          | 54        |
| 6.3.2    | Deduplicação Semântica com pgvector . . . . .                                      | 55        |
| 6.3.3    | Classificação de Padrões de Erro . . . . .                                         | 55        |
| 6.3.4    | Chunking de Conteúdo para Documentos Extensos . . . . .                            | 55        |
| 6.3.5    | Sanitização de Saída da IA . . . . .                                               | 55        |
| 6.3.6    | Garantias de Qualidade das Questões . . . . .                                      | 56        |

|          |                                                                            |           |
|----------|----------------------------------------------------------------------------|-----------|
| <b>7</b> | <b>Discussão</b>                                                           | <b>57</b> |
| 7.1      | Análise dos Resultados face aos Objetivos . . . . .                        | 57        |
| 7.2      | O que Correu Bem . . . . .                                                 | 58        |
| 7.3      | Limitações e Dificuldades . . . . .                                        | 59        |
| 7.4      | Comparação com o Estado da Arte . . . . .                                  | 59        |
| 7.5      | Trabalho Futuro . . . . .                                                  | 60        |
| <b>8</b> | <b>Conclusão</b>                                                           | <b>63</b> |
|          | <b>Referências</b>                                                         | <b>69</b> |
| <b>A</b> | <b>Exemplos de Prompts Completos</b>                                       | <b>71</b> |
| A.1      | Prompt de Geração de Tópicos e Desafios . . . . .                          | 71        |
| A.2      | Prompt de Análise de Dificuldade e Geração de Subtarefas Adaptativas . . . | 73        |
| A.3      | Prompt de Explicação Holística e Conversação . . . . .                     | 75        |
| <b>B</b> | <b>Diagramas Complementares</b>                                            | <b>77</b> |
| B.1      | Diagrama Entidade-Relação . . . . .                                        | 77        |
| B.2      | Formulário de Avaliação de Experiência de Utilizador . . . . .             | 77        |
| B.3      | Formulário de Avaliação Técnica . . . . .                                  | 77        |
| <b>C</b> | <b>Variáveis de Ambiente</b>                                               | <b>89</b> |



# Capítulo 1

## Introdução

A transformação digital acelerada das últimas décadas tornou a capacidade de utilizar as tecnologias digitais de forma confiante, crítica e responsável uma competência fundamental para a vida moderna. A União Europeia reconheceu esta necessidade através do *Digital Competence Framework for Citizens* (DigComp), atualmente na versão 2.2, que organiza 21 competências digitais em cinco áreas e serve de base a políticas de educação digital em toda a Europa [1]. Este projeto insere-se na aliança universitária europeia U!REKA, da qual o ISEL é membro ativo, e é desenvolvido em colaboração com a Amsterdam University of Applied Sciences (HvA), parceira da rede.

### 1.1 Contextualização

O *Digital Compass* e o subsequente *Digital Decade Policy Programme* da União Europeia fixam o objetivo de dotar pelo menos 80% da população europeia de competências digitais básicas até 2030, tendo o DigComp 2.2 como instrumento de referência para o operacionalizar [2, 1]. Apesar deste enquadramento, escasseiam plataformas de aprendizagem que o integrem nativamente, que tirem partido da Inteligência Artificial (IA) para personalizar a experiência de aprendizagem, e que permitam a gestão autónoma de conteúdos adaptados ao perfil e progresso de cada utilizador.

### 1.2 Motivação

Em 1984, Bloom demonstrou que um aluno com tutoria individual supera em dois desvios padrão ( $2\sigma$ ) o desempenho médio de uma sala de aula tradicional [3] — o “problema dos 2 sigma”: como escalar essa qualidade a um custo viável? Os LLM reacenderam este debate, ao aproximar esse ideal do custo marginal [4].

A investigação em eficácia do ensino mostra ainda que o *feedback* imediato e formativo acelera a aprendizagem [5], algo que as plataformas de *e-learning* tradicionais raramente oferecem. No domínio específico do DigComp 2.2 não existe, até ao momento, uma plataforma

adaptativa que integre nativamente este referencial e recorra à IA para personalizar o percurso de cada utilizador.

Técnicas como o *Retrieval-Augmented Generation* (RAG) permitem ancorar as respostas do modelo em conhecimento específico e verificável [6], abrindo a oportunidade de conjugar o quadro estruturado do DigComp 2.2 com uma experiência na interseção entre aprendizagem formal e informal [7].

### 1.3 Objetivos

O presente projeto tem como objetivo geral conceber, desenvolver e validar o **Play4Change**, uma plataforma de aprendizagem adaptativa centrada no desenvolvimento de competências digitais segundo o referencial DigComp 2.2, com recurso a Inteligência Artificial para a geração automática de conteúdos e personalização dos percursos de aprendizagem.

A plataforma assenta numa arquitetura multi-cliente que serve dois perfis distintos: os **Administradores**, que gerem e criam conteúdos através de um painel web, e os **Learners**, que desenvolvem as suas competências através de uma aplicação móvel nativa, assente no modelo de um desafio diário. De forma mais específica, pretende-se:

- Desenvolver um **cliente web** composto por um painel de administração para gestão de conteúdos e utilizadores, e por uma *landing page* que permite aos Learners descarregar a aplicação móvel;
- Desenvolver um **cliente móvel** para Learners, centrado numa experiência de aprendizagem contínua e diária — um desafio por dia —, tirando partido da ubiquidade do telemóvel;
- Integrar um pipeline de extração e processamento de conteúdo a partir de documentos PDF e páginas web, como base para a geração automática de tópicos e desafios via IA;
- Implementar um sistema de *Retrieval-Augmented Generation* (RAG) que permita ao modelo de IA gerar conteúdo ancorado em conhecimento específico e persistente;
- Conceber um mecanismo de progressão de desafios (*consolidation path*) que adapte o percurso de aprendizagem ao desempenho individual do Learner;
- Garantir a segurança da plataforma através de autenticação *passwordless*, proteção contra vulnerabilidades web comuns e controlo de utilização da API de IA.

Estes entregáveis concretizam-se em cinco objetivos operacionais: (1) plataforma adaptativa alinhada com o DigComp 2.2; (2) *pipeline* de geração de conteúdo por IA; (3) remediação adaptativa por padrão de erro; (4) tutoria conversacional como escalamento; e (5) segurança e qualidade do conteúdo gerado. A concretização de cada um é analisada no Capítulo 7 (§7.1).

## 1.4 Âmbito, Limitações e Organização do Documento

O Play4Change foi desenvolvido no âmbito do projeto *U!REKA SHIFT*, iniciativa da aliança U!REKA que visa soluções educativas inovadoras para as cidades do futuro, com foco na literacia digital. A colaboração entre o ISEL e a HvA enquadra-se neste objetivo, contribuindo para as metas do *Digital Compass* para 2030 [2]. Em termos técnicos, o âmbito cobre o *backend*, o cliente web e o cliente móvel para Learners.

As principais limitações são: a avaliação pedagógica da eficácia da plataforma a larga escala não foi realizada, sendo o foco a conceção técnica do sistema; a integração com sistemas de gestão de aprendizagem externos (LMS) fica para trabalho futuro; e, apesar de a arquitetura Kotlin Multiplatform permitir compilação nativa para iOS, o projeto entrega apenas o alvo Android.

O restante relatório organiza-se da seguinte forma: o Capítulo 2 apresenta o estado da arte em plataformas de aprendizagem adaptativa, modelos de linguagem aplicados à educação, RAG e autenticação *passwordless*; o Capítulo 3 descreve a análise de utilizadores, requisitos e casos de uso; o Capítulo 4 detalha a arquitetura e implementação do sistema; o Capítulo 5 apresenta a estratégia e os resultados dos testes; o Capítulo 6 demonstra o sistema em funcionamento; o Capítulo 7 discute os resultados face aos objetivos e ao estado da arte; e o Capítulo 8 apresenta as conclusões.



## Capítulo 2

# Estado da Arte

Este capítulo situa o Play4Change no panorama da aprendizagem adaptativa, da Inteligência Artificial na educação, da distinção entre aprendizagem formal e informal, do *Retrieval-Augmented Generation*, da aprendizagem móvel e da autenticação *passwordless*, terminando com uma síntese comparativa face às soluções existentes.

### 2.1 Aprendizagem Adaptativa e Sistemas de Tutoria Inteligente

A ideia de adaptar o ensino ao ritmo e ao perfil individual de cada aluno não é nova: em meados do século XX, Skinner propôs as primeiras “máquinas de ensinar”, baseadas no reforço imediato da resposta correta [8], evoluindo nas décadas seguintes para os *Intelligent Tutoring Systems* (ITS) — sistemas capazes de modelar o estado de conhecimento do aluno e adaptar dinamicamente a instrução [9].

Os ITS modernos assentam tipicamente em três módulos: o **modelo de domínio**, o **modelo do estudante** e o **módulo pedagógico** [10], o segundo frequentemente implementado através de *Knowledge Tracing* [11], cujas versões recentes baseadas em redes neurais recorrentes melhoraram significativamente a precisão da modelação [12].

No mercado atual, plataformas como o **Duolingo**, o **Khan Academy** e o **Coursera** incorporam princípios de adaptatividade em graus distintos. O Duolingo, pioneiro no modelo de exercício diário no canal móvel, reportou num estudo encomendado pela própria empresa resultados comparáveis a um semestre universitário para leitura e audição [13] — afirmação a ler com reserva, dado tratar-se de um estudo não revisto por pares, com amostra pequena e auto-selecionada e sem grupo de controlo independente, cuja conclusão foi publicamente contestada por outros investigadores [14]. Estas plataformas partilham, ainda assim, uma limitação comum: o conteúdo é estático e curado manualmente por equipas especializadas, não podendo ser adaptado por terceiros para domínios específicos — é aqui que o Play4Change se distingue, permitindo que qualquer Administrador introduza novo conhecimento, automaticamente transformado em conteúdo pedagógico pela IA.

## 2.2 Inteligência Artificial na Educação

A aplicação da Inteligência Artificial à educação (*AI in Education*, AIED) tem uma história de várias décadas, mas a emergência dos LLM introduziu uma mudança qualitativa sem precedentes nas possibilidades desta área.

### 2.2.1 O Problema dos 2 Sigma e a Escalabilidade da Tutoria

Em 1984, Bloom demonstrou que alunos com tutoria individual (relação 1-para-1) superaram em dois desvios padrão (*2 sigma*) — ou seja, 98% dos colegas — os alunos sujeitos ao ensino tradicional em sala de aula [3]. Durante décadas, este “problema dos 2 sigma” ficou sem resposta: a tutoria individual é eficaz, mas economicamente inviável a larga escala. Os LLM reabriram o debate de forma concreta [4]: um modelo de linguagem disponível 24 horas por dia, capaz de responder a questões em linguagem natural, adaptar a complexidade da explicação ao nível do utilizador e fornecer *feedback* imediato e contextualizado, aproxima pela primeira vez o ideal da tutoria personalizada de uma escala de implementação massiva [15].

### 2.2.2 Feedback Formativo e Aprendizagem Visível

A investigação em eficácia pedagógica converge num ponto, independentemente da tecnologia: o *feedback* imediato e formativo é um dos fatores que mais acelera a aprendizagem. Na sua meta-análise de mais de 800 estudos, Hattie (2009) coloca o *feedback* entre os dez maiores aceleradores da aprendizagem, com um tamanho de efeito (*effect size*) de  $d = 0,73$  [5] — um valor agregado cuja metodologia foi criticada por outros investigadores como estatisticamente pouco robusta e potencialmente enganadora quando apresentada como um número único e preciso [16], ainda que a direção geral do efeito seja consensual na literatura. Este princípio é relevante no contexto do Play4Change: ao fornecer *feedback* explicativo imediatamente após cada desafio diário, a plataforma incorpora um mecanismo pedagógico amplamente (ainda que não precisamente) suportado pela evidência.

### 2.2.3 Teoria da Carga Cognitiva

A *Cognitive Load Theory* (CLT), desenvolvida por Sweller [17], postula que a memória de trabalho humana tem capacidade limitada e distingue três tipos de carga cognitiva: *intrínseca* (complexidade inerente ao conteúdo), *extrínseca* (causada por má apresentação da informação) e *germane* (esforço cognitivo dedicado à formação de esquemas de conhecimento). O modelo de um desafio curto por dia e por tópico é consistente com os princípios da CLT, minimizando a carga extrínseca e permitindo que o esforço cognitivo do Learner seja dirigido à assimilação do conteúdo. Esta propriedade aplica-se, contudo, por inscrição: o sistema permite que um Learner esteja simultaneamente inscrito em vários tópicos ativos (Secção 4.7.2 do Capítulo 4), cada um com o seu próprio desafio diário independente, pelo

que um Learner com múltiplas inscrições recebe vários desafios no mesmo dia — o que dilui parcialmente o argumento da carga cognitiva mínima para esse perfil de utilização, e é uma tensão de desenho que a versão atual do sistema não resolve explicitamente (por exemplo, limitando o número de inscrições ativas em simultâneo).

## 2.3 Aprendizagem Formal, Informal e Móvel

A distinção entre aprendizagem formal e informal é central para compreender o posicionamento do Play4Change. A **aprendizagem formal** caracteriza-se por ser institucionalizada, estruturada e avalizada por certificações reconhecidas, com motivação frequentemente extrínseca [18]. A **aprendizagem informal**, por contraste, é não estruturada, autodirigida e motivada pela necessidade imediata ou curiosidade intrínseca [7]: Knowles demonstrou que os adultos aprendem melhor quando a aprendizagem resolve problemas reais e é controlada pelo próprio [19], e Cross estimou que 80% do conhecimento prático usado no trabalho é adquirido informalmente [7]. O Play4Change opera deliberadamente na interseção destes dois paradigmas: ancorado no referencial estruturado do DigComp 2.2, mas com um modelo de utilização — desafio diário, sem horários fixos nem avaliações sumativas — intrinsecamente informal e autodirigido.

O canal escolhido para essa interseção é o dispositivo móvel. A aprendizagem móvel (*m-learning*) tira partido da portabilidade, conectividade e ubiquidade destes dispositivos [20]; Laurillard (2007) argumenta que o telemóvel transforma a aprendizagem de um evento programado num processo contínuo e contextualizado, integrado nos interstícios da vida quotidiana [21] — esta ubiquidade é central para o Play4Change, cujo desafio diário se integra nos momentos em que o utilizador já usa o dispositivo. Com mais de 5 mil milhões de utilizadores de telemóvel no mundo [22], o canal móvel é também o mais democrático e inclusivo disponível, uma dimensão relevante para o objetivo do DigComp 2.2 de desenvolver competências digitais para *todos* os cidadãos [1].

## 2.4 Retrieval-Augmented Generation

Os LLM apresentam uma limitação estrutural relevante para aplicações de domínio específico: o seu conhecimento é estático, limitado à data de treino, e caro de atualizar sem re-treino do modelo. O *Retrieval-Augmented Generation* (RAG) surgiu como resposta a esta limitação, combinando a capacidade generativa dos LLM com a consulta dinâmica de bases de conhecimento externas [6].

### 2.4.1 Arquitetura RAG

Na sua formulação original, proposta por Lewis et al. (2020), o RAG funciona em duas fases [6]:

1. **Fase de recuperação (*retrieval*):** dado um *query*, o sistema recupera os documentos ou fragmentos de texto (*chunks*) mais relevantes de uma base de conhecimento indexada vetorialmente, tipicamente por similaridade cosseno entre *embeddings*.
2. **Fase de geração:** os *chunks* recuperados são injetados no contexto do LLM, que gera uma resposta fundamentada nessa informação específica.

Esta arquitetura reduz as *hallucinations* (respostas factualmente incorretas geradas com confiança), permite que o sistema responda com base em conhecimento privado ou recente, e torna as respostas rastreáveis às fontes originais [23].

### 2.4.2 RAG em Contextos Educativos

A aplicação do RAG a sistemas educativos é uma área de investigação em crescimento acelerado: ancorar a geração de questões e *feedback* em documentos fornecidos pelo formador — em vez de no conhecimento genérico do modelo — é particularmente valioso em contextos de formação especializada, onde a precisão e a especificidade do conteúdo são críticas [4]. No Play4Change, o RAG garante que os desafios gerados para cada Learner estão diretamente ancorados no conteúdo submetido pelo Administrador, e não em conhecimento genérico do modelo.

## 2.5 Autenticação *Passwordless*

A autenticação por *password* é, há décadas, o mecanismo dominante de controlo de acesso em sistemas web, mas a investigação em segurança acumulou evidência consistente de que as *passwords* constituem o elo mais fraco da cadeia: reutilizadas entre serviços, sujeitas a força bruta, *phishing* e roubo em *data breaches*, e frequentemente esquecidas [24]. Bonneau et al. (2012) avaliaram 35 esquemas alternativos e concluíram que nenhum supera as *passwords* em todos os critérios simultaneamente, mas que os esquemas *passwordless* oferecem vantagens claras em usabilidade e resistência a *phishing* [24].

A autenticação *passwordless* substitui a *password* por um fator de posse (*magic link* por email, OTP via SMS ou aplicação) ou por um fator biométrico (FIDO2/*Passkeys*) [25]. No Play4Change, serve dois objetivos complementares: reduz a fricção de entrada para o Learner (que não precisa de memorizar uma *password* para uma utilização diária breve) e elimina um vetor de ataque relevante numa aplicação que lida com dados de progressão de aprendizagem.

## 2.6 Síntese Comparativa

A Tabela 2.1 apresenta uma análise comparativa entre o Play4Change e as principais plataformas de referência identificadas no estado da arte, segundo os critérios mais relevantes para o posicionamento do projeto.



Tabela 2.1: Comparação entre o Play4Change e plataformas de referência

| Critério                               | Duolingo | Khan Academy | Coursera | Play4Change |        |
|----------------------------------------|----------|--------------|----------|-------------|--------|
|                                        |          |              |          | Atual       | Futuro |
| Gamificação                            | ✓        | ~            | ×        | ~           | ✓      |
| Adaptação à dificuldade do utilizador  | ✓        | ✓            | ×        | ✓           | ✓      |
| Catálogo de conteúdo pré-definido      | ✓        | ✓            | ✓        | ×           | ~      |
| Reconhecimento com credenciais formais | ~        | ×            | ✓        | ×           | ✓      |
| Comunidade e interação social          | ✓        | ~            | ✓        | ×           | ✓      |
| Modelo de desafio diário no móvel      | ✓        | ×            | ×        | ✓           | ✓      |
| Cliente móvel nativo                   | ✓        | ✓            | ✓        | ✓           | ✓      |
| Autenticação <i>passwordless</i>       | ×        | ×            | ×        | ✓           | ✓      |

✓ Suportado    × Não suportado    ~ Parcialmente suportado

A análise revela um posicionamento diferenciado para o Play4Change, mas expõe também limitações claras face às plataformas estabelecidas. Nos critérios onde estas lideram — gamificação (*streaks*, ligas e pontuação no Duolingo), reconhecimento formal por certificados (Coursera), catálogo de conteúdo pré-definido e comunidade/interação social — o Play4Change fica em desvantagem: depende do conteúdo submetido pelo Administrador, o que exige esforço de curadoria inicial, e não cobre ainda estas dimensões sociais. Estas lacunas são reconhecidas como direções prioritárias de trabalho futuro.

O Play4Change diferencia-se, ainda assim, pelo seu modelo de entrega: um desafio diário por tópico no canal móvel, com adaptação ao desempenho do utilizador e autenticação *passwordless* — combinação que nenhuma das plataformas analisadas oferece. Note-se que este modelo de “desafio diário” descreve o padrão pretendido por tópico; como discutido na Secção 2.1, um Learner com múltiplas inscrições ativas em simultâneo recebe múltiplos desafios diários, pelo que a garantia de um único desafio por dia não é, presentemente, uma propriedade imposta pelo sistema.



## Capítulo 3

# Análise e Requisitos

A definição clara dos requisitos de um sistema é um dos fatores mais determinantes para o sucesso de um projeto de engenharia de software [26]. Este capítulo apresenta a análise dos utilizadores da plataforma Play4Change, os requisitos funcionais e não funcionais identificados, e os principais casos de uso que guiaram as decisões de desenho e implementação.

### 3.1 Identificação dos Utilizadores

A identificação dos utilizadores é o ponto de partida de qualquer processo de desenvolvimento centrado no utilizador (*User-Centered Design*) [27], e levou, no contexto do Play4Change, à identificação de dois perfis de utilizador com necessidades, objetivos e contextos de uso distintos.

#### 3.1.1 Administrador

O **Administrador** é o perfil responsável pela criação e gestão de conteúdo pedagógico — tipicamente um formador ou responsável de uma instituição parceira da rede U!REKA, sem necessidade de *expertise* em IA ou engenharia de software. Interage com a plataforma exclusivamente através do **cliente web**: submete PDF ou URLs como fontes de conhecimento, revê os tópicos e desafios gerados pela IA, e gere os Learners registados. Esta separação — produção de conteúdo versus consumo e progressão — é consistente com os modelos de *Intelligent Tutoring Systems* (ITS) [9].

#### 3.1.2 Learner

O **Learner** é o destinatário da experiência de aprendizagem. O seu perfil é deliberadamente amplo: qualquer cidadão que pretenda desenvolver as suas competências digitais no referencial DigComp 2.2, independentemente do nível de partida ou do contexto institucional em que se insere.

O Learner interage com a plataforma através do **cliente móvel**, numa experiência desenhada para ser discreta e integrada na rotina diária. O modelo de um **desafio por dia**

não é arbitrário: sessões curtas e regulares são significativamente mais eficazes do que sessões longas e esporádicas (*spaced repetition*) [28, 29], e a Teoria da Autodeterminação de Deci e Ryan mostra que a motivação intrínseca é sustentada por *autonomia*, *competência crescente* e *ligação* a um propósito [30] — fatores a que este modelo responde diretamente. A escolha do telemóvel é também suportada pela investigação em *mobile learning* [20], com mais de 5 mil milhões de utilizadores no mundo [22].

## 3.2 Requisitos Funcionais

Os requisitos funcionais descrevem os comportamentos que o sistema deve exibir em resposta a determinadas entradas ou condições [26]. A Tabela 3.1 apresenta os requisitos funcionais do Play4Change, organizados por área funcional.

Tabela 3.1: Requisitos funcionais do sistema Play4Change

| ID   | Área          | Descrição                                                                                                                                                                                                              |
|------|---------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| RF01 | Autenticação  | O sistema deve suportar autenticação para ambos os perfis de utilizador.                                                                                                                                               |
| RF02 | Ingestão      | O Administrador deve poder submeter documentos PDF como fonte de conhecimento.                                                                                                                                         |
| RF03 | Ingestão      | O Administrador deve poder submeter URLs como fonte de conhecimento.                                                                                                                                                   |
| RF04 | IA            | O sistema deve gerar automaticamente tópicos a partir do conteúdo submetido pelo Administrador.                                                                                                                        |
| RF05 | IA            | O sistema deve gerar automaticamente desafios (questões) a partir dos tópicos identificados.                                                                                                                           |
| RF06 | RAG           | O sistema deve armazenar o conhecimento extraído em forma de <i>embeddings</i> e recuperá-lo para contextualizar a geração de conteúdo pela IA.                                                                        |
| RF07 | RAG           | A regeneração completa de um tópico pelo Administrador deve invalidar e recalcular os <i>embeddings</i> associados; a edição pontual de uma tarefa individual pode aceitar um vetor desactualizado (ver Secção 4.6.3). |
| RF08 | Desafios      | O sistema deve atribuir um desafio diário a cada Learner, de acordo com o seu percurso de progressão.                                                                                                                  |
| RF09 | Desafios      | O Learner deve receber <i>feedback</i> imediato após responder a cada desafio.                                                                                                                                         |
| RF10 | Consolidação  | O sistema deve implementar um percurso de re-mediação ( <i>struggle path</i> ) que gere sub-tarefas adaptadas ao padrão de erro do Learner, reutilizando contextos de dificuldade semelhantes já resolvidos.           |
| RF11 | Cliente Web   | O sistema deve disponibilizar um painel de administração acessível via browser.                                                                                                                                        |
| RF12 | Cliente Web   | O sistema deve disponibilizar uma <i>landing page</i> pública com informação sobre a plataforma e ligação para descarregar a aplicação móvel.                                                                          |
| RF13 | Cliente Móvel | O sistema deve disponibilizar uma aplicação móvel para os Learners, centrada na experiência de um desafio diário.                                                                                                      |

### 3.3 Requisitos Não Funcionais

Os requisitos não funcionais definem as propriedades e restrições do sistema que não dizem respeito a comportamentos específicos, mas à qualidade global da solução [31]. A Tabela 3.2 apresenta os requisitos não funcionais identificados para o Play4Change.

Tabela 3.2: Requisitos não funcionais do sistema Play4Change

| ID    | Categoria        | Descrição                                                                                                                                                                                                                                                                                          |
|-------|------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| RNF01 | Segurança        | O sistema deve proteger os utilizadores contra ataques <i>Cross-Site Scripting</i> (XSS), removendo ou codificando HTML potencialmente malicioso nos conteúdos gerados por IA antes de os persistir ou renderizar.                                                                                 |
| RNF02 | Segurança        | O sistema deve aplicar <i>rate limiting</i> por endereço IP para prevenir abusos nos endpoints públicos.                                                                                                                                                                                           |
| RNF03 | Segurança        | O sistema deve aplicar <i>rate limiting</i> por endereço IP nas chamadas à API de IA, para controlo de custos e prevenção de abusos.                                                                                                                                                               |
| RNF04 | Segurança        | A comunicação entre clientes e servidor deve ser efetuada exclusivamente via HTTPS.                                                                                                                                                                                                                |
| RNF05 | Usabilidade      | A aplicação móvel deve seguir os princípios de <i>mobile-first design</i> , com interações mínimas para completar o desafio diário.                                                                                                                                                                |
| RNF06 | Escalabilidade   | A arquitetura do sistema deve permitir o aumento do número de utilizadores sem alterações estruturais ao domínio ou à aplicação; componentes de estado local por processo (e.g. o <i>cache</i> de <i>rate limiting</i> ) são uma limitação conhecida a endereçar antes de escalar horizontalmente. |
| RNF07 | Manutenibilidade | O código deve seguir os princípios SOLID e ser coberto por testes unitários e de integração.                                                                                                                                                                                                       |

### 3.4 Casos de Uso Principais

Os casos de uso descrevem as interações entre os atores e o sistema para atingir um objetivo específico [32]. São apresentados de seguida os três casos de uso centrais do Play4Change.

#### 3.4.1 CU01 — Submeter Conteúdo e Gerar Desafios

**Ator principal:** Administrador.

**Pré-condição:** O Administrador está autenticado no painel web.

**Fluxo principal:**

1. O Administrador define o tópico e submete um documento PDF ou um URL como fonte de conhecimento; o sistema cria de imediato o tópico em estado **PENDING**.
2. De forma assíncrona, o sistema extrai e limpa o texto do documento ou página.
3. O sistema divide o texto em *chunks* e invoca o modelo de IA para gerar módulos e os respetivos desafios (*task templates*).
4. Por cada desafio gerado, o sistema calcula o *embedding*, verifica duplicação semântica face aos desafios já existentes no módulo, e persiste o resultado.

5. Concluída a geração, o tópico transita automaticamente para o estado **ACTIVE**, sem aprovação explícita do Administrador; este pode editar um desafio específico ou desencadear a regeneração completa do tópico.

**Pós-condição:** O tópico está **ACTIVE**, com os desafios e o conhecimento associado indexados e disponíveis para atribuição aos Learners.

### 3.4.2 CU02 — Responder ao Desafio Diário

**Ator principal:** Learner.

**Pré-condição:** O Learner está autenticado na aplicação móvel e tem um desafio diário atribuído.

**Fluxo principal:**

1. O Learner abre a aplicação móvel e visualiza o desafio do dia.
2. O sistema apresenta o desafio correspondente ao seu percurso atual, já gerado antecipadamente pela IA durante o pipeline de ingestão do tópico — não há recuperação vetorial em tempo real neste passo.
3. O Learner submete a sua resposta.
4. O sistema avalia a resposta e apresenta *feedback* imediato, com explicação contextualizada.
5. O sistema regista o resultado e atualiza o perfil de progressão do Learner.

**Pós-condição:** O resultado é registado; se a resposta estiver incorreta, é desencadeada a sessão de remediação descrita em CU03.

### 3.4.3 CU03 — Remediação Adaptativa (Struggle Path)

**Ator principal:** Learner.

**Pré-condição:** O Learner respondeu incorretamente a um desafio do dia.

**Fluxo principal:**

1. O sistema classifica deterministicamente o padrão do erro (por exemplo, atraso na submissão ou opção adjacente à correta).
2. De forma assíncrona, o sistema gera três sub-tarefas mais simples, centradas no padrão de erro detetado, reutilizando um ramo já gerado para um contexto semelhante sempre que a similaridade semântica o permita.
3. O Learner resolve as sub-tarefas; se as completar todas corretamente, a sessão é marcada como resolvida e o desafio original do dia é repostado para nova tentativa.

4. Se o Learner voltar a falhar após esgotar a profundidade de remediação definida, o sistema substitui as sub-tarefas por uma sessão de explicação sintetizada por IA, com possibilidade de diálogo de esclarecimento.

**Pós-condição:** O Learner é conduzido de volta ao desafio original, com uma remediação centrada no seu erro específico; esta adaptação ocorre dentro do próprio desafio do dia, não altera a escolha de que tópico apresentar em dias seguintes — essa seleção continua a ser feita pelo próprio Learner, através de inscrição explícita nos tópicos disponíveis.



## Capítulo 4

# Desenvolvimento

O Play4Change é uma plataforma de aprendizagem adaptativa composta por três superfícies cliente (Android/iOS/Web), um serviço de backend e um módulo de geração por Inteligência Artificial, orquestrados através de uma infraestrutura totalmente contida em *containers*. Este capítulo descreve as decisões de arquitetura e as tecnologias escolhidas para concretizar cada componente.

### 4.1 Arquitetura Geral do Sistema

#### 4.1.1 Visão Macro e Estilo Arquitetural

O backend do Play4Change adota a **Arquitetura Hexagonal** (*Ports & Adapters*), organizada dentro de um modelo de contextos delimitados (*Bounded Contexts*) de *Domain-Driven Design* (DDD) [33] — exigida pela natureza do problema: a complexidade reside no domínio (geração adaptativa de tarefas, detecção de dificuldade, percurso de consolidação), que tem de permanecer isolado de detalhes de persistência, protocolo HTTP ou fornecedor de LLM.

A arquitetura organiza-se em três anéis concêntricos com dependências que fluem sempre para o interior:

- **Anel de domínio:** classes Kotlin puras, sem qualquer anotação de *framework*. Contém as entidades, os agregados, os eventos de domínio e as interfaces de *port*.
- **Anel de aplicação:** casos de uso que orquestram o domínio, chamando exclusivamente interfaces de *port* — nunca implementações concretas.
- **Anel de infraestrutura:** adaptadores de entrada (*REST controllers*, filtros de segurança JWT) e adaptadores de saída (JPA, Resend, LangChain4j, MinIO), todos injetados pelo contentor Spring em tempo de execução.

Uma consequência prática desta separação: o domínio e a aplicação nunca referenciam LangChain4j diretamente, pelo que substituir o fornecedor de LLM de Mistral para outro modelo não exige alterar nenhuma linha de lógica de negócio — exige apenas uma nova

implementação de `TaskGenerationPort` anotada com `@Primary` e, ao nível do *build*, trocar a dependência de `ai-agent:langchain` pelo módulo Gradle correspondente ao novo adaptador.

### 4.1.2 Decomposição em Módulos

O sistema está decomposto em seis módulos com regras de dependência estritas, apresentados na Tabela 4.1.

Tabela 4.1: Módulos do sistema Play4Change e responsabilidades

| Módulo                          | Tecnologia                           | Responsabilidade                                                                                              |
|---------------------------------|--------------------------------------|---------------------------------------------------------------------------------------------------------------|
| <code>server</code>             | Kotlin, Spring Boot 3, JVM 21        | API REST, lógica de domínio e aplicação, adaptadores de infraestrutura                                        |
| <code>ai-agent:api</code>       | Kotlin puro                          | Contratos de <i>port</i> para geração IA — sem implementação nem dependências de <i>runtime</i>               |
| <code>ai-agent:langchain</code> | Kotlin, LangChain4j, Mistral         | Adaptador IA: geração de tarefas, ramificação adaptativa, síntese de explicações                              |
| <code>composeApp</code>         | Kotlin Multiplatform, Compose MP     | Cliente móvel Android e iOS — arquitetura MVI via Decompose                                                   |
| <code>common</code>             | Kotlin Multiplatform                 | Objetos de valor compartilhados, tipos de erro, <i>result wrappers</i> — sem dependências de <i>framework</i> |
| <code>play4change-web</code>    | React 18, TypeScript, Vite, TanStack | SPA de administração — gestão de tópicos, utilizadores e métricas                                             |

A regra de dependência é rigorosa: `common` não depende de nenhum módulo; `ai-agent:api` depende apenas de `common`; o **domínio e a aplicação** do `server` referenciam apenas a interface `TaskGenerationPort`, nunca `LangChain4j` diretamente — a implementação concreta é injetada em *runtime* via `@Primary`.

### 4.1.3 Camadas do Sistema

A Figura 4.1 apresenta a visão macro do sistema, organizada em quatro zonas de rede com fronteiras explícitas.




Figura 4.1: Arquitetura geral do sistema Play4Change

**Camada de apresentação:** os dois clientes — móvel (Android/iOS) e web (SPA React) — comunicam exclusivamente via HTTPS com a camada de rede de fronteira.

**Rede de fronteira:** um *reverse proxy* Nginx centraliza o tráfego de entrada, encaminhando pedidos de API para o Spring Boot via HTTP interno e servindo os ficheiros estáticos da SPA React (`try_files` para *client-side routing*); o servidor de aplicação nunca serve ativos estáticos.

**Rede privada:** o servidor Spring Boot, as bases de dados e a observabilidade estão isolados numa rede privada inacessível externamente. O servidor acede ao **PostgreSQL 16** (`pgvector` + `uuid-oss`) para persistência relacional e vetorial, e ao **MinIO** (compatível com S3) para ficheiros e APKs; Prometheus e Grafana completam a pilha de observabilidade (§6.2).

**Serviços externos:** o **Mistral AI** (via LangChain4j) para geração de tarefas e explicações, e o **Resend** para entrega de email no fluxo *passwordless*.

#### 4.1.4 Domínio: Contextos Delimitados

O domínio está particionado em **oito contextos delimitados**, cada um com os seus próprios agregados, contratos de repositório e serviços de aplicação. Nenhum contexto acede diretamente aos agregados de outro — a comunicação inter-contexto passa sempre por interfaces de serviço de aplicação.

- **Auth** — Fluxo de *magic link*, ciclo de vida de tokens JWT, gestão de papéis (*roles*)
- **Identity** — Perfil do Learner, preferências, fuso horário, email de recuperação
- **Topic** — Estrutura curricular: tópicos → módulos → *templates* de tarefas (versionados, com *embeddings*)
- **Enrollment** — Inscrição do Learner em tópicos, agendamento de atribuições, rastreio de progresso
- **Struggle** — Heurísticas de deteção de dificuldade, persistência de registos de *struggle*, lógica de activação adaptativa
- **Explanation** — Sessões de explicação sintetizadas por IA e conversa de seguimento
- **Badge** — Avaliação de critérios de conquista, ciclo de vida de atribuição de *badges*
- **Report** — Métricas agregadas de desempenho em tarefas para análise de administração

#### 4.1.5 Fluxo Geral de Dados

Um pedido típico do Learner atravessa Nginx, o filtro de segurança JWT e o controlador REST, que delega de imediato ao caso de uso de aplicação — sem conter lógica de negócio —

que por sua vez invoca os *ports* de repositório e de geração IA necessários. A cadeia completa de filtros HTTP é detalhada na Seção 4.2.2.

## 4.2 Backend — Spring Server e Pipeline

### 4.2.1 Organização do Projeto

O servidor é uma aplicação Spring Boot 3 escrita em Kotlin (JVM 21), estruturada segundo a Arquitetura Hexagonal com separação estrita entre três camadas: **domain**, **application** e **infrastructure/web**.

A camada **domain** é Kotlin puro (sem anotações Spring, JPA ou LangChain4j), com as entidades, agregados e interfaces de *port* dos oito contextos delimitados (**auth**, **identity**, **topic**, **enrollment**, **struggle**, **explanation**, **badge**, **report**). A camada **application** contém os casos de uso e os serviços que os implementam, invocando exclusivamente interfaces de *port* — nunca implementações concretas — para que a lógica de negócio seja testável independentemente da base de dados ou do fornecedor de LLM. A camada **infrastructure** contém os adaptadores de saída (JPA, `MinioFileStorageAdapter`, `UrlScrapeAdapter`, `UnstructuredPdfAdapter`, `ResendEmailAdapter`) e os adaptadores de entrada HTTP, organizados em **admin**, **user** e **public**.

O módulo de IA está separado em dois módulos Gradle: `ai-agent:api` define o contrato `TaskGenerationPort` sem dependências de *runtime*; `ai-agent:langchain` é a única localização que referencia LangChain4j, implementando esse contrato com `@Primary`. O `:server` depende apenas da interface — substituir o fornecedor de LLM não exige alterar lógica de negócio, apenas trocar essa dependência de *build*.

A gestão do esquema é feita exclusivamente por Flyway (32 migrações), com `ddl-auto:validate`; *queries* críticas para atomicidade (e.g. `claimToken`) usam SQL nativo com `RETURNING` para eliminar janelas TOCTOU.

### 4.2.2 Pipeline de Processamento de Pedidos

Cada pedido HTTP atravessa um conjunto de camadas ordenadas de forma determinista antes de atingir o *controller*, descritas na Tabela 4.2.

#### Filtros e interceptores — ordem de execução

Quatro componentes operam em camadas distintas antes de o pedido atingir o *controller*, descritos na Tabela 4.2.

O `RateLimitFilter` corre efetivamente antes de qualquer outro componente da cadeia — inclusive do `RequestIdFilter` e de qualquer lógica de autenticação — o que impede ataques de força bruta mesmo sobre utilizadores não autenticados; em contrapartida, um pedido rejeitado (429) nunca chega a ter `X-Request-Id` nem entra no MDC de logging.

Tabela 4.2: Componentes do pipeline HTTP e responsabilidades

| Ordem | Componente                                           | Responsabilidade                                                                                                                                                                                     |
|-------|------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1     | <code>RateLimitFilter (HIGHEST_PRECEDENCE)</code>    | <i>Rate limiting</i> por $IP \times path$ normalizado, via <code>Bucket4j</code> com <i>cache</i> <code>Caffeine</code> ; devolve 429 com <code>Retry-After</code> quando o <i>bucket</i> é excedido |
| 2     | <code>RequestIdFilter (@Order(1))</code>             | Gera ou propaga o header <code>X-Request-Id</code> ; coloca-o no MDC do <code>SLF4J</code> para correlação de logs distribuídos                                                                      |
| 3     | <code>JwtAuthFilter (OncePerRequestFilter)</code>    | Valida o JWT do header <code>Authorization: Bearer</code> ; popula o <code>SecurityContextHolder</code> com <code>userId</code> e <code>role</code> ; devolve 401 em token inválido                  |
| 4     | <code>LoggingInterceptor (HandlerInterceptor)</code> | Regista $\rightarrow$ <code>METHOD path</code> em <code>preHandle</code> e $\leftarrow$ <code>status [Xms]</code> em <code>afterCompletion</code>                                                    |

Os limites por *endpoint* — e o problema de duas regras de submissão hoje inoperantes por desalinhamento de rota — são discutidos na Secção 4.8.2 e detalhados na Secção 6.2.3.

### Pipeline assíncrono de geração de tópicos

A criação de um tópico é o fluxo mais complexo do sistema, envolvendo extração de conteúdo, geração por LLM e indexação vetorial. A Figura 4.2 ilustra o pipeline completo, que atravessa cinco estados de máquina de estados:

INGESTION  $\rightarrow$  ANALYSIS  $\rightarrow$  GENERATION  $\rightarrow$  INDEXING  $\rightarrow$  ACTIVE

(qualquer fase pode transitar para FAILED em caso de erro)

O pedido `POST /admin/topics` devolve imediatamente 201 `Created` com o tópico em estado `PENDING`; o pipeline executa em paralelo num executor dedicado (`generationExecutor`) com três *threads* e fila de 25 pedidos. O `SupervisorJob` Kotlin garante que a falha de uma geração não cancela outras em curso. O Admin acompanha o progresso em tempo real via *Server-Sent Events* (SSE) no *endpoint* `GET /admin/topics/{id}/progress`, recebendo eventos `phase-change`, `generation-progress` e `complete`.

Dois *schedulers* Spring garantem a robustez do pipeline: o `StuckGenerationWatchdogJob` (a cada 120s) deteta tópicos presos em `GENERATING` por mais de 15 minutos e transita-os para `FAILED`; o `TopicExpirationJob` (a cada 60s) marca como `EXPIRED` os tópicos `ACTIVE` cuja `expires_at` passou. A integração com o LLM é protegida por *circuit breaker*, *retry* e *timeout* (configuração detalhada na Secção 6.2.4).

### 4.2.3 Integração com os Restantes Componentes

O servidor integra-se com cinco sistemas de infraestrutura e dois sistemas externos, sempre mediados por interfaces de *port* no domínio — nunca por referências diretas às implementações (Tabela 4.3).




Figura 4.2: Pipeline assíncrono de geração de tópicos com notificação SSE

Tabela 4.3: Integrações do servidor com componentes de infraestrutura e serviços externos

| Componente                   | Papel                              | Detalhe                                                                                                                      |
|------------------------------|------------------------------------|------------------------------------------------------------------------------------------------------------------------------|
| Nginx                        | Reverse proxy + estáticos          | Rewrite de prefixo, proxy_read_timeout 120s (chamadas LLM), headers de segurança e CORS restritivo                           |
| PostgreSQL + pgvector        | Persistência relacional e vetorial | Spring Data JPA/Hibernate por contexto; embeddings de 1024 dimensões para deduplicação                                       |
| MinIO                        | Armazenamento de objetos           | MinioFileStorageAdapter guarda PDFs e texto extraído de URLs; conteúdo descarregado uma vez, LLM nunca acede ao URL original |
| Playwright + Unstructured.io | Extração de conteúdo               | Microserviços dedicados para URL (HTML renderizado) e PDF (OCR); UrlSsrValidator valida antes de qualquer fetch              |
| Resend                       | Email transacional                 | Magic link; em desenvolvimento, ConsoleEmailAdapter regista o token no log sem enviar email                                  |
| Prometheus + Grafana         | Observabilidade                    | /actuator/prometheus (porta de gestão, 9090); métricas e dashboards detalhados na Secção 6.2                                 |

## 4.3 Autenticação Passwordless

O Play4Change implementa autenticação *passwordless* por *magic link*, sem qualquer OAuth externo ou SSO. O design resolve três requisitos simultâneos: eliminar *passwords* para o utilizador gerir, garantir resistência a ataques de reutilização de tokens, e suportar um email de recuperação alternativo como segunda via de acesso.

### 4.3.1 Modelo de Dados e Propriedades Criptográficas

O subsistema de autenticação mantém quatro tabelas independentes do domínio principal. A Tabela 4.4 descreve a estrutura e as propriedades de segurança de cada uma.

Tabela 4.4: Tabelas do modelo de dados de autenticação

| Tabela            | Campos relevantes                                                         | Função e propriedades de segurança                                                                    |
|-------------------|---------------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------|
| users             | id (UUID), email, provider (MAGIC_LINK), role (USER ADMIN)                | Perfil de autenticação; email é normalizado (lowercase + trim) antes de qualquer operação             |
| magic_link_tokens | token (SHA-256 do token em claro), expires_at (+15 min), used (bool)      | Apenas o <i>hash</i> é persistido; consumo atômico via UPDATE ... RETURNING elimina janelas TOCTOU    |
| refresh_tokens    | token_hash (SHA-256), family_id (UUID), expires_at (+7 dias), used (bool) | family_id agrupa todos os <i>tokens</i> de uma sessão; detecção de reutilização revoga toda a família |
| recovery_emails   | email, verified (bool), token_hash, token_expires_at (+24h)               | Permite autenticação com email alternativo verificado; não cria utilizador duplicado                  |

Todos os tokens são gerados pela classe `AuthCrypto` com 32 bytes de `SecureRandom` (64 caracteres hexadecimais). **Apenas o SHA-256 do token é persistido**; o token em claro existe exclusivamente em memória e no email enviado ao utilizador, nunca na base de dados.

### 4.3.2 Fluxo de Autenticação por Magic Link

O fluxo de autenticação decorre em duas fases: pedido do *magic link* e verificação do token. A Figura 4.3 apresenta o diagrama de sequência completo, incluindo os casos de token inválido.

O fluxo assenta em três decisões de segurança deliberadas. Primeiro, o pedido do *link* (utilizador submete o email, `MagicLinkService` normaliza-o e persiste o SHA-256) responde sempre `202 Accepted`, independentemente de o email existir — não confirmando nem negando a sua existência, evitando enumeração de contas. Segundo, o consumo do token (móvel via *deep link*; web via *redirect* que não consome, apenas encaminha para o POST) é uma operação atômica `UPDATE ... WHERE used=false AND expires_at>now() RETURNING email`, eliminando janelas de corrida. Terceiro, zero linhas devolvidas significa indistintamente token inválido, expirado ou já usado — as três condições de falha são propositadamente indistinguíveis para o cliente, evitando *oracle attacks*.

Em caso de sucesso, o serviço resolve o email a um utilizador existente, a um email de recuperação verificado, ou a um novo registo implícito, emitindo de seguida o par *access token* (15 min) / *refresh token* (7 dias).




Figura 4.3: Diagrama de sequência — fluxo completo de autenticação por *magic link*

### 4.3.3 Ciclo de Vida dos Tokens JWT e Rotação de Refresh Tokens

O *access token* é um JWT assinado com HMAC-SHA-256, com a estrutura de *claims* {*sub*, *email*, *role*, *iat*, *exp*}. A chave de assinatura é validada em arranque pelo `JwtSecretStartupGuard`: em perfil `prod`, o arranque falha (`IllegalStateException`) se a chave tiver menos de 64 caracteres ou for igual ao valor de desenvolvimento por omissão; fora de `prod`, o uso desse valor por omissão gera apenas um aviso em log, sem impedir o arranque. A sessão Spring é `STATELESS` (`SessionCreationPolicy.STATELESS`) — cada pedido é autenticado independentemente pelo `JwtAuthFilter`.

O mecanismo de rotação de *refresh tokens* segue o padrão *token rotation* com deteção de reutilização. Quando o cliente faz `POST /auth/refresh`, o `TokenService` localiza o *refresh token* pelo hash. Se o token já foi marcado como `used`, é detetado um possível roubo de sessão: todos os tokens da mesma `family_id` são imediatamente revogados, forçando o utilizador a re-autenticar. Em caso de token válido, o token atual é marcado como usado e é emitido um novo par, mantendo o mesmo `family_id` — o que garante que o *logout* revoga toda a cadeia de rotação da sessão.

### 4.3.4 Autorização e Controlo de Acesso

A `SecurityConfig` define quatro zonas de acesso com regras distintas, descritas na Tabela 4.5.



Tabela 4.5: Zonas de controlo de acesso configuradas no Spring Security

| Zona          | Paths                                                                             | Requisito                                  |
|---------------|-----------------------------------------------------------------------------------|--------------------------------------------|
| Pública       | /auth/**, /api/stats/public,<br>/error, /actuator/health,<br>/actuator/prometheus | Sem autenticação                           |
| Swagger       | /swagger-ui/**, /v3/api-docs/**                                                   | ROLE_ADMIN em <i>prod</i> ; público em dev |
| Administração | /admin/**                                                                         | ROLE_ADMIN obrigatório                     |
| Utilizador    | Todos os restantes <i>paths</i>                                                   | JWT válido (qualquer <i>role</i> )         |

A separação da zona de administração é particularmente relevante: um Learner com JWT válido que tente aceder a `/admin/**` recebe 403 `Forbidden` sem que o pedido atinja qualquer *controller*. O Swagger é restrito a administradores em produção para evitar exposição do contrato de API a utilizadores não autorizados.

## 4.4 Ingestão e Extração de Conteúdo

A ingestão de conteúdo é a primeira fase do pipeline de criação de tópicos. Um Administrador fornece uma fonte — um URL público ou um ficheiro PDF — a partir da qual o sistema extrai texto simples que servirá de base à geração automática de tarefas educativas.

A camada de extração segue o padrão *Port & Adapter*: a interface `ContentExtractorPort` é definida na camada de aplicação com dois métodos, `extractFromUrl(url: String): String` e `extractFromPdf(pdfBytes: ByteArray): String`, e é implementada na infraestrutura pelo `ContentExtractorAdapter`. O domínio nunca referencia nenhuma tecnologia de extração diretamente.

Independentemente da fonte, o fluxo síncrono partilha o mesmo padrão: o `TopicManagementService` extrai o texto, valida que não está vazio, persiste o conteúdo original no MinIO (como ficheiro de auditoria e para eventual regeneração), cria o tópico em estado `PENDING` e lança o pipeline assíncrono de geração — devolvendo 201 `Created` imediatamente sem aguardar a conclusão da IA.

### 4.4.1 Extração de Texto: PDF e URL

A ingestão suporta duas fontes com tecnologias distintas mas o mesmo contrato (`ContentExtractorPort`), resumidas na Tabela 4.6: PDF, delegado à **Unstructured API** [34] (contentor Docker, porta 9500) pela necessidade de OCR em documentos digitalizados; e URL, delegado a um microserviço **Playwright** [35] (Node.js, porta 3000) porque muitas páginas educativas são *Single Page Applications* que exigem execução de JavaScript para renderizar conteúdo invisível a uma chamada HTTP convencional.

O ponto de entrada HTTP partilha os campos de metadados descritos na Tabela 4.7, substituindo `file` por `url` (String, sujeito a validação SSRF) no fluxo por URL.

A Figura 4.4 detalha o fluxo por URL, incluindo a validação de segurança SSRF; o

Tabela 4.6: Extração de texto por fonte: PDF vs URL

|               | PDF (POST /admin/topics/pdf)                                                                                                                                                                                                                                                         | URL (POST /admin/topics)                                           |
|---------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------|
| Processamento | multipart/form-data para Browser Chromium persistente; /general/v0/general aguarda domcontentloaded (strategy=auto: texto nativo (25 s) e networkidle (5 s, ou OCR consoante a página); filtra ignora falhas); remove elementos vazios, une por parágrafo, remove bytes nulos de OCR |                                                                    |
| Timeout       | 120 s (documentos extensos ou totalmente digitalizados)                                                                                                                                                                                                                              | 45 s no servidor, 35 s no scraper (headroom para latência de rede) |
| Persistência  | MinIO, topics/{id}/content.pdf                                                                                                                                                                                                                                                       | MinIO, topics/{id}/content.txt                                     |

Tabela 4.7: Campos do pedido POST /admin/topics/pdf (multipart/form-data)

| Campo       | Tipo       | Obrigatório | Restrições                                             |
|-------------|------------|-------------|--------------------------------------------------------|
| file        | binary PDF | Sim         | máx. 25 MB                                             |
| title       | String     | Sim         | máx. 200 caracteres                                    |
| description | String     | Sim         | máx. 1 000 caracteres                                  |
| category    | String     | Não         | máx. 100 caracteres                                    |
| difficulty  | Enum       | Não         | BEGINNER   INTERMEDIATE   ADVANCED (omissão: BEGINNER) |
| language    | String     | Não         | código ISO 639-1 (omissão: en), máx. 10 caracteres     |
| taskCount   | Int        | Não         | omissão: 10                                            |
| expiresAt   | ISO 8601   | Não         | omissão: agora + 90 dias                               |

fluxo por PDF segue o mesmo padrão de invocação síncrona ao adaptador, substituindo o Playwright pela Unstructured API.

## Prevenção de SSRF

Antes de qualquer pedido de rede, o `UrlSsrValidator` executa uma validação sequencial que termina na primeira violação detetada:

1. **Esquema obrigatório https** — rejeita URLs com esquema `http` ou outros protocolos.
2. **Host não nulo** — rejeita URLs malformadas sem componente de *host*.
3. **Resolução DNS e filtragem de endereços privados** — invoca `InetAddress.getAllByName(host)` e rejeita qualquer endereço resolvido que pertença a: *loopback* (127.0.0.0/8, ::1), redes privadas RFC 1918 (10.0.0.0/8, 172.16.0.0/12, 192.168.0.0/16), *link-local* (169.254.0.0/16, fe80::/10) ou *multicast*.

Qualquer violação lança uma `UrlSsrViolationException` que o `TopicManagementService` converte em `BadRequest.InvalidField("url", detalhe)` devolvido como 400 `Bad Request`. Esta validação mitigua o ataque OWASP A10:2021 (SSRF), impedindo que o sistema seja usado como *proxy* para alcançar serviços internos da rede Docker.




Figura 4.4: Diagrama de sequência — extração de texto de URL com validação SSRF e Playwright

#### 4.4.2 Limites e Validações

A ingestão de conteúdo envolve quatro camadas de validação independentes, cada uma responsável por uma classe distinta de erros, aplicadas pela ordem que se segue.

##### Camada 1 — Rate Limiting (por IP, antes da autenticação)

O mesmo `RateLimitFilter` descrito na Secção 4.2.2 aplica limites intencionalmente conservadores aos *endpoints* de ingestão — a operação de maior custo computacional e financeiro do sistema — detalhados na Secção 6.2.3.

##### Camada 2 — Validação HTTP (tamanho e campos obrigatórios)

O `TopicController` verifica o tamanho do ficheiro PDF antes de qualquer processamento: ficheiros superiores a 25MB são rejeitados com 413 Payload Too Large. Este limite é reforçado pela configuração Spring (`spring.servlet.multipart.max-file-size: 25MB; max-request-size: 2`). A validação dos campos de metadados é declarativa via anotações `@Valid` do Jakarta Validation API, que geram automaticamente 400 Bad Request com o nome do campo e a restrição violada.

### Camada 3 — Validação de Domínio (no serviço de aplicação)

O `TopicManagementService` aplica invariantes de negócio que não são expressáveis por anotações: conteúdo binário não pode estar vazio (`pdfBytes.isNotEmpty()`), e `taskCount` tem de ser positivo. Em caso de violação SSRF (URL), a exceção propagada do `UrlSsrValidator` é convertida em `BadRequest.InvalidField("url", detalhe)`.

### Camada 4 — Validação do Conteúdo Extraído

Independentemente da fonte, o texto extraído é validado após a chamada ao adaptador. A Tabela 4.8 resume os cenários de falha e as respostas correspondentes.

Tabela 4.8: Cenários de falha na extração de conteúdo e respostas HTTP

| Cenário                                      | Resposta                                | Campo em erro     |
|----------------------------------------------|-----------------------------------------|-------------------|
| PDF com apenas imagens sem OCR bem-sucedida  | 400 “PDF contains no extractable text”  | <code>file</code> |
| Página com conteúdo exclusivamente em canvas | 400 “page returned no extractable text” | <code>url</code>  |
| Timeout ou indisponibilidade do Unstructured | 400 com mensagem de erro propagada      | <code>file</code> |
| Timeout ou indisponibilidade do scraper      | 400 com mensagem de erro propagada      | <code>url</code>  |
| Violação SSRF                                | 400 com detalhe da violação             | <code>url</code>  |

### Limites de Contexto para Geração (`ContentChunker`)

Após extração bem-sucedida, o texto é particionado pelo `ContentChunker` antes de ser enviado ao LLM. Os parâmetros são definidos em `AiContextLimits`: tamanho máximo de cada *chunk* de 32 000 caracteres, com sobreposição (*overlap*) de 2 000 caracteres entre *chunks* consecutivos para preservar contexto nas fronteiras. O algoritmo prefere divisões em limites de parágrafo (`\n\n`) dentro dos últimos 500 caracteres de cada *chunk*, recorrendo ao corte rígido por posição apenas quando não encontra parágrafo — garantindo que o contexto enviado ao modelo preserve a coerência semântica do texto original.

## 4.5 Modelo de IA e Estratégia de Prompting

O módulo de IA do Play4Change serve três finalidades distintas: geração de tarefas educativas a partir de conteúdo ingerido, síntese de ramos adaptativos para estudantes com dificuldades, e condução de sessões de explicação interactiva. Cada finalidade tem o seu próprio prompt, com preocupações de segurança e limites de contexto especificamente calibrados.

### 4.5.1 Modelo Escolhido e Justificação

O sistema utiliza **Mistral AI** como fornecedor de LLM, integrado através da biblioteca `LangChain4j` v0.36.2. O modelo configurado por omissão é `mistral-small-latest`, com temperatura  $T = 0.7$  e *timeout* de 60 segundos por chamada.

São instanciados dois clientes distintos, ambos configurados na classe `LangChain4jConfig` e ativados condicionalmente via `@ConditionalOnExpression` apenas quando a variável de

ambiente `MISTRAL_API_KEY` está definida: o `ChatLanguageModel` (`MistralAiChatModel`), para geração de texto e JSON estruturado, e o `EmbeddingModel` (`MistralAiEmbeddingModel`), que produz vectores de 1024 dimensões para o pgvector.

A escolha de Mistral Small justifica-se por quatro razões concretas. Primeiro, a capacidade multilingue: os prompts incluem um parâmetro `language` obrigatório (e.g., `pt`, `en`, `es`), e o modelo gera conteúdo educativo com qualidade adequada em múltiplas línguas. Segundo, a relação custo/desempenho: a geração de questões de escolha múltipla e explicações requer capacidade de raciocínio moderada, não justificando modelos de maior escala e custo. Terceiro, a fiabilidade no output JSON estruturado: o sistema exige que o modelo produza JSON válido com esquema rigoroso (*arrays* com `title`, `description`, `hint`, `pointsReward`, `options`, `correctAnswerIndex`). Quarto, a intercambiabilidade: a integração via LangChain4j e a interface `TaskGenerationPort` permitem substituir o modelo sem qualquer alteração ao domínio ou à aplicação — basta criar uma nova implementação de `TaskGenerationPort` e anotá-la com `@Primary`.

Quando a chave de API não está definida, o `NoOpTaskGenerationAdapter` é ativado automaticamente, respondendo com `503 Service Unavailable` em todos os *endpoints* de IA — garantindo que o sistema falha de forma explícita em vez de silenciosa.

#### 4.5.2 Estratégia de Prompting

O sistema define três famílias de prompts, cada uma com *system prompt* fixo e *user prompt* parametrizado com dados do contexto de domínio. Em nenhuma das três famílias é injetado diretamente input do utilizador final — essa separação é a principal defesa contra *prompt injection*, conforme descrito na Secção 4.5.3.

##### A — Geração de Tarefas (`TaskGenerationPrompt`)

O *system prompt* estabelece a *persona* de designer de conteúdo educativo, as regras de formato (4 opções por questão, resposta correta sempre no índice 0 para o sistema a misturar aleatoriamente), o idioma obrigatório, e o esquema JSON esperado. O *user prompt* injeta exclusivamente dados do domínio: título do tópico, objetivo do módulo, nível de audiência (`BEGINNER/INTERMEDIATE/ADVANCED`), idioma e número de tarefas pretendidas.

O mecanismo de *retry* com *schema reminder* funciona assim: se o JSON de resposta do modelo não contiver o número mínimo de tarefas válidas, o adaptador reenvia o mesmo *user prompt* acrescido de uma mensagem de correção de esquema, consumindo até duas chamadas à API por *chunk*. A deduplicação semântica usa *embeddings* de 1024 dimensões armazenados em pgvector: uma tarefa gerada é descartada se a sua similaridade coseno com qualquer *template* existente no mesmo módulo exceder o limiar de 0.90, evitando redundância no catálogo de tarefas.

## B — Ramo Adaptativo (StruggleAnalysisPrompt)

Quando um estudante esgota as tentativas de uma tarefa, o sistema gera um ramo de sub-tarefas mais simples centradas no padrão de erro detetado (`ErrorPattern`: `CONCEPTUAL_MISUNDERSTANDING`, `PROCEDURAL_ERROR`, `KNOWLEDGE_GAP`, `UNCLEAR_INSTRUCTIONS`, `TIME_PRESSURE`). Este `ErrorPattern` pertence ao modelo do módulo `ai-agent` e é distinto do `ErrorPattern` do domínio do `server` (`WRONG_CONCEPT`, `PARTIAL_UNDERSTANDING`, `READING_ERROR`, `TIME_PRESSURE`), produzido de forma determinística pelo `ErrorPatternClassifier` (Secção 4.7.3); os dois são ligados por uma função de tradução (`mapErrorPattern()`) que mapeia `WRONG_CONCEPT` → `CONCEPTUAL_MISUNDERSTANDING`, `PARTIAL_UNDERSTANDING` → `PROCEDURAL_ERROR`, `READING_ERROR` → `UNCLEAR_INSTRUCTIONS` e `TIME_PRESSURE` → `TIME_PRESSURE`. Como o `ErrorPatternClassifier` nunca produz `PARTIAL_UNDERSTANDING` na sua implementação atual, apenas três dos cinco valores do `ErrorPattern` do `ai-agent` são de facto alcançáveis hoje (`CONCEPTUAL_MISUNDERSTANDING`, `UNCLEAR_INSTRUCTIONS`, `TIME_PRESSURE`); `PROCEDURAL_ERROR` e `KNOWLEDGE_GAP` estão modelados no contrato para uma classificação mais granular ainda não implementada no classificador determinístico.

Antes de invocar o LLM, o sistema verifica a similaridade do contexto de dificuldade atual com contextos anteriores armazenados em `pgvector`, decidindo entre reutilização total, parcial ou geração de novo ramo consoante o limiar de similaridade (Tabela 4.10, Secção 4.6.2). O vetor de entrada é construído como a concatenação de `errorPattern`, `taskDescription` e `subjectDomain`, embebido em 1024 dimensões pelo `MistralAiEmbeddingModel`.

## C — Sessão de Explicação (ExplanationPrompt)

A explicação opera em dois modos sequenciais. Na **fase holística** (assíncrona), após esgotamento das tentativas, o sistema gera uma explicação detalhada baseada no historial completo de erros do estudante; o *system prompt* instrui o modelo a adoptar a persona de tutor empático e a explicar a causa raiz da dificuldade. Na **fase conversacional** (síncrona), o estudante pode fazer perguntas de seguimento, recebendo respostas geradas em tempo real.

Ambas as fases passam pelo `AiOutputSanitiser` antes de a resposta chegar ao cliente; o fluxo completo, incluindo o diagrama de sequência, é apresentado na Secção 4.7.4 (Figura 4.6).

### Limites de Contexto

Os limites de contexto aplicados em todos os prompts estão centralizados na classe `AiContextLimits`, descritos na Tabela 4.9.

### 4.5.3 Proteção e Limites da API de IA

O sistema implementa seis camadas de defesa independentes entre a entrada HTTP e a chamada ao LLM; as subsecções seguintes detalham as mais específicas ao módulo de IA.

As camadas 1 (rate limiting), 2 (autenticação JWT), 3 (validação de input) e 4 (SSRF) foram descritas nas Secções 4.2.2 e 4.4.2. As secções seguintes detalham as camadas 5 e 6,

Tabela 4.9: Limites de contexto da camada de IA (AiContextLimits)

| Constante              | Valor        | Utilização                                         |
|------------------------|--------------|----------------------------------------------------|
| CONTENT_CHARS          | 32 000 chars | Tamanho máximo de cada <i>chunk</i> enviado ao LLM |
| CHUNK_OVERLAP          | 2 000 chars  | Sobreposição entre <i>chunks</i> consecutivos      |
| DESCRIPTION_CHARS      | 500 chars    | Objetivo do módulo nos prompts de geração          |
| STRUGGLE_CONTEXT_CHARS | 8 000 chars  | Contexto de dificuldade no prompt adaptativo       |
| OBJECTIVE_CHARS        | 500 chars    | Objetivo do módulo em prompts secundários          |

específicas ao módulo de IA.

## Camada 5 — Prevenção de Prompt Injection (Multi-Mensagem Tipada)

A vulnerabilidade clássica de *prompt injection* em sistemas conversacionais ocorre quando o input do utilizador é interpolado numa string de prompt única, permitindo que o utilizador escape o contexto com instruções como “*Ignora as instruções anteriores e...*”.

O Play4Change adopta uma arquitetura de **multi-mensagem tipada**: em vez de construir uma string única, cada peça de informação é encapsulada no tipo de mensagem LangChain4j correspondente ao seu nível de confiança. A Figura 4.5 detalha a construção da lista de mensagens para a fase conversacional da explicação.



Figura 4.5: Arquitectura anti-*injection*: construção tipada de mensagens por nível de confiança

A lista de mensagens é construída pela seguinte ordem: (1) **SystemMessage** com a *persona* e as regras — origem confiada; (2) **UserMessage** com dados estruturados da base de dados

(sujeito, tarefa original) — origem confiada; (3) alternância de `AiMessage/UserMessage` para o historial da sessão; (4) `UserMessage` com o input atual do utilizador — origem não confiada, isolada na sua própria mensagem. A fronteira de *role* da API Mistral garante que o conteúdo de uma `UserMessage` nunca pode alterar o comportamento definido no `SystemMessage`.

Os prompts de geração de tarefas (`TaskGenerationPrompt`) e de análise de dificuldade (`StruggleAnalysisPrompt`) não recebem qualquer input do utilizador final — são alimentados exclusivamente com dados estruturados do domínio, eliminando o vector de injeção nessas chamadas.

## Camada 6 — Sanitização de Output (`AiOutputSanitiser`)

Todo o texto gerado pelo LLM passa pelo `AiOutputSanitiser` antes de ser persistido ou devolvido ao cliente, incluindo a resposta conversacional de explicação; o mecanismo e os pontos de aplicação estão descritos na Secção 4.8.1.

## Resiliência e Observabilidade

A integração com a API Mistral é protegida por *circuit breaker*, *retry* com *backoff* exponencial e *timeout*, com *fail-safe* que repõe o *assignment* em `PENDING` caso a geração falhe irremediavelmente — garantindo que o estudante nunca fica bloqueado. A configuração exacta e as métricas instrumentadas (duração, falhas por tipo, estratégia de reutilização) são detalhadas na Secção 6.2.

## 4.6 RAG — Retrieval-Augmented Generation

O Play4Change implementa um padrão RAG que difere do RAG documental clássico: em vez de recuperar fragmentos de texto para enriquecer um *prompt* a cada resposta, recupera vectores semânticos previamente computados para tomar decisões de reutilização e injeta contexto pedagógico estruturado nos prompts enviados ao LLM. O sistema mantém duas colecções vectoriais independentes em `pgvector`, executando pesquisa por similaridade cosseno em dois contextos distintos: deduplicação durante a geração de tarefas e branching adaptativo durante a sessão de dificuldade.

### 4.6.1 Armazenamento de Conhecimento

#### Base de Dados Vectorial

O armazenamento persistente de conhecimento assenta em PostgreSQL com a extensão `pgvector`, activada na migração V3. São mantidas duas colecções vectoriais independentes, cada uma com um índice `IVFFLAT` (predicado `WHERE embedding IS NOT NULL`, para que apenas registos com vector calculado entrem no plano de pesquisa): `task_templates.embedding`



`vector(1024)`, que representa semanticamente o par título+descrição de cada tarefa gerada; e `struggle_events.embedding vector(1024)`, que representa o contexto de dificuldade de um aprendente (padrão de erro + descrição da tarefa + domínio), associado à tabela `adaptive_branches` que regista os ramos gerados para reutilização futura (migração V21).

O operador de distância cosseno do pgvector é `<=>`; a similaridade é derivada como  $1 - (\text{embedding} \Leftrightarrow ?::\text{vector})$ , com valores no intervalo  $[0, 1]$ . O modelo de *embedding* é o `MistralAiEmbeddingModel`, que produz vectores de 1024 dimensões.

## Pipeline de Ingestão

O conhecimento é ingerido em quatro fases executadas de forma assíncrona pelo `TaskGenerationOrchestrator` com o estado rastreado na coluna `current_phase` da tabela `topics`, seguindo a mesma máquina de estados já apresentada na Secção 4.2.2.

Antes da fase GENERATION, o `ContentChunker` segmenta o texto extraído em janelas com sobreposição (parâmetros na Tabela 4.9, Secção 4.5), respeitando fronteiras de parágrafo dentro dos últimos 500 caracteres de cada janela.

Por cada tarefa gerada pelo LLM num chunk, o pipeline calcula o embedding do par título+descrição e consulta o índice IVFFLAT antes de persistir: se a similaridade máxima face aos templates existentes no módulo for superior a 0.90, a tarefa é descartada como duplicado semântico. O diagrama de sequência completo deste pipeline, desde a submissão até à activação do tópico, foi já apresentado na Figura 4.2 (Secção 4.2.2).

### 4.6.2 Recuperação e Reinjeção de Contexto

O sistema executa recuperação vectorial em dois contextos distintos: geração de ramos adaptativos (via similaridade entre vectores de dificuldade) e geração de explicações (via joins relacionais, sem pesquisa vectorial).

#### Recuperação de Ramo Adaptativo

Quando um aprendente falha uma tarefa, o `HandleStruggleService` lança assincronamente a geração de um ramo adaptativo. O vector de entrada é construído concatenando `errorPattern`, `taskDescription` e `subjectDomain` (truncado a 8 000 chars), e embebido em 1024 dimensões. A pesquisa vectorial no `PgVectorDeduplicationService.findSimilarStruggle()` ordena os ramos já COMPLETED por distância cosseno ao vector de entrada, excluindo os ramos que o aprendente já viu, e devolve o mais próximo.

A estratégia de reutilização é determinada por dois limiares configuráveis em `application.yml`:

Para PARTIAL REUSE, a proporção de reutilização é calculada por interpolação linear,  $n_{\text{reuse}} = \lfloor n_{\text{total}} \times \frac{\text{sim}-0.65}{0.90-0.65} \rfloor$  — a mesma fórmula e o mesmo mecanismo são também usados na síntese de ramos adaptativos a partir de sessões de dificuldade (Secção 4.5).

Tabela 4.10: Estratégias de reutilização adaptativa por limiar de similaridade

| Similaridade | Estratégia       | Comportamento                                                                                                      |
|--------------|------------------|--------------------------------------------------------------------------------------------------------------------|
| > 0.90       | FULL_REUSE       | Devolver ramo existente sem chamada ao LLM                                                                         |
| [0.65, 0.90] | PARTIAL_REUSE    | Reutilizar $\lfloor n \times \text{normSim} \rfloor$ tarefas; gerar o complemento via Mistral; persistir novo ramo |
| < 0.65       | FRESH_GENERATION | Gerar ramo completo via Mistral; persistir embedding para reutilização futura                                      |

### Assemblagem e Reinjeção de Contexto para Explicações

Quando o aprendente esgota o nível máximo de dificuldade (`MAX_STRUGGLE_DEPTH = 1`), é criada uma sessão de explicação. O `ExplanationService.buildContext()` recupera e assembleia contexto exclusivamente por joins relacionais — sem pesquisa vectorial — construindo o `ExplanationContext` a partir da descrição da tarefa, do objetivo do módulo e do domínio (truncados conforme a Tabela 4.9), do nível de audiência e língua do tópico, do padrão de erro traduzido, e do historial completo de sessões de dificuldade anteriores (profundidade, padrão de erro e títulos das tarefas adaptativas).

Este contexto é injetado no *prompt* de utilizador de `ExplanationPrompt.userExplanation()`, que inclui o historial completo de sessões de dificuldade do aprendente nessa tarefa. Para as respostas conversacionais, a lista tipada de `ChatMessage` (descrita na Secção 4.5.3) isola dados de controlo de conteúdo do utilizador; o ciclo completo de explicação está ilustrado na Figura 4.6 (Secção 4.7.4).

#### 4.6.3 Edição de Conteúdo e Invalidação

A base de conhecimento vectorial pode tornar-se incoerente quando o conteúdo pedagógico é alterado por um administrador. O sistema trata dois tipos de invalidação com estratégias distintas.

##### Edição Pontual de Tarefa

Quando um administrador edita uma `TaskTemplate` (título, descrição, opções, resposta correta), o `AdminTaskService.updateTask()` executa os seguintes passos:

1. **Incremento de versão:** `version = template.version + 1` — o registo é atualizado *in place*.
2. **Embedding não recalculado:** o campo `embedding` mantém o vector da versão anterior. Esta é uma inconsistência deliberadamente aceite — o vector desatualizado apenas afeta a deduplicação em futuras gerações, não a entrega de tarefas ao aprendente.
3. **Invalidação de instâncias:** `taskInstanceRepository.deleteByTaskTemplateId(templateId)` elimina todas as instâncias da versão anterior.

4. **Recriação de instâncias:** `batchInstanceGenerationService.generateAndSave([updated])` recria as instâncias com o novo conteúdo.

### Regeneração Completa de Tópico

A regeneração completa, desencadeada por `POST /admin/topics/{id}/regenerate`, é rejeitada com `Conflict.ConcurrentModification` se o tópico já estiver em `GENERATING`; caso contrário, transita-o de volta a `INGESTION` e reinicia o pipeline de ingestão completo de forma assíncrona. Na fase `ANALYSIS`, antes de criar os novos módulos, o orquestrador executa a invalidação em dois passos: (1) `markAllSuperseded(module.id)` desactiva logicamente todos os templates do módulo (`is_current = FALSE`), preservando o historial para auditoria; (2) `deleteByTopicId(topicId)` elimina o módulo em si, activando uma cascata de deleções físicas sobre `task_templates`, `task_instances`, `struggle_events` e `adaptive_branches`, purgando todos os vectores obsoletos do índice `IVFFLAT`.

A diferença central entre os dois mecanismos é o tratamento dos *embeddings*: a edição pontual aceita um vector desactualizado, enquanto a regeneração completa recalcula todos os vectores de raiz e purga o índice `IVFFLAT` por `CASCADE`.

## 4.7 Geração e Atribuição de Desafios

Esta secção descreve o ciclo de vida completo dos desafios no Play4Change — desde a geração por IA até à entrega ao utilizador, passando pelo percurso adaptativo de remediação (*struggle path*) e pelo modo de tutoria conversacional com IA. Na nomenclatura interna do sistema, os desafios são denominados *tasks* e cada conceito de negócio tem correspondência direta a entidades de domínio bem delimitadas.

### 4.7.1 Geração de Desafios

#### Modelo de Dados

Cada desafio existe em dois níveis de abstracção complementares:

- **TaskTemplate** — definição canónica gerada pelo LLM: `title`, `description`, `hint`, `taskType` (`MULTIPLE_CHOICE`, único valor suportado), `options[4]`, `correctAnswer` (sempre índice 0), `embedding` (vector de 1024 dimensões para deduplicação), `dayIndex`, `poolIndex`, `version`, `isCurrent`.
- **TaskInstance** — variante com distratores alternativos: partilha o `correctAnswer` do template mas oferece `options` diferentes, permitindo que utilizadores distintos recebam a mesma questão conceptual com opções erradas variadas. A relação é 1:N, até `instancesPerTask = 5` instâncias por template.

O facto de o `correctAnswer` ser sempre o índice 0 no template e na instância é uma invariante da geração: o *system prompt* do `TaskGenerationPrompt` instrui explicitamente o LLM a colocar a resposta correta sempre na primeira posição, o que simplifica a lógica de validação e elimina ambiguidade na persistência.

## Pipeline de Geração em Quatro Fases

A geração é um processo *batch* assíncrono, orquestrado pelo `TaskGenerationOrchestrator`, com estado rastreado na coluna `current_phase` pela mesma máquina de estados da Secção 4.2.2.

A fase `ANALYSIS` marca todos os templates existentes como `is_current = FALSE` e cria o novo módulo. Na fase `GENERATION`, por cada *chunk* (32 000 chars, sobreposição 2 000), o `TaskGenerationPrompt` instrui o LLM a gerar tarefas com quatro opções, resposta correta no índice 0, sem sobreposição semântica com tarefas já geradas (verificada via pgvector com limiar  $> 0.90$ ). Na fase `INDEXING`, o `BatchInstanceGenerationService` processa os templates em lotes de 10 e gera até 5 instâncias por template via chamadas LLM adicionais.

O mecanismo de *retry* com *schema reminder* (Secção 4.5) aplica-se a cada *chunk* nesta fase. A falha no primeiro *chunk* aborta a geração (`FAILED`); falhas em *chunks* subsequentes são toleradas, preservando as tarefas já persistidas. A deduplicação por pgvector (Secção 4.6.1) e as seis garantias de qualidade aplicadas a cada questão gerada estão detalhadas na Secção 6.3.6.

### 4.7.2 Atribuição aos Utilizadores

#### Entidades de Atribuição

Dois agregados gerem o estado da aprendizagem por utilizador:

- `Enrollment` — inscrição ativa num módulo: `currentDayIndex`, `status` (`ACTIVE` — `COMPLETED` — `EXPIRED` — `PAUSED`), `totalPointsEarned`, `streakDays`.
- `TaskAssignment` — atribuição concreta: `enrollmentId`, `taskTemplateId`, `taskInstanceId` (variante seleccionada), `optionOrder` (permutação aleatória das opções), `correctAnswerIndex`, `dueAt` (24 horas após `assignedAt`), `status` (`PENDING` — `SUBMITTED` — `LATE`), `wrongAttemptCount`.

#### Fluxo Pull-based

A atribuição de desafios é *pull-based*: o utilizador solicita a tarefa do dia via `GET /tasks/today`, e o serviço resolve quatro casos mutuamente exclusivos, por ordem de precedência: (1) sessão de *struggle* aberta; (2) sessão de explicação ativa; (3) assignment já existente para o `dayIndex` atual; (4) criação de novo assignment.

No caso (4), o sistema selecciona aleatoriamente uma das `TaskInstance` disponíveis (variedade de distratores), gera uma permutação aleatória das quatro opções (`optionOrder`), e define `dueAt = now() + 24h`.

## Permutação das Opções e Penalizações por Atraso

A `optionOrder` é uma lista de índices (ex.: `[2,0,3,1]`) que define a ordem de apresentação no ecrã. A resposta correta, sempre no índice 0 da instância, aparece numa posição aleatória para o utilizador. A resposta submetida é um índice de posição de ecrã; o sistema resolve o índice canónico antes de validar, via `optionOrder[selectedOption]`.

A submissão após `dueAt` é aceite mas penalizada em função do atraso *face ao próprio dueAt* (e não do tempo total desde a atribuição): 100% dos pontos sem atraso, 75% até 24 h, 50% até 72 h, e 25% (mínimo 1 ponto) além disso.

### 4.7.3 Consolidation Path (Struggle Path)

Quando um utilizador responde incorrectamente, o sistema não termina a interação — desencadeia automaticamente uma sessão de remediação adaptativa (*struggle session*). O objetivo é diagnosticar a causa do erro e apresentar três sub-tarefas *scaffolded* que devolvam o utilizador ao nível da tarefa original.

## Classificação do Padrão de Erro

Antes de invocar a IA, o `ErrorPatternClassifier` classifica a falha de forma determinística em três categorias, com base no contexto da submissão:

Tabela 4.11: Padrões de erro classificados pelo `ErrorPatternClassifier`

| Padrão        | Condição                                                                          | Estratégia de remediação            |
|---------------|-----------------------------------------------------------------------------------|-------------------------------------|
| TIME_PRESSURE | Submissão após <code>dueAt</code>                                                 | Tarefas paceadas, passo a passo     |
| READING_ERROR | Opção seleccionada adjacente à correta ( <code> pos_sel - pos_corr  == 1</code> ) | Instruções mais explícitas e claras |
| WRONG_CONCEPT | Qualquer outro caso                                                               | Re-explicação do conceito de raiz   |

## Geração Assíncrona da Sessão

Após classificar o erro, o `TaskService` persiste o resultado e delega ao `HandleStruggleService` via `triggerAsync` — a resposta HTTP é devolvida imediatamente ao utilizador, sem esperar pela geração do ramo adaptativo pelo LLM. Em caso de falha ou *timeout* do LLM, a sessão é marcada como `ABANDONED` e o assignment original é reposto em `PENDING` — o utilizador nunca fica bloqueado.

## Submissão e Resolução das Tarefas Adaptativas

O utilizador acede às três sub-tarefas via `GET /struggle/enrollment/{enrollmentId}`. Cada submissão pode resultar em quatro desfechos, avaliados após a conclusão de todas as tarefas: (1) **ainda não concluídas** — devolver resultado parcial; (2) **todas corretas** — marcar sessão como `RESOLVED` e repor assignment em `PENDING`; (3) **falha, depth < MAX\_STRUGGLE\_DEPTH** — gerar nova sessão de *struggle* encadeada; (4) **falha, depth ≥ MAX\_STRUGGLE\_DEPTH (= 1)** — criar sessão de explicação por IA.

As tarefas adaptativas atribuem zero pontos e não afetam o *streak* — são modo de aprendizagem puro.

#### 4.7.4 Tutoria com IA

Quando o utilizador esgota toda a profundidade de remediação sem sucesso, o sistema ativa o modo de tutoria conversacional com IA. Esta sessão sintetiza o historial completo de erros e oferece uma explicação holística em prosa, seguida de um diálogo de esclarecimento sem limite de turnos.

#### Estados da Sessão de Explicação

A sessão de explicação percorre três estados:

GENERATING → ACTIVE → RESOLVED

A transição **GENERATING** → **ACTIVE** ocorre quando a geração pelo LLM termina com sucesso. Se a geração falhar ou esgotar o *timeout* (60s via `withTimeoutOrNull`), a sessão transita diretamente para **RESOLVED** e o assignment é repostado em **PENDING** (*fail-safe* — o utilizador nunca fica bloqueado). A transição para **RESOLVED** pelo utilizador, via `POST /explanation/{sessionId}/resolve`, também repõe o assignment em **PENDING**, devolvendo-o ao fluxo diário normal.

#### Geração Holística e Diálogo Conversacional

A geração holística é assíncrona (`generationExecutor`), permitindo que o utilizador navegue para o ecrã de explicação enquanto a geração ocorre em *background*, com *polling* até o estado ser **ACTIVE**. O contexto injetado inclui o historial completo de sessões de dificuldade, assemblado por joins relacionais sem pesquisa vectorial (Secção 4.6.2).

Para o diálogo conversacional, cada mensagem é processada com o historial completo, usando a mesma estrutura multi-mensagem tipada descrita na Secção 4.5.3 para isolar o input do utilizador. A Figura 4.6 detalha o fluxo completo desde a criação assíncrona até à resolução.

### 4.8 Segurança da Aplicação

A segurança do Play4Change foi implementada em profundidade (*defense in depth*), com controlos independentes em cada camada da arquitetura: proxy reverso (Nginx), servidor de aplicação (Spring Boot), agente de IA (LangChain4j) e cliente web (React/Vite). As ameaças foram mapeadas com base no OWASP Top 10 (2021); o mapeamento completo entre cada ameaça, o controlo implementado e o risco residual é apresentado na Tabela 4.13 (Secção 4.8.5), evitando duplicar aqui a mesma informação.




Figura 4.6: Tutoria com IA — geração assíncrona, diálogo conversacional e resolução

### 4.8.1 Proteção Contra XSS

A proteção contra *Cross-Site Scripting* opera em três camadas complementares e independentes.

#### Camada 1 — Sanitização de Output de IA

O `AiOutputSanitiser` sanitiza todo o conteúdo gerado pelo modelo Mistral antes de ser persistido, usando `Jsoup.parse(input).text()` para remover elementos HTML, decodificar entidades e descartar o conteúdo de `<script>/<style>`. É aplicado a cada campo `String` do `TaskTemplate` gerado e às respostas conversacionais de explicação — mitigando o vetor de páginas raspadas (*scraped*) que possam conter HTML malicioso e ser reproduzidas

literalmente pelo modelo.

## Camada 2 — Content Security Policy via Nginx

O Nginx aplica uma *Content Security Policy* restritiva em todas as respostas HTTP — `default-src` e `script-src` limitados a `'self'` (sem `unsafe-eval` nem CDNs externos), `style-src` com `'unsafe-inline'` apenas pelo necessário aos estilos gerados pelo Vite/React no *build*, e `frame-ancestors 'none'` contra *clickjacking* — consolidada com os restantes *headers* de segurança na Tabela 4.12 (Secção 4.8.4).

## Camada 3 — React JSX Auto-escaping

O React aplica *escaping* automático de todas as expressões `{expression}` ao renderizar no DOM. Mesmo que a base de dados contivesse HTML residual (falha nas camadas anteriores), o React converteria `<` e `>` em entidades HTML antes da inserção no DOM, eliminando XSS reflexo em componentes bem formados.

### 4.8.2 Rate Limiting por IP

O *rate limiting* é implementado no filtro `RateLimitFilter`, com ordem `HIGHEST_PRECEDENCE` na cadeia de filtros Spring, garantindo que a verificação ocorre antes de qualquer autenticação ou lógica de negócio. O algoritmo utilizado é *token bucket* via `Bucket4j`, com janela de *refill* de 10 minutos. Os *buckets* são mantidos em cache `Caffeine` com TTL de 15 minutos e capacidade máxima de 50 000 entradas. Cada *bucket* é identificado pela chave composta `<<ip>:<path_normalizado>`", isolando os limites por recurso e por origem.

O `IpExtractor` extrai o IP do header `X-Forwarded-For` definido pelo Nginx, mas rejeita endereços privados para prevenir *spoofing* por injeção de header, caindo nesse caso para `remoteAddr`. Os limites concretos por *endpoint* — incluindo quatro regras hoje inoperantes por desalinhamento de padrão de rota, duas delas resíduo da funcionalidade de *Peer Review* entretanto removida — são apresentados e discutidos na Secção 6.2.3 (Tabelas 6.3 e 6.4).

### 4.8.3 Validação e Sanitização de Inputs

A validação de *inputs* é realizada em quatro níveis independentes: **Cliente** (TypeScript, optimização de UX — não controlo de segurança — para email, PDF e URLs); **Servidor** (Jakarta Bean Validation nos DTOs de entrada, `@NotBlank/@Email/@Size`, devolvendo 400 sem chegar à camada de serviço); **Prevenção de SSRF** (`UrlSsrValidator`: esquema HTTPS obrigatório, resolução DNS e rejeição de IPs privados/*loopback/link-local*, detalhado na Secção 4.4.1); e **Limites de Contexto para IA** (`AiContextLimits`, Tabela 4.9, Secção 4.5), aplicados antes de construir os prompts independentemente do tamanho do *input* original.



## 4.8.4 Outros Controlos de Segurança

### Autenticação JWT com Validação de Arranque

O `JwtSecretStartupGuard` valida o segredo JWT no arranque, falhando se tiver menos de 64 caracteres ou for igual ao valor de desenvolvimento por omissão (apenas em perfil `prod`, ver Secção 4.3.3); o `CredentialStartupGuard` verifica analogamente as credenciais de serviços externos. Estes guardas impedem a promoção de configurações de desenvolvimento para produção.

### Rotação de Refresh Token com Detecção de Reutilização

O mecanismo de rotação com família (Secção 4.3) deteta roubo de token: se um token já marcado como `used = true` for apresentado, toda a família é revogada e um evento `SECURITY` é emitido.

### RBAC e CORS Restritivo

O `SecurityConfig` define rotas protegidas por papel (`/admin/**` exige `ROLE_ADMIN`; Swagger restrito a `admin` em produção), validado no `JwtAuthFilter` contra a lista `VALID_ROLES`. O `WebMvcConfig` configura CORS com lista de origens explícita, verificada ao arranque (rejeita *wildcards* e entradas em branco), definidas em produção via `APP_CORS_ALLOWED_ORIGINS`.

### Headers HTTP de Segurança (Nginx)

Tabela 4.12: Headers HTTP de segurança configurados no Nginx (incl. diretivas CSP)

| Header                    | Valor                                                                                                                  | Proteção                                           |
|---------------------------|------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------|
| Strict-Transport-Security | max-age=63072000; includeSubDomains                                                                                    | Força HTTPS por 2 anos, inclui subdomínios         |
| X-Content-Type-Options    | nosniff                                                                                                                | Impede MIME-type sniffing                          |
| X-Frame-Options           | DENY                                                                                                                   | Previne clickjacking                               |
| Referrer-Policy           | strict-origin-when-cross-origin                                                                                        | Limita informação de <i>referrer cross-origin</i>  |
| Content-Security-Policy   | default-src 'self'; style-src 'self' 'unsafe-inline'; img-src 'self' data:; connect-src 'self'; frame-ancestors 'none' | Previne XSS e clickjacking via política de browser |

### Segurança do Scraper

O scraper Playwright opera com *timeout* de navegação de 25 s, *timeout* total de 35 s, e remoção ativa de `<script>`, `<style>`, `<iframe>`, `<nav>`, `<footer>` antes de extrair texto — em complemento ao `UrlSsrValidator` que valida a URL antes de qualquer pedido ao scraper.

## 4.8.5 Análise de Riscos

A análise de riscos foi conduzida segundo a metodologia OWASP Risk Rating: Risco = Probabilidade × Impacto, com escala 1–9 em cada dimensão. A Tabela 4.13 apresenta os dez riscos identificados com o risco residual após aplicação dos controlos.

Os três riscos classificados como **Médio** merecem atenção particular:

Tabela 4.13: Análise de riscos OWASP — probabilidade e impacto residuais (escala 1–9)

| ID  | OWASP | Ameaça                           | Controlo                                 | Prob. | Imp. | Classif. |
|-----|-------|----------------------------------|------------------------------------------|-------|------|----------|
| R01 | A03   | XSS via conteúdo IA              | AiOutputSanitiser + CSP + React          | 1     | 7    | Baixo    |
| R02 | A03   | Prompt Injection                 | Multi-mensagem tipada + AiContextLimits  | 2     | 5    | Médio    |
| R03 | A04   | DoS económico via API de IA      | Rate limiting 10 req/10 min /explanation | 2     | 6    | Médio    |
| R04 | A07   | Roubo de <i>refresh token</i>    | Rotação com família + revogação total    | 2     | 8    | Médio    |
| R05 | A05   | Segredo JWT padrão em produção   | JwtSecretStartupGuard                    | 1     | 9    | Baixo    |
| R06 | A10   | SSRF via URL de ingestão         | UrlSsrifValidator                        | 1     | 8    | Baixo    |
| R07 | A07   | Força bruta em <i>magic-link</i> | Rate limiting 5 req/10 min               | 1     | 6    | Baixo    |
| R08 | A05   | <i>Spoofing</i> de IP no RL      | IpExtractor rejeita privados             | 2     | 5    | Médio    |
| R09 | A01   | Escalada de privilégios          | RBAC + validação de papel no JWT         | 1     | 9    | Baixo    |
| R10 | A05   | CORS wildcard                    | Verificação ao arranque                  | 1     | 6    | Baixo    |

**R02 — Prompt Injection (Médio):** o controlo atual (separação de mensagens + truncagem) mitiga ataques simples, mas o Mistral não garante resistência total a *adversarial inputs* sofisticados; mitigação adicional passaria por *fine-tuning* de *guardrails* ou um modelo com moderação integrada.

**R03 — DoS Económico (Médio):** o *rate limiting* por IP mitiga abuso de um único atacante mas não ataques distribuídos, dado que o custo por chamada ao Mistral não é nulo; mitigação adicional passaria por *throttling* global por *endpoint* e alertas de custo na API.

**R04 — Roubo de Refresh Token (Médio):** A janela de 7 dias representa risco se um token for exfiltrado via XSS (R01, já mitigado) ou comprometimento de armazenamento local. O impacto é limitado pela TTL de 15 minutos do *access token* e pela deteção por família (mecanismo já descrito na Secção 4.3.3).

## Capítulo 5

# Testes e Validação

A validação do Play4Change assenta em quatro camadas complementares: testes unitários que verificam o comportamento isolado do domínio e dos serviços de aplicação, testes de integração que exercitam a camada HTTP em contexto Spring parcial, testes de segurança que confrontam as defesas com os vectores de ataque identificados na análise de risco (§4.8.5), e um questionário de usabilidade aplicado a doze utilizadores reais. Juntas, estas camadas cobrem 49 ficheiros de teste distribuídos pelos módulos *server* e *play4change-web*.

### 5.1 Estratégia de Testes

A estratégia decorre diretamente das decisões de arquitetura do sistema e assenta em três princípios: (1) **isolamento total pelo padrão hexagonal** — todas as dependências externas (repositórios, portas de e-mail, publicadores de eventos, geradores de IA) são interfaces, substituídas em cada teste unitário por duplicados *Mockk*, pelo que os testes de domínio executam em memória pura, na ordem dos microssegundos; (2) **Either<Error, T> como contrato de resultado** — a biblioteca Arrow impõe que cada caso de uso devolva *Either<DomainError, T>* em vez de lançar exceções, e os testes inspeccionam o tipo concreto do erro, tornando os casos de insucesso tão verificáveis como os de sucesso; e (3) **separação clara dos três níveis**, conforme a Tabela 5.1.

Tabela 5.1: Níveis da suite de testes automatizados.

| Nível      | Ferramenta principal  | Contexto Spring      | Dependências externas |
|------------|-----------------------|----------------------|-----------------------|
| Unitário   | JUnit 5 + Mockk       | Nenhum               | Todas em mock         |
| Integração | @WebMvcTest + MockMvc | Parcial (camada web) | Serviços em mock      |
| Segurança  | JUnit 5 + @WebMvcTest | Parcial ou nenhum    | Todas em mock         |

No frontend (React/Vite), os testes de componente e de utilitários utilizam *Vitest* com *React Testing Library*. A Tabela 5.2 resume a dimensão total da suite.

Tabela 5.2: Dimensão da suite de testes por módulo.

| Módulo                                | Ficheiros de teste | Linguagem  | Ferramenta            |
|---------------------------------------|--------------------|------------|-----------------------|
| Servidor — aplicação, domínio e infra | 25                 | Kotlin     | JUnit 5 + Mockk       |
| Servidor — camada web / integração    | 11                 | Kotlin     | @WebMvcTest + MockMvc |
| Frontend — componentes e utilitários  | 13                 | TypeScript | Vitest + RTL          |
| <b>Total</b>                          | <b>49</b>          |            |                       |

## 5.2 Testes Unitários

### 5.2.1 Objetos de Valor — Name

O `Name` é o objeto de valor que representa o nome de perfil de um utilizador, construído pelo método de fábrica `Name.create(raw: String?)`. O `NameValidationTest.kt` (8 testes) cobre nulos, entradas só de espaços, comprimentos fora do intervalo 2–100 e caracteres de controlo, conforme a Tabela 5.3.

Tabela 5.3: Casos de teste do objeto de valor `Name`.

| Caso                          | Entrada                       | Resultado esperado                   |
|-------------------------------|-------------------------------|--------------------------------------|
| Null                          | <code>null</code>             | <code>Result.Failure</code>          |
| Só espaços                    | <code>" "</code>              | <code>Result.Failure</code>          |
| Comprimento 1                 | <code>"A"</code>              | <code>Result.Failure</code>          |
| Comprimento 101               | <code>"A" × 101</code>        | <code>Result.Failure</code>          |
| Caracter de controlo          | <code>"Alice\u0000Bob"</code> | <code>Result.Failure</code>          |
| Comprimento 2 (limite inf.)   | <code>"A1"</code>             | <code>Result.Success</code>          |
| Comprimento 100 (limite sup.) | <code>"A" × 100</code>        | <code>Result.Success</code>          |
| Válido                        | <code>"Alice"</code>          | <code>Result.Success("Alice")</code> |

### 5.2.2 Autenticação — `TokenService` e `MagicLinkService`

O `TokenServiceTest.kt` (2 testes) valida a revogação de família de tokens JWT: quando um token de actualização é revogado, toda a família (`familyId`) é invalidada, protegendo contra reutilização em caso de roubo (ameaça R04, §4.8.5); a revogação de um token inexistente é silenciosa, sem chamadas indevidas. O `MagicLinkServiceTest.kt` (7 testes) cobre o ciclo completo do fluxo *magic link*: o token em claro nunca é guardado na base de dados (apenas o SHA-256); `claimToken` é um `UPDATE ... WHERE used=false` atómico, pelo que um segundo consumo concorrente falha; e a conta é criada automaticamente na primeira verificação bem-sucedida.

### 5.2.3 Baralhagem Anti-fraude e Cadência de Entrega

O `AntiCheatShuffleTest.kt` (5 testes) valida a baralhagem determinística de opções (§4.7.2), usando (`userId`, `taskId`, `enrollmentId`) como semente: o mesmo utilizador vê sempre a

mesma ordem, utilizadores distintos recebem ordens distintas, o índice da resposta correta é sempre mapeado correctamente, e a permutação é uma bijecção.

O `TaskDeliveryRateTest.kt` (6 testes) valida os dois modos de operação e o guarda de arranque, que lança `IllegalStateException` se detetar `devMode=true` com perfil `prod` ativo. O `EnrollmentPrerequisiteGateTest.kt` (6 testes) confirma que o `EnrollmentService` recusa inscrições com pré-requisitos incompletos.

#### 5.2.4 Gestão de Tópicos e Detecção de Ciclos no DAG

O `TopicPrerequisiteServiceTest.kt` (12 testes) valida a detecção de ciclos no grafo de pré-requisitos por pesquisa em profundidade (DFS) — ciclo direto, ciclo transitivo e grafo válido — bem como a rejeição de auto-ciclos e referências a tópicos inexistentes.

O `GenerationPhaseTransitionTest.kt` (9 testes) valida cada transição da máquina de estados `GenerationPhase` (`INGESTION` → `ANALYSIS` → `GENERATION` → `INDEXING` → `ACTIVE`), incluindo a recuperação após falha (`GENERATION` → `FAILED` → `INGESTION`).

#### 5.2.5 Detecção e Escalamento de Dificuldades

O `StruggleDetectionTest.kt` (3 testes) verifica que qualquer resposta errada despoleta imediatamente a criação assíncrona de uma sessão de dificuldade. O `StruggleResolutionTest.kt` (4 testes) valida o ciclo de vida da `StruggleSession`: submissão parcial (`OPEN`), aprovação total (`RESOLVED`) e falha total com `depth ≥ MAX_STRUGGLE_DEPTH` (escalamento para explicação). O `ErrorPatternClassifierTest.kt` (8 testes) valida a classificação por prioridade estrita — `TIME_PRESSURE > READING_ERROR > WRONG_CONCEPT`.

### 5.3 Testes de Integração

Os testes de integração arrancam um contexto Spring parcial (`@WebMvcTest`) e exercitam a camada HTTP completa — serialização JSON, filtros de segurança, validação de *beans* e tratamento de erros — com os serviços de aplicação em mock.

#### 5.3.1 Limitação de Taxa — `RateLimitTest`

O teste de integração mais sofisticado da suite: o contexto inclui o `SecurityConfig` e o `RateLimitService` reais (`Bucket4j`), mas substitui o `TimeMeter` por um `ManualTimeMeter` que avança o relógio programaticamente. Quatro casos são cobertos: limite estrito (5 pedidos → 202; 6.<sup>o</sup> → 429); reset de janela temporal ao avançar 11 minutos; isolamento por IP; e presença do cabeçalho `Retry-After` na resposta 429.

### 5.3.2 Controlo de Acesso ao Swagger

O `SwaggerAccessControlTest.kt`, activado em dois perfis Spring distintos, valida a política de acesso à documentação da API (Tabela 5.4).

Tabela 5.4: Matriz de acesso ao Swagger UI testada por `SwaggerAccessControlTest`.

| Perfil        | Papel  | HTTP esperado     | Verificação                                         |
|---------------|--------|-------------------|-----------------------------------------------------|
| default (dev) | nenhum | não é 401 nem 403 | <code>status != 401 &amp;&amp; status != 403</code> |
| prod          | nenhum | 401               | <code>status().isUnauthorized()</code>              |
| prod          | USER   | 403               | <code>status().isForbidden()</code>                 |
| prod          | ADMIN  | não é 401 nem 403 | <code>status != 401 &amp;&amp; status != 403</code> |

### 5.3.3 Controladores REST

Nove ficheiros `@WebMvcTest` (mais o `RateLimitTest.kt`, §5.3.1) cobrem os endpoints principais, sumariados na Tabela 5.5.

Tabela 5.5: Cobertura dos testes de integração por controlador REST.

| Controlador                                   | Casos testados                                                                              |
|-----------------------------------------------|---------------------------------------------------------------------------------------------|
| <code>AdminTopicPrerequisiteController</code> | GET pré-requisitos, POST com ciclo, POST sem ciclo, grafo de aprendizagem, 404              |
| <code>StruggleController</code>               | GET sessão ativa, submissão de tarefa adaptativa, autenticação obrigatória                  |
| <code>TaskReportController</code>             | Criar relatório, correcção pelo admin, dismissal, listagem por tópico                       |
| <code>UserPreferencesController</code>        | Língua (BCP 47) e fuso horário (ZoneId) — válidos e inválidos                               |
| <code>UserProfileController</code>            | GET perfil, PATCH com nome válido e inválido                                                |
| <code>BadgeController</code>                  | Crachás do utilizador, estatísticas de admin                                                |
| <code>AdminTaskController</code>              | Estatísticas de tarefa, tarefas com dificuldade, actualização em lote                       |
| <code>TopicController</code>                  | Campo <code>currentPhase</code> no GET de admin, conteúdo do <code>generationLog</code>     |
| <code>SwaggerAccessControlTest</code>         | Acesso sem autenticação em perfil padrão; 401/403/200 em perfil <code>prod</code> por papel |
| <code>AuthControllerValidationTest</code>     | Formato de e-mail, token de verificação inválido                                            |

### 5.3.4 Frontend — Vitest + React Testing Library

Treze ficheiros de teste cobrem componentes, *hooks*, adaptadores de dados e utilitários de validação (Tabela 5.6).

Tabela 5.6: Ficheiros de teste do frontend (Vitest + RTL).

| Ficheiro                              | O que valida                                                                             |
|---------------------------------------|------------------------------------------------------------------------------------------|
| <code>ProtectedRoute.test.tsx</code>  | Redirecionamento de utilizadores não autenticados para <code>/login</code>               |
| <code>validators.test.ts</code>       | Formato de e-mail, URL, lista de URLs (1–5), ficheiro PDF (tipo + tamanho $\leq 100$ MB) |
| <code>useTopics.test.ts</code>        | Estado de carregamento, erro e dados do hook <code>useTopics</code>                      |
| <code>mockTopicAdapter.test.ts</code> | Fidelidade dos adaptadores de dados em mock                                              |
| <code>LoginPage.test.tsx</code>       | Submissão de formulário, mensagens de erro                                               |
| <code>AuthVerifyPage.test.tsx</code>  | Verificação de token da URL, estados de carregamento                                     |
| <code>CreateTopicPage.test.tsx</code> | Validação de formulário, submissão com sucesso                                           |
| <code>UserList.test.tsx</code>        | Renderização de lista, filtros                                                           |
| <code>PromoteUser.test.tsx</code>     | Confirmação de promoção, feedback visual                                                 |
| <code>BadgeOverview.test.tsx</code>   | Renderização de crachás e contagens                                                      |
| <code>ReportList.test.tsx</code>      | Listagem, filtro por estado                                                              |
| <code>ReportDetail.test.tsx</code>    | Detalhe de relatório, ações de admin                                                     |
| <code>formatters.test.ts</code>       | Formatação de datas, pontos e níveis de audiência                                        |

## 5.4 Testes de Segurança

Os testes de segurança validam as defesas contra as ameaças identificadas na análise de risco (§4.8.5).

### 5.4.1 Prevenção de SSRF — `UrlSsrValidatorTest`

O vector SSRF é crítico porque os administradores submetem URLs de conteúdo que a aplicação vai buscar para gerar tarefas com IA (§4.4). O `UrlSsrValidatorTest.kt` (10 testes) valida que `UrlSsrValidator.validate()` lança `UrlSsrViolationException` para cada categoria de URL proibida (Tabela 5.7).

Tabela 5.7: Casos de teste de prevenção de SSRF — `UrlSsrValidatorTest`.

| URL testada                                                                        | Categoria                    | Resultado                             |
|------------------------------------------------------------------------------------|------------------------------|---------------------------------------|
| <code>https://localhost/admin</code> , <code>127.0.0.1</code> , <code>[::1]</code> | Loopback (IPv4/IPv6)         | <code>UrlSsrViolationException</code> |
| <code>192.168.1.1</code> , <code>10.0.0.1</code> , <code>172.16.0.1</code>         | RFC 1918 (redes privadas)    | <code>UrlSsrViolationException</code> |
| <code>https://169.254.1.1/metadata</code>                                          | Link-local                   | <code>UrlSsrViolationException</code> |
| <code>http://example.com/page</code>                                               | Esquema HTTP (não HTTPS)     | <code>UrlSsrViolationException</code> |
| <code>https://nonexistent.tld.invalid</code>                                       | Host inexistente (DNS falha) | <code>UrlSsrViolationException</code> |
| <code>https://1.1.1.1/</code>                                                      | IP público conhecido         | Sem exceção                           |

### 5.4.2 Sanitização de Output IA — `AiOutputSanitiserTest`

O `AiOutputSanitiserTest.kt` (5 testes) valida que `AiOutputSanitiser.sanitise()` remove tags, scripts e entidades HTML que o Mistral possa gerar sob condições adversariais (§4.8.1).

### 5.4.3 Força Bruta e Magic Link

A proteção contra força bruta no *endpoint* `/auth/magic-link` e as propriedades de segurança do fluxo *magic link* já foram cobertas em §5.3.1 e §5.2.2, respetivamente; não se repetem aqui.

### 5.4.4 Anti-fraude e Guarda de Arranque

Dois mecanismos de segurança de negócio complementam os testes de rede: a baralhagem determinística (§5.2.3), que impede que estudantes partilhem a ordem de opções correta entre si, e o `TaskDeliveryStartupGuard`, que impede que uma cadência de desenvolvimento seja activada em produção.

## 5.5 Testes de Usabilidade

### 5.5.1 Metodologia

A avaliação de usabilidade foi conduzida através de um questionário Google Forms aplicado a 12 participantes entre 8 e 12 de Junho de 2026 (4 estudantes actuais do ISEL, 7 testadores externos, 1 antigo aluno), organizado em quatro secções: avaliação global (escala 1–5), quatro declarações de envolvimento (Likert 1–5), a escala SUS (*System Usability Scale*) de Brooke [36] (10 itens, Likert 1–5), e questões abertas.

### 5.5.2 Análise SUS

A pontuação SUS segue a fórmula de Brooke: subtrai-se 1 aos itens ímpares (positivos) e o valor a 5 nos pares (negativos), soma-se os 10 resultados e multiplica-se por 2,5, numa escala de 0 a 100. A Tabela 5.8 apresenta as pontuações e a Figura 5.1 a distribuição.

Tabela 5.8: Pontuações SUS por participante ( $n = 12$ ).

| Part.          | Perfil    | Classificação | SUS         |
|----------------|-----------|---------------|-------------|
| P01            | Estudante | Bom           | 80,0        |
| P02            | Estudante | Excelente     | 97,5        |
| P03            | Externo   | Excelente     | 90,0        |
| P04            | Externo   | Não aceitável | 45,0        |
| P05            | Alumni    | Não aceitável | 35,0        |
| P06            | Externo   | Marginal      | 50,0        |
| P07            | Externo   | Bom           | 77,5        |
| P08            | Externo   | Excelente     | 95,0        |
| P09            | Estudante | Marginal      | 60,0        |
| P10            | Externo   | Excelente     | 97,5        |
| P11            | Externo   | Excelente     | 92,5        |
| P12            | Estudante | Excelente     | 92,5        |
| <b>Média</b>   |           |               | <b>76,0</b> |
| <b>Mediana</b> |           |               | <b>85,0</b> |

A média de 76,0 situa-se na categoria *Bom* (70–85); a mediana de 85,0 marca a fronteira com *Excelente*. A discrepância reflecte dois *outliers* ( $P04 = 45$ ,  $P05 = 35$ ) que puxam a média para baixo — sem eles, a média sobe para 83,25. Seis participantes (50%) obtiveram *Excelente*, dois *Bom*, dois *Marginal* e dois *Não aceitável*. A avaliação global obteve uma média de 4,25 em 5.

As declarações de envolvimento (Tabela 5.9) mostram o design visual como a mais bem pontuada (4,33) e o encorajamento a regressar diariamente como a mais baixa (3,92), sugerindo margem de melhoria na retenção.






Figura 5.1: Distribuição das pontuações SUS por participante ( $n = 12$ ). A linha tracejada indica a média (76,0). As bandas de cor distinguem as quatro categorias: Excelente ( $\geq 85$ ), Bom (70–85), Marginal (50–70) e Não aceitável ( $< 50$ ).

Tabela 5.9: Médias das declarações de envolvimento (escala Likert 1–5,  $n = 12$ ).

| Declaração                                                                     | Média |
|--------------------------------------------------------------------------------|-------|
| A aplicação motivou-me a aprender sobre educação cívica / cidades inteligentes | 3,83  |
| Os desafios pareceram relevantes para problemas do mundo real                  | 4,00  |
| O design visual e a estética do jogo foram apelativos                          | 4,33  |
| Senti-me encorajado/a a regressar e completar desafios diariamente             | 3,92  |
| Os caminhos de aprendizagem IA adaptaram-se eficazmente ao meu desempenho      | 4,08  |

### 5.5.3 Análise Qualitativa

As respostas abertas revelaram pontos fortes e oportunidades de melhoria consistentes.

**Pontos fortes.** A explicação adaptativa após resposta errada foi apontada como melhor funcionalidade por quatro participantes; a intuitividade da interface por outros quatro; e a adaptabilidade da IA ao desempenho individual por três. Os desafios diários e a relevância das questões foram igualmente referidos positivamente.

**Problemas técnicos.** A mais grave foi uma *race condition* visual no caminho de consolidação: a resposta era marcada correta e, meio segundo depois, aparecia como errada. Foram também reportados a barra de pesquisa oculta durante a inserção de e-mail, respostas corretas marcadas intermitentemente como erradas, e questões repetidas em caminhos alternativos. Os dois participantes com pontuações mais baixas (P04, P05) apontaram ainda a confusão causada pela transição abrupta para um novo desafio após resposta errada, sem explicação — comportamento que ocorre antes de a sessão de *struggle* ser criada.

**Perfis de afinidade tecnológica.** A observação direta revelou uma segunda linha de segmentação, além do vínculo institucional (Tabela 5.8): P04 e P05, os dois *outliers*

negativos, pertencem a um perfil de utilização tecnológica mínima, sugerindo que a sua pontuação reflecte não só o bug de transição identificado acima, mas também uma dificuldade de base com aprendizagem digital autónoma — precisamente o perfil que mais beneficiaria do Play4Change (retomada em §7.5).

**Sugestões de melhoria.** As mais recorrentes foram funcionalidades sociais (amigos, tabelas de classificação), diversificação de tópicos, maior concisão das explicações IA em mobile, e personalização geográfica das questões por localização.

**Conclusão da avaliação.** Os resultados SUS indicam usabilidade global *Bom*, com a maioria dos participantes a classificar o sistema como *Excelente*. Os dois *outliers* convergem num problema de comunicação de estado após erro, mitigável com uma transição animada, mas reflectem também uma barreira de entrada mais alta para o perfil de menor afinidade tecnológica.

# Capítulo 6

## Resultados

Este capítulo apresenta os resultados concretos do projeto Play4Change em três dimensões complementares: a demonstração dos fluxos funcionais do sistema; as métricas de desempenho e a infraestrutura de observabilidade instrumentada; e os mecanismos que garantem a qualidade pedagógica e a segurança das questões geradas por inteligência artificial.

### 6.1 Demonstração do Sistema

O Play4Change é composto por três interfaces: a aplicação móvel (Kotlin Multiplatform + Compose Multiplatform para Android e iOS), o painel de administração web (React 18 + Vite + TypeScript) e o servidor REST (Spring Boot 3.2, Kotlin, JVM 21). A infraestrutura é orquestrada por Docker Compose com oito serviços: PostgreSQL 16 com pgvector, MinIO, Playwright Scraper, Unstructured.io, Spring Boot, Nginx, Prometheus e Grafana; o módulo de IA (LangChain4j + Mistral) é invocado como API externa, sem contentor próprio.

Os mecanismos internos de cada fluxo — autenticação por *magic link*, geração assíncrona de tópicos, atribuição de tarefas, remediação adaptativa e tutoria com IA — estão descritos em detalhe no Capítulo 4 e não se repetem aqui. Esta secção regista, em vez disso, a evidência de que cada objetivo operacional (Capítulo 1) está de facto concretizado no sistema implementado; para uma demonstração passo a passo do sistema em funcionamento, ver o guia de execução entregue em separado.

A Tabela 6.1 mapeia cada objetivo à evidência que o sustenta.

Tabela 6.1: Evidência de concretização dos objetivos operacionais

| Objetivo                                  | Requisitos cobertos         | Evidência                                              |
|-------------------------------------------|-----------------------------|--------------------------------------------------------|
| OBJ-1 — Plataforma adaptativa DigComp 2.2 | RF01, RF08, RF09, RF11–RF13 | Figuras 6.1 e 6.3; avaliação SUS (§5.5)                |
| OBJ-2 — Pipeline de geração por IA        | RF02–RF07                   | Figura 6.3; pipeline e RAG detalhados em §4.2.2 e §4.6 |
| OBJ-3 — Remediação adaptativa             | RF10                        | Figura 6.2; mecanismo em §4.7.3                        |
| OBJ-4 — Tutoria conversacional com IA     | RF09, RF10                  | Figura 6.2; mecanismo em §4.7.4                        |
| OBJ-5 — Segurança e qualidade do conteúdo | RNF01–RNF04                 | Tabela 4.13; suite de testes (Capítulo 5)              |

As Figuras 6.1 a 6.3 documentam os três pontos do sistema mais difíceis de validar sem

uma execução real — o ciclo de desafio e *feedback*, a remediação adaptativa e a tutoria com IA, e o pipeline de geração assíncrona do lado do Administrador — e não as operações de CRUD simples (autenticação, listagens, formulários), cujo funcionamento se dá como estabelecido pela suite de testes do Capítulo 5.

*[Inserir aqui screenshot: ecrã do desafio diário no cliente móvel, com o feedback imediato da IA após submissão da resposta]*

Figura 6.1: Desafio diário e *feedback* imediato da IA (RF08, RF09)

*[Inserir aqui screenshot: sessão de remediação adaptativa (struggle) ou diálogo de tutoria com IA no cliente móvel]*

Figura 6.2: Remediação adaptativa e tutoria conversacional com IA (RF10)

*[Inserir aqui screenshot: painel de administração a meio da criação de um tópico, com o progresso da pipeline (SSE) visível — fase INGESTION ou GENERATION]*

Figura 6.3: Criação de tópico com progresso assíncrono em tempo real (RF02–RF07)

## 6.2 Métricas de Desempenho

### 6.2.1 Arquitetura de Observabilidade

O sistema implementa uma pilha de observabilidade alinhada com três pilares — métricas, logs estruturados e alertas. As métricas são expostas pelo Spring Boot Actuator em `/actuator/prometheus` e recolhidas de 5 em 5 segundos pelo Prometheus (retenção de 7 dias), com avaliação das

regras de alerta a cada 15 segundos e consulta via PromQL no Grafana, com dashboards provisionados automaticamente.

## 6.2.2 Métricas Instrumentadas

O sistema instrumenta dezoito métricas com Micrometer, cobrindo as camadas HTTP, IA, aprendizagem e segurança (Tabela 6.2).

Tabela 6.2: Catálogo de métricas instrumentadas com Micrometer.

| Métrica                             | Tipo    | Tags                                        | Descrição                                       |
|-------------------------------------|---------|---------------------------------------------|-------------------------------------------------|
| http.server.requests.seconds        | Timer   | uri, method, status                         | Latência e throughput HTTP (Spring MVC auto)    |
| task.generation.duration            | Timer   | status (success/failed/timeout)             | Duração total da pipeline de geração por tópico |
| ai.generation.duration              | Timer   | generation.phase (GENERATION/ANALYSIS)      | Tempo de chamada ao Mistral por fase            |
| ai.generation.failures              | Counter | type                                        | Falhas de geração por categoria                 |
| ai.adaptive.reuse                   | Counter | strategy (full/partial/fresh)               | Distribuição de estratégias de reutilização     |
| ai.dedup.duplicates.skipped         | Counter | module_id                                   | Tarefas descartadas por deduplicação semântica  |
| ai.struggle.reuse.strategy          | Counter | strategy                                    | Estratégia de reuso no pgvector por ocorrência  |
| struggle.sessions.total             | Counter | error_pattern                               | Sessões de dificuldade por padrão de erro       |
| explanation.sessions.created.total  | Counter | —                                           | Total de sessões de explicação criadas          |
| explanation.sessions.resolved.total | Counter | outcome                                     | Resultado das sessões de explicação             |
| task.submissions.total              | Counter | outcome (correct/incorrect/late), task_type | Submissões por resultado e tipo de tarefa       |
| enrollments.completed.total         | Counter | topic_id                                    | Inscrições concluídas por tópico                |
| rate_limit.exceeded.total           | Counter | path                                        | Bloqueios por limite de taxa por caminho de API |
| executor.queued.tasks               | Gauge   | name=generationExecutor                     | Tarefas na fila do thread pool de geração       |
| jvm.memory.used.bytes               | Gauge   | area=heap/nonheap                           | Utilização de memória JVM                       |
| resilience4j.circuitbreaker.state   | Gauge   | name=aiAgent, state                         | Estado do circuit breaker de IA (aiAgent)       |

## 6.2.3 Limitação de Taxa por Caminho

O limitador de taxa (§4.8.2) usa *token bucket* (Bucket4j) com cache Caffeine (expiração de 15 min, 50.000 entradas), com granularidade por IP e caminho normalizado. A Tabela 6.3 apresenta a configuração ativa; a auditoria deste capítulo identificou também duas regras (Tabela 6.4) configuradas contra padrões de rota que não correspondem a nenhum *endpoint* real, pelo que nunca são accionadas.

Tabela 6.3: Limites de taxa efetivamente ativos por caminho de API (janela de 10 minutos por IP).

| Caminho                            | Limite | Justificação                                          |
|------------------------------------|--------|-------------------------------------------------------|
| POST /auth/magic-link              | 5      | Previne enumeração de e-mails e spam de tokens        |
| POST /auth/magic-link/verify       | 10     | Previne força bruta sobre tokens de 15 minutos        |
| POST /auth/refresh                 | 20     | Rotação de tokens em sessões ativas                   |
| POST /explanation/{id}/message     | 10     | Cada mensagem invoca a API Mistral (custo económico)  |
| POST /admin/topics                 | 3      | Criação de tópico desencadeia pipeline de IA completa |
| POST /admin/topics/pdf             | 2      | Upload de PDF + pipeline + Unstructured.io            |
| POST /admin/topics/{id}/regenerate | 2      | Regeneração consome créditos Mistral API              |

Os dois *endpoints* atingidos são, precisamente, os de maior frequência de utilização em toda a aplicação — a submissão da resposta à tarefa diária e a submissão de uma sub-tarefa de *struggle* — hoje acedidos sem qualquer limite de taxa, apesar do comentário no próprio `RateLimitService.kt` indicar a intenção contrária.

Tabela 6.4: Regras de *rate limiting* configuradas mas nunca accionadas — o padrão de rota não corresponde a nenhum *endpoint* real.

| Padrão configurado                        | Limite | Endpoint real (sem limite)                |
|-------------------------------------------|--------|-------------------------------------------|
| /topics/{id}/task-assignments/{id}/submit | 30     | POST /tasks/{assignmentId}/submit         |
| /enrollments/{id}/struggle/{id}/submit    | 30     | POST /struggle/{sessionId}/tasks/{taskId} |

### 6.2.4 Pool de Threads de Geração e Circuit Breaker

A configuração do *thread pool* de geração e do *circuit breaker* Resilience4j está descrita na Secção 4.5.3; ambos são instrumentados pelas métricas `executor_queued_tasks` e `resilience4j_circuitbreaker_state` (Tabela 6.2), com o correspondente alerta `AiCircuitBreakerOpen` (Tabela 6.5).

### 6.2.5 Regras de Alerta Prometheus

O sistema define oito alertas com avaliação a cada 15 segundos, em quatro grupos temáticos e duas severidades (Tabela 6.5).

Tabela 6.5: Regras de alerta Prometheus configuradas (*evaluation\_interval*: 15s).

| Alerta                             | Expressão PromQL (simplificada)                                   | Limiar             | Duração  | Sev.    |
|------------------------------------|-------------------------------------------------------------------|--------------------|----------|---------|
| ServerDown                         | <code>up{job="spring-boot"} == 0</code>                           | —                  | 1 min    | Crítico |
| AiCircuitBreakerOpen               | <code>resilience4j_circuitbreaker_state{state="open"} == 1</code> | —                  | Imediato | Crítico |
| JvmHeapUsageCritical               | <code>jvm_memory_used / jvm_memory_max</code>                     | $\geq 95\%$        | 2 min    | Crítico |
| HighHttpRequestRate                | <code>rate(http_5xx[5m]) / rate(http_all[5m])</code>              | $\geq 5\%$         | 2 min    | Aviso   |
| HighAiGenerationFailureRate        | <code>rate(ai_generation_failures_total[10m])</code>              | $\geq 0,1/s$       | 5 min    | Aviso   |
| AiGenerationP95High                | <code>histogram_quantile(0.95, task_generation[10m])</code>       | $\geq 90\text{ s}$ | 5 min    | Aviso   |
| JvmHeapUsageHigh                   | <code>jvm_memory_used / jvm_memory_max</code>                     | $\geq 85\%$        | 5 min    | Aviso   |
| GenerationThreadPoolQueueSaturated | <code>executor_queued_tasks{name="generationExecutor"}</code>     | $\geq 20$          | 2 min    | Aviso   |

## 6.3 Qualidade das Questões Geradas

A qualidade das questões geradas é garantida por seis mecanismos complementares que actuam em camadas sucessivas, assegurando que apenas questões válidas, distintas e seguras chegam ao utilizador.

### 6.3.1 Engenharia de Prompts e Reutilização Adaptativa

O sistema implementa três templates de prompt com propósitos distintos, em que a separação entre `SystemMessage` (instrução) e `UserMessage` (dados) é explícita e tipada, cumprindo o princípio de prevenção de injeção de prompt (§4.8.1).

O contributo mais original do sistema, do ponto de vista da eficiência de custos de API, é a reutilização de ramos adaptativos: em vez de gerar um novo ramo para cada utilizador que falha, o sistema pesquisa a base de dados vectorial por contextos semanticamente semelhantes (pgvector IVFFlat, similaridade coseno), decidindo entre três estratégias por limiar de similaridade (Tabela 4.10, Secção 4.6.2 do Capítulo 4).

O prompt de geração de tarefas do percurso principal instrui o modelo a produzir 4 opções com a resposta correta sempre no índice 0 (baralhado antes de exibir), a limitar cada tarefa a 5–15 minutos, e a garantir progressão lógica; quando o número de tarefas válidas é inferior ao pedido, um *schema reminder* é injetado e o modelo é invocado uma segunda vez.

### 6.3.2 Deduplicação Semântica com pgvector

A deduplicação semântica (§4.6.1) previne que o mesmo conceito seja ensinado duas vezes no mesmo módulo. Usa o operador de distância cosseno  $\leq$  do pgvector (IVFFlat): se a similaridade do *embedding* de uma nova tarefa face a uma existente ultrapassar 0,90, a tarefa é descartada e o contador `ai.dedup.duplicates_skipped` é incrementado.

### 6.3.3 Classificação de Padrões de Erro

O `ErrorPatternClassifier` (§4.7.3) aplica três regras com prioridade estrita: `TIME_PRESSURE` (submissão após `dueAt`), `READING_ERROR` ( $|\text{diff}| \leq 1$ ) e `WRONG_CONCEPT` (por omissão). Estes três valores são traduzidos, antes de alimentar o prompt do ramo adaptativo, para um *enum* maior de seis valores usado do lado da IA (Secção 4.5.2), mapeado para instruções pedagógicas específicas (Tabela 6.6).

Tabela 6.6: Mapeamento de padrões de erro para estratégias pedagógicas de geração.

| Padrão detetado             | Diagnóstico pedagógico           | Instrução ao modelo           |
|-----------------------------|----------------------------------|-------------------------------|
| CONCEPTUAL_MISUNDERSTANDING | Não compreende o conceito base   | Re-explicar o conceito de for |
| PROCEDURAL_ERROR            | Aplica passos errados            | Focar no procedimento e nos   |
| KNOWLEDGE_GAP               | Falta conhecimento pré-requisito | Preencher a lacuna antes de   |
| UNCLEAR_INSTRUCTIONS        | Instrução da tarefa confusa      | Fornecer orientação mais cla  |
| TIME_PRESSURE               | Erros por precipitação           | Subtarefas de prática com ri  |
| UNKNOWN                     | Causa indeterminada              | Scaffolding geral de básico a |

### 6.3.4 Chunking de Conteúdo para Documentos Extensos

Para tópicos com mais de 32.000 caracteres, o `ContentChunker` divide o texto em blocos com sobreposição de 2.000 caracteres, preservando fronteiras de parágrafo. A geração é executada chunk a chunk; se um chunk intermédio falhar, o sistema degrada graciosamente, preservando as tarefas acumuladas — apenas o chunk 0 é crítico, e a sua falha produz `FAILED` sem recuperação.

### 6.3.5 Sanitização de Saída da IA

Toda a saída de texto gerada pela IA é sanitizada com `Jsoup.parse(input).text()` antes de ser persistida ou devolvida ao cliente, removendo tags HTML, decodificando entidades e normalizando espaços (§4.8.1). Os campos cobertos incluem `title`, `description`, `hint`,

`options[]` e `explanationText`; esta defesa actua na camada de serviço (OWASP A03:2021) e é complementada pelo CSP Nginx e pelo auto-escaping do React JSX.

### 6.3.6 Garantias de Qualidade das Questões

O sistema fornece seis garantias estruturais para cada questão gerada:

1. **Unicidade semântica:** similaridade coseno  $< 0,90$  com qualquer tarefa existente no mesmo módulo (pgvector IVFFlat).
2. **Formato válido:** exactamente 4 opções, resposta correta persistida no índice 0 (baralhada antes de exibir).
3. **Língua correta:** o prompt instrui o modelo a gerar exclusivamente na língua configurada, com *gating* de idioma no `DayIndexCalculator`.
4. **Adequação ao nível:** o prompt inclui descrição expandida do nível de audiência (*Beginner*, *Intermediate*, *Advanced*).
5. **Segurança:** sanitização Jsoup em todos os campos de texto; input do utilizador nunca interpolado em strings de prompt.
6. **Resiliência a falhas do modelo:** *schema reminder* automático, abandono gracioso se o resultado final for zero tarefas válidas, e circuit breaker contra cascata de falhas.



## Capítulo 7

# Discussão

Este capítulo analisa criticamente os resultados obtidos, confrontando-os com os objetivos propostos, identificando as decisões técnicas mais bem-sucedidas, reconhecendo as limitações encontradas, posicionando o trabalho face ao estado da arte e traçando direções para trabalho futuro.

### 7.1 Análise dos Resultados face aos Objetivos

O projeto foi orientado por cinco objetivos operacionais, cuja concretização se analisa de seguida.

**OBJ-1 — Plataforma de aprendizagem adaptativa alinhada com o DigComp 2.2.**

O sistema implementa todos os elementos estruturantes de uma plataforma adaptativa: inscrição com gating de pré-requisitos, entrega de tarefas por calendário, percurso de dificuldade com ramos de remediação, e escalamento para tutoria IA. O alinhamento com o DigComp 2.2 é assegurado ao nível dos tópicos, curados pelos administradores a partir de fontes documentais alinhadas com as áreas de competência da framework. A avaliação de usabilidade (§5.5) confirmou que 66,7% dos participantes classificaram a aplicação na categoria SUS *Bom* ou *Excelente*, com mediana de 85,0.

**OBJ-2 — Pipeline de geração de conteúdo por IA a partir de fontes arbitrárias.**

O pipeline (§4.6) funciona de ponta a ponta — *ingestion*, *chunking*, geração por Mistral com *schema reminder*, e deduplicação semântica — e é robusto a falhas intermediárias: degradação graciosa por chunk e circuit breaker Resilience4j (§6.2.4). O objetivo foi atingido com seis garantias de qualidade verificáveis (§6.3.6).

**OBJ-3 — Remediação adaptativa personalizada por padrão de erro.** O `ErrorPatternClassifier` classifica cada resposta errada em três padrões e injeta esse diagnóstico no prompt do ramo adaptativo (§4.7.3); a reutilização semântica de ramos (§4.6.2) acrescenta eficiência económica ao evitar invocações desnecessárias do modelo. O objetivo foi atingido; a limitação identificada é a profundidade máxima de *struggle* (`MAX_STRUGGLE_DEPTH = 1`).

**OBJ-4 — Tutoria conversacional com IA como escalamento da remediação.**

A `ExplanationSession` (§4.7.4) implementa um ciclo completo — geração assíncrona com contexto relacional, diálogo multi-turno e resolução com retorno ao fluxo principal — com injeção de cabeçalho de contexto para prevenir injeção de prompt. O objetivo foi atingido; a avaliação qualitativa (§5.5.3) confirmou que esta foi a funcionalidade mais valorizada.

**OBJ-5 — Segurança e qualidade do conteúdo gerado numa aplicação web multi-utilizador.** A análise de risco OWASP (§4.8.5) identificou dez ameaças, com os três riscos residuais de nível Médio mitigados por controlos implementados; a suite de segurança (§5.4) valida SSRF, XSS, magic link e controlo de acesso ao Swagger. O objetivo foi atingido para o perfil de ameaças identificado.

## 7.2 O que Correu Bem

**Arquitetura hexagonal como base de testabilidade.** Modelar todas as dependências externas como interfaces revelou-se a decisão mais impactante do projeto: permitiu uma suite de 49 ficheiros de teste em que os unitários executam em memória pura, em microssegundos. O contrato `Either<DomainError, T>` da Arrow tornou os casos de insucesso tão explícitos e verificáveis como os de sucesso.

**Reutilização semântica de ramos adaptativos.** O mecanismo de três estratégias (`FULL_REUSE`, `PARTIAL_REUSE`, `FRESH_GENERATION`) por similaridade coseno pg-vector é o contributo técnico mais original do sistema: servir um ramo sem qualquer chamada ao modelo (`FULL_REUSE`, similaridade > 0,90) reduz os custos de API de forma estrutural à medida que a base de ramos cresce — uma melhoria contínua sem custo marginal crescente, valiosa para uma plataforma em escala.

**Resiliência por design no pipeline de geração.** A combinação de circuit breaker, degradação graciosa por chunk, *schema reminder* automático e *fail-safe* na `ExplanationSession` tornou o sistema tolerante a falhas intermitentes da API externa sem expor o utilizador a erros, com visibilidade operacional imediata via alerta `AiCircuitBreakerOpen`.

**Autenticação sem senha com garantias de segurança formais.** O fluxo *magic link* eliminou a complexidade de gestão de passwords e é mais seguro para utilizadores não técnicos; hashing SHA-256, consumo atómico e rotação de família de tokens cobrem as ameaças mais relevantes do modelo de autenticação (§4.3).

**Rate limiting com teste determinístico.** A substituição do `TimeMeter` por `ManualTimeMeter` nos testes de integração (§5.3.1) permitiu verificar limites e resets de janela sem dependência de tempo de parede, tornando os testes 100% determinísticos — uma técnica diretamente transferível a qualquer componente sensível ao tempo.

## 7.3 Limitações e Dificuldades

**Conformidade de schema do modelo de linguagem.** O Mistral não garante que a resposta JSON respeite sempre o schema pedido. O *schema reminder* mitiga o problema com uma segunda invocação, mas não elimina a possibilidade de falha persistente; sem dados de produção em escala não é possível quantificar a taxa de ocorrência real.

**Profundidade máxima de struggle.** `MAX_STRUGGLE_DEPTH = 1` significa que após um único ramo falhado o sistema escala imediatamente para explicação. Numa plataforma com tópicos de nível avançado, uma profundidade maior poderia ser pedagogicamente mais adequada; a constante é configurável apenas por código, dificultando a experimentação.

**Bugs de interface identificados na avaliação.** A avaliação (§5.5.3) identificou uma *race condition* visual no caminho de consolidação, responsável pelas duas pontuações SUS mais baixas ( $P04 = 45$ ,  $P05 = 35$ ), além da barra de pesquisa oculta durante a inserção de e-mail e inconsistência de idioma nos conteúdos — problemas que afetam a percepção de qualidade de forma desproporcionada à sua complexidade técnica de resolução.

**Ausência de métricas de produção em escala.** O sistema instrumenta 18 métricas e oito alertas (§6.2), mas a avaliação foi conduzida com 12 participantes num ambiente controlado; latências reais, distribuição de estratégias de reutilização e taxa de deduplicação efetiva sob carga real permanecem por medir.

**Dependência de fornecedor de IA único.** O sistema está acoplado ao Mistral AI. A abstracção LangChain4j isola o código de negócio da implementação concreta, mas os prompts estão calibrados ao comportamento específico do Mistral; uma migração exigiria recalibração e re-embedding de todos os vectores existentes.

**Validação pedagógica do alinhamento DigComp 2.2.** O alinhamento é garantido pela curação humana dos tópicos, mas não é validado automaticamente pela IA — não existe verificação de que uma tarefa gerada testa efetivamente a competência DigComp 2.2 pretendida, e não apenas conhecimento genérico.

## 7.4 Comparação com o Estado da Arte

O Play4Change insere-se no cruzamento de três linhas de trabalho revistas no Capítulo 2: plataformas gamificadas, sistemas de tutoria inteligente (ITS) e geração de conteúdo educativo por LLM.

**Face a plataformas gamificadas estabelecidas.** O Duolingo usa repetição espaçada e um currículo pré-construído por especialistas humanos; o Play4Change não usa SRS, mas distingue-se pela capacidade de gerar conteúdo a partir de qualquer fonte documental. Nem a Khan Academy nem o Coursera estão alinhados com o DigComp 2.2 ou permitem que instituições adicionem conteúdo próprio com geração automática de tarefas.

**Face a sistemas de tutoria inteligente clássicos.** Os ITS tradicionais (Cognitive

Tutor, ALEKS) usam modelos de utilizador explícitos (BKT, PFA); o Play4Change usa uma heurística mais simples — classificação de padrão de erro em três categorias — trivial mas pedagogicamente interpretável. A vantagem dos ITS clássicos é a precisão diagnóstica; a do Play4Change é a generalidade, funcionando em qualquer domínio sem dados de calibração histórica.

**Face a soluções baseadas em LLM para educação.** Usar ChatGPT ou Claude diretamente para tutoria é flexível mas não estruturado pedagogicamente: sem percurso definido, sem gamificação, sem progressão garantida e sem isolamento do input do utilizador. O Play4Change estrutura a progressão (tarefa → struggle → explicação → retentativa), gamifica, garante qualidade por schema e deduplicação, e isola o input em mensagens tipadas separadas.

**Contributos originais.** Três aspetos distinguem o Play4Change: a reutilização semântica de ramos adaptativos por similaridade coseno, que melhora continuamente a eficiência de custo sem intervenção humana; o modelo de escalamento estruturado (tarefa → struggle → explicação IA → retentativa), com transições de estado explícitas; e a baralhagem determinística por utilizador, que previne partilha de respostas sem eliminar a reprodutibilidade dentro da mesma sessão.

## 7.5 Trabalho Futuro

**Funcionalidades sociais e de retenção.** A sugestão mais recorrente na avaliação de usabilidade foi a adição de funcionalidades sociais — lista de amigos, tabelas de classificação, rivalidade positiva — com impacto direto na retenção diária, já que a declaração de envolvimento mais baixa (3,92) foi precisamente sobre o regresso diário. Conquistas e medalhas por nível de aprendizagem podem ser implementadas sobre a infraestrutura de `micro_competences` já existente, tal como notificações comportamentais personalizadas junto da janela habitual de utilização do utilizador.

**Reconhecimento formal via Open Badges e créditos ECTS.** O sistema de crachás atual é interno e não portátil. Mapear estas conquistas para o *standard* europeu *Open Badges* permitiria a sua exportação e verificação externa, podendo suportar, no contexto da rede U!REKA, o reconhecimento formal de micro-créditos ECTS em unidades curriculares de reduzida carga horária.

A Tabela 7.1 resume cinco direções adicionais, de menor prioridade estratégica que as duas acima mas tecnicamente viáveis sobre a arquitetura atual sem alterações estruturais.

**Duas direções estratégicas para o futuro.** A segmentação de perfis de afinidade tecnológica observada nos testes de usabilidade (§5.5.3) sugere duas direções não necessariamente exclusivas: aprofundar a vertente universitária junto do perfil tecnologicamente confortável, através de Open Badges e créditos ECTS na rede U!REKA; ou, para o perfil de menor afi-

Tabela 7.1: Direções de trabalho futuro de prioridade secundária

| Direção                                         | Descrição                                                                                                                                                                                                                                      |
|-------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Explicações adaptadas ao móvel                  | A avaliação qualitativa revelou que as explicações IA em prosa são longas demais para ecrãs pequenos; configurar o comprimento em função do <code>audienceLevel</code> e do canal, ou gerar uma versão resumida expansível.                    |
| Personalização geográfica                       | Um participante sugeriu usar a localização do dispositivo para personalizar questões sobre cidades inteligentes ao município do utilizador — viável com a arquitetura atual, bastando injetar metadados de localização no contexto de geração. |
| Profundidade variável de struggle               | Substituir <code>MAX_STRUGGLE_DEPTH = 1</code> por um valor configurável por tópico, complementado por um modelo de utilizador simples baseado no histórico de <code>wrongAttemptCount</code> e na distribuição de padrões de erro.            |
| Análise de desempenho das questões              | O sistema já instrumenta <code>tasks_submitted_total</code> por resultado e tópico; um painel de qualidade (taxa de acerto, tempo médio) sinalizaria para revisão questões com taxa de acerto $<20\%$ ou $>95\%$ .                             |
| Validação automática de alinhamento DigComp 2.2 | Um segundo prompt poderia classificar a competência DigComp 2.2 testada por cada tarefa gerada e verificar a correspondência com o módulo configurado, sinalizando incongruências para revisão humana.                                         |
| Suporte nativo multi-plataforma                 | O Kotlin Multiplatform possibilita compilação nativa para iOS com código partilhado, mas o projeto atual entrega apenas o alvo Android.                                                                                                        |

nidade tecnológica — que é precisamente quem mais beneficiaria do reforço de competências digitais —, acrescentar mecanismos de acompanhamento, orientação ou mediação humana, em vez de depender exclusivamente da auto-motivação do utilizador. A escolha entre estas direções, ou a exploração de ambas em paralelo, fica em aberto para trabalho futuro.



## Capítulo 8

# Conclusão

O Play4Change nasceu de uma lacuna concreta: não existia, até ao momento, uma plataforma de aprendizagem adaptativa que integrasse nativamente o referencial DigComp 2.2 e recorresse à Inteligência Artificial para gerar e personalizar conteúdo a partir de fontes documentais arbitrárias, em vez de um catálogo estático curado por especialistas. O projeto respondeu a essa lacuna com uma plataforma multi-cliente completa — painel de administração web, aplicação móvel para Learners e um *backend* que orquestra ingestão de conteúdo, geração por IA, indexação vetorial e um percurso de remediação adaptativa — e validou-a tecnicamente de ponta a ponta, da arquitetura ao utilizador final.

Os cinco objetivos operacionais definidos no Capítulo 1 foram todos alcançados, com o detalhe da concretização de cada um analisado no Capítulo 7 (§7.1): a plataforma adaptativa está operacional e alinhada com o DigComp 2.2 ao nível da curadoria de tópicos, confirmada por uma avaliação de usabilidade em que 66,7% dos participantes classificaram o sistema como *Bom* ou *Excelente* (SUS, mediana 85,0); o *pipeline* de geração de conteúdo por IA funciona de ponta a ponta sobre fontes arbitrárias — PDF ou URL — com seis garantias estruturais de qualidade por questão gerada; a remediação adaptativa classifica o padrão de erro do Learner e gera sub-tarefas dirigidas a esse padrão; a tutoria conversacional por IA escala a remediação quando esta se esgota, com isolamento tipado do *input* do utilizador; e a plataforma está protegida por um modelo de segurança em profundidade, validado por uma análise de risco OWASP que não deixou nenhum risco residual em nível Alto ou Crítico.

Do ponto de vista técnico, três decisões distinguem-se como as mais determinantes para o resultado final. A arquitetura hexagonal, com o domínio isolado de qualquer *framework* e o contrato `Either<DomainError, T>` da Arrow a tornar os casos de insucesso tão explícitos como os de sucesso, tornou possível uma suite de 49 ficheiros de teste em que a esmagadora maioria corre em memória pura, sem infraestrutura — uma propriedade que se revelou mais valiosa em produtividade de desenvolvimento do que qualquer otimização de desempenho isolada. A reutilização semântica de ramos adaptativos por similaridade coseno em pgvector é o contributo mais original do sistema: ao decidir entre reutilização total, parcial ou geração de novo conteúdo consoante a proximidade a contextos de dificuldade já resolvidos, o custo

marginal de servir cada novo Learner tende a diminuir à medida que a base de conhecimento cresce, em vez de escalar linearmente com o número de utilizadores. E a defesa em profundidade — desde a validação de SSRF na ingestão até à sanitização de saída da IA e ao isolamento tipado de mensagens contra *prompt injection* — tratou a superfície de ataque introduzida pela IA generativa como um cidadão de primeira classe do modelo de ameaça, e não como uma reflexão tardia.

O processo de desenvolvimento também deixou lições que vale a pena registar. A auditoria conduzida para este relatório encontrou duas regras de *rate limiting* inoperantes precisamente nos dois *endpoints* mais utilizados da aplicação — um lembrete de que cobertura de configuração não é o mesmo que cobertura de teste de integração, e de que a auditoria retrospectiva de um sistema em produção encontra sempre algo que a implementação inicial não previu. De forma semelhante, a avaliação de usabilidade com utilizadores reais revelou uma *race condition* visual que nenhum teste automatizado tinha capturado, e expôs uma tensão de desenho — a inscrição simultânea em múltiplos tópicos dilui o modelo de “um desafio por dia” que motivou a escolha do canal móvel — que só se torna visível quando o sistema é usado, não quando é apenas especificado. Estas descobertas não diminuem o resultado; são, precisamente, o que distingue uma validação técnica de uma validação superficial.

A limitação mais honesta do projeto é também a mais simples de enunciar: o sistema foi validado com doze participantes num ambiente controlado, não com utilização real em escala. As métricas instrumentadas — dezoito indicadores Micrometer e oito regras de alerta Prometheus — garantem que o sistema está preparado para ser observado em produção, mas não substituem os dados que só a produção pode gerar. Latências reais sob carga concorrente, a distribuição efetiva das três estratégias de reutilização adaptativa, e a taxa de deduplicação semântica sobre um catálogo de conteúdo muito maior permanecem, nesta fase, hipóteses bem fundamentadas em vez de factos medidos.

As direções de trabalho futuro mais relevantes — funcionalidades sociais para reforçar a retenção diária, reconhecimento formal via Open Badges e créditos ECTS na rede U!REKA, e validação automática do alinhamento de cada tarefa gerada com a competência DigComp 2.2 pretendida — estão detalhadas no Capítulo 7 (§7.5) e não se repetem aqui. Fica, no entanto, a síntese da decisão estratégica que as enquadra a todas: o Play4Change pode aprofundar-se junto do público universitário tecnologicamente confortável, através do reconhecimento formal de competências, ou pode voltar-se para o perfil de menor afinidade digital que mais beneficiaria do reforço dessas competências, através de mecanismos de acompanhamento humano que reduzam a dependência exclusiva da auto-motivação. As duas direções não se excluem, mas exigem prioridades de engenharia distintas; a escolha entre elas define o que o Play4Change deve ser na sua próxima iteração.

O que este projeto demonstra, acima de tudo, é que é tecnicamente viável construir uma plataforma de aprendizagem adaptativa que gera e adapta o seu próprio conteúdo pe-



dagógico a partir de conhecimento fornecido por um formador, sem depender de um catálogo pré-construído — e que fazê-lo com garantias de segurança e qualidade verificáveis não é incompatível com um modelo de utilização simples, de um desafio por dia, pensado para caber na rotina de qualquer cidadão.



# Referências

- [1] Riina Vuorikari, Stefano Kluzer, and Yves Punie. DigComp 2.2: The Digital Competence Framework for Citizens — With new examples of knowledge, skills and attitudes. EUR 31006 EN, Publications Office of the European Union, Luxembourg, 2022. JRC128415.
- [2] European Parliament and Council of the European Union. Decision (EU) 2022/2481 of the European Parliament and of the Council of 14 December 2022 establishing the Digital Decade Policy Programme 2030. Official Journal of the European Union, L 323, 2022. Sets the target of at least 80% of EU adults with basic digital skills by 2030, building on the 2030 Digital Compass (COM(2021) 118 final).
- [3] Benjamin S. Bloom. The 2 sigma problem: The search for methods of group instruction as effective as one-to-one tutoring. *Educational Researcher*, 13(6):4–16, 1984.
- [4] Enkelejda Kasneci, Kathrin Seßler, Stefan Küchemann, Maria Bannert, Daryna Dementieva, Frank Fischer, Urs Gasser, Georg Groh, Stephan Günnemann, Eyke Hüllermeier, et al. ChatGPT for good? on opportunities and challenges of large language models for education. *Learning and Individual Differences*, 103:102274, 2023.
- [5] John Hattie. *Visible Learning: A Synthesis of Over 800 Meta-Analyses Relating to Achievement*. Routledge, London, 2009.
- [6] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems*, volume 33, pages 9459–9474, 2020.
- [7] Jay Cross. *Informal Learning: Rediscovering the Natural Pathways That Inspire Innovation and Performance*. Pfeiffer, San Francisco, CA, 2007.
- [8] Burrhus F. Skinner. Teaching machines. *Science*, 128(3330):969–977, 1958.
- [9] John R. Anderson, C. Franklin Boyle, and Brian J. Reiser. Intelligent tutoring systems. *Science*, 228(4698):456–462, 1985.

- [10] Kurt VanLehn. The relative effectiveness of human tutoring, intelligent tutoring systems, and other tutoring systems. *Educational Psychologist*, 46(4):197–221, 2011.
- [11] Albert T. Corbett and John R. Anderson. Knowledge tracing: Modeling the acquisition of procedural knowledge. *User Modeling and User-Adapted Interaction*, 4(4):253–278, 1994.
- [12] Chris Piech, Jonathan Spencer, Jonathan Huang, Surya Ganguli, Mehran Sahami, Leonidas Guibas, and Jascha Sohl-Dickstein. Deep knowledge tracing. In *Advances in Neural Information Processing Systems*, volume 28, 2015.
- [13] Roumen Vesselinov and John Grego. Duolingo effectiveness study. Technical report, City University of New York, 2012. Estudo encomendado e financiado pelo Duolingo; não sujeito a revisão por pares.
- [14] Stephen Krashen. Research on Duolingo: Not much, 2019. [Online; accessed 2026].
- [15] Rishi Bommasani, Drew A. Hudson, Ehsan Aditi, et al. On the opportunities and risks of foundation models. Technical report, Stanford University, 2021.
- [16] Adrian Simpson. The misdirection of public policy: Comparing and combining standardised effect sizes. *Journal of Education Policy*, 32(4):450–466, 2017.
- [17] John Sweller. Cognitive load theory, learning difficulty, and instructional design. *Learning and Instruction*, 4(4):295–312, 1994.
- [18] Helen Colley, Phil Hodgkinson, and Janice Malcolm. Informality and formality in learning: A report for the learning and skills research centre. *Learning and Skills Research Centre*, 2003.
- [19] Malcolm S. Knowles. *Andragogy in Action: Applying Modern Principles of Adult Learning*. Jossey-Bass, San Francisco, 1984.
- [20] John Traxler. Defining, discussing and evaluating mobile learning: The moving finger writes and having writ. *International Review of Research in Open and Distributed Learning*, 8(2), 2007.
- [21] Diana Laurillard. Pedagogical forms of mobile learning: Framing research questions. *Mobile Learning: Towards a Research Agenda*, pages 153–175, 2007.
- [22] International Telecommunication Union. Measuring digital development: Facts and figures 2023. Technical report, ITU, Geneva, 2023.
- [23] Yunfan Gao, Yun Xiong, Xinyu Gao, Kangxiang Jia, Jinliu Pan, Yuxi Bi, Yi Dai, Jiawei Sun, and Haofen Wang. Retrieval-augmented generation for large language models: A survey. *arXiv preprint*, arXiv:2312.10997, 2024.

- [24] Joseph Bonneau, Cormac Herley, Paul C. van Oorschot, and Frank Stajano. The quest to replace passwords: A framework for comparative evaluation of web authentication schemes. In *IEEE Symposium on Security and Privacy*, pages 553–567, 2012.
- [25] FIDO Alliance. FIDO2: Moving the world beyond passwords. Technical report, FIDO Alliance, 2019.
- [26] Ian Sommerville. *Software Engineering*. Pearson, Harlow, 10th edition, 2016.
- [27] Donald A. Norman. *The Design of Everyday Things*. Basic Books, New York, 1988.
- [28] Hermann Ebbinghaus. *Über das Gedächtnis: Untersuchungen zur experimentellen Psychologie*. Duncker & Humblot, Leipzig, 1885. Translated as *Memory: A Contribution to Experimental Psychology*, 1913.
- [29] Nicholas J. Cepeda, Harold Pashler, Edward Vul, John T. Wixted, and Doug Rohrer. Distributed practice in verbal recall tasks: A review and quantitative synthesis. *Psychological Bulletin*, 132(3):354–380, 2006.
- [30] Edward L. Deci and Richard M. Ryan. *Intrinsic and Extrinsic Motivations: Classic Definitions and New Directions*, volume 25. 2000.
- [31] Len Bass, Paul Clements, and Rick Kazman. *Software Architecture in Practice*. Addison-Wesley, Boston, 4th edition, 2021.
- [32] Ivar Jacobson, Magnus Christerson, Patrik Jonsson, and Gunnar Övergaard. *Object-Oriented Software Engineering: A Use Case Driven Approach*. Addison-Wesley, Wokingham, 1992.
- [33] Eric Evans. *Domain-Driven Design: Tackling Complexity in the Heart of Software*. Addison-Wesley, Boston, 2003.
- [34] Unstructured Technologies. Unstructured: Open source library and API for document extraction, 2023. [Online; accessed 2025].
- [35] Microsoft Corporation. Playwright: Fast and reliable end-to-end testing for modern web apps, 2023. [Online; accessed 2025].
- [36] John Brooke. SUS: A ‘quick and dirty’ usability scale. pages 189–194, 1996.



## Apêndice A

# Exemplos de Prompts Completos

Este apêndice reproduz, na íntegra e sem alterações, os *templates* de *prompt* definidos no módulo `ai-agent` (pacote `com.ureka.play4change.prompt`) e efetivamente enviados ao modelo `mistral-small-latest` através do `LangChain4j`. Os campos entre `$` são interpolados em *runtime* a partir do contexto de domínio (tópico, módulo, sessão de dificuldade, etc.). Todos os *prompts* de geração de conteúdo obrigam o modelo a responder exclusivamente em JSON, sem texto envolvente, para permitir *parsing* determinístico pelo `OptionsJsonParser`.

### A.1 Prompt de Geração de Tópicos e Desafios

Utilizado pelo `LangChain4jTaskGenerationAdapter` sempre que é necessário gerar tarefas de escolha múltipla — quer na ingestão inicial de um tópico (`TaskGenerationOrchestrator`), quer na geração de variantes por idioma (`LanguageGenerationAdapter`), quer na geração de instâncias distratoras em lote (`BatchInstanceAdapter`).

#### System Message

You are an expert educational content designer specialising in gamified learning experiences. You create engaging daily multiple-choice tasks that teach real skills through practice, not memorisation.

LANGUAGE: You MUST generate ALL text content in `$language`.

This is mandatory. Do not mix languages. Do not respond in English unless `$language` is English.

#### RULES:

- Each task must be completable in 5-15 minutes
- Tasks must be practical and actionable, not theoretical
- Difficulty must match the audience level exactly
- Hints must guide without giving away the answer

- Every task must directly advance the module objective
- Tasks must be distinct | no semantic overlap with existing content
- Always generate exactly 4 options per task
- The correct answer must always be at index 0 in the options array  
(the system will shuffle before showing to the user)
- Wrong options must be plausible | not obviously incorrect

OUTPUT FORMAT: Respond with a valid JSON array only. No preamble. No explanation.

Schema:

```
[
  {
    "title": "string (max 60 chars)",
    "description": "string (max 300 chars | frame it as a question or scenario)",
    "hint": "string (max 150 chars)",
    "pointsReward": number (10-100, higher for harder tasks),
    "options": ["correct answer", "wrong option 1", "wrong option 2", "wrong option 3"],
    "correctAnswerIndex": 0
  }
]
```

## User Message

Generate \${request.taskCount} multiple-choice learning tasks for the following context:

Subject Domain: \${request.subjectDomain}

Module Objective: \${request.moduleObjective}

Audience Level: \${request.audienceLevel.toPromptDescription()}

Language: \${request.language}

The tasks must progress logically | earlier tasks build foundations,  
later tasks apply concepts in more complex scenarios.

Important: N tasks already exist for this module. Generate semantically  
distinct tasks that complement the existing content.

[linha condicional, omitida quando não existem tarefas prévias no módulo]

Remember: always put the correct answer at index 0 in the options array.

Generate the JSON array now:

O nível de audiência (AudienceLevel) é traduzido para uma descrição textual antes de



ser injetado no *prompt*:

```
BEGINNER      -> "Beginner | assumes no prior knowledge, uses simple
                language, concrete examples"
INTERMEDIATE -> "Intermediate | assumes basic familiarity, introduces
                complexity, some abstraction"
ADVANCED      -> "Advanced | assumes solid foundation, focuses on nuance,
                edge cases, and depth"
```

### Reforço de Esquema (retry)

Quando a resposta do modelo é incompleta ou não corresponde ao número de tarefas pedido, o Resilience4j `retry` reenvia o pedido com um reforço adicional do esquema:

```
Your previous response was incomplete or malformed.
Please respond with EXACTLY $taskCount tasks in the JSON array schema above.
Every task must have: title, description, hint, pointsReward, options (4 items),
and correctAnswerIndex set to 0. No extra fields. Valid JSON only.
```

## A.2 Prompt de Análise de Dificuldade e Geração de Subtarefas Adaptativas

Utilizado pelo `HandleStruggleService` quando um aprendiz falha repetidamente uma tarefa. Ao contrário do *prompt* de geração base, este inclui o padrão de erro diagnosticado (`ErrorPattern`), permitindo que o modelo gere um percurso de recuperação escalonado em vez de tarefas genéricas sobre o mesmo tópico.

### System Message

You are an expert adaptive learning coach. A student is struggling with a specific task in their learning journey. Your job is to create a short sequence of simpler subtasks that scaffold the student back to success.

#### PRINCIPLES:

- Diagnose the root cause of the struggle from the error pattern
- Start with the simplest possible related concept
- Each subtask builds on the previous one
- The final subtask should bring the student back to the original task level
- Be encouraging | frame tasks as achievable steps, not remediation
- Keep each subtask completable in 3-10 minutes

OUTPUT FORMAT: Respond with a valid JSON array only. No preamble. No explanation.

Schema:

```
[
  {
    "title": "string (max 60 chars)",
    "description": "string (max 300 chars)",
    "hint": "string (max 150 chars)",
    "pointsReward": number (5-50, lower than main tasks to reflect smaller scope),
    "options": ["string", "string", "string", "string"],
    "correctAnswerIndex": number (0-based index into options array)
  }
]
```

## User Message

A student is struggling with the following task after `${context.attemptCount}` attempts:

Task: `${context.taskDescription}`

Subject Domain: `${context.subjectDomain}`

Module Objective: `${context.moduleObjective}`

Student Level: `${context.audienceLevel.toPromptDescription()}`

Language: `${context.language}`

Diagnosed Struggle Type: `${context.errorPattern.toPromptDescription()}`

Generate `$subtaskCount` adaptive subtasks that:

1. Address the specific struggle type diagnosed above
2. Start simpler than the original task
3. Progressively build back toward the original task level
4. Are encouraging and reframe the struggle as a learning opportunity

Generate the JSON array now:

Cada `ErrorPattern` é traduzido numa instrução específica de diagnóstico antes de ser injetado no *prompt*:

CONCEPTUAL\_MISUNDERSTANDING -> "The student misunderstands the core concept.

Start by re-explaining it differently."

PROCEDURAL\_ERROR -> "The student understands the concept but

applies the wrong steps. Focus on procedure."

|                      |                                                                                                      |
|----------------------|------------------------------------------------------------------------------------------------------|
| KNOWLEDGE_GAP        | -> "The student is missing prerequisite knowledge. Fill the gap before returning to the task."       |
| UNCLEAR_INSTRUCTIONS | -> "The task instructions were unclear. Provide clearer, more explicit guidance."                    |
| TIME_PRESSURE        | -> "The student rushed and made errors under time pressure. Use paced, step-by-step practice tasks." |
| UNKNOWN              | -> "The struggle cause is unclear. Provide general scaffolding from basic to intermediate."          |

### A.3 Prompt de Explicação Holística e Conversação

Utilizado pelo `ExplanationService` quando um aprendente esgota todos os níveis de profundidade do percurso adaptativo sem resolver a dificuldade. Divide-se em dois modos: a explicação inicial (síntese de todas as tentativas) e as respostas conversacionais subsequentes, caso o aprendente continue confuso.

#### System Message — Explicação Inicial

You are a patient and empathetic learning coach helping a student who has struggled repeatedly with the same concept. They have now exhausted all their practice attempts and need a clear, holistic explanation.

YOUR GOAL:

- Synthesise what went wrong across all their attempts
- Explain the underlying concept clearly and simply
- Use concrete examples relevant to the subject domain
- Be encouraging | frame struggles as a normal part of learning
- Keep the explanation concise: 3-5 paragraphs maximum
- Write in plain prose | no JSON, no bullet lists, no headers
- Match the learner's language exactly

#### User Message — Explicação Inicial

A student in a `${context.audienceLevel.toLabel()}` course on "`${context.subjectDomain}`" has struggled with the following task after exhausting their practice attempts:

Task: `${context.taskDescription}`

Module objective: \${context.moduleObjective}  
Struggle type: \${context.errorPattern.toLabel()}  
Language: \${context.language}

Here is their struggle history:

Session \${depth} (\${errorPattern.toLabel()}) : \${taskTitles joined by ", "}  
[uma linha por sessão de dificuldade anterior]

Write a clear, encouraging explanation that helps them finally understand this concept.

Respond in \${context.language}. Plain prose only.

### System Message — Réplica Conversacional

You are a patient learning coach in an ongoing conversation with a confused student. They have already received an initial explanation of a concept they struggled with. Your role now is to answer their specific questions and clear up remaining confusion.

#### PRINCIPLES:

- Address their exact question directly
- Use simple language and concrete examples
- Keep replies focused: 2-4 sentences unless the question demands more
- Be warm and encouraging
- Write in the same language as the student
- Plain prose only | no JSON, no bullet lists

O primeiro turno da conversa é sempre um bloco de contexto gerado a partir de dados confiáveis (provenientes da base de dados), nunca de conteúdo fornecido pelo utilizador — separação deliberada que impede que uma futura mensagem maliciosa do aprendente altere o enquadramento da conversa (ver secção sobre defesas contra *prompt injection*, Figura 4.5):

Subject: \${context.subjectDomain}  
Original task: \${context.taskDescription}

## Apêndice B

# Diagramas Complementares

Este apêndice reúne o diagrama entidade-relação completo do esquema relacional e a evidência documental bruta dos dois questionários de avaliação aplicados ao Play4Change, cuja análise é apresentada na Secção 5.5 do Capítulo 5.

### B.1 Diagrama Entidade-Relação

A Figura B.1 apresenta o esquema relacional completo, tal como definido pelas *migrations* Flyway (V1 a V32) em `server/src/main/resources/db/migration`. As entidades estão agrupadas por domínio: identidade e autenticação (azul), conteúdo e conhecimento (verde), progresso de aprendizagem (amarelo), suporte adaptativo e explicações (vermelho), e governança/moderação (roxo). Tabelas puramente internas ao serviço de deduplicação do ai-agent (`struggle_events`, `adaptive_branches`) foram omitidas por não pertencerem ao domínio aplicacional principal.

### B.2 Formulário de Avaliação de Experiência de Utilizador

Reprodução integral dos resultados do formulário *Play4Change — User Experience Evaluation* (Google Forms,  $n = 12$ ), aplicado entre 8 e 12 de junho de 2026 e cuja análise — pontuações SUS, declarações de envolvimento e síntese qualitativa — é apresentada na Secção 5.5. As páginas seguintes são a captura bruta da plataforma, sem qualquer edição.

### B.3 Formulário de Avaliação Técnica

Reprodução integral dos resultados do formulário complementar *Play4Change: User & Technical Evaluation* (Google Forms,  $n = 3$ ), focado em desempenho percebido e na eficácia do formato de *micro-learning* diário. A amostra é reduzida e não sustenta generalização estatística; é apresentada como evidência qualitativa complementar à avaliação principal da Secção 5.5, não como uma segunda medição independente.




Figura B.1: Diagrama entidade-relação do esquema relacional da base de dados

## Play4Change - User Experience Evaluation


12 respostas

[Publicar estatísticas](#)

What is your primary relationship with ISEL/Politécnico de Lisboa?

[Copiar gráfico](#)

12 respostas



How would you rate the overall usability and navigation of the Play4Change application?

[Copiar gráfico](#)

12 respostas




Figura B.2: Formulário UX — perfil dos participantes e avaliação global de usabilidade


02/07/2026, 15:29

Play4Change - User Experience Evaluation

On a scale of 1 to 5, how clear were the instructions provided for the gamified challenges?

 Copiar gráfico

12 respostas




How engaging did you find the daily challenges and quizzes?

 Copiar gráfico

11 respostas

Average rating (4.00)



[https://docs.google.com/forms/d/1T\\_gjT1RGzM8IPInk01ChjFKznVQ7SdKbEA8h5VjDZpI/viewanalytics](https://docs.google.com/forms/d/1T_gjT1RGzM8IPInk01ChjFKznVQ7SdKbEA8h5VjDZpI/viewanalytics)


2/8

Figura B.3: Formulário UX — clareza das instruções e envolvimento com os desafios diários




Please indicate your level of agreement with the following statements regarding **Engagement**.

 Copiar gráfico



Please indicate your level of agreement on a scale of 1 to 5

 Copiar gráfico



The AI-driven learning paths adapted effectively to my performance and interests.

 Copiar gráfico

12 respostas




Figura B.4: Formulário UX — declarações de envolvimento e adaptação dos percursos de IA

If you experienced any technical issues or bugs, please describe them briefly here.

8 respostas

In the consolidation path, when I got the question right it marked me as correct, but then half a second later it showed me as wrong.

When I make a mistake another question suddenly appears, making the experience confusing and preventing me to understand what happened and made confusions

The search bar is hidden when I'm entering my email.

Confusing, titles in english and also in portuguese  
Some confusing questions  
Some similarity of answers and/or not so evident  
One answer ware an question

None for me

Every time I made a mistake I would be shown a different question, without any explanation of what happened or why did I get it wrong. Also, some questions would appear again with a different answer.

I didnt see anything.

Umas das questões corretas davam errado  
Nos alternative patos apareceram-me perguntas repetidas numa das vezes que usei, no dia a seguir já não.  
Nas minhas questões sobre estar confuso o agente IA foi confuso na mesma, não soube interpretar as minhas questões.  
Streak não atualizou quando terminei o segundo tópico.



Figura B.5: Formulário UX — problemas técnicos reportados livremente pelos participantes

02/07/2026, 15:29

Play4Change - User Experience Evaluation

What is the single best feature of Play4Change, in your opinion?

11 respostas

Daily Challenges because force us to not give up

Easy way to understand

The fact that when we get an answer wrong, artificial intelligence tries to help us understand why we got it wrong is great.

AI support helping and clarifying for good response

I think it's quite intuitive , very easy to understand and in my opinion it is a good thing

It is a very interactive app and easy to use

O facto de apresentar explicações rápidas quando não se acerta em alguma pergunta, o que permite esclarecer imediatamente as dúvidas.

Conversar e utilizar a AI para aprender, assim é possível retirar duvidas mais especificas que possamos ter.

The way that the adaptive content was generated, I could learn new things.

AI adaptability to your answers

Quando foi dado o feedback por parte do AI, ele soube perceber onde errei e aprendi com o texto dele.



[https://docs.google.com/forms/d/1T\\_gjT1RGm8IPnk01ChjFKznVQ7SdKbEA8h5VjDZpI/viewanalytics](https://docs.google.com/forms/d/1T_gjT1RGm8IPnk01ChjFKznVQ7SdKbEA8h5VjDZpI/viewanalytics)

5/8

Figura B.6: Formulário UX — funcionalidade mais valorizada, na opinião dos participantes

What is the one major area you would recommend for improvement?

11 respostas

Community and interactions with friends or followers

Short and clear explanation

The user interface format

AI based support should be more concise or graphical for smartphone app, long text is annoying

Maybe the aesthetic part of it but it's not a huge problem overall

The main thing to improve is making the app more consistent

Em termos do conteúdo, diversificar os temas e as questões. Em termos de interação, sugeria que fossem colocar desafios extra para a obtenção de mais pontos (para cativar mais) e de medalhas/ reconhecimento quando é atingido determinando nível de aprendizagem.

Adicionas funcionalidade de amigos, de forma a comprar e de certa forma criar uma "rivalidade" positiva. O que poderá a trazer novos utilizadores, e alguma consistência no uso da aplicação

I think you could put more topics about more things that surely important.

Questions could be clearer

Melhoraria um pouco o agente AI porque se já achei que ele funcionou bem, com um modelo mais treinado ainda dá informações mais úteis.



Figura B.7: Formulário UX — principal área recomendada para melhoria

Do you have any further comments or suggestions regarding the application or this test experience?

10 respostas

Change Auth token to smaller one

Because it so confusing, it ends up not being so helpful what would make people lose interest in this app and also patience

This is a very well-conceived idea and has everything it needs to evolve.

Actually, since i'm not really an expert on this type of things , it seemed fine to me , as I said , very intuitive , easy to understand and I think it's what really "sells" , people want easy things.

When making a mistake, there should be an explanation and not a sudden change of question

O processo de aprendizagem com esta aplicação é bastante fácil dado que é feito de forma gradual e continua, pelo que permite reter mais informação.

No geral a aplicação está bem conseguida :)

The app could interact with other users to share knowledge. Just a opinion!

Easy to use UI

Layout muito apelativo, interativo, perguntas interessantes e úteis para serem aplicadas no mundo real. Um dia mais tarde se fosse possível punha uma opção para detetar a localização do dispositivo que está a usar a aplicação e com o AI as perguntas para uma cidade mais sustentável aplicavam-se ao local em questão, porque o AI com a informação que tem da internet conseguiria perceber as vulnerabilidades ou o que não é preciso mudar na localização onde se encontra a pessoa.

Este conteúdo não foi criado nem aprovado pela Google. - [Contactar proprietário do formulário](#) - [Termos de Utilização](#) - [Política de privacidade](#)

Este formulário parece suspeito? [Relatório](#)

Google Formulários



Figura B.8: Formulário UX — comentários e sugestões finais

## Play4Change: User & Technical Evaluation


3 respostas

[Publicar estatísticas](#)

How intuitive was the app's interface and navigation?

[Copiar gráfico](#)

3 respostas



How relevant, coherent, and challenging were the AI-generated responses?

[Copiar gráfico](#)

3 respostas




Figura B.9: Formulário técnico — intuitividade da interface e qualidade das respostas geradas por IA


02/07/2026, 15:28

Play4Change: User & Technical Evaluation

How would you rate the app's loading speed and the AI's response time?

 Copiar gráfico


3 respostas



Is the short, daily micro-learning format effective for learning civic and digital skills?

 Copiar gráfico

3 respostas



Did you encounter any bugs, or do you have suggestions for new features?

1 resposta

No

Este conteúdo não foi criado nem aprovado pela Google. - [Contactar proprietário do formulário](#) - [Termos de Utilização](#) - [Política de privacidade](#)

Este formulário parece suspeito? [Relatório](#)

Google Formulários



<https://docs.google.com/forms/d/1FAw5666cVnI4sCYdbRVGKxJ-s63ck-peKsHjVrtZzZc/viewanalytics>

2/3

Figura B.10: Formulário técnico — velocidade percebida e eficácia do formato de micro-aprendizagem diária





## Apêndice C

# Variáveis de Ambiente

Este apêndice lista todas as variáveis de ambiente configuráveis no sistema, tal como definidas em `application.yml` (servidor), `docker-compose.yml` (orquestração de contentores) e nos ficheiros `.env.example` das aplicações cliente. Os valores reais (segredos, chaves de API, credenciais) não são reproduzidos; apenas os nomes das variáveis e o respetivo propósito.

### Base de Dados

Tabela C.1: Variáveis de ligação à base de dados

| Variável              | Descrição                                                                                                  |
|-----------------------|------------------------------------------------------------------------------------------------------------|
| SPRING_DATASOURCE_URL | URL JDBC de ligação ao PostgreSQL (por omissão aponta para o contentor <code>play4change-postgres</code> ) |
| DB_USER / DB_PASS     | Credenciais da base de dados usadas pelo <code>docker-compose</code>                                       |

Não existe camada de *cache* distribuída no sistema: o *rate limiting* usa *buckets* em memória por processo (Bucket4j + Caffeine), sem necessidade de um *backing store* partilhado.

### Inteligência Artificial e Geração

Tabela C.2: Variáveis de configuração do modelo de IA

| Variável        | Descrição                                                                                                                                                                  |
|-----------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| MISTRAL_API_KEY | Chave de acesso à API da Mistral AI; se omitida ou igual a <code>not-set-yet</code> , os <i>beans</i> do LangChain4j não são carregados e os endpoints de IA respondem 503 |

Os restantes parâmetros do modelo de IA (`ai.mistral.model`, `ai.mistral.temperature`, `ai.mistral.timeout-seconds`, tamanho da *pool* de geração, limiares de deduplicação) são definidos diretamente em `application.yml` e não variam por ambiente — apenas a chave de API é externalizada como segredo.

## Armazenamento de Objetos (MinIO)

Tabela C.3: Variáveis de armazenamento de ficheiros

| Variável            | Descrição                                        |
|---------------------|--------------------------------------------------|
| MINIO_ENDPOINT      | URL do serviço MinIO (S3-compatível)             |
| MINIO_ROOT_USER     | / Utilizador/chave de acesso ao MinIO            |
| MINIO_ACCESS_KEY    |                                                  |
| MINIO_ROOT_PASSWORD | / Password/chave secreta do MinIO                |
| MINIO_SECRET_KEY    |                                                  |
| MINIO_BUCKET        | Nome do <i>bucket</i> usado para PDFs submetidos |

## Ingestão de Conteúdo

Tabela C.4: Variáveis dos serviços auxiliares de extracção de conteúdo

| Variável         | Descrição                                                                 |
|------------------|---------------------------------------------------------------------------|
| SCRAPER_URL      | URL do sidecar Playwright usado para extracção de conteúdo de páginas web |
| UNSTRUCTURED_URL | URL da API Unstructured.io usada para extracção de texto de PDF           |

## Autenticação, Segurança e CORS

Tabela C.5: Variáveis de segurança e autenticação

| Variável             | Descrição                                                                                                                                  |
|----------------------|--------------------------------------------------------------------------------------------------------------------------------------------|
| JWT_SECRET           | Segredo usado para assinar (HS256) os <i>access tokens</i> JWT; mínimo de 64 caracteres em produção ( <code>JwtSecretStartupGuard</code> ) |
| APP_BASE_URL         | URL base da aplicação, usada na construção de <i>deep links</i> de autenticação                                                            |
| FRONTEND_ORIGIN      | Origem do <i>frontend</i> , propagada para <code>APP_BASE_URL</code> no <code>docker-compose</code>                                        |
| CORS_ALLOWED_ORIGINS | Lista de origens autorizadas pela política CORS do servidor                                                                                |

Os parâmetros de duração dos tokens (`jwt.access-ttl-minutes` = 15, `jwt.refresh-ttl-days` = 7) e os limites de *rate limiting* por IP são fixados em `application.yml` e não são externalizados como variáveis de ambiente.

## Envio de E-mail

### Observabilidade e Infra-estrutura

A exposição pública do serviço em produção (`https://radesh-govind.com/play4change-server`, referenciada em `play4change-web/.env.production`) não é orquestrada por nenhum serviço

Tabela C.6: Variáveis do serviço de e-mail (Resend)

| Variável       | Descrição                                                |
|----------------|----------------------------------------------------------|
| RESEND_API_KEY | Chave de acesso à API de envio de e-mail Resend          |
| RESEND_FROM    | Endereço de origem usado no envio dos <i>magic links</i> |

Tabela C.7: Variáveis de monitorização e exposição pública

| Variável               | Descrição                                                       |
|------------------------|-----------------------------------------------------------------|
| GRAFANA_ADMIN_PASSWORD | Password do utilizador administrador do Grafana                 |
| SPRING_PROFILES_ACTIVE | Perfil Spring ativo (ex. <code>prod</code> , <code>dev</code> ) |

definido no `docker-compose.yml` deste repositório — não existe um contentor *tunnel* nem variáveis de ambiente associadas no código-fonte; a exposição é gerida externamente ao repositório.

### Aplicação Cliente (Web)

Tabela C.8: Variáveis de ambiente do cliente web (Vite)

| Variável          | Descrição                                                                                                                                             |
|-------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------|
| VITE_API_BASE_URL | URL base da API do servidor a que o cliente web se liga (URL de produção, <i>tunnel</i> ngrok, ou <code>localhost</code> )                            |
| VITE_USE MOCK     | Quando <code>true</code> , o cliente usa adaptadores <i>mock</i> em vez de chamadas reais à API — usado em desenvolvimento isolado do <i>frontend</i> |